

**Kontextsensitive, lokale KI-Assistenz zur automatisierten Barrierefreiheitsanalyse  
von Rich-Client-Webanwendungen mittels Tool-Reports,  
Playwright-Interaktionen und Codeanalyse**

Bachelorarbeit

vorgelegt am 11.05.2026

Fakultät Wirtschaft und Gesundheit

Studiengang Wirtschaftsinformatik

Kurs WWI2023

von

JOEL YERAI MARTINEZ CAMPO

Betreuung in der Ausbildungsstätte:

BITBW

Ilko Hoffmann

Betreuer der Bachelorarbeit

Unterschrift

DHBW Stuttgart:

Sascha Alexander Ströbel

## Abstract

Web-Barrierefreiheit ist trotz gesetzlicher Verpflichtung durch den European Accessibility Act (EAA) und das Barrierefreiheitsstärkungsgesetz (BFSG) in der Praxis nach wie vor unzureichend umgesetzt. 94,8 % der meistbesuchten Webseiten weisen nachweisbare WCAG-Verstöße auf. Bestehende automatisierte Prüfwerkzeuge wie axe, WAVE und Lighthouse erfassen lediglich syntaktische Verstöße und übersehen semantische sowie zustandsabhängige Barrieren in dynamischen Rich-Client-Anwendungen systembedingt. Obwohl LLM-gestützte Analysen diese semantischen Lücken schließen könnten, scheidet der Transfer sensibler Anwendungsdaten an cloudbasierte LLM-APIs für öffentliche Verwaltungen aus datenschutzrechtlichen Gründen weitgehend aus.

Diese Bachelorarbeit konzipiert und implementiert nach dem Design Science Research (DSR)-Paradigma das lokal ausführbare Assistenzsystem *Accessibility Context Engine* (ACE). Sämtliche Verarbeitung erfolgt auf der eigenen Infrastruktur – kein Quellcode und kein DOM-Inhalt verlässt das lokale System. ACE kombiniert axe-core-Violation-Reports, Playwright-Interaktionsdaten und statische Quellcodeanalysen in einer zweistufigen Datenpipeline. In der ersten Stufe analysiert ein LLM-Detektor den Quellcode der zu prüfenden React-Anwendung chunkweise auf semantische Barrierefreiheitsmuster; in der zweiten Stufe priorisiert ein weiterer LLM-Schritt alle Findings und generiert datei- sowie zeilenspezifische Handlungsempfehlungen.

Die Evaluation auf drei kontrollierten Benchmarksuiten – test-12 (12 Violations, Kalibrierung), test-50 (50 Violations, mittlere Last) und test-100 (100 Violations, Skalierungstest) – mit drei lokalen Modellen steigender Parameterzahl und Reasoning-Tiefe (`qwen2.5-coder:7b` und `qwen2.5-coder:14b` als code-spezialisierte Modelle sowie `qwen3:32b` mit erweitertem Reasoning-Vermögen) sowie eine ergänzende Erprobung am realen BW-Empfangsclient (BWEC) zeigen modellabhängig deutliche Recall-Gewinne gegenüber der reinen Tool-Baseline. Mit `qwen3:32b` steigt der Recall auf test-12 von 66,7 % auf 100 %, auf test-50 ebenfalls auf 100 % und auf test-100 von 34 % auf 63 %. Kleinere Modelle (`qwen2.5-coder:7b`) können bei hoher Violations-Dichte durch tokenlimitbedingte Kürzung der Eingabe hingegen unter das Baseline-Niveau fallen. Auf den kleineren Benchmarksuiten werden für die Mehrzahl der Violations datei- und zeilenspezifische Handlungsempfehlungen mit direktem Umsetzungsbezug im Quellcode erzielt.

**Schlüsselwörter:** Web-Barrierefreiheit, WCAG, Large Language Models, Prompt-Engineering, axe-core, Playwright, React, Rich-Client-Anwendungen, Lokale KI, Design Science Research, Ollama, Accessibility-Automatisierung, BITV, EAA.

# Inhaltsverzeichnis

|                                                                                 |            |
|---------------------------------------------------------------------------------|------------|
| <b>Abkürzungsverzeichnis</b>                                                    | <b>V</b>   |
| <b>Abbildungsverzeichnis</b>                                                    | <b>VII</b> |
| <b>Tabellenverzeichnis</b>                                                      | <b>IX</b>  |
| <b>1 Einleitung</b>                                                             | <b>1</b>   |
| 1.1 Motivation und Kontext . . . . .                                            | 1          |
| 1.2 Problemstellung . . . . .                                                   | 2          |
| 1.3 Zielsetzung und Forschungsfragen . . . . .                                  | 3          |
| 1.4 Aufbau der Arbeit . . . . .                                                 | 5          |
| <b>2 Theoretische Grundlagen</b>                                                | <b>6</b>   |
| 2.1 Barrierefreiheit von Webanwendungen . . . . .                               | 6          |
| 2.1.1 Begriffsdefinition und Relevanz . . . . .                                 | 6          |
| 2.1.2 WCAG: Aufbau, Prinzipien und Konformitätsstufen . . . . .                 | 7          |
| 2.1.3 Rechtlicher Rahmen . . . . .                                              | 9          |
| 2.2 Automatisierte Barrierefreiheitsanalyse . . . . .                           | 9          |
| 2.2.1 Klassische Tool-Ansätze . . . . .                                         | 9          |
| 2.2.2 Grenzen bestehender Tools . . . . .                                       | 10         |
| 2.2.3 Taxonomie der Verstöße: syntaktisch, semantisch, Layout . . . . .         | 11         |
| 2.3 Rich-Client-Webanwendungen und Testautomatisierung . . . . .                | 12         |
| 2.3.1 Charakteristika und Abgrenzung . . . . .                                  | 12         |
| 2.3.2 Herausforderungen für die Barrierefreiheitsprüfung . . . . .              | 13         |
| 2.3.3 Playwright als Testautomatisierungswerkzeug . . . . .                     | 14         |
| 2.4 KI-Assistenzsysteme für Softwareanalyse und Handlungsempfehlungen . . . . . | 15         |
| 2.4.1 Grundlagen: Large Language Models . . . . .                               | 15         |
| 2.4.2 Prompt-Engineering-Strategien . . . . .                                   | 16         |
| 2.4.3 RAG und Fine-Tuning als Erweiterungsansätze . . . . .                     | 17         |
| 2.4.4 Datenschutz bei KI-gestützten Accessibility-Services . . . . .            | 18         |
| <b>3 Stand der Forschung</b>                                                    | <b>19</b>  |
| 3.1 Vorgehen der Literaturrecherche . . . . .                                   | 19         |
| 3.2 Von frühen KI-Ansätzen zur LLM-basierten Erkennung . . . . .                | 19         |
| 3.3 LLM-basierte Korrektur und Prompt-Engineering . . . . .                     | 20         |
| 3.4 Hybride Pipelines und Ensemble-Testing . . . . .                            | 20         |
| 3.5 Forschungslücken und Einordnung der vorliegenden Arbeit . . . . .           | 21         |
| <b>4 Methodik</b>                                                               | <b>23</b>  |
| 4.1 Wissenschaftliche Methode . . . . .                                         | 23         |
| 4.2 Untersuchungsgegenstand und Anwendungsbereich . . . . .                     | 24         |
| 4.3 Evaluationsdesign und Kriterien . . . . .                                   | 24         |
| 4.3.1 Evaluationslogik . . . . .                                                | 25         |
| 4.3.2 Bewertungskriterien . . . . .                                             | 25         |
| 4.3.3 Limitationen des Evaluationsdesigns . . . . .                             | 26         |

|          |                                                             |           |
|----------|-------------------------------------------------------------|-----------|
| <b>5</b> | <b>Analyse und Anforderungen</b>                            | <b>27</b> |
| 5.1      | Problemkontext und Handlungsbedarf . . . . .                | 27        |
| 5.2      | Funktionale Anforderungen . . . . .                         | 27        |
| 5.3      | Nicht-funktionale Anforderungen . . . . .                   | 28        |
| 5.4      | Lokale Inferenzinfrastruktur und Modellkandidaten . . . . . | 29        |
| 5.4.1    | Ollama als Laufzeitumgebung . . . . .                       | 29        |
| 5.4.2    | Anforderungen an das Sprachmodell . . . . .                 | 30        |
| 5.4.3    | Ausgewählte Modellkandidaten für die Evaluation . . . . .   | 30        |
| 5.4.4    | Zusammenfassung der Anforderungen . . . . .                 | 30        |
| <b>6</b> | <b>Konzeption des Assistenzsystems</b>                      | <b>32</b> |
| 6.1      | Zielarchitektur und Datenpipeline . . . . .                 | 32        |
| 6.1.1    | Analysequellen . . . . .                                    | 33        |
| 6.1.2    | Unified Finding Schema . . . . .                            | 34        |
| 6.2      | Prompt-Strategie . . . . .                                  | 35        |
| 6.2.1    | Zweistufige Prompt-Strategie . . . . .                      | 35        |
| 6.2.2    | Wahl der Prompt-Engineering-Strategien . . . . .            | 35        |
| 6.2.3    | Token-Budget-Steuerung . . . . .                            | 36        |
| 6.3      | Ausgabeformat: entwicklernahe To-Do-Liste . . . . .         | 36        |
| <b>7</b> | <b>Implementierung des Proof of Concept</b>                 | <b>38</b> |
| 7.1      | Technischer Rahmen und Projektstruktur . . . . .            | 38        |
| 7.2      | axe-core-Modul . . . . .                                    | 38        |
| 7.3      | Playwright-Modul . . . . .                                  | 39        |
| 7.4      | Quellcode-Anreicherung und Anti-Pattern-Erkennung . . . . . | 40        |
| 7.4.1    | Anreicherung bestehender Findings . . . . .                 | 40        |
| 7.4.2    | Pattern-Findings . . . . .                                  | 40        |
| 7.5      | LLM-Detektor-Modul . . . . .                                | 40        |
| 7.5.1    | Abgrenzung zu grep und Nutzen der Kombination . . . . .     | 41        |
| 7.5.2    | Beispielhafter Ablauf eines LLM-Findings . . . . .          | 41        |
| 7.6      | Prompt-Builder und System-Prompt . . . . .                  | 42        |
| 7.6.1    | System-Prompt . . . . .                                     | 42        |
| 7.6.2    | Token-Budget-Steuerung . . . . .                            | 43        |
| 7.6.3    | Serialisierung . . . . .                                    | 43        |
| 7.7      | Ollama-Client und Output-Formatter . . . . .                | 43        |
| 7.8      | Pipeline-Orchestrierung . . . . .                           | 44        |
| 7.9      | Beispielabläufe am Untersuchungsobjekt . . . . .            | 44        |
| <b>8</b> | <b>Evaluation und Diskussion</b>                            | <b>46</b> |
| 8.1      | Versuchsdesign . . . . .                                    | 46        |
| 8.1.1    | Testobjekte und Ground Truth . . . . .                      | 46        |
| 8.1.2    | Modelle, Konfiguration und Testläufe . . . . .              | 47        |
| 8.1.3    | Metriken und Messverfahren . . . . .                        | 47        |
| 8.2      | Ergebnisse: Detektionsqualität (Recall) . . . . .           | 48        |
| 8.2.1    | Baseline: Tool-Pipeline ohne LLM-Detektor . . . . .         | 48        |
| 8.2.2    | Recall nach LLM-Detektor-Augmentierung . . . . .            | 48        |
| 8.2.3    | Erkennungsleistung nach Verstößkategorie . . . . .          | 49        |
| 8.2.4    | Precision und F1-Score . . . . .                            | 49        |
| 8.3      | Ergebnisse: Priorisierungsqualität . . . . .                | 50        |
| 8.3.1    | Modellvergleich Must-have und Nice-to-have . . . . .        | 50        |
| 8.4      | Ergebnisse: Fix-Qualität (qualitativ) . . . . .             | 51        |

|          |                                                                           |            |
|----------|---------------------------------------------------------------------------|------------|
| 8.4.1    | Bewertungsmaßstab . . . . .                                               | 51         |
| 8.4.2    | Fallbeispiele nach Modell . . . . .                                       | 52         |
| 8.5      | Ergebnisse: Effizienz und Robustheit . . . . .                            | 52         |
| 8.5.1    | Laufzeit und NFA-02-Konformität . . . . .                                 | 52         |
| 8.5.2    | Konsistenz und Parsing-Stabilität . . . . .                               | 53         |
| 8.5.3    | Token-Nutzung . . . . .                                                   | 53         |
| 8.6      | Limitationen und Validität . . . . .                                      | 53         |
| 8.6.1    | Externe Validität . . . . .                                               | 53         |
| 8.6.2    | Interne Validität und Token-Limit-Effekt . . . . .                        | 54         |
| 8.6.3    | Weitere Einschränkungen . . . . .                                         | 54         |
| 8.7      | Belastungsprüfung: test-50 und test-100 . . . . .                         | 54         |
| 8.7.1    | Evaluation an test-50 . . . . .                                           | 55         |
| 8.7.2    | Evaluation an test-100 . . . . .                                          | 56         |
| 8.7.3    | Evaluation am BWEC-Untersuchungsobjekt . . . . .                          | 57         |
| 8.8      | Beantwortung der Forschungsfragen . . . . .                               | 58         |
| 8.8.1    | Übergeordnete Forschungsfrage . . . . .                                   | 58         |
| 8.8.2    | TF1: Erkennungsleistung nach Verstoßtyp . . . . .                         | 58         |
| 8.8.3    | TF2: Mehrwert der Kontextkombination und Ablationsanalyse . . . . .       | 59         |
| 8.9      | Modellwahl und Einsatzempfehlungen . . . . .                              | 60         |
| <b>9</b> | <b>Fazit</b>                                                              | <b>61</b>  |
| 9.1      | Zusammenfassung der Ergebnisse . . . . .                                  | 61         |
| 9.1.1    | Beitrag zur übergeordneten Forschungsfrage . . . . .                      | 61         |
| 9.1.2    | Erfüllung der funktionalen und nicht-funktionalen Anforderungen . . . . . | 61         |
| 9.2      | Kritische Reflexion . . . . .                                             | 62         |
| 9.2.1    | Grenzen der externen Validität . . . . .                                  | 62         |
| 9.2.2    | Methodische Einschränkungen . . . . .                                     | 62         |
| 9.3      | Ausblick . . . . .                                                        | 63         |
| 9.3.1    | Kurz- und mittelfristige Weiterentwicklungen . . . . .                    | 63         |
| 9.3.2    | Langfristige Forschungsperspektiven . . . . .                             | 64         |
|          | <b>Anhang</b>                                                             | <b>65</b>  |
|          | <b>Literaturverzeichnis</b>                                               | <b>160</b> |

# Abkürzungsverzeichnis

|              |                                              |
|--------------|----------------------------------------------|
| <b>ACE</b>   | <i>Accessibility Context Engine</i>          |
| <b>API</b>   | Application Programming Interface            |
| <b>AST</b>   | Abstract Syntax Tree                         |
| <b>BFSG</b>  | Barrierefreiheitsstärkungsgesetz             |
| <b>BITBW</b> | IT Baden-Württemberg                         |
| <b>BITV</b>  | Barrierefreie-Informationstechnik-Verordnung |
| <b>BWEC</b>  | BW-Empfangsclient                            |
| <b>CoT</b>   | Chain-of-Thought Prompting                   |
| <b>CI</b>    | Continuous Integration                       |
| <b>CI/CD</b> | Continuous Integration/Continuous Delivery   |
| <b>CLI</b>   | Command Line Interface                       |
| <b>CPU</b>   | Central Processing Unit                      |
| <b>CSS</b>   | Cascading Style Sheets                       |
| <b>DOM</b>   | Document Object Model                        |
| <b>DSGVO</b> | Datenschutz-Grundverordnung                  |
| <b>DSR</b>   | Design Science Research                      |
| <b>EAA</b>   | European Accessibility Act                   |
| <b>FA</b>    | Funktionale Anforderungen                    |
| <b>FP</b>    | False Positives                              |
| <b>GPU</b>   | Graphics Processing Unit                     |
| <b>HTML</b>  | Hypertext Markup Language                    |
| <b>HTTP</b>  | Hypertext Transfer Protocol                  |
| <b>IQR</b>   | Interquartile Range                          |
| <b>JSON</b>  | JavaScript Object Notation                   |
| <b>JSX</b>   | JavaScript XML                               |
| <b>KI</b>    | Künstliche Intelligenz                       |
| <b>KPI</b>   | Key Performance Indicator                    |
| <b>LLM</b>   | Large Language Model                         |
| <b>NFA</b>   | Nicht-funktionale Anforderungen              |
| <b>PoC</b>   | Proof of Concept                             |

|             |                                      |
|-------------|--------------------------------------|
| <b>PW</b>   | Playwright                           |
| <b>RAG</b>  | Retrieval-Augmented Generation       |
| <b>RAM</b>  | Random-Access Memory                 |
| <b>SEO</b>  | Search Engine Optimization           |
| <b>SPA</b>  | Single-Page Application              |
| <b>TF</b>   | Teilfragen                           |
| <b>TP</b>   | True Positive                        |
| <b>UFS</b>  | Unified Finding Schema               |
| <b>UI</b>   | User Interface                       |
| <b>URL</b>  | Uniform Resource Locator             |
| <b>W3C</b>  | World Wide Web Consortium            |
| <b>WAI</b>  | Web Accessibility Initiative         |
| <b>WCAG</b> | Web Content Accessibility Guidelines |

# Abbildungsverzeichnis

|    |                                                            |     |
|----|------------------------------------------------------------|-----|
| 1  | WCAG-Schichtenmodell (WCAG 2.1) . . . . .                  | 8   |
| 2  | Taxonomie der Barrierefreiheitsverstöße . . . . .          | 12  |
| 3  | Zero-Shot und Few-Shot Prompting im Vergleich . . . . .    | 17  |
| 4  | Datenpipeline des Assistenzsystems . . . . .               | 32  |
| 5  | Komplexität von Home Pages . . . . .                       | 68  |
| 6  | Schematische Übersicht der ACE-Pipeline . . . . .          | 70  |
| 7  | Aufteilung des Token-Budgets . . . . .                     | 76  |
| 8  | Anmeldefenster der test-12-Suite . . . . .                 | 93  |
| 9  | Kontaktformular der test-12-Suite . . . . .                | 93  |
| 10 | Dashboard-Übersicht der test-50-Suite . . . . .            | 112 |
| 11 | Profil-Tab (Profil bearbeiten) der test-50-Suite . . . . . | 112 |
| 12 | Serverstatus der test-50-Suite . . . . .                   | 113 |
| 13 | Benachrichtigungen der test-50-Suite . . . . .             | 113 |
| 14 | Pareto nicht erkannter Violations . . . . .                | 142 |
| 15 | Boxplot Laufzeiten test-100 . . . . .                      | 143 |
| 16 | Pipeline der Findings-Verarbeitung . . . . .               | 144 |
| 17 | Chat-Modul der test-100-Suite . . . . .                    | 145 |
| 18 | Suche-Modul der test-100-Suite . . . . .                   | 145 |
| 19 | Einstellungen-Modul der test-100-Suite . . . . .           | 145 |
| 20 | Kalender-Modul der test-100-Suite . . . . .                | 146 |
| 21 | Hilfe-Center-Modul der test-100-Suite . . . . .            | 146 |
| 22 | Datei-Upload-Modul der test-100-Suite . . . . .            | 146 |
| 23 | Recall-Degradation im Suite-Vergleich . . . . .            | 148 |
| 24 | Gesamtlaufzeit-Skalierung im Suite-Vergleich . . . . .     | 149 |
| 25 | LLM-Konsistenz $\sigma$ im Suite-Vergleich . . . . .       | 150 |
| 26 | Recall und Überschuss im Suite-Vergleich . . . . .         | 151 |
| 27 | Truncation-Rate im Suite-Vergleich . . . . .               | 152 |
| 28 | Heatmap der Recall-Werte . . . . .                         | 153 |
| 29 | Must/Nice-Verteilung je Modell und Suite . . . . .         | 154 |



# Tabellenverzeichnis

|    |                                                                                  |     |
|----|----------------------------------------------------------------------------------|-----|
| 1  | Erkennungsleistung von Accessibility-Tools . . . . .                             | 11  |
| 2  | Konzeptmatrix (Hauptmatrix, hoch priorisierte Studien) . . . . .                 | 22  |
| 3  | Zuordnung der DSRM-Phasen zu den Kapiteln der Arbeit. . . . .                    | 23  |
| 4  | Anforderungsübersicht: funktionale und nicht-funktionale Anforderungen . . . . . | 31  |
| 5  | Zuordnung der Analysequellen . . . . .                                           | 34  |
| 6  | Durchgeführte Benchmarkläufe je Modell und Testsuite . . . . .                   | 47  |
| 7  | Recall-Vergleich je Bedingung und Modell . . . . .                               | 48  |
| 8  | Recall nach Verstößkategorie und Modell . . . . .                                | 49  |
| 9  | Precision, Recall und F1 auf test-50 und test-100 . . . . .                      | 50  |
| 10 | Priorisierungsverhalten der drei Modelle (test-12) . . . . .                     | 51  |
| 11 | Ablationsanalyse: Recall-Beitrag der Pipeline-Stufen . . . . .                   | 59  |
| 12 | Modellwahl nach Anwendungsszenario. . . . .                                      | 60  |
| 13 | Übersicht: generell vs. suite-spezifisch . . . . .                               | 67  |
| 14 | Konzeptmatrix (vollständige Übersicht) . . . . .                                 | 69  |
| 15 | Implementierte Playwright-Checks mit WCAG-Zuordnung und Kategorie . . . . .      | 72  |
| 16 | Implementierte grep-Patterns mit WCAG-Zuordnung . . . . .                        | 72  |
| 17 | Modellempfehlungen nach Anwendungsszenario . . . . .                             | 77  |
| 18 | Bewertungsskala der Empfehlungsqualität . . . . .                                | 78  |
| 19 | Erfüllungsgrad der funktionalen und nicht-funktionalen Anforderungen . . . . .   | 80  |
| 20 | Umgebungs- und Konfigurationsparameter . . . . .                                 | 81  |
| 21 | Threats to Validity . . . . .                                                    | 82  |
| 22 | Accessibility-Verstöße (test-12) . . . . .                                       | 84  |
| 23 | Erkennungsrate der Violations (test-12) . . . . .                                | 85  |
| 24 | Recall-Matrix (test-12) . . . . .                                                | 86  |
| 25 | Rohdaten Benchmark-Runs (test-12) . . . . .                                      | 87  |
| 26 | Modell-Leistungsvergleich (test-12) . . . . .                                    | 88  |
| 27 | Token-Nutzung pro Modell (test-12) . . . . .                                     | 89  |
| 28 | Laufzeiten je Pipeline-Phase (test-12) . . . . .                                 | 89  |
| 29 | Effizienzvergleich der Modelle (test-12) . . . . .                               | 89  |
| 30 | Über-Detektion (test-12) . . . . .                                               | 90  |
| 31 | Detektor-Konsistenz (test-12) . . . . .                                          | 90  |
| 32 | Empfehlungsqualität (test-12) . . . . .                                          | 91  |
| 33 | CSV-Spaltenschema . . . . .                                                      | 92  |
| 34 | Beispielzeilen aus dem CSV-Export (test-12) . . . . .                            | 92  |
| 35 | Accessibility-Verstöße (test-50) . . . . .                                       | 94  |
| 36 | Erkennungsrate der Violations (test-50) . . . . .                                | 97  |
| 37 | Recall-Matrix (test-50) . . . . .                                                | 100 |
| 38 | Rohdaten Benchmark-Runs (test-50) . . . . .                                      | 103 |
| 39 | Modell-Leistungsvergleich (test-50) . . . . .                                    | 104 |
| 40 | Token-Nutzung pro Modell (test-50) . . . . .                                     | 105 |
| 41 | Effizienzvergleich der Modelle (test-50) . . . . .                               | 105 |
| 42 | Über-Detektion (test-50) . . . . .                                               | 106 |
| 43 | Precision je Run: test-50-Suite . . . . .                                        | 107 |
| 44 | Detektor-Konsistenz (test-50) . . . . .                                          | 107 |
| 45 | Empfehlungsqualität (test-50) . . . . .                                          | 108 |
| 46 | Accessibility-Verstöße (test-100) . . . . .                                      | 114 |

|    |                                                                  |     |
|----|------------------------------------------------------------------|-----|
| 47 | Erkennungsrate der Violations (test-100) . . . . .               | 118 |
| 48 | Recall-Matrix (test-100) . . . . .                               | 123 |
| 49 | Rohdaten Benchmark-Runs (test-100) . . . . .                     | 128 |
| 50 | Modell-Leistungsvergleich (test-100) . . . . .                   | 129 |
| 51 | Token-Nutzung pro Modell (test-100) . . . . .                    | 130 |
| 52 | Effizienzvergleich der Modelle (test-100) . . . . .              | 130 |
| 53 | Über-Detektion (test-100) . . . . .                              | 131 |
| 54 | Stichproben-Plausibilisierung des finalen Reports . . . . .      | 132 |
| 55 | Precision je Run: test-100-Suite . . . . .                       | 133 |
| 56 | Detektor-Konsistenz (test-100) . . . . .                         | 134 |
| 57 | Empfehlungsqualität (test-100) . . . . .                         | 135 |
| 58 | Zentrale Metriken im Suite-Vergleich . . . . .                   | 147 |
| 59 | Detektionsquellen-Übersicht BWEC . . . . .                       | 155 |
| 60 | BWEC Tool-Findings Katalog . . . . .                             | 155 |
| 61 | Rohdaten BWEC ( <b>maxfiles</b> =100) . . . . .                  | 156 |
| 62 | Modell-Leistungsvergleich BWEC ( <b>maxfiles</b> =100) . . . . . | 157 |
| 63 | Rohdaten BWEC ( <b>maxfiles</b> =500) . . . . .                  | 158 |
| 64 | Modell-Leistungsvergleich BWEC ( <b>maxfiles</b> =500) . . . . . | 159 |

# 1 Einleitung

Web-Barrierefreiheit ist eine zentrale Voraussetzung für den gleichberechtigten Zugang zu digitalen Informationen und Dienstleistungen – unabhängig von individuellen Einschränkungen. In der Praxis zeigt sich jedoch eine erhebliche Diskrepanz zwischen den normativen Anforderungen und der tatsächlichen Umsetzung: Barrierefreiheit wird im Entwicklungsprozess häufig erst spät berücksichtigt. Bestehende Prüfwerkzeuge erfassen zudem nur einen Bruchteil der tatsächlichen Barrieren, während manuelle Prüf- und Korrekturprozesse zeitaufwändig bleiben.<sup>1</sup> Diese Arbeit untersucht, inwieweit ein LLM-basierter Ansatz diese Lücke schließen kann, indem Barrierefreiheitsprobleme in Webanwendungen automatisiert erkannt und entwicklernahe Handlungsempfehlungen abgeleitet werden – lokal ausführbar und ohne den Transfer sensibler Daten an externe Dienste.<sup>2</sup>

## 1.1 Motivation und Kontext

Rund 1,3 Milliarden Menschen, entsprechend rund 16% der Weltbevölkerung, leben mit einer Form von Behinderung.<sup>3</sup> Für diese Personengruppe ist der Zugang zu digitalen Angeboten keine Komfortfrage, sondern eine grundlegende Voraussetzung gesellschaftlicher Teilhabe. Ohne barrierefreie Webanwendungen bleiben wesentliche Lebensbereiche verschlossen – von der Kommunikation mit Behörden über den Zugang zu Bildung und Gesundheitsinformationen bis hin zur Teilnahme am wirtschaftlichen und gesellschaftlichen Leben. Das Recht auf barrierefreien Zugang zu Informations- und Kommunikationstechnologien ist völkerrechtlich in der UN-Behindertenrechtskonvention verankert und hat sich in den vergangenen Jahren zunehmend auch in verbindlichem nationalen und europäischen Recht niedergeschlagen.<sup>4</sup>

Auf europäischer Ebene verpflichtet der European Accessibility Act (EAA) die Mitgliedstaaten, Barrierefreiheitsanforderungen für digitale Produkte und Dienstleistungen durchzusetzen.<sup>5</sup> In Deutschland wurde diese Richtlinie durch das Barrierefreiheitsstärkungsgesetz (BFSG) in nationales Recht überführt, das seit dem 28. Juni 2025 auch für weite Teile der Privatwirtschaft gilt.<sup>6</sup> Ergänzt wird dieser Rahmen durch die Barrierefreie-Informationstechnik-Verordnung (BITV), die für Behörden und öffentliche Stellen bereits seit Jahren verbindliche Vorgaben festlegt.<sup>7</sup>

Trotz dieser eindeutigen Rechtslage ist die praktische Umsetzung barrierefreier Webanwendungen nach wie vor unzureichend. Die jährlich durchgeführte WebAIM-Million-Studie, die die Startseiten der meistbesuchten Webseiten weltweit analysiert, stellte 2025 fest, dass 94,8% der untersuchten Seiten nachweisbare Verstöße gegen die Web Content Accessibility Guidelines (WCAG)

---

<sup>1</sup> Vgl. Souza et al. 2024; Vgl. Abuaddous, Jali, Basir 2016, S. 175

<sup>2</sup> Vgl. Bassi et al. 2025, S. 297

<sup>3</sup> Vgl. World Health Organization 2026

<sup>4</sup> Vgl. United Nations 2006

<sup>5</sup> Vgl. European Commission 2026

<sup>6</sup> Vgl. Deutscher Bundestag 2026

<sup>7</sup> Vgl. Bundesministerium für Digitales und Staatsmodernisierung 2025; Vgl. Heinemann 2024, S. 281

aufweisen.<sup>8</sup> Gegenüber 2019 (97,8%) entspricht dies lediglich einer Verbesserung um drei Prozentpunkte.<sup>9</sup> Für die öffentliche Verwaltung ist diese Situation besonders gravierend. Während privatwirtschaftliche Anbieter erst seit Juni 2025 durch das BFSG verpflichtet wurden, galten für Behörden und öffentliche Stellen bereits seit Jahren verbindliche Barrierefreiheitsanforderungen nach der BITV – dennoch weisen auch öffentliche Webangebote trotz dieser langjährigen Verpflichtung vergleichbare Mängel auf wie der von WebAIM erfasste privatwirtschaftliche Durchschnitt.<sup>10</sup> Damit bleibt Barrierefreiheit in der Entwicklungspraxis trotz gesetzlicher Verpflichtung systematisch unterrepräsentiert.

Die IT Baden-Württemberg (BITBW) nimmt als zentrale IT-Dienstleisterin der Landesverwaltung Baden-Württemberg in diesem Kontext eine besondere Stellung ein.<sup>11</sup> Als Entwicklerin und Betreiberin öffentlicher Webanwendungen für Ministerien, Polizeibehörden und Kommunen ist sie gesetzlich zur Einhaltung der BITV und des BFSG verpflichtet.<sup>12</sup> Drei Faktoren machen die BITBW zu einem besonders geeigneten Praxiskontext für die vorliegende Arbeit:

1. Ihre Anwendungen unterliegen strengeren Barrierefreiheitsanforderungen als privatwirtschaftliche Produkte.
2. Die Datenschutzvorgaben der öffentlichen Verwaltung schließen die Nutzung cloudbasierter LLM-APIs weitgehend aus.
3. Gewachsene Systemlandschaften mit Legacy-Anteilen und begrenzten Entwicklungsressourcen erschweren die manuelle Barrierefreiheitsprüfung im erforderlichen Umfang.

Die BITBW bietet somit einen geeigneten Rahmen zur Durchführung des praktischen Teils der Arbeit.

## 1.2 Problemstellung

Die mangelhafte Umsetzung von Barrierefreiheit in Softwareprojekten lässt sich nicht allein durch fehlende Motivation oder Ressourcen erklären. Wesentliche Gründe sind die Schwächen der verfügbaren Tools: automatisierte Barrierefreiheitsanalyse-Tools wie axe<sup>13</sup>, WAVE<sup>14</sup> oder Lighthouse<sup>15</sup> erkennen zwar syntaktische Verstöße, stoßen jedoch bei semantischen Problemen an ihre Grenzen. Ob ein Alternativtext den Bildinhalt angemessen beschreibt oder eine Schaltflächenbeschriftung für Screenreader-Nutzende verständlich ist, entzieht sich der regelbasierten Prüflogik dieser Tools.

---

<sup>8</sup>Vgl. WebAIM 2025

<sup>9</sup>Vgl. WebAIM 2019

<sup>10</sup>Vgl. Heinemann 2024, S. 281, 469–488

<sup>11</sup>Vgl. BITBW 2021

<sup>12</sup>Vgl. Landesrecht BW 2015

<sup>13</sup>Vgl. Deque Systems 2026

<sup>14</sup>Vgl. WebAIM 2026a

<sup>15</sup>Vgl. Google 2025

Empirisch belegt wird diese Schwäche durch das Mutation-Testing-Framework **Ma11y**.<sup>16</sup> Es injiziert gezielt Barrierefreiheitsfehler in reale Webanwendungen und prüft anschließend, ob bestehende Accessibility-Tools diese künstlich eingebrachten Defekte erkennen. In einer systematischen Evaluation mit 25 gezielt eingebrachten Barrierefreiheitsproblemen erkannte kein einziges der sechs untersuchten Tools mehr als 50% der injizierten Fehler. Somit blieb im Durchschnitt nahezu die Hälfte aller Defekte unentdeckt.<sup>17</sup>

Eine zweite strukturelle Schwäche betrifft die Charakteristik moderner Webanwendungen. Rich-Client-Anwendungen auf Basis von Frameworks wie React erzeugen ihren Inhalt größtenteils clientseitig und verändern das Document Object Model (DOM) dynamisch in Abhängigkeit von Nutzerinteraktionen. Barrieren entstehen häufig erst in bestimmten Zuständen: wenn ein Modalfenster geöffnet wird, eine Fehlermeldung erscheint oder ein Dropdown-Menü aktiviert ist. Rein statische Analysen – oder solche, die ausschließlich den initialen Seitenladezustand prüfen – erfassen diese zustandsabhängigen Barrieren nicht.<sup>18</sup>

Jüngere Forschungsarbeiten deuten darauf hin, dass LLMs geeignet sein können, zentrale Grenzen regelbasierter Accessibility-Tools zu überwinden. Systeme wie **AccessGuru**<sup>19</sup> und **GenA11y**<sup>20</sup> setzen das cloudbasierte Large Language Model (LLM) GPT-4o ein und erzielen bei der Erkennung und Korrektur von Barrierefreiheitsverstößen vielversprechende Ergebnisse. Beide Ansätze beschränken sich jedoch im Wesentlichen auf die Analyse statischen HTMLs und berücksichtigen weder dynamische Zustandswechsel noch den Quellcode der geprüften Anwendung. Der Schritt von der Fehlererkennung zu einer entwicklernahen, auf den Quellcode bezogenen Handlungsempfehlung wird in der Literatur als offenes Problem benannt,<sup>21</sup> bleibt aber bislang ungelöst. Eine vertiefte Analyse dieser und weiterer Arbeiten erfolgt in Kapitel 3 „Stand der Forschung“.

Die vorliegende Forschungsliteratur weist auf drei zentrale Defizite hin: Kein bekannter Ansatz kombiniert (a) automatisierte Erfassung dynamischer Zustände in React-basierten Webanwendungen, (b) Verknüpfung von Tool-Reports mit dem Quellcode der geprüften Anwendung und (c) entwicklernaher, priorisierter Handlungsempfehlung – unter den Randbedingungen lokaler Inferenz und ohne den Transfer sensibler Anwendungsdaten an externe Dienste.

### 1.3 Zielsetzung und Forschungsfragen

Ziel dieser Bachelorarbeit ist die Konzeption und prototypische Umsetzung einer lokal ausführbaren, kontextsensitiven Assistenzlösung zur Barrierefreiheitsanalyse von Rich-Client-Webanwendungen. Als Praxisrahmen und Motivationskontext dient der BW-Empfangsclient (BWEC), eine React-basierte Webanwendung der BITBW; die Hauptevaluation erfolgt jedoch an synthetisch

---

<sup>16</sup>Vgl. Tafreshipour et al. 2024, S. 97

<sup>17</sup>Vgl. Tafreshipour et al. 2024, S. 100

<sup>18</sup>Vgl. Bassi et al. 2025, S. 303

<sup>19</sup>Vgl. Fathallah, Hernández, Staab 2025

<sup>20</sup>Vgl. He, Huq, Malek 2025, FSE101:10–11

<sup>21</sup>Vgl. He, Huq, Malek 2025, FSE101:15–17

konstruierten Testsuiten mit vollständig bekannter Ground Truth (d. h. vorab definierter und im System eingebetteter Menge aller vorhandenen Violations). Der Proof of Concept (PoC) soll drei Datenquellen in einer gemeinsamen Pipeline zusammenführen:

1. strukturierte Violation-Reports aus axe-core,
2. Interaktionsdaten aus Playwright-gesteuerten Browser-Tests sowie
3. Quellcode der geprüften React-Komponenten, der sowohl regelbasiert extrahiert als auch vom LLM kontextsensitiv analysiert wird.

Auf dieser Grundlage werden priorisierte, entwicklernahe Handlungsempfehlungen abgeleitet und strukturiert aufbereitet.

Aus der Zielsetzung der Arbeit ergeben sich drei konkrete Beiträge:

1. Einen strukturierten Überblick darüber, wie unterschiedliche Datenquellen der Barrierefreiheitsanalyse systematisch kombiniert und interpretiert werden können.
2. Einen Proof of Concept (PoC), der das Vorgehen exemplarisch demonstriert.
3. Eine qualitative und quantitative Bewertung der Untersuchungsergebnisse anhand definierter Kriterien, die aus den Anforderungen und der einschlägigen Fachliteratur abgeleitet werden.

Die übergeordnete Forschungsfrage dieser Arbeit lautet:

**Inwieweit kann ein kontextsensitives KI-Assistenzsystem, das Tool-Reports, Playwright-Interaktionsdaten und Quellcode kombiniert, Barrierefreiheitsverstöße in React-basierten Webanwendungen automatisiert erkennen und entwicklernahe Handlungsempfehlungen generieren?**

Die übergeordnete Forschungsfrage unterteilt sich in zwei untergeordnete Teilfragen (TF):

- TF1: Welche Typen von Barrierefreiheitsverstößen – syntaktisch, semantisch und layout-bezogen – lassen sich durch den gewählten Ansatz zuverlässig erkennen und wo liegen die methodischen Grenzen?
- TF2: Inwiefern verbessert die vollständige Kontextkombination aus Tool-Reports, Playwright-Interaktionsdaten und Quellcode die Erkennungsleistung und Empfehlungsqualität gegenüber einer reinen regelbasierten Tool-Baseline ohne LLM-Kontextualisierung?

TF1 adressiert dabei das Erkennungsproblem und erlaubt eine differenzierte Aussage über die Leistungsfähigkeit und Grenzen des Systems entlang der Verstoß-Taxonomie von Fathallah et al.<sup>22</sup> TF2 greift den in der Literatur identifizierten Mehrwert der Kontextualisierung auf und überprüft ihn durch einen systematischen Vergleich zwischen der reinen Tool-Baseline (axe-core,

---

<sup>22</sup>Vgl. Fathallah, Hernández, Staab 2025, S. 114–115

Playwright, grep ohne LLM) und der vollständigen Pipeline (Baseline + LLM-gestützte Quellcodeanalyse) an den synthetischen Testsuiten mit bekannter Ground Truth.

### 1.4 Aufbau der Arbeit

Die Arbeit gliedert sich in neun Kapitel. Im Anschluss an die Einleitung werden in Kapitel 2 die theoretischen Grundlagen erarbeitet: Barrierefreiheit im Web, die WCAG-Standards und der rechtliche Rahmen, die Charakteristika von Rich-Client-Webanwendungen sowie Grundlagen zu Large Language Models und Prompt-Engineering-Strategien.

Kapitel 3 gibt einen systematischen Überblick über den Stand der Forschung, gliedert die relevanten Arbeiten thematisch – nach LLM-basierter Erkennung, Code-Korrektur, hybriden Pipelines und Evaluation – und schließt mit einer expliziten Einordnung des Beitrags der vorliegenden Arbeit.<sup>23</sup>

Kapitel 4 legt das methodische Vorgehen dar. Es beschreibt die Wahl des Design-Science-Research-Paradigmas als wissenschaftliche Methode, definiert den Untersuchungsgegenstand und entwirft das Evaluationsdesign.<sup>24</sup>

Kapitel 5 analysiert den Problemkontext anhand des BWEC als Praxisrahmen und leitet daraus funktionale und nicht-funktionale Anforderungen an das System ab. Dabei werden auch die Auswahlkriterien für die eingesetzten lokalen Sprachmodelle begründet.

Auf Basis dieser Anforderungen wird in Kapitel 6 das Assistenzsystem konzipiert: Systemarchitektur, Datenpipeline, Prompt-Strategie und Ausgabeformat werden begründet entworfen.

Kapitel 7 beschreibt die prototypische Implementierung des PoC und illustriert die Systemfunktionalität anhand von Beispielabläufen für syntaktische, semantische und dynamisch erzeugte Barrierefreiheitsprobleme.

Kapitel 8 präsentiert und diskutiert die Evaluationsergebnisse auf den drei synthetischen Benchmarksuiten sowie am realen BWEC. Es beantwortet die Forschungsfragen auf Basis der Messwerte und reflektiert die Limitationen des Ansatzes.

Das abschließende Kapitel 9 fasst die Kernaussagen zusammen, ordnet den Beitrag der Arbeit in die Forschungslandschaft ein und formuliert Empfehlungen für weiterführende Untersuchungen.

---

<sup>23</sup>Vgl. Webster, Watson 2002

<sup>24</sup>Vgl. Hevner, A. R. et al. 2004, S. 75

## 2 Theoretische Grundlagen

Dieses Kapitel bündelt die theoretischen Grundlagen für die Konzeption und Evaluation des Proof of Concept. Im Mittelpunkt stehen Web-Barrierefreiheit, die Grenzen automatisierter Prüfwerkzeuge, Rich-Client-Webanwendungen sowie LLM-basierte Assistenzsysteme einschließlich Prompting und Datenschutz.

### 2.1 Barrierefreiheit von Webanwendungen

#### 2.1.1 Begriffsdefinition und Relevanz

Der Begriff *Web Accessibility*, im Deutschen Web-Barrierefreiheit, bezeichnet nach Definition der Web Accessibility Initiative (WAI) die Eigenschaft von Webangeboten, von allen Menschen unabhängig von körperlichen, motorischen oder sensorischen Einschränkungen sowie individuellen Fähigkeiten wahrgenommen, bedient und genutzt werden zu können.<sup>25</sup> Im Mittelpunkt der vorliegenden Arbeit stehen vor allem visuelle und motorische Beeinträchtigungen; der gesellschaftliche und rechtliche Kontext wurde in Abschnitt 1.1 dargelegt.

In der Forschungsliteratur werden vier wesentliche Behinderungsformen unterschieden, aus denen sich unterschiedliche Anforderungen an die Gestaltung barrierefreier Webangebote ergeben.<sup>26</sup> Für diese Arbeit sind insbesondere zwei Kategorien relevant – visuelle Beeinträchtigungen und motorische Einschränkungen –, da sie den Großteil der automatisiert prüfbaren WCAG-Verstöße betreffen:

**Visuelle Beeinträchtigungen** umfassen vollständige oder partielle Blindheit sowie Farbfehlsichtigkeit.<sup>27</sup> Betroffene Personen nutzen häufig Screenreader-Software (z.B. **JAWS**, **NVDA**, **VoiceOver**), deren Wirksamkeit auf einer korrekten semantischen HTML-Struktur beruht.<sup>28</sup> Fehlende Alternativtexte, unzureichende Farbkontraste und fehlende **aria**-Labels bilden die häufigsten Verstöße in dieser Kategorie<sup>29</sup> und zugleich den primären Erkennungsbereich des in dieser Arbeit entwickelten Systems.

**Motorische Einschränkungen** betreffen Personen, die konventionelle Eingabegeräte wie Maus oder Touchscreen nicht präzise bedienen können.<sup>30</sup> Sie sind auf Tastaturnavigation, Sprachsteuerung oder spezielle assistive Eingabegeräte angewiesen.<sup>31</sup> Eine vollständige Bedienbarkeit über

---

<sup>25</sup>Vgl. Abuaddous, Jali, Basir 2016, S. 172

<sup>26</sup>Vgl. Lazar, Feng, Hochheiser 2017, S. 493–494

<sup>27</sup>Vgl. Gubbi Mohanbabu, Pavel 2024

<sup>28</sup>Vgl. Morris et al. 2016, S. 5508

<sup>29</sup>Vgl. World Wide Web Consortium (W3C) 2023, Erfolgskriterium 1.1.1

<sup>30</sup>Vgl. Pérez et al. 2020, S. 110381–110382

<sup>31</sup>Vgl. Kouroupetroglou 2013, S. 208



die Tastatur ist daher eine zentrale Voraussetzung für barrierefreie Nutzung.<sup>32</sup> Für das vorliegende System ist diese Kategorie besonders relevant, da Tastaturfallen und fehlende Fokussteuerung in (React-)Anwendungen häufig erst durch interaktionsbasierte Tests, etwa mit Playwright, sichtbar werden.<sup>33</sup>

**Auditive Beeinträchtigungen** betreffen Personen mit vollständiger oder partieller Hörbeeinträchtigung. Barrierefreiheit erfordert hier Untertitel, Transkripte und Gebärdensprachvideos. Da diese Kategorie kaum automatisiert prüfbar ist, wird sie in der vorliegenden Arbeit nicht weiter vertieft.<sup>34</sup>

**Kognitive Beeinträchtigungen** umfassen ein breites Spektrum – von Lernschwierigkeiten über Aufmerksamkeitsstörungen bis hin zu eingeschränktem Arbeitsgedächtnis. Barrierefreie Gestaltung erfordert klare Sprache und konsistente Navigation. Auch diese Kategorie entzieht sich weitgehend der automatisierten Prüfung und wird daher nicht vertieft.<sup>35</sup>

Assistive Technologien – darunter Screenreader, Bildschirmvergrößerungssoftware und alternative Eingabegeräte – bilden die technische Voraussetzung für die Nutzung digitaler Angebote durch die genannten Personengruppen.<sup>36</sup> Ihre Wirksamkeit hängt jedoch unmittelbar davon ab, dass Webanwendungen klar definierte strukturelle und semantische Anforderungen erfüllen.<sup>37</sup> Die Nichterfüllung dieser Anforderungen führt nicht nur zu einer Beeinträchtigung der betroffenen Personen, sondern kann auch wirtschaftliche und rechtliche Konsequenzen nach sich ziehen.<sup>38</sup>

### 2.1.2 WCAG: Aufbau, Prinzipien und Konformitätsstufen

Die WCAG sind der internationale Standard für barrierefreie Webinhalte und werden vom World Wide Web Consortium (W3C) im Rahmen der WAI veröffentlicht. Die derzeit maßgebliche Referenzversion ist WCAG 2.2, die im Oktober 2023 WCAG 2.1 (2018) ablöste und gegenüber der Vorgängerversion neun zusätzliche Erfolgskriterien einführt – insbesondere zur Verbesserung der Bedienbarkeit für Personen mit kognitiven Einschränkungen und zur mobilen Nutzung.<sup>39</sup>

Die WCAG ist hierarchisch in vier Ebenen gegliedert: Prinzipien, Richtlinien, Erfolgskriterien und unterstützende Techniken (vgl. Abbildung 1). An der Spitze stehen die vier grundlegenden Prinzipien, zusammengefasst im Akronym **POUR**: *Perceivable* (Wahrnehmbarkeit), *Operable* (Bedienbarkeit), *Understandable* (Verständlichkeit) und *Robust* (Robustheit).<sup>40</sup> Aus diesen Prinzipien leiten sich 13 Richtlinien ab, die durch insgesamt 87 testbare Erfolgskriterien konkretisiert

---

<sup>32</sup>Vgl. WebAIM 2026b

<sup>33</sup>Vgl. Chiou, Alotaibi, Halfond 2021, S. 855

<sup>34</sup>Vgl. Abou-Zahra, Brewer, Cooper 2018

<sup>35</sup>Vgl. Abou-Zahra, Brewer, Cooper 2018

<sup>36</sup>Vgl. World Wide Web Consortium (W3C) 2026b; Abou-Zahra, Brewer, Cooper 2018

<sup>37</sup>Vgl. Morrison et al. 2017, S. 82

<sup>38</sup>Vgl. Krok 2024, S. 864–865

<sup>39</sup>Vgl. World Wide Web Consortium (W3C) 2018; World Wide Web Consortium (W3C) 2023; Vgl. Purwandari et al. 2025, S. 118; Vgl. Souza et al. 2024

<sup>40</sup>Vgl. Souza et al. 2024

werden.<sup>41</sup> Typische Anforderungen sind Alternativtexte für Bilder (Kriterium 1.1.1), ausreichende Farbkontraste (1.4.3) und vollständige Tastaturerreichbarkeit aller Funktionen (2.1.1).<sup>42</sup>

Jedes Erfolgskriterium ist einer von drei Konformitätsstufen zugeordnet.<sup>43</sup> Stufe A umfasst grundlegende Anforderungen, deren Nichteinhaltung bestimmte Nutzergruppen vollständig ausschließt. Stufe AA ist der in Europa gesetzlich geforderte Mindeststandard für öffentliche Stellen und weitere Teile der Privatwirtschaft.<sup>44</sup> Stufe AAA beschreibt Anforderungen, die nicht für alle Inhalte generell erfüllbar sind. Die vorliegende Arbeit fokussiert sich entsprechend dem gesetzlichen Mindeststandard auf Stufe A und AA.




Abb. 1: WCAG-Schichtenmodell (dargestellt nach WCAG 2.1; in WCAG 2.2 strukturell unverändert).

Die praktische Umsetzung dieser Standards bleibt trotz ihrer langen Etablierung unzureichend.<sup>45</sup> Die WebAIM Million Study wird seit 2019 jährlich von WebAIM (*Web Accessibility In Mind*), einer gemeinnützigen Organisation der Utah State University, veröffentlicht. Sie analysiert automatisiert die Startseiten der jeweils meistbesuchten eine Million Websites weltweit und gilt damit als die umfangreichste empirische Erhebung zur Verbreitung von WCAG-Verstößen im Web.<sup>46</sup> Die Ausgabe 2025 identifizierte durchschnittlich 56,8 WCAG-Fehler pro Seite. Die häufigsten Verstößkategorien betrafen fehlende Alternativtexte (54,5 % der untersuchten Seiten), unzureichende Farbkontraste (80,6 %), fehlende Labels (47,4 %), leere Links (44,6 %) und fehlende Sprachangaben im HTML (17,1 %).<sup>47</sup>

---

<sup>41</sup>Vgl. World Wide Web Consortium (W3C) 2023

<sup>42</sup>Vgl. World Wide Web Consortium (W3C) 2023, Abschnitte 1–4

<sup>43</sup>Vgl. Fathallah, Hernández, Staab 2025

<sup>44</sup>Vgl. Kerkmann, Lewandowski 2015, S. 40, 195–197

<sup>45</sup>Vgl. Bassi et al. 2025, S. 297

<sup>46</sup>Vgl. WebAIM 2025

<sup>47</sup>Vgl. WebAIM 2025

### 2.1.3 Rechtlicher Rahmen

Der rechtliche Rahmen – EAA, BFGS und BITV 2.0 – wurde in Abschnitt 1.1 dargestellt. Für die technische Umsetzung gilt WCAG 2.2, Konformitätsstufe AA, als verbindlicher Prüfmaßstab.<sup>48</sup> Dieser Standard bildet die Grundlage sowohl für die Testsuite-Konstruktion als auch für die Anforderungsableitung der vorliegenden Arbeit.

## 2.2 Automatisierte Barrierefreiheitsanalyse

Wie in Abschnitt 1.2 dargelegt, erschweren späte Integration in Entwicklungsprozesse, begrenztes WCAG-Wissen und Zeitdruck eine konsequente Umsetzung von Barrierefreiheit.<sup>49</sup> Automatisierte Prüfwerkzeuge setzen an diesen Defiziten an; der folgende Abschnitt beschreibt deren Funktionsweise, Leistungsumfang und strukturelle Grenzen.

### 2.2.1 Klassische Tool-Ansätze

Für die automatisierte Überprüfung von Webanwendungen auf Barrierefreiheit existiert eine stetig wachsende Zahl von Werkzeugen. Die WAI führt in ihrer aktuellen Evaluation-Tool-Liste über 160 Werkzeuge<sup>50</sup>, von denen 84 explizit die WCAG 2.1 adressieren.<sup>51</sup> Alle gängigen Werkzeuge arbeiten regelbasiert, das heißt, sie prüfen den DOM einer geladenen Seite anhand eines vordefinierten Regelkatalogs gegen bekannte Verstoßmuster.<sup>52</sup> Das Document Object Model (DOM) ist eine vom Browser erzeugte, baumartige Objektstruktur, die den HTML-Code einer Webseite als hierarchische Struktur aus Elementknoten repräsentiert.<sup>53</sup> Skripte und Analysewerkzeuge können auf diese Struktur über standardisierte Programmierschnittstellen zugreifen und sie gezielt auswerten.

Zu den verbreitetsten automatisierten Werkzeugen der Barrierefreiheitsprüfung gehören unter anderem:

- **axe-core**, entwickelt von Deque Systems, hat sich als Standardlösung für die automatische Integration von Accessibility-Tests in Entwicklungspipelines etabliert.<sup>54</sup>
- **WAVE** (WebAIM) bietet visuelle Browser-Extensions, die Fehler direkt in der gerenderten Seitenansicht annotieren.<sup>55</sup>

---

<sup>48</sup>Vgl. World Wide Web Consortium (W3C) 2023; Bundesministerium für Digitales und Staatsmodernisierung 2025; Deutscher Bundestag 2026

<sup>49</sup>Vgl. Bassi et al. 2025, S. 298; Vgl. Mowar 2024, S. 123

<sup>50</sup>Vgl. World Wide Web Consortium (W3C) 2026a

<sup>51</sup>Vgl. Delnevo, Andruccioli, Mirri 2024

<sup>52</sup>Vgl. Kodithuwakku, Wickramaarachchi 2025; Manca et al. 2023, 3:9

<sup>53</sup>Vgl. Robie 2026

<sup>54</sup>Vgl. Deque Systems 2026

<sup>55</sup>Vgl. WebAIM 2026a

- **Lighthouse** ist in die Chrome-DevTools integriert und kombiniert Accessibility-Testing mit Performance- und SEO-Analysen.<sup>56</sup>

Der typische Output solcher Werkzeuge ist ein strukturierter Violation Report, bei dem jedem erkannten Verstoß eine Bezeichnung, Beschreibung und ein Schweregrad zugewiesen wird (bei axe-core: minor, moderate, serious, critical) sowie, falls möglich, ein HTML-Ausschnitt des betroffenen Elements.<sup>57</sup> Dieser standardisierte Output bildet in der vorliegenden Arbeit die Grundlage für die erste Stufe der Datenpipeline.

### 2.2.2 Grenzen bestehender Tools

Trotz ihrer weiten Verbreitung weisen regelbasierte Accessibility-Tools grundlegende strukturelle Grenzen auf. Diese lassen sich in drei Kategorien einteilen: begrenzte Regelabdeckung, semantische Blindheit und fehlende Dynamik.

Die Regelabdeckung der Werkzeuge ist deutlich geringer, als häufig angenommen wird. Kodithuwakku und Wickramaarachchi zeigen, dass selbst die leistungsfähigsten untersuchten Tools lediglich 21% aller WCAG-Tests automatisiert abdecken können (vgl. Tabelle 1).<sup>58</sup> Die in der Tabelle ausgewiesenen Werte CER und ICR messen davon abweichende Dimensionen: CER beschreibt, welcher Anteil der tatsächlich gemeldeten Befunde korrekt ist (Präzision), während ICR angibt, wie viele der vorhandenen Probleme vom Tool gefunden wurden (Recall). Für Tastaturzugänglichkeit und auditive Barrieren lag die Erkennungsrate in ihrer Studie bei null Prozent; hinzu kommt eine hohe Rate an *False Positives*.<sup>59</sup> Bassi et al. kommen zu dem Ergebnis, dass das beste verfügbare Einzeltool (**ARC Toolkit**) nur 26% der WCAG-Tests abdeckt.<sup>60</sup>

Die Kombination mehrerer Tools in einem Ensemble verbessert die Abdeckung, beseitigt das strukturelle Problem jedoch nicht vollständig. Pool zeigt, dass selbst ein Ensemble aus acht gleichzeitig eingesetzten Tools, darunter auch **axe-core**, **WAVE** und **Qualweb**, erhebliche Lücken hinterlässt: jedes einzelne Tool erkennt mindestens sieben Violations exklusiv.<sup>61</sup> Manca et al. stellen zudem fest, dass von elf untersuchten Werkzeugen lediglich drei explizit auf ihre Erkennungslücken hinweisen.<sup>62</sup>

Ein zentrales Defizit liegt in der semantischen Blindheit der Werkzeuge.<sup>64</sup> Regelbasierte Tools können lediglich prüfen, ob ein Accessibility-Attribut vorhanden ist, nicht aber, ob der Inhalt dem richtigen Zweck dient. Ein Bild mit dem Alternativtext *image* oder *IMG\_0042.jpg* wird von allen Tools als regelkonform eingestuft, obwohl dieser Text für Screenreader-Nutzende keinen

---

<sup>56</sup>Vgl. Google 2025

<sup>57</sup>Vgl. Kodithuwakku, Wickramaarachchi 2025; Deque Systems 2026

<sup>58</sup>Vgl. Kodithuwakku, Wickramaarachchi 2025

<sup>59</sup>Vgl. Kodithuwakku, Wickramaarachchi 2025

<sup>60</sup>Vgl. Bassi et al. 2025, S. 298

<sup>61</sup>Vgl. Pool 2023

<sup>62</sup>Vgl. Manca et al. 2023, S. 4

<sup>63</sup>Entnommen aus Kodithuwakku, Wickramaarachchi 2025.

<sup>64</sup>Vgl. Fathallah, Hernández, Staab 2025

| Tool                           | True Positives | False Positives | CER (%) | ICR (%) |
|--------------------------------|----------------|-----------------|---------|---------|
| Lighthouse                     | 17             | 16              | 52.94   | 15.92   |
| WAVE                           | 16             | 12              | 35.29   | 14.65   |
| SiteImprove                    | 23             | 18              | 47.06   | 19.75   |
| axe                            | 15             | 10              | 52.94   | 15.29   |
| Accessibility Insights         | 24             | 19              | 47.06   | 15.29   |
| A11y                           | 6              | 8               | 23.53   | 3.82    |
| Includia Accessibility Checker | 33             | 31              | 41.18   | 21.02   |

Tab. 1: Vergleich der Erkennungsleistung verschiedener Accessibility-Prüfwerkzeuge.<sup>63</sup> CER beschreibt den Anteil korrekt erkannter Verstöße im Verhältnis zu allen gemeldeten Verstößen, während ICR den Anteil tatsächlich vorhandener Accessibility-Probleme misst, die vom jeweiligen Tool erkannt werden.

Mehrwert bietet. **Ma11y**, ein Mutation-Testing-Framework für Accessibility, hat dieses Problem empirisch quantifiziert: Bei der systematischen Injektion von 25 gezielten Defekten in reale Webanwendungen erkannten die sechs ausgewählten Tools semantische Verstöße nur zu 26% und syntaktische Verstöße zu 54% – im Durchschnitt blieb damit nahezu die Hälfte aller injizierten Defekte unentdeckt.<sup>65</sup>

Ein weiteres strukturelles Problem besteht in der **fehlenden Dynamik** der Analyse. Viele Tools analysieren ausschließlich den initial geladenen DOM-Zustand einer Seite.<sup>66</sup> Barrieren, die erst durch Nutzerinteraktionen entstehen – etwa beim Öffnen eines Modalfensters, beim Aktivieren eines Dropdown-Menüs oder beim Erscheinen einer Fehlermeldung – bleiben dabei unsichtbar. Hinzu kommt, dass alle Violation Reports generischer Natur sind: Sie beschreiben das Problem auf der Ebene des gerenderten DOM, ohne Bezug zur Quellcodestruktur der geprüften Anwendung herzustellen.<sup>67</sup>

### 2.2.3 Taxonomie der Verstöße: syntaktisch, semantisch, Layout

Um Barrierefreiheitsverstöße systematisch analysieren und gezielt adressieren zu können, legt diese Arbeit eine dreiteilige Taxonomie zugrunde, die auf Fathallah et al. zurückgeht (vgl. Abbildung 2).<sup>68</sup>

- **Syntaktische Verstöße** bezeichnen Fälle, in denen ein erforderliches Accessibility-Element vollständig fehlt oder formal falsch gebildet ist.<sup>69</sup> Ein typisches Beispiel ist ein fehlendes `alt`-Attribut an einem `<img>`-Element. Diese Kategorie ist für regelbasierte Tools am besten prüfbar, da die Verletzung rein struktureller Natur ist.<sup>70</sup>

<sup>65</sup>Vgl. Tafreshipour et al. 2024, S. 108

<sup>66</sup>Vgl. Fathallah, Hernández, Staab 2025

<sup>67</sup>Vgl. Delnevo, Andruccioli, Mirri 2024

<sup>68</sup>Vgl. Fathallah, Hernández, Staab 2025

<sup>69</sup>Vgl. Tafreshipour et al. 2024, S. 102

<sup>70</sup>Vgl. Flanagan 2020, S. 569 ff.

- **Semantische Verstöße** liegen vor, wenn Accessibility-Attribute zwar vorhanden sind, ihren Zweck aber inhaltlich verfehlen.<sup>71</sup> Ein Bild mit dem Alternativtext *Bild* oder ein Link mit dem Text *hier klicken* sind typische Beispiele. Da die Bewertung solcher Verstöße Sprachverständnis und Kontextwissen erfordert, bilden sie das primäre Anwendungsfeld für LLM-basierte Analysen.<sup>72</sup>
- **Layout-Verstöße** betreffen visuelle Barrieren, insbesondere unzureichende Farbkontraste<sup>73</sup> und fehlende oder schwer erkennbare Fokusindikatoren.<sup>74</sup> Einige dieser Verstöße können algorithmisch geprüft werden; andere erfordern ein kontextuelles visuelles Urteil.

### Taxonomie der Barrierefreiheitsverstöße




Abb. 2: Taxonomie der Barrierefreiheitsverstöße nach Fathallah et al. mit Beispielen und Erkennungscharakteristik je Kategorie.<sup>75</sup>

## 2.3 Rich-Client-Webanwendungen und Testautomatisierung

### 2.3.1 Charakteristika und Abgrenzung

Im Rahmen dieser Arbeit bezeichnet eine Rich-Client-Webanwendung eine webbasierte Anwendung, bei der ein wesentlicher Teil der Anwendungslogik und Darstellungssteuerung clientseitig im Browser ausgeführt wird.<sup>76</sup> Im Gegensatz zu klassischen serverseitig gerenderten Anwendungen werden bei einer Single-Page Application (SPA) nach dem initialen Laden des HTML-Rahmens ausschließlich Daten zwischen Client und Server ausgetauscht, wobei die Darstellung durch clientseitige Skriptsprachen wie JavaScript oder TypeScript direkt im Browser durch Manipulation des DOM gesteuert wird.<sup>77</sup> Die zunehmende Komplexität solcher Anwendungen ist in Anhang 2 veranschaulicht.

<sup>71</sup>Vgl. World Wide Web Consortium (W3C) 2023

<sup>72</sup>Vgl. He, Huq, Malek 2025, FSE101:2

<sup>73</sup>Vgl. World Wide Web Consortium (W3C) 2023, Erfolgskriterium 1.4.3

<sup>74</sup>Vgl. World Wide Web Consortium (W3C) 2023, Erfolgskriterium 2.4.7–2.4.13

<sup>76</sup>Vgl. Meta Open Source 2026b; Vgl. Sommerville 2016, S. 184–186, 499–501

<sup>77</sup>Vgl. Meta Open Source 2026a

React, ein von Meta entwickeltes JavaScript-Framework, ist derzeit einer der dominierenden Ansätze zur Entwicklung solcher Anwendungen. Laut Stack Overflow Developer Survey 2025 wird React von 44,7% aller befragten Entwicklerinnen und Entwickler eingesetzt.<sup>78</sup>

Für die Barrierefreiheitsanalyse sind zwei Architekturmerkmale von React besonders relevant:

1. Anwendungslogik und Darstellung werden in wiederverwendbaren Komponenten gekapselt, deren Kommunikation über Props (unveränderliche Eingabeparameter) und internen State (veränderlicher Zustand) erfolgt.<sup>79</sup>
2. Die Darstellung der Komponenten wird mithilfe der Syntaxerweiterung JavaScript XML (JSX) (bzw. TSX bei Verwendung von TypeScript) definiert, die HTML-ähnliche Strukturen direkt in JavaScript- oder TypeScript-Code einbettet.<sup>80</sup>

### 2.3.2 Herausforderungen für die Barrierefreiheitsprüfung

Komponentenbasierte Frameworks wie React, Vue oder Angular weisen gemeinsame Architekturmerkmale auf, die die Barrierefreiheitsanalyse grundsätzlich erschweren.<sup>81</sup> Da die vorliegende Arbeit eine React-Anwendung als Untersuchungsgegenstand verwendet, werden die folgenden Herausforderungen anhand von React konkretisiert; sie gelten in ähnlicher Form jedoch auch für andere komponentenbasierte Frameworks.

1. Viele Barrierefreiheitsprobleme entstehen zustandsabhängig, wie bereits in Abschnitt 2.2.2 erläutert wurde. Ein Modalfenster kann sich nach einem Klick öffnen, ohne den Tastaturfokus korrekt zu verwalten. Ebenso kann eine Fehlermeldung nach dem Absenden eines Formulars erscheinen, ohne über eine ARIA-Live-Region programmatisch angekündigt zu werden. Auch ein Dropdown-Menü kann für Tastaturnutzende nicht navigierbar sein. All diese Probleme sind im initialen Seitenzustand nicht vorhanden und damit für statische Analysewerkzeuge unsichtbar.<sup>82</sup> In React wird diese Problematik durch das State-Management verstärkt: Zustandsänderungen lösen ein erneutes Rendering einzelner Komponenten aus, wobei sich die Accessibility-Eigenschaften des resultierenden DOM je nach State unterscheiden können.
2. Zwischen Quellcode und gerendertem DOM besteht eine Diskrepanz, die für die entwicklernahe Behebung von Befunden zentral ist. In React werden Benutzeroberflächen in JSX/TSX definiert; der im Browser gerenderte DOM ist das Ergebnis der React-Laufzeitumgebung, die diese Definitionen in DOM-Elemente übersetzt. Ein Accessibility-Tool analysiert den gerenderten DOM, nicht aber den Quellcode, aus dem er hervorging.<sup>83</sup> Für Entwicklerinnen und Entwickler ist jedoch der Quellcode der relevante

---

<sup>78</sup>Vgl. Stack Overflow 2025

<sup>79</sup>Vgl. Meta Open Source 2026b

<sup>80</sup>Vgl. Bai 2022

<sup>81</sup>Vgl. Tafreshipour et al. 2024, S. 110

<sup>82</sup>Vgl. He, Huq, Malek 2025, S. 5–6; Vgl. World Wide Web Consortium (W3C) 2023, Erf.-krit. 2.4.3 & 4.1.3

<sup>83</sup>Vgl. Fernandes et al. 2012, S. 31

Interventionspunkt.<sup>84</sup> Ein konkretes Beispiel: Eine React-Komponente `IconButton` rendert im DOM ein `<button>`-Element mit einem `<svg>`-Icon, jedoch ohne sichtbaren Text und ohne `aria-label`. `axe-core` meldet den Verstoß *button-has-visible-text* mit dem HTML-Ausschnitt `<button class="btn-icon">...</button>` – ohne Hinweis darauf, dass die Ursache in der Datei `IconButton.tsx` liegt, wo das `aria-label`-Prop nicht weitergereicht wird.

3. Die Komponentenabstraktion erschwert die Ursachenanalyse: Eine wiederverwendbare Komponente mit einem Accessibility-Problem manifestiert sich im gerenderten DOM an jeder Stelle, an der sie eingesetzt wird. Accessibility-Tool-Reports melden jeden einzelnen Treffer separat, ohne den Bezug zur gemeinsamen Quellkomponente herzustellen, deren einmalige Korrektur alle Treffer beseitigen würde.<sup>85</sup>

### 2.3.3 Playwright als Testautomatisierungswerkzeug

Um diese dynamischen Zustände automatisiert reproduzierbar testen zu können, werden Werkzeuge zur Browserautomatisierung benötigt.

Playwright ist ein von Microsoft entwickeltes Open-Source-Framework für die End-to-End-Testautomatisierung von Webanwendungen.<sup>86</sup> Es ermöglicht die automatisierte Steuerung von Chromium, Firefox und WebKit über eine einheitliche Application Programming Interface (API) und führt Anwendungen in einem echten Browser-Kontext aus, sodass JavaScript-Ausführung, clientseitiges Rendering und dynamische DOM-Manipulationen vollständig nachgebildet werden.

Für die Barrierefreiheitsanalyse ist Playwright aus mehreren Gründen besonders geeignet:

1. Durch programmierte Interaktionen – Klicks, Formularausfüllungen, Tastatureingaben, Hover-Aktionen – können gezielt verschiedene Anwendungszustände ausgelöst werden.<sup>87</sup>
2. Mit `@axe-core/playwright` bietet Playwright eine direkte Integration der `axe-core`-Bibliothek: Nach jeder Interaktion kann unmittelbar eine vollständige `axe`-Prüfung des aktuellen DOM-Zustands angestoßen werden.<sup>88</sup>

Verschiedene Forschungsarbeiten nutzen diese Integration bereits erfolgreich für die Barrierefreiheitsanalyse dynamischer Webanwendungen (vgl. Kapitel 3). In der vorliegenden Arbeit dient Playwright als zentrales Werkzeug der Detection-Phase: Es löst definierte Interaktionssequenzen aus, erfasst die resultierenden DOM-Zustände und stößt `axe-core`-Prüfungen an, deren strukturierter JSON-Output als erster Input für die LLM-Analysepipeline dient.

---

<sup>84</sup>Vgl. Fathallah, Hernández, Staab 2025

<sup>85</sup>Vgl. Abou-Zahra, Brewer, Cooper 2018

<sup>86</sup>Vgl. Microsoft 2026

<sup>87</sup>Vgl. Microsoft 2026

<sup>88</sup>Vgl. Deque Systems 2026



## 2.4 KI-Assistenzsysteme für Softwareanalyse und Handlungsempfehlungen

Innerhalb der KI-Forschung haben sich LLMs als leistungsfähige Klasse von Systemen für sprachbasierte Aufgaben etabliert.<sup>89</sup> Für die vorliegende Arbeit sind sie relevant, weil sie sowohl Code verstehen als auch natürlichsprachige Handlungsempfehlungen generieren können.

### 2.4.1 Grundlagen: Large Language Models

LLMs sind neuronale Netzwerke, die auf extrem großen Datensätzen mit dem Ziel trainiert werden, das nächste Token einer Textsequenz vorherzusagen.<sup>90</sup> Die zugrunde liegende Architektur ist der Transformer, der ausschließlich auf Attention-Mechanismen basiert und rekurrente sowie konvolutionale Netze in der Sequenzmodellierung ablöst.<sup>91</sup> Auf dieser Trainingsbasis entstehen Modelle, die komplexe Sprachstrukturen, semantische Zusammenhänge und Formen logischen Schlussfolgerns abbilden.

Zu den bekanntesten Modellfamilien zählen GPT-4o (OpenAI), Claude (Anthropic) und LLaMA (Meta).<sup>92</sup> Für den Anwendungskontext dieser Arbeit sind insbesondere Fähigkeiten relevant, die in der Literatur ab einer bestimmten Modellgröße beobachtet werden – darunter Code-Generierung, kontextuelles Schlussfolgern und Aufgabenverständnis.<sup>93</sup>

Im Kontext der Barrierefreiheitsanalyse bieten LLMs gegenüber regelbasierten Tools wesentliche Vorteile.<sup>94</sup> Sie verfügen über ein Sprachverständnis, das die Bewertung semantischer Inhalte ermöglicht – etwa ob ein Alternativtext den Bildinhalt angemessen beschreibt oder eine Schaltflächenbeschriftung für Screenreader-Nutzende aussagekräftig ist.<sup>95</sup> Darüber hinaus können sie Code generieren und transformieren<sup>96</sup> sowie heterogene Eingaben – strukturierte Tool-Reports, Quellcode und natürlichsprachige Anweisungen – in einer gemeinsamen Anfrage verarbeiten und daraus entwicklernahe Handlungsempfehlungen formulieren.<sup>97</sup>

Diesen Stärken stehen bekannte Schwächen gegenüber. Besonders kritisch sind *Halluzinationen*: Das Modell kann inhaltlich plausible, aber faktisch fehlerhafte Empfehlungen generieren, ohne dies anzuzeigen.<sup>98</sup> Hinzu kommen Wissensgrenzen durch den *Knowledge-Cutoff* – neuere WCAG-Kriterien könnten dem Modell unbekannt sein<sup>99</sup> – sowie *Nicht-Determinismus* und mögliche *Bias-Effekte*.<sup>100</sup> Der Nicht-Determinismus lässt sich über den Parameter `temperature`

---

<sup>89</sup>Vgl. Russell, Norvig 2021, S. 22

<sup>90</sup>Vgl. Brynjolfsson, Li, Raymond 2025, S. 5–6; Vgl. Jurafsky, Martin 2026, S. 146–148

<sup>91</sup>Vgl. Jurafsky, Martin 2026, S. 173–174; Vgl. Vaswani et al. 2023

<sup>92</sup>Vgl. Anthropic 2026a; OpenAI 2023; Touvron et al. 2023

<sup>93</sup>Vgl. Wei, Tay et al. 2022, S. 2

<sup>94</sup>Vgl. Fathallah, Hernández, Staab 2025

<sup>95</sup>Vgl. Tafreshipour et al. 2024

<sup>96</sup>Vgl. Touvron et al. 2023, S. 3

<sup>97</sup>Vgl. Bassi et al. 2025, S. 298

<sup>98</sup>Vgl. Huang, L. et al. 2025, 1:2

<sup>99</sup>Vgl. Anthropic 2026b, S. 7; Huang, L. et al. 2025, 1:9–10

<sup>100</sup>Vgl. OpenAI 2026; Vgl. Anthropic 2026a; Vgl. Bender et al. 2021, S. 614–615

regulieren: Niedrige Werte (nahe 0) erhöhen die Ausgabe-Stabilität; höhere Werte fördern kreativere, aber weniger reproduzierbare Ausgaben. Eine weitere praktische Einschränkung bildet die *Kontextfensterbegrenzung*: Bei der gleichzeitigen Verarbeitung umfangreicher Tool-Reports, Playwright-Daten und Quellcode kann relevanter Kontext das verfügbare Kontextfenster überschreiten, was die Vollständigkeit der Analyse beeinträchtigen kann.<sup>101</sup>

Eine zentrale Frage der vorliegenden Arbeit ist, ob diese Fähigkeiten auch bei kleineren, lokal ausführbaren Modellen in ausreichendem Maße vorhanden sind. Alle in Kapitel 3 untersuchten Systeme – AccessGuru, GenA11y, ACCESS – setzen GPT-4o ein, ein Modell mit geschätzt über 200 Milliarden Parametern und Zugang zu umfangreichen Cloud-Ressourcen.<sup>102</sup> Lokal ausführbare Modelle der 7B-Klasse verfügen über deutlich weniger Parameter und damit potenziell über ein eingeschränkteres Sprachverständnis und schwächere Reasoning-Fähigkeiten. Ob ein solches Modell semantische Accessibility-Verstöße zuverlässig erkennen kann, ist empirisch bislang nicht belegt und wird in der vorliegenden Arbeit als explizite Forschungsfrage adressiert. Die Begründung der konkreten Modellauswahl erfolgt in Abschnitt 5.4.

### 2.4.2 Prompt-Engineering-Strategien

Die Qualität der Ausgaben eines LLM hängt maßgeblich von der Formulierung der Eingabe, also des sogenannten Prompts, ab. Prompt-Engineering bezeichnet die systematische Gestaltung dieser Eingaben, um die Ausgabequalität zu maximieren.<sup>103</sup> Im Folgenden werden die für diese Arbeit relevanten Strategien beschrieben, die in Kapitel 7 als Grundlage für das Prompt-Design des PoC dienen.

- **Zero-Shot Prompting** bezeichnet die direkte Anfrage ohne Beispiele oder Kontextinformationen. Das Modell nutzt ausschließlich sein vortrainiertes Wissen. Diese Strategie ist einfach umzusetzen, erzielt bei komplexen Aufgaben wie der Barrierefreiheitsanalyse jedoch häufig unzureichende Ergebnisse.<sup>104</sup>
- **Few-Shot Prompting** ergänzt den Prompt um eine kleine Anzahl von Beispielen (Input-Output-Paaren), die dem Modell das erwartete Ausgabeformat und die inhaltlichen Erwartungen verdeutlichen. Dieser Ansatz verbessert die Konsistenz und Präzision der Ausgaben erheblich, erfordert jedoch sorgfältig ausgewählte Beispiele.<sup>105</sup> Abbildung 3 vergleicht Zero-Shot- und Few-Shot-Prompting.
- **Chain-of-Thought Prompting (CoT)** veranlasst das Modell, seinen Lösungsweg Schritt für Schritt zu erklären, bevor es zur finalen Antwort gelangt. Dieses explizite Reasoning reduziert nachweislich Halluzinationen bei komplexen Schlussfolgerungen.<sup>106</sup>

---

<sup>101</sup>Vgl. Jurafsky, Martin 2026, S. 146–148

<sup>102</sup>Vgl. Fathallah, Hernández, Staab 2025; Vgl. He, Huq, Malek 2025, FSE101:10; Vgl. Huang, C. et al. 2024, S. 7

<sup>103</sup>Vgl. Schulhoff et al. 2024, S. 4

<sup>104</sup>Vgl. Brown et al. 2020, S. 4; Vgl. Njifenjou et al. 2024

<sup>105</sup>Vgl. Brown et al. 2020, S. 5

<sup>106</sup>Vgl. Wei, Wang, X. et al. 2022, S. 2; Fathallah, Hernández, Staab 2025

- **ReAct-Prompting** kombiniert Reasoning (Re) und Action (Act) iterativ: Das Modell wechselt zwischen Denk- und Handlungsschritten, etwa durch das Einbeziehen von Tools und Zwischenergebnissen. Huang et al. demonstrieren, dass ReAct-Prompting bei der automatisierten Barrierefreiheitskorrektur (**ACCESS**) mit einem Severity Score Reduction von 51,3% alle anderen verglichenen Strategien übertrifft.<sup>107</sup>
- **Role-Play Prompting** weist dem Modell eine Expertenrolle zu, die seine Ausgaben in Richtung domänenspezifischen Wissens lenkt. Ein Prompt, der dem Modell die Rolle eines „erfahrenen Barrierefreiheitsexperten und React-Entwicklers“ zuweist, verbessert nachweislich die Qualität accessibility-spezifischer Ausgaben.<sup>108</sup>
- **Metacognitive Prompting** fordert das Modell auf, die eigene Ausgabe in einem zweiten Schritt zu reflektieren und zu bewerten, bevor diese finalisiert wird.<sup>109</sup> In Verbindung mit Corrective Re-Prompting – einer Technik, bei der fehlerhafte Ausgaben dem Modell mit einer Fehlerbeschreibung zurückgespielt werden – ermöglicht dieser Ansatz eine iterative Qualitätssteigerung. Fathallah et al. belegen, dass Corrective Re-Prompting in **Access-Guru** den Violation Score Decrease von 0,72 auf 0,84 verbessert.<sup>110</sup>




Abb. 3: Zero-Shot und Few-Shot Prompting im Vergleich.<sup>111</sup>

### 2.4.3 RAG und Fine-Tuning als Erweiterungsansätze

**Retrieval-Augmented Generation (RAG)** erweitert den Prompt zur Laufzeit mit thematisch passenden Dokumenten aus einer externen Wissensbasis und könnte im Accessibility-Kontext aktuelle WCAG-Kriterien unabhängig vom Trainings-Cutoff abrufbar machen.<sup>112</sup>

<sup>107</sup>Vgl. Huang, C. et al. 2024, S. 5; Yao et al. 2022, S. 1

<sup>108</sup>Vgl. Fathallah, Hernández, Staab 2025; Njifenjou et al. 2024; Schulhoff et al. 2024, S. 6, 12

<sup>109</sup>Vgl. Wang, Y., Zhao 2024; Schulhoff et al. 2024, S. 8–9

<sup>110</sup>Vgl. Fathallah, Hernández, Staab 2025

<sup>111</sup>Entnommen aus Brown et al. 2020.

<sup>112</sup>Vgl. Lewis et al. 2020, S. 1–2

**Fine-Tuning** bezeichnet das domänenspezifische Training auf einem aufgabenspezifischen Datensatz; für den Kontext der BITBW wäre insbesondere ein Fine-Tuning auf BITV-spezifischen Anforderungen denkbar.<sup>113</sup> Beide Ansätze liegen außerhalb des Untersuchungsumfangs dieser Arbeit und werden im Ausblick (Abschnitt 9.3) aufgegriffen.

### 2.4.4 Datenschutz bei KI-gestützten Accessibility-Services

Der Einsatz von LLMs im Kontext öffentlicher Verwaltungen wirft spezifische Datenschutzfragen auf. Webanwendungen der öffentlichen Verwaltung verarbeiten häufig personenbezogene Daten – etwa in Formularseiten, die persönliche Angaben von Bürgerinnen und Bürgern erfassen. Werden diese Seiten für eine KI-gestützte Accessibility-Analyse an externe LLM-APIs übermittelt, ist die Wahrung der Datenschutzgarantien fraglich.

Die Datenschutz-Grundverordnung (DSGVO) schreibt vor, dass personenbezogene Daten nur auf Basis einer Rechtsgrundlage und unter Wahrung der Grundsätze der Zweckbindung und Datenminimierung verarbeitet werden dürfen.<sup>114</sup> Die Übermittlung von HTML-Quellcode der produktiven Anwendung, der im schlimmsten Fall personenbezogene Daten als Attributwerte enthalten kann, an externe API-Dienste wie die OpenAI API oder die Anthropic API ist ohne explizite Rechtsgrundlage und einen Auftragsverarbeitungsvertrag nach Art. 28 DSGVO für öffentliche Verwaltungen in Deutschland problematisch.<sup>115</sup>

Als Lösungsansatz wird in dieser Arbeit ein Lokal-First-Prinzip verfolgt: Das KI-Assistenzsystem soll ohne externe API-Aufrufe betreibbar sein, indem lokal ausführbare Open-Source-Modelle – etwa Modelle der LLaMA-Familie oder Mistral – eingesetzt werden.<sup>116</sup> Damit bleiben sämtliche Analyse- und Codedaten innerhalb der eigenen Infrastruktur. Diese Anforderung prägt sowohl die nicht-funktionalen Anforderungen in Kapitel 5 als auch die Architekturentscheidungen in Kapitel 7.

Die in diesem Kapitel erarbeiteten theoretischen Grundlagen – das normative Fundament der WCAG, die empirisch belegten Grenzen regelbasierter Tools, die Besonderheiten von React-Anwendungen sowie die Möglichkeiten und Grenzen von LLMs und des Prompt Engineerings – bilden den konzeptionellen Rahmen für den im folgenden Kapitel dargestellten Forschungsstand sowie für die anschließende Methodik.

---

<sup>113</sup>Vgl. Silvestre, Pietzuch 2025, S. 90

<sup>114</sup>Vgl. Europäisches Parlament und Rat der Europäischen Union 2016

<sup>115</sup>Vgl. Europäisches Parlament und Rat der Europäischen Union 2016, Art. 28

<sup>116</sup>Vgl. Touvron et al. 2023

## 3 Stand der Forschung

Dieses Kapitel gibt einen thematisch strukturierten Überblick über den Forschungsstand zur KI-gestützten Barrierefreiheitsanalyse. Ausgehend davon werden die für diese Arbeit relevanten Forschungslücken herausgearbeitet. Die untersuchten Arbeiten lassen sich drei Entwicklungslinien zuordnen:

1. LLM-basierte Erkennung von Accessibility-Verstößen,
2. LLM-basierte Korrektur und Code-Generierung sowie
3. hybride Pipelines, die regelbasierte Tools mit LLM-Analyse kombinieren.

### 3.1 Vorgehen der Literaturrecherche

Zur Einordnung des Forschungsstands wurde eine strukturierte Literaturrecherche in wissenschaftlichen Repositorien und Datenbanken durchgeführt (u. a. ACM Digital Library, IEEE Xplore, ScienceDirect und arXiv).<sup>117</sup> Die Recherche erfolgte themenorientiert auf Basis von Suchbegriffen wie „web accessibility“, „LLM accessibility“, „accessibility violation detection“ und „axe-core“. Berücksichtigt wurden primär aktuelle Arbeiten mit Bezug zur automatisierten Erkennung oder Behebung von Barrierefreiheitsverstößen in Webanwendungen mit KI-Assistenzsystemen. Die identifizierten Arbeiten wurden thematisch gruppiert, priorisiert und abschließend vergleichend ausgewertet.

### 3.2 Von frühen KI-Ansätzen zur LLM-basierten Erkennung

Eine der frühen Arbeiten in diesem Kontext stammt von Delnevo et al. (2024). Die Autoren zeigen, dass GPT-3.5 einfache syntaktische Verstöße mit moderater Genauigkeit erkennt, bei semantischen Problemen jedoch inkonsistente Bewertungen liefert.<sup>118</sup> Bassi et al. (2025) vergleichen GPT-4o, GPT-3.5 und LLaMA 3.1 in einer zweistufigen Evaluation. GPT-4o identifiziert dabei 74% der Verstöße korrekt, während 15% der Befunde als Halluzinationen eingestuft werden.<sup>119</sup> Eine nachgelagerte Chain-of-Verification-Stufe erhöht die Zuverlässigkeit deutlich; RAG wird nur als zukünftige Erweiterung diskutiert.<sup>120</sup>

---

<sup>117</sup>Vgl. Webster, Watson 2002

<sup>118</sup>Vgl. Delnevo, Andruccioli, Mirri 2024

<sup>119</sup>Vgl. Bassi et al. 2025, S. 302

<sup>120</sup>Vgl. Bassi et al. 2025, S. 301

### 3.3 LLM-basierte Korrektur und Prompt-Engineering

Abu Doush und Kassem (2024) zeigen, dass strukturierte Prompts die Qualität LLM-generierter barrierefreier HTML-Alternativen deutlich verbessern, bei komplexen Interaktionsmustern jedoch weiterhin Schwächen bestehen.<sup>121</sup> Guriță und Vatavu (2025) zeigen, dass accessibility-orientierte Prompts paradoxerweise zunächst mehr Violations erzeugen können als neutrale Formulierungen – erst iteratives Prompting über fünf Runden senkte den Violation Score von 0,84 auf 0,32.<sup>122</sup>

Einen zentralen Referenzpunkt des aktuellen Forschungsstands bildet **AccessGuru** von Fathallah et al. (2025).<sup>123</sup> Das System kombiniert eine zweistufige Pipeline: zunächst regelbasierte Detection via Playwright und **axe-core**, anschließend eine LLM-basierte Korrektur durch GPT-4o mit Role-Play-, Contextual- und Metacognitive-Prompting. Corrective Re-Prompting verbessert den Violation Score Decrease<sup>124</sup> von 0,72 auf 0,84 bei einer semantischen Ähnlichkeit von 77% zu menschlichen Referenzlösungen. Als offenes Problem benennen die Autoren die fehlende Verknüpfung korrigierter HTML-Snippets mit dem Quellcode der geprüften Anwendung.

Fernández-Navarro und Chicano (2026) erweitern diesen Ansatz um eine direkte Quellcode-Korrektur und adressieren damit explizit die Lücke zwischen DOM-Korrektur und entwicklerseitiger Umsetzung.<sup>125</sup> Ihr Tool injiziert Korrekturen auf Basis einer Quellcodeanalyse gezielt in tatsächliche Komponentendateien und erreicht in der Evaluation auf öffentlichen Websites und Open-Source-Angular-Projekten Remediation Rates<sup>126</sup> von über 80% bei vollständiger Build-Integrität. Der Ansatz beschränkt sich jedoch auf Angular und setzt auf cloudbasiertes GPT-4o; eine Übertragung auf React wird von den Autoren als kurzfristiger Folgeschritt benannt.<sup>127</sup>

### 3.4 Hybride Pipelines und Ensemble-Testing

Huang et al. entwickeln 2024 mit **ACCESS** ein System, das Prompt-Engineering gezielt zur automatisierten Barrierefreiheitskorrektur einsetzt und dabei verschiedene Strategien systematisch vergleicht.<sup>128</sup> Der Vergleich von ReAct, Chain-of-Thought und Few-Shot Prompting zeigt, dass ReAct mit einem Severity Score Reduction<sup>129</sup> von 51,3% alle anderen Strategien übertrifft – ein Ergebnis, das die Bedeutung iterativer, werkzeuggestützter Reasoning-Strategien für diese Aufgabenklasse unterstreicht.

---

<sup>121</sup>Vgl. Doush, Kassem 2025, S. 343

<sup>122</sup>Vgl. Guriță, Vatavu 2025, S. 1000

<sup>123</sup>Vgl. Fathallah, Hernández, Staab 2025

<sup>124</sup>Der *Violation Score Decrease* gibt an, um welchen Anteil die gewichtete Gesamtanzahl der Violations durch das System reduziert werden konnte (Wert zwischen 0 und 1).

<sup>125</sup>Vgl. Fernández-Navarro, Chicano 2026

<sup>126</sup>*Remediation Rate*: Anteil der Violations, die durch das System erfolgreich behoben wurden.

<sup>127</sup>Vgl. Fernández-Navarro, Chicano 2026

<sup>128</sup>Vgl. Huang, C. et al. 2024, S. 7, 9

<sup>129</sup>*Severity Score Reduction*: prozentualer Rückgang des gewichteten Schweregradwerts aller Violations gegenüber dem Ausgangszustand.

He et al. präsentieren 2025 mit **GenA11y** eines der methodisch ausgefeiltesten Detection-Systeme des aktuellen Forschungsstands.<sup>130</sup> **GenA11y** extrahiert nach vollständigem clientseitigem Rendering den DOM via Playwright und prüft ihn anschließend kriteriumsspezifisch mit GPT-4o. Eine Ablation Study belegt, dass weder DOM-Extraktion noch optimiertes Prompting allein die Gesamtleistung von Precision 94,5% und Recall 87,61% erreichen.<sup>131</sup> **GenA11y** erkennt acht Verstoßtypen, die von keinem der verglichenen regelbasierten Tools gefunden werden.<sup>132</sup> Paternò et al. ergänzen dieses Bild mit **TeVal**, das semantische WCAG-Kriterien durch Role-Play Prompting mit Few-Shot-Beispielen und Confidence Score bewertet und dabei eine Effektivität von 92,4% erzielt.<sup>133</sup>

Pool (2023) adressiert die Detection-Schicht mit **Testaro**, einem Ensemble aus acht Accessibility-Werkzeugen (u. a. axe-core, WAVE, QualWeb); die Analyse zeigt, dass jedes Tool exklusive Violations erkennt und die Werkzeuge damit komplementär wirken.<sup>134</sup>

## 3.5 Forschungslücken und Einordnung der vorliegenden Arbeit

Die Analyse der bestehenden Forschungsarbeiten zeigt drei persistente Forschungslücken, die den Ausgangspunkt der vorliegenden Arbeit bilden.

1. Keiner der untersuchten Ansätze berücksichtigt zustandsabhängige Barrieren systematisch, die erst durch Nutzerinteraktionen in React-basierten Single-Page Applications entstehen.<sup>135</sup> Zwar setzen einzelne Systeme wie **AccessGuru** Playwright zur DOM-Extraktion ein, jedoch beschränkt sich dies auf das initiale Rendering – interaktionsbedingte Zustandswechsel werden nicht geprüft.<sup>136</sup>
2. Keiner der analysierten Ansätze verknüpft Tool-Reports systematisch mit dem Quellcode der geprüften Anwendung. **AccessGuru** selbst benennt dies als offenes Problem: die generierten Korrekturen beziehen sich auf isolierte DOM-Snippets und nicht auf die JSX-Komponenten, in denen Entwicklerinnen und Entwickler tatsächlich eingreifen müssten.<sup>137</sup> Die Lücke zwischen technischer Fehlererkennung und entwicklernaher Umsetzung bleibt damit bestehen.
3. Keine der untersuchten Arbeiten adressiert explizit die datenschutzrechtlichen Anforderungen öffentlicher Verwaltungen: alle Systeme setzen auf cloubasierte LLM-APIs (primär GPT-4o), was für die BITBW und vergleichbare Institutionen ohne vertiefte datenschutzrechtliche Prüfung nicht nutzbar ist.<sup>138</sup>

---

<sup>130</sup> Vgl. He, Huq, Malek 2025, FSE101:20–21

<sup>131</sup> Vgl. He, Huq, Malek 2025, FSE101:20

<sup>132</sup> Vgl. He, Huq, Malek 2025, FSE101:20

<sup>133</sup> Vgl. Paternò et al. 2025

<sup>134</sup> Vgl. Pool 2023

<sup>135</sup> Vgl. Tafreshipour et al. 2024, S. 110

<sup>136</sup> Vgl. Fathallah, Hernández, Staab 2025

<sup>137</sup> Vgl. Fathallah, Hernández, Staab 2025

<sup>138</sup> Vgl. Europäisches Parlament und Rat der Europäischen Union 2016, Art. 28, 44 ff.

Die Konzeptmatrix in Tabelle 2 fasst die zentralen Merkmale der untersuchten Studien im Vergleich zum eigenen PoC zusammen und macht die identifizierten Forschungslücken strukturell sichtbar.

| Studie                             |                                          | Konzepte          |                       |                         |                         |                                |                   |                |                       |                  |                      |                   |              |                   |                            |
|------------------------------------|------------------------------------------|-------------------|-----------------------|-------------------------|-------------------------|--------------------------------|-------------------|----------------|-----------------------|------------------|----------------------|-------------------|--------------|-------------------|----------------------------|
| Autor(en)<br>& Jahr                | System                                   | Ziel              |                       |                         | Datenquellen            |                                |                   | KI-/LLM-Ansatz |                       |                  | Evaluation           |                   |              | Kontext           |                            |
|                                    |                                          | WCAG-Konf. prüfen | Barrieren korrigieren | Entwickler unterstützen | Tool-Reports (axe etc.) | Interaktionsdaten (Playwright) | Quellcode-Analyse | LLM-basiert    | Kontextsensitiv / RAG | Lokal ausführbar | Automatisierte Eval. | Qualitative Eval. | Nutzerstudie | Rich-Client / SPA | Rechtl. Rahmen (BFSG etc.) |
| Hoch priorisierte Studien          |                                          |                   |                       |                         |                         |                                |                   |                |                       |                  |                      |                   |              |                   |                            |
| He et al. (2025)                   | GenA11y                                  | x                 |                       |                         | x                       |                                |                   | x              |                       |                  | x                    |                   |              |                   |                            |
| Fathallah et al. (2025)            | AccessGuru                               | x                 | x                     | x                       | x                       | x                              |                   | x              |                       |                  | x                    |                   |              |                   |                            |
| Bassi et al. (2025)                | LLM Auditing                             | x                 | x                     | x                       |                         |                                |                   | x              |                       |                  |                      | x                 |              | x                 |                            |
| Paternò et al. (2025)              | TeVal                                    | x                 |                       | x                       | x                       |                                |                   | x              | x                     |                  |                      | x                 |              |                   |                            |
| Tafreshipour et al. (2024)         | Ma11y                                    | x                 |                       |                         | x                       | x                              |                   |                |                       |                  | x                    |                   |              |                   |                            |
| Fernández-Navarro & Chicano (2026) | LLM Remediation                          | x                 | x                     | x                       | x                       |                                | x                 | x              |                       |                  | x                    |                   |              | x                 |                            |
| Eigener Proof of Concept           |                                          |                   |                       |                         |                         |                                |                   |                |                       |                  |                      |                   |              |                   |                            |
| Martinez Campo (2026)              | Accessibility Context Engine (ACE) (PoC) | x                 | x                     | x                       | x                       | x                              | x                 | x              | x                     | x                | x                    | x                 |              | x                 |                            |

Tab. 2: Konzeptmatrix nach Webster Watson<sup>139</sup>: hoch priorisierte Studien im Vergleich zum eigenen Proof of Concept (PoC). **x** = Konzept vorhanden/adressiert; leer = nicht adressiert. Für den eigenen PoC bezeichnen die Markierungen angestrebte Designziele, deren Umsetzung und Wirksamkeit in Kapitel 8 evaluiert wird. Die vollständige Matrix aller analysierten Studien findet sich in Anhang 3.

<sup>139</sup>Vgl. Webster, Watson 2002.



## 4 Methodik

Dieses Kapitel beschreibt das methodische Vorgehen der Arbeit. Zunächst wird die gewählte Forschungsmethode begründet (Abschnitt 4.1), anschließend der Untersuchungsgegenstand abgegrenzt (Abschnitt 4.2) und schließlich das Evaluationsdesign mit den zugehörigen Bewertungskriterien definiert (Abschnitt 4.3).

### 4.1 Wissenschaftliche Methode

Die vorliegende Arbeit folgt dem Forschungsparadigma des Design Science Research (DSR), das von Hevner et al. für die Wirtschaftsinformatik systematisiert wurde.<sup>140</sup> DSR eignet sich für diese Arbeit aus zwei Gründen:

1. Die Konstruktion eines konkreten technischen Artefakts steht im Zentrum der Forschungsfrage, nicht die Überprüfung einer statistischen Hypothese.
2. DSR fordert explizit die Evaluation des Artefakts in einem realen Anwendungskontext, was dem praxisorientierten Charakter der Arbeit entspricht.<sup>141</sup>

Alternative Ansätze wie Action Research oder kontrollierte Experimente wurden verworfen: Action Research setzt eine längerfristige Praktikerzusammenarbeit voraus, während kontrollierte Experimente eine Stichprobenbasis erfordern, die im Verwaltungskontext nicht verfügbar ist.<sup>142</sup>

Als prozessualer Rahmen dient das sechshebige DSRM-Prozessmodell nach Peffers et al.<sup>143</sup> Die Zuordnung der einzelnen Phasen zu den Kapiteln dieser Arbeit zeigt Tabelle 3.

| DSRM-Phase             | Kapitel                           |
|------------------------|-----------------------------------|
| Problem-Identifikation | Kapitel 1-3                       |
| Zieldefinition         | Kapitel 1.3 & 3.5                 |
| Design & Entwicklung   | Kapitel 5-7                       |
| Demonstration          | Kapitel 7 (insb. Beispielabläufe) |
| Evaluation             | Kapitel 8                         |
| Kommunikation          | Gesamtarbeit; Kap. 9              |

Tab. 3: Zuordnung der DSRM-Phasen zu den Kapiteln der Arbeit.

Ergänzt wird dieser methodische Rahmen durch einen Fallstudienansatz nach Yin.<sup>144</sup> Der BWEC dient als Einzelfallstudie, da die Forschungsfrage auf ein zeitgenössisches Phänomen in einem spezifischen Praxiskontext abzielt und die Grenzen zwischen technischem System und organisatorischem Kontext nicht trennscharf sind.

<sup>140</sup>Vgl. Hevner, A. R. et al. 2004

<sup>141</sup>Vgl. Hevner, A. R. et al. 2004, S. 80

<sup>142</sup>Vgl. Baskerville, R. L. 1999, S. 1–2; Vgl. Baskerville, R., Myers 2004, S. 239–335

<sup>143</sup>Vgl. Peffers et al. 2007

<sup>144</sup>Vgl. Yin 2018

Die Wahl eines PoC als Artefakttyp ist durch den explorativen Charakter der Forschungsfrage begründet: Das Ziel ist die konzeptionelle Demonstration der technischen Machbarkeit, nicht die statistisch belastbare Generalisierung auf eine Grundgesamtheit.<sup>145</sup>

### 4.2 Untersuchungsgegenstand und Anwendungsbereich

Als Praxisrahmen und Motivationskontext dient der BWEC, eine öffentlich zugängliche React-basierte Webanwendung der BITBW.<sup>146</sup> Er vereint drei für die Forschungsfrage zentrale Merkmale: gesetzlich relevante Anforderungen an digitale Barrierefreiheit, einen datenschutzsensiblen Einsatzkontext in der öffentlichen Verwaltung sowie typische Interaktionsmuster moderner Single-Page Applications. Die formale Hauptevaluation erfolgt jedoch an synthetisch konstruierten Testsuiten (test-12, test-50, test-100) mit vollständig bekannter Ground Truth.<sup>147</sup> Der BWEC wird ergänzend als Feldtest ohne quantitativen Ground-Truth-Vergleich eingesetzt (vgl. Abschnitt 8.7.3).

Der Untersuchungsbereich ist wie folgt abgegrenzt:

- **Eingeschlossen:** Öffentlich zugängliche Bereiche der Anwendung ohne Authentifizierung. Betrachtet werden WCAG 2.2-Verstöße auf Konformitätsstufe A und AA, soweit sie durch regelbasierte Prüfung, DOM-Analyse und Interaktionsausführung im Frontend beobachtbar sind.<sup>148</sup>
- **Ausgeschlossen:** Backend-Logik, Datenbankstrukturen sowie eine vollständige rechtliche Bewertung im Sinne einer formalen BITV-Prüfung.<sup>149</sup>

Die Einschränkungen hinsichtlich vollständiger WCAG-Abdeckung und Generalisierbarkeit auf beliebige Frameworks werden in Kapitel 8 als Limitationen diskutiert.

### 4.3 Evaluationsdesign und Kriterien

Ziel der Evaluation ist es, die technische Machbarkeit und den praktischen Nutzen des entwickelten PoC anhand synthetisch konstruierter Testsuiten mit vollständig bekannter Ground Truth zu untersuchen. Der BWEC dient ergänzend als Feldtest-Kontext ohne quantitativen Recall-Vergleich (vgl. Abschnitt 8.7.3).

---

<sup>145</sup>Vgl. Hevner, A. R. et al. 2004

<sup>146</sup>Vgl. Land Baden-Württemberg 2025

<sup>147</sup>Als *Ground Truth* (dt. Referenzwahrheit) bezeichnet man die vorab definierte, gesichert korrekte Lösung, anhand derer die Ausgaben eines Systems gemessen werden. Im vorliegenden Kontext umfasst sie die Gesamtmenge der absichtlich in die Testsuite eingebetteten WCAG-Violations.

<sup>148</sup>Vgl. World Wide Web Consortium (W3C) 2023

<sup>149</sup>Vgl. Bundesministerium für Digitales und Staatsmodernisierung 2025

### 4.3.1 Evaluationslogik

Die Evaluation folgt einem fünfstufigen Vorgehen:

1. **Testsuite-Konstruktion:** Drei synthetische React-SPAs werden mit gezielt eingebetteten WCAG-Violations entwickelt (test-12: 12, test-50: 50, test-100: 100 Violations), die alle drei Verstoßkategorien der in Abschnitt 2.2.3 eingeführten Taxonomie abdecken.<sup>150</sup>
2. **Benchmarkläufe:** Jede Suite wird mit drei Modellen jeweils zehnmal analysiert (insgesamt 90 Testläufe). Pro Lauf werden Recall, Priorisierungsverhalten, Fix-Qualität und Laufzeit erfasst.
3. **Recall-Auswertung:** Die Ergebnisse werden mit der bekannten Ground Truth verglichen. Eine Violation gilt als erkannt, wenn sie in der Mehrzahl der zehn Testläufe im finalen LLM-Report erscheint.
4. **Qualitative Empfehlungsbewertung:** Die generierten Handlungsempfehlungen werden anhand einer dreistufigen Bewertungsskala (Stufe 0–2) nach Dateikonkretheit und Code-Fix-Qualität bewertet.
5. **BWEC-Feldtest:** Die Pipeline wird ergänzend auf dem realen BWEC-Untersuchungsobjekt eingesetzt, um Systemstabilität und qualitative Plausibilität unter realen Bedingungen zu prüfen.<sup>151</sup>

### 4.3.2 Bewertungskriterien

Die Evaluation erfolgt anhand von vier Kriterien, die aus den Forschungsfragen und der Fachliteratur abgeleitet wurden.

**Kriterium 1 – Korrektheit der Erkennung:** Die vom System identifizierten Verstöße werden mit der bekannten Ground Truth der synthetischen Testsuiten verglichen. Als Orientierungswerte dienen die Ergebnisse vergleichbarer Systeme, insbesondere **GenA11y** erreicht eine Precision von 94,5% und einen Recall von 87,61%.<sup>152</sup>

**Kriterium 2 – Qualität der Handlungsempfehlungen:** Die generierten Empfehlungen werden anhand einer dreistufigen Skala (Stufe 0–2) qualitativ bewertet: Stufe 2 bezeichnet einen konkreten Fix mit Dateiname, Zeilennummer und umsetzbarem Code-Vorschlag; Stufe 1 einen zutreffenden Fix-Typ ohne Quellcode-Kontext; Stufe 0 eine generische Problembeschreibung. **AccessGuru** erreicht als Referenzwert einen Violation Score Decrease von 84%.<sup>153</sup>

**Kriterium 3 – Mehrwert der Kontextualisierung:** Der Zusatznutzen der vollständigen Kontextkombination wird durch den systematischen Vergleich zweier Konfigurationen ermittelt:

---

<sup>150</sup>Vgl. World Wide Web Consortium (W3C) 2023

<sup>151</sup>Vgl. Deque Systems 2026; Vgl. Kodithuwakku, Wickramarachchi 2025

<sup>152</sup>Vgl. He, Huq, Malek 2025, FSE101:20

<sup>153</sup>Vgl. Fathallah, Hernández, Staab 2025

(a) die reine Tool-Baseline (axe-core, Playwright, grep ohne LLM-Kontextualisierung) und (b) die vollständige Pipeline (Baseline + LLM-gestützte Quellcodeanalyse). Verglichen werden Recall, Fix-Qualität sowie die Fähigkeit, datei- und zeilenspezifische Handlungsempfehlungen zu generieren.<sup>154</sup>

**Kriterium 4 – Technische Praktikabilität:** Laufzeit, Stabilität und Qualität des JSON-Outputs werden unter realen Bedingungen dokumentiert.

### 4.3.3 Limitationen des Evaluationsdesigns

Zwei methodische Einschränkungen des Evaluationsdesigns sind vorab zu benennen:

1. Die Bewertung wird durch den Autor selbst durchgeführt und nicht durch unabhängige Gutachter validiert.
2. Die genannten Referenzwerte von **AccessGuru**<sup>155</sup> und **GenA11y**<sup>156</sup> sind nur eingeschränkt vergleichbar, da sie auf anderen Datensätzen und unter anderen Rahmenbedingungen ermittelt wurden. Sie dienen daher als Orientierung, nicht als direkter Benchmark.

---

<sup>154</sup>Siehe Abschnitt 1.3.

<sup>155</sup>Vgl. Fathallah, Hernández, Staab 2025

<sup>156</sup>Vgl. He, Huq, Malek 2025

## 5 Analyse und Anforderungen

Dieses Kapitel erarbeitet die Grundlagen für das in Kapitel 6 beschriebene Systemdesign. Zunächst werden Problemkontext und Handlungsbedarf analysiert. Anschließend werden die funktionalen und nicht-funktionalen Anforderungen an das zu entwickelnde System spezifiziert. Abschließend wird die Auswahl der eingesetzten Inferenzinfrastruktur und der Modellkandidaten begründet.

### 5.1 Problemkontext und Handlungsbedarf

Wie in Kapitel 1 dargelegt, unterliegen alle von der BITBW entwickelten und betriebenen Webanwendungen den gesetzlichen Anforderungen der BITV 2.0, für die WCAG 2.2 auf Konformitätsstufe AA den verbindlichen Maßstab bildet.<sup>157</sup> In der Praxis erfolgt die Barrierefreiheitsprüfung bislang überwiegend manuell oder mithilfe einzelner regelbasierter Tools. Dieses Vorgehen ist aus zwei Gründen problematisch: Manuelle Audits sind personalintensiv und skalieren nur unzureichend mit der Anzahl zu betreuender Anwendungen; regelbasierte Tools erfassen, wie in Kapitel 2.2.1 dargelegt, nur einen Bruchteil der tatsächlich vorhandenen Barrieren.<sup>158</sup>

Die in Kapitel 3 identifizierten drei Forschungslücken bilden den Ausgangspunkt der Anforderungserhebung.<sup>159</sup> Dazu zählen die fehlende Zustandserfassung durch Interaktionen, die fehlende Verknüpfung von DOM-Befunden mit dem Quellcode sowie die Unvereinbarkeit cloudbasierter LLM-APIs mit den Datenschutzanforderungen öffentlicher Verwaltungen (vgl. Abschnitt 2.4.4). Daraus ergibt sich als Systemziel ein lokal ausführbares, LLM-gestütztes Assistenzsystem, das axe-core-Reports, Playwright-Interaktionsdaten und statische Quellcodeanalyse kombiniert (vgl. Abschnitt 1.3).<sup>160</sup>

### 5.2 Funktionale Anforderungen

Funktionale Anforderungen (FA) beschreiben die Leistungen, die ein System erbringen soll.<sup>161</sup> Die folgenden Anforderungen leiten sich aus der Problemanalyse (Abschnitt 5.1), den identifizierten Forschungslücken (Abschnitt 3.5) sowie der Analyse vergleichbarer Systeme aus der Literatur ab.

---

<sup>157</sup>Vgl. Bundesministerium für Digitales und Staatsmodernisierung 2025

<sup>158</sup>Vgl. Tafreshipour et al. 2024, S. 8–9

<sup>159</sup>Vgl. Hevner, A., Chatterjee 2010, S. 79; Vgl. Hevner, A., Chatterjee 2010, S. 9–11, 23–24

<sup>160</sup>Vgl. Hevner, A., Chatterjee 2010, S. 9–11, 23–24

<sup>161</sup>Vgl. Sommerville 2016, S. 105–107

### FA-01 Regelbasierte Accessibility-Erkennung

Das System muss den BVEC automatisiert auf Barrierefreiheitsverstöße gemäß WCAG 2.2 der Konformitätsstufen A und AA prüfen.<sup>162</sup> Die Prüfung basiert auf axe-core als Detection-Backend.<sup>163</sup> Der Output je Verstoß umfasst mindestens: Regel-ID, Schweregrad (critical/serious/moderate/minor) sowie ein HTML-Ausschnitt des betroffenen Elements.

### FA-02 Dynamische Zustandserfassung via Playwright

Das System muss mit Playwright definierte Interaktionssequenzen ausführen und zustandsabhängige Barrieren durch generische Interaktionschecks erfassen.<sup>164</sup> Damit werden Barrieren erfasst, die im initialen Seitenzustand nicht vorhanden sind.<sup>165</sup>

### FA-03 Statische Quellcodeanalyse

Das System muss den Quellcode der geprüften React-Anwendung automatisiert auf Muster untersuchen, die auf Barrierefreiheitsprobleme hindeuten, etwa fehlende `aria`-Attribute, `onClick`-Handler auf nicht-interaktiven Elementen, fehlende `alt`-Attribute sowie fehlende Formular-Assoziationen.<sup>166</sup>

### FA-04 LLM-gestützte Analyse und Handlungsempfehlung

Das System muss die Ergebnisse aus FA-01, FA-02 und FA-03 in einem strukturierten Kontext zusammenführen und an ein lokal ausgeführtes Sprachmodell übergeben, das daraus je Verstoß eine Handlungsempfehlung im Format Must-have/Nice-to-have unter Angabe der betroffenen Datei generiert.<sup>167</sup>

### FA-05 Strukturierter JSON-Output

Das System muss seine Ergebnisse in einem maschinenlesbaren JSON-Format bereitstellen.<sup>168</sup> Der Report enthält je Befund: Verstoß-ID, Kategorie (syntaktisch/semantisch/layout), Schweregrad, betroffene Datei(en), Handlungsempfehlung (Must-have/Nice-to-have), WCAG-Erfolgskriterium und – falls vorhanden – den relevanten Quellcode-Ausschnitt.

## 5.3 Nicht-funktionale Anforderungen

Nicht-funktionale Anforderungen (NFA) beschreiben die Qualitätseigenschaften des Systems. Für das vorliegende System haben sie besonderes Gewicht, da der Betriebskontext der BITBW (öffentliche Verwaltung, lokale Infrastruktur) strenge Rahmenbedingungen setzt.

---

<sup>162</sup>Vgl. Land Baden-Württemberg 2025; World Wide Web Consortium (W3C) 2023

<sup>163</sup>Vgl. Deque Systems 2026

<sup>164</sup>Vgl. Microsoft 2026

<sup>165</sup>Siehe Kapitel 2.3.2

<sup>166</sup>Siehe Kapitel 2.1

<sup>167</sup>Siehe Abschnitt 6.2

<sup>168</sup>Vgl. Paternò et al. 2025; Pool 2023

### **NFA-01 Datenschutz und Lokal-First**

Das System muss vollständig ohne externe API-Aufrufe betreibbar sein. Weder Quellcode noch DOM-Inhalte noch Violation-Reports dürfen das interne Netzwerk verlassen.<sup>169</sup>

### **NFA-02 Laufzeit und Praktikabilität**

Der vollständige Analyselauf muss auf einem Entwicklungsrechner innerhalb einer für den Entwicklungsalltag praktikablen Zeit abgeschlossen werden. Als Richtwert gilt eine Gesamtlaufzeit von unter zehn Minuten für eine einzelne Seite mit bis zu 20 axe-Verstößen. Diese Anforderung schließt mehrstufige Reasoning-Schleifen aus dem Rahmen des PoC aus.<sup>170</sup>

### **NFA-03 Wartbarkeit und Erweiterbarkeit**

Die Systemarchitektur muss eine modulare Trennung der Komponenten (Detection, Context-Building, Synthesis) vorsehen, sodass einzelne Bestandteile unabhängig angepasst oder ausgetauscht werden können.

### **NFA-04 Reproduzierbarkeit**

Das System muss hinreichend deterministisch sein, damit zwei aufeinanderfolgende Analyseläufe auf derselben Anwendungsversion im Wesentlichen dieselben Befunde erzeugen. Reproduzierbarkeit wird durch eine feste Temperatur-Einstellung (`temperature = 0.05`) und durch strukturierte Ausgabeformate (JSON-Schema im Prompt) sichergestellt.<sup>171</sup>

## **5.4 Lokale Inferenzinfrastruktur und Modellkandidaten**

Die Wahl der Inferenzinfrastruktur ist durch NFA-01 (Lokal-First) weitgehend vorgegeben: Cloudbasierte Modell-APIs scheiden aus, da ihre Nutzung die Übermittlung potenziell schützenswerter Quellcodeausschnitte und DOM-Inhalte an externe Server erfordert.<sup>172</sup>

### **5.4.1 Ollama als Laufzeitumgebung**

Ollama ist ein quelloffenes Werkzeug, das die lokale Ausführung von LLMs über eine einheitliche REST-API ermöglicht.<sup>173</sup> Die REST-API ist kompatibel mit der OpenAI-API-Spezifikation, wodurch sich bestehende Node.js-Bibliotheken ohne größeren Anpassungsaufwand integrieren lassen. Darüber hinaus unterstützt Ollama quantisierte Modellvarianten (z. B. Q4\_K\_M), die eine speichereffiziente Ausführung auf Central Processing Unit (CPU)-basierten Systemen ohne dedizierte Grafikkarte ermöglichen. Dies ist insbesondere für Entwicklungsrechner der BITBW

---

<sup>169</sup>Vgl. Europäisches Parlament und Rat der Europäischen Union 2016, Art. 28 und Art. 32

<sup>170</sup>Siehe Kapitel 2.4.2

<sup>171</sup>Vgl. OpenAI 2026, Temperature; Vgl. Anthropic 2026a, Temperature

<sup>172</sup>Vgl. Europäisches Parlament und Rat der Europäischen Union 2016, Art. 28 und Art. 44 ff.

<sup>173</sup>Vgl. Ollama 2026

relevant, bei denen nicht von Graphics Processing Unit (GPU)-Hardware ausgegangen werden kann.

### 5.4.2 Anforderungen an das Sprachmodell

Unabhängig von der konkreten Modellwahl lassen sich vier zentrale Anforderungen an das Sprachmodell ableiten:<sup>174</sup>

1. JSX und TypeScript verarbeiten können (FA-03)
2. Strukturierte Ausgaben in einem vorgegebenen Format erzeugen (FA-05, NFA-04)
3. Innerhalb eines Kontextfensters von mindestens 8.192 Tokens arbeiten (FA-04)
4. Auf CPU-basierten Systemen mit akzeptabler Latenz betreibbar sein, was die Modellgröße auf ca. 7–32 Milliarden Parameter begrenzt (NFA-02)

Die Auswahl konkreter Modellkandidaten sowie deren vergleichende Evaluation werden in Abschnitt 6.2 bzw. Kapitel 8 behandelt.

### 5.4.3 Ausgewählte Modellkandidaten für die Evaluation

Für die Evaluation in Kapitel 8 werden vier lokal ausführbare Modellkandidaten betrachtet, soweit die verfügbaren Hardware-Ressourcen eine Ausführung zulassen: `qwen2.5-coder:7b`, `qwen2.5-coder:14b`<sup>175</sup>, `qwen3:32b`<sup>176</sup> und `deepseek-r1:70b`<sup>177</sup>. Die Auswahl folgt dem Ziel, unterschiedliche Modellgrößen systematisch miteinander zu vergleichen: 7B und 14B repräsentieren ressourcenschonende Modelle für den operativen Lokalbetrieb, 32B einen mittleren Kompromiss aus Qualität und Laufzeit, 70B ein leistungsstarkes Referenzmodell mit höherem Rechenbedarf. DeepSeek-R1:70b wurde als Kandidat betrachtet, konnte jedoch aufgrund der verfügbaren Hardware-Ressourcen und der damit verbundenen Laufzeitanforderungen nicht in die finale Benchmarkserie aufgenommen werden; die Evaluation in Kapitel 8 basiert daher auf den drei verbleibenden Modellen.

### 5.4.4 Zusammenfassung der Anforderungen

Tabelle 4 fasst die spezifizierten Anforderungen zusammen und ordnet ihnen jeweils Ursprung und Priorität zu.

---

<sup>174</sup>Vgl. Hui et al. 2024, S. 3

<sup>175</sup>Vgl. Hui et al. 2024

<sup>176</sup>Vgl. Yang et al. 2025

<sup>177</sup>Vgl. Guo et al. 2025



| ID                                     | Beschreibung                                           | Ursprung                           | Priorität |
|----------------------------------------|--------------------------------------------------------|------------------------------------|-----------|
| <b>Funktionale Anforderungen</b>       |                                                        |                                    |           |
| FA-01                                  | Regelbasierte Accessibility-Erkennung via axe-core     | Forschungsliteratur (Kap. 3)       | Muss      |
| FA-02                                  | Dynamische Zustandserfassung via Playwright            | Forschungslücke 1 (Kap. 3.5)       | Muss      |
| FA-03                                  | Statische Quellcodeanalyse (grep-basiert)              | Forschungslücke 2 (Kap. 3.5)       | Muss      |
| FA-04                                  | LLM-gestützte Analyse und Handlungsempfehlung          | Forschungsliteratur (Kap. 3)       | Muss      |
| FA-05                                  | Strukturierter JSON-Output                             | Praxisanforderung BITBW            | Muss      |
| <b>Nicht-funktionale Anforderungen</b> |                                                        |                                    |           |
| NFA-01                                 | Datenschutz und Lokal-First (kein externer API-Aufruf) | Institutionell (DSGVO, BITBW)      | Muss      |
| NFA-02                                 | Laufzeit < 10 min pro Seite (ohne GPU)                 | Praxisanforderung BITBW            | Soll      |
| NFA-03                                 | Wartbarkeit und Erweiterbarkeit (modulare Architektur) | Software-Engineering Best Practice | Soll      |
| NFA-04                                 | Reproduzierbarkeit (Temperature = 0.05, JSON-Schema)   | Forschungsmethodik                 | Soll      |

Tab. 4: Anforderungsübersicht: funktionale und nicht-funktionale Anforderungen mit Ursprung und Priorität.

Die Anforderungen FA-01 bis FA-05 sowie NFA-01 bis NFA-04 bilden die verbindliche Grundlage für das Systemdesign in Kapitel 6. NFA-01 (Lokal-First) hat dabei Vorrang vor allen anderen Anforderungen und schränkt den Lösungsraum strukturell ein.

## 6 Konzeption des Assistenzsystems

Dieses Kapitel beschreibt den konzeptionellen Entwurf des Assistenzsystems **ACE**. Die Entwurfsentscheidungen leiten sich aus den Anforderungen (Kapitel 5), den theoretischen Grundlagen (Kapitel 2) sowie den in Kapitel 3 identifizierten Forschungslücken ab.

### 6.1 Zielarchitektur und Datenpipeline

Die Systemarchitektur folgt einer sequenziellen Datenpipeline, die vier Analysequellen zusammenführt, deren Ergebnisse normalisiert und an ein lokales Sprachmodell übergibt.




Abb. 4: Datenpipeline des Assistenzsystems: Vier Analysequellen (axe-core, Playwright, grep und LLM-Codeanalyse – im Diagramm als Code-Schiene zusammengefasst) werden über einen Normalizer in das UFS überführt und durch ein lokal ausführbares LLM zu priorisierten Handlungsempfehlungen verdichtet. Eine vergrößerte Darstellung findet sich in Anhang 4.

Wie Abbildung 4 veranschaulicht, durchläuft ein vollständiger Analysedurchlauf folgende Schritte:

1. axe-core: DOM analysieren, Findings normalisieren
2. Playwright: sieben Interaktionschecks ausführen, fehlgeschlagene normalisieren
3. Code-Anreicherung: axe-/Playwright-Findings mit Quellcode-Kontext ergänzen
4. Code-Patterns: Anti-Patterns im Quellcode suchen, deduplizieren
5. LLM-Codeanalyse: semantische Quellcodeanalyse ausführen, zusätzliche Findings normalisieren

6. Prompt-Builder: Findings serialisieren, Token-Budget anwenden
7. Ollama: kombinierten Priorisierungsprompt senden, Antwort empfangen
8. Output: Markdown- und JSON-Report generieren und speichern

Die folgenden Abschnitte beschreiben die konzeptionellen Grundlagen der einzelnen Komponenten.

### 6.1.1 Analysequellen

Die in Abschnitt 3.5 identifizierten Forschungslücken bilden den Ausgangspunkt der Konzeption und werden im Folgenden in konkrete Analysequellen und Verarbeitungsschritte überführt.

**axe-core** analysiert den vollständig gerenderten DOM der Zielanwendung auf Verstöße gegen WCAG-Erfolgskriterien. Da Rich-Client-Webanwendungen ihre Inhalte erst zur Laufzeit per JavaScript erzeugen (vgl. Abschnitt 2.3), ist die Ausführung in einem echten Browser unerlässlich.<sup>178</sup> axe-core erfasst dabei primär *syntaktische* Verstöße; semantische und interaktionsbedingte Barrieren bleiben außerhalb seiner Regelabdeckung.<sup>179</sup>

**Playwright** führt sieben generische Interaktionschecks aus und adressiert damit gezielt das in Abschnitt 2.3.2 beschriebene Problem *zustandsabhängiger Barrieren*. Geprüft werden unter anderem die Tastaturerreichbarkeit interaktiver Elemente, die Sichtbarkeit des Fokusindikators und das Vorhandensein eines Skip-Links – Eigenschaften, die erst durch tatsächliche Browser-Interaktion sichtbar werden.<sup>180</sup>

**grep** übernimmt zwei komplementäre Aufgaben: Bestehende axe-core- und Playwright-Findings werden um ihren Quellcode-Kontext angereichert (*Kontextanreicherung*); unabhängig davon erkennt grep bekannte Anti-Patterns im React-Quellcode (*Pattern-Erkennung*). Beide Aufgaben adressieren die in Kapitel 3.5 beschriebene Lücke zwischen DOM-Analyse und Quellcode.<sup>181</sup> Die Pattern-Erkennung basiert auf regulären Ausdrücken: Da die gesuchten Anti-Patterns textuell im JSX-Markup erkennbar sind, bietet ein vollständiger Abstract Syntax Tree (AST)-Parser keinen konzeptionellen Mehrwert bei erhöhter Komplexität.<sup>182</sup>

**LLM-Codeanalyse** ergänzt die regelbasierten Quellen um eine semantische Detektionsstufe: Das lokale Modell analysiert Quellcode-Chunks mit Zeilennummern und erzeugt strukturierte Findings im UFS-Schema, die anschließend mit den übrigen Befunden zusammengeführt werden.<sup>183</sup>

---

<sup>178</sup>Vgl. Fathallah, Hernández, Staab 2025

<sup>179</sup>Vgl. Kodithuwakku, Wickramaarachchi 2025

<sup>180</sup>Vgl. Huang, C. et al. 2024

<sup>181</sup>Vgl. Fathallah, Hernández, Staab 2025

<sup>182</sup>Vgl. Bassi et al. 2025, S. 12

<sup>183</sup>Vgl. Fathallah, Hernández, Staab 2025

Tabelle 5 fasst die Zuordnung der vier Analysequellen zu den adressierten Problemen und den jeweiligen Verstößtypen zusammen.

| Quelle          | Adressiertes Problem                              | Verstößtypen                    | Theoriebezug             |
|-----------------|---------------------------------------------------|---------------------------------|--------------------------|
| axe-core        | Begrenzte Regelabdeckung <sup>184</sup>           | primär syntaktisch              | Abschnitt 2.2.2          |
| Playwright      | Fehlende Dynamik bei zustandsabhängigen Barrieren | semantisch, layout              | Abschnitt 2.3.2          |
| grep            | DOM/Quellcode-Diskrepanz <sup>185</sup>           | alle (Anreicherung)             | Abschnitte 2.2.2 und 3.5 |
| LLM-Codeanalyse | Semantische Muster jenseits fester Regex-Regeln   | semantisch, syntaktisch, layout | Abschnitte 2.4 und 3.5   |

Tab. 5: Zuordnung der Analysequellen zu adressierten Problemen, Verstößtypen und theoretischer Herleitung.

### 6.1.2 Unified Finding Schema

Die vier Analysequellen liefern heterogene Ausgabeformate.<sup>186</sup> axe-core gibt Objekte mit **impact**-Stufen und DOM-Selektorketten zurück, Playwright boolesche **passed**-Felder, grep Datei-Zeilen-Tupel und die LLM-Codeanalyse strukturierte JSON-Objekte mit Evidenz- und Zeilenfeldern. Ohne Normalisierung wäre eine quellenübergreifende Deduplizierung und Priorisierung nicht möglich; zudem enthalten rohe axe-core-Ausgaben vollständige DOM-Snapshots, die das Token-Budget der LLM-Inferenz unnötig belasten.

Das UFS überführt daher alle Findings in eine einheitliche TypeScript-Schnittstelle (vollständiges Interface: Anhang 5). Die Felder gliedern sich in drei Gruppen: Identifikation und Klassifikation (**id**, **source**, **ruleId**, **severity**, **category**), WCAG-Bezug (**wcagCriteria**, **wcagLevel**) und Quellcode-Kontext (**selector**, **componentPath**, **codeSnippet**, **lineRange**). Felder, die eine Quelle nicht belegen kann, bleiben **null** und werden gegebenenfalls durch grep-Anreicherung oder LLM-Codeanalyse ergänzt.

Das Feld **category** bildet die in Abschnitt 2.2.3 eingeführte Taxonomie nach Fathallah et al. direkt im Datenmodell ab.<sup>187</sup> Das Feld **componentPath** bildet das entscheidende Bindeglied zwischen DOM-Analyse und Quellcode: Erst durch die Verknüpfung eines axe-Findings mit dem konkreten Dateipfad und der Zeilennummer wird aus einer generischen Meldung („*Element hat keinen alternativen Text*“) eine entwicklernahe Handlungsanweisung („*In LoginForm.tsx, Zeile 46: Füge alt-Attribut hinzu*“).

<sup>184</sup>Vgl. Kodithuwakku, Wickramaarachchi 2025.

<sup>185</sup>Vgl. Fathallah, Hernández, Staab 2025.

<sup>186</sup>Vgl. Pool 2023

<sup>187</sup>Vgl. Fathallah, Hernández, Staab 2025

## 6.2 Prompt-Strategie

Dieser Abschnitt beschreibt die Interaktionsstrategie mit dem lokalen Sprachmodell. Im Fokus stehen der zweistufige Prompt-Ansatz, die eingesetzten Prompt-Engineering-Strategien sowie die Steuerung des Token-Budgets.

### 6.2.1 Zweistufige Prompt-Strategie

Konzeptionell wäre ein stärker iterativer Ansatz denkbar; entsprechende Vorarbeiten wie Access-Guru und ACCESS wurden in Kapitel 3 bereits eingeordnet.

Für den vorliegenden Anwendungsfall wird eine zweistufige Strategie gewählt: In Stufe 1 erzeugt das Modell als LLM-Detektor strukturierte Code-Findings aus Quellcode-Chunks; in Stufe 2 priorisiert ein kombinierter Prompt alle Quellen (axe-core, Playwright, grep, LLM). Der zentrale Grund gegen weitere iterative Schleifen liegt im verfügbaren Latenzbudget: Ein LLM-Aufruf auf einem lokalen CPU-basierten System benötigt je nach Modellgröße bereits mehrere Minuten. Zusätzliche ReAct- oder Corrective-Re-Prompting-Schleifen würden die Laufzeit weiter erhöhen und damit NFA-02 gefährden – eine Einschränkung, die bei cloudbasierten Systemen mit GPU-Beschleunigung in dieser Form nicht besteht.

Der kombinierte Priorisierungsprompt in Stufe 2 ermöglicht es dem Sprachmodell, Zusammenhänge zwischen den einzelnen Quellen unmittelbar zu erkennen: Meldet axe-core ein fehlendes `aria-label`, liefert grep den zugehörigen Quellcodeausschnitt und bestätigt die LLM-Codeanalyse dieselbe Stelle, kann das Modell diese Evidenz in einem konkreten Vorschlag zusammenführen.

### 6.2.2 Wahl der Prompt-Engineering-Strategien

**Role-Play Prompting** wird eingesetzt, um dem Modell die Rolle eines Barrierefreiheitsexperten und React-Entwicklers zuzuweisen. Njifenjou et al. und Fathallah et al. belegen, dass diese Strategie die Qualität accessibility-spezifischer Ausgaben verbessert.<sup>188</sup>

**Few-Shot Prompting** wird ergänzend eingesetzt, um dem Modell das erwartete Ausgabeformat anhand konkreter Beispiele zu demonstrieren. Few-Shot-Beispiele verbessern nachweislich die Konsistenz und Formatkonformität der Modellausgaben<sup>189</sup> – besonders relevant bei kleineren Modellen, die ohne Beispiele häufiger vom vorgegebenen Schema abweichen.

---

<sup>188</sup>Vgl. Njifenjou et al. 2024; Vgl. Fathallah, Hernández, Staab 2025

<sup>189</sup>Vgl. Brown et al. 2020, S. 5

**Chain-of-Thought** wird bewusst nicht eingesetzt: CoT kann zwar Halluzinationen bei komplexen Schlussfolgerungen reduzieren<sup>190</sup>, verbraucht jedoch zusätzliche Output-Tokens und verlängert die Inferenzzeit auf lokaler Hardware. Die konkrete Umsetzung des Prompts wird in Kapitel 7 beschrieben.

### 6.2.3 Token-Budget-Steuerung

Jedes Modell verfügt über ein festes *Kontextfenster*, das die maximale Anzahl verarbeitbarer Tokens definiert – dabei müssen sowohl Eingabe (Prompt) als auch Ausgabe (Antwort) in dieses Fenster passen. Da der System-Prompt und die Ausgabe-Reserve einen festen Anteil des Kontextfensters belegen, steht für die Findings ein variables Budget zur Verfügung (vgl. Abbildung 7 im Anhang).

Übersteigt die Gesamtmenge der serialisierten Findings dieses Budget, greift eine Priorisierungsstrategie: Alle Findings werden quellenübergreifend nach Schweregrad sortiert, wobei Einträge niedriger Priorität bei Bedarf entfernt werden. Auf diese Weise wird sichergestellt, dass gesetzlich relevante Verstöße (*critical/serious*) stets im Prompt enthalten sind.

Ergänzend wird grep selektiv eingesetzt: Statt die gesamte Codebasis zu durchsuchen, werden vorrangig jene Dateien analysiert, die durch bestehende Befunde als relevant erscheinen. Die LLM-Codeanalyse arbeitet mit chunkbasiertem Retrieval – Quelldateien werden mit Zeilennummern versehen und in Textsegmente fester Zeichenlänge (*Chunks*) unterteilt (vgl. Abschnitt 7.5). Konzeptionell folgt dieses selektive Retrieval dem Grundprinzip von RAG-Systemen:<sup>191</sup> relevanter Kontext wird zur Laufzeit gezielt abgerufen und in den Prompt eingebettet.

## 6.3 Ausgabeformat: entwicklernahe To-Do-Liste

Das Ausgabeformat des Systems ist als priorisierte To-Do-Liste für Entwicklerinnen und Entwickler konzipiert. Die Wahl dieses Formats ergibt sich aus FA-05 sowie aus der Beobachtung, dass bestehende Violation Reports das Problem auf Ebene des gerenderten DOM beschreiben, ohne Bezug zur Quellcodestruktur herzustellen (vgl. Abschnitt 2.2.2).<sup>192</sup>

Die Liste ist in zwei Prioritätsstufen gegliedert: *Must-have*-Einträge bezeichnen Verstöße gegen Erfolgskriterien der Konformitätsstufen A und AA (gesetzliche Konformitätspflicht nach BITV und BfSG); *Nice-to-have*-Einträge umfassen Empfehlungen über den gesetzlichen Mindeststandard hinaus. Jeder Eintrag enthält – sofern durch grep-Anreicherung oder LLM-Codeanalyse verfügbar – den Dateipfad, die Zeilennummer sowie einen konkreten Code-Fix-Vorschlag.

---

<sup>190</sup>Vgl. Wei, Wang, X. et al. 2022, S. 2

<sup>191</sup>Vgl. Lewis et al. 2020, S. 1–2

<sup>192</sup>Vgl. Fathallah, Hernández, Staab 2025

Zu berücksichtigen ist, dass das Ausgabeformat zwar durch einen System-Prompt vorgegeben wird, dessen Einhaltung jedoch nicht garantiert werden kann – insbesondere bei kleineren Modellen der 7B-Klasse.<sup>193</sup> Die Evaluation in Kapitel 8 untersucht, inwieweit die getesteten Modelle das vorgegebene Schema einhalten; Limitationen werden in Abschnitt 8.6 diskutiert.

Zusammenfassend ergibt sich aus den Anforderungen, den theoretischen Grundlagen und den identifizierten Forschungslücken ein System, das vier komplementäre Analysequellen über ein einheitliches Datenmodell (UFS) zusammenführt und in einer zweistufigen LLM-Strategie verarbeitet: Stufe 1 für LLM-basierte Code-Findings und Stufe 2 für die quellenübergreifende Priorisierung. Kapitel 7 beschreibt die prototypische Umsetzung dieser Konzeption.

---

<sup>193</sup>Vgl. Brown et al. 2020, S. 5

## 7 Implementierung des Proof of Concept

Dieses Kapitel beschreibt die prototypische Umsetzung des in Kapitel 6 konzipierten Assistenzsystems. Zunächst werden der technische Rahmen und die Projektstruktur dargestellt. Anschließend wird die Implementierung der einzelnen Pipeline-Module erläutert. Abschließend wird die Umsetzung der Prompt-Strategie einschließlich des System-Prompts beschrieben.

### 7.1 Technischer Rahmen und Projektstruktur

Der PoC ist als Node.js-Anwendung auf Basis von TypeScript implementiert.<sup>194</sup> Die Wahl von TypeScript ist durch die technologische Nähe zum Untersuchungsgegenstand begründet: Der BWEC ist in ein TypeScript-basiertes Monorepo eingebettet, sodass auch der PoC im selben technologischen Kontext entwickelt wird. Dies erleichtert sowohl die Integration als auch eine mögliche Übertragung auf weitere Anwendungen innerhalb vergleichbarer Architekturen. Darüber hinaus ermöglicht TypeScript eine typsichere Definition des UFS (vgl. Listing 9.1). Als Laufzeitumgebung wird Node.js ab Version 24 eingesetzt; die Ausführung erfolgt über **tsx**, einen TypeScript-Runner, der Kompilierung und Ausführung in einem Schritt verbindet. Auf ein zusätzliches Framework wurde bewusst verzichtet, um den PoC minimal zu halten.

Als Kernabhängigkeiten dienen **playwright@1.50** für die Browser-Automatisierung,<sup>195</sup> **@axe-core/playwright@4.10** für die axe-core-Integration sowie **dotenv@17.3** für die Konfigurationsverwaltung und **tsx@6.5.7** als TypeScript-Runner.

Die Projektstruktur folgt einer flachen Modulorganisation (vgl. Anhang 6). Jedes Modul in **src/modules/** übernimmt sowohl die Datenerhebung als auch die Normalisierung in das UFS.

Die Pipeline wird über **src/index.ts** orchestriert und unterstützt fünf Command Line Interface (CLI)-Flags: **--url** (Ziel-URL), **--src-dir** (Quellcode-Pfad), **--skip-llm** (Prompt speichern ohne finale Priorisierung), **--axe-only** (nur axe-core ausführen) und **--llm-detect** (zusätzliche LLM-Codeanalyse aktivieren). Die Konfiguration – einschließlich Ollama-URL, Modellname und Timeout-Werte – erfolgt zentral in **config.ts** und kann über Umgebungsvariablen überschrieben werden.

### 7.2 axe-core-Modul

Das axe-core-Modul realisiert FA-01 und übernimmt die regelbasierte Accessibility-Erkennung. Es startet über Playwright einen headless Chromium-Browser, navigiert zur Ziel-URL und wartet auf **networkidle**, um sicherzustellen, dass die React-Anwendung vollständig gerendert ist.

<sup>194</sup>Vgl. *JavaScript With Syntax For Types*. 2026

<sup>195</sup>Vgl. Microsoft 2026



Anschließend wird über **AxeBuilder** eine axe-core-Analyse ausgeführt, die auf die Tags **wcag2a**, **wcag2aa**, **wcag21a**, **wcag21aa**, **wcag21a** und **wcag22aa** beschränkt ist – entsprechend dem gesetzlichen Mindeststandard (vgl. Abschnitt 2.1).

Die Normalisierung überführt jede Violation in ein **UnifiedFinding**. Dabei erfolgen drei zentrale Transformationen:

- **Severity-Mapping:** Das **impact**-Feld von axe-core (**critical**, **serious**, **moderate**, **minor**) wird direkt auf das **severity**-Feld des UFS abgebildet.
- **WCAG-Extraktion:** Aus den axe-Tags (z. B. **wcag143**) werden die Erfolgskriterien (z. B. 1.4.3) und die Konformitätsstufe extrahiert.
- **Kategorie-Heuristik:** Jede Regel wird anhand ihres **ruleId** einer Kategorie der in Abschnitt 2.2.3 eingeführten Taxonomie zugeordnet. Farbkontrast-Regeln werden als **layout** klassifiziert, ARIA-Strukturregeln als **semantisch**, alle übrigen als **syntaktisch**.

Die Felder **componentPath**, **codeSnippet** und **lineRange** bleiben nach der axe-Normalisierung zunächst **null** und werden erst in der Code-Phase (Abschnitt 7.4) angereichert.

Zu berücksichtigen ist, dass axe-core im PoC nur einmal beim initialen Seitenaufruf ausgeführt wird und nicht nach jeder Playwright-Interaktion. Eine Analyse pro Zustandswechsel wäre technisch realisierbar, würde jedoch bei sieben Checks mit je mehreren Zustandsänderungen die Laufzeit um bis zu 168 Sekunden erhöhen und damit NFA-02 verletzen. Diese Einschränkung wird in Abschnitt 8.6 als Limitation diskutiert.

### 7.3 Playwright-Modul

Das Playwright-Modul implementiert FA-02 (dynamische Zustandserfassung). Es definiert sieben generische Interaktionschecks, die jeweils ein spezifisches WCAG-Erfolgskriterium adressieren (vgl. Anhang 7, Tabelle 15).

Die Checks sind bewusst anwendungsunabhängig konzipiert: Sie setzen keine Kenntnis der konkreten Anwendungslogik voraus und sind auf jeder Web-App ausführbar. Der Keyboard-Trap-Check beispielsweise simuliert 40 Tab-Schritte und prüft, ob der Fokus in den letzten zehn Schritten auf demselben Element verbleibt. Der Check **focus-visible** navigiert per Tab durch die Seite und prüft für jedes fokussierte Element, ob ein sichtbarer Fokusindikator (**outline** oder **box-shadow**) vorhanden ist – eine Prüfung, die Tafreshipour et al. als Schwachstelle bestehender Tools identifizieren.<sup>196</sup>

Fehlgeschlagene Checks werden über ein statisches Mapping (**CHECK\_DEFINITIONS**) in **UnifiedFinding**-Objekte überführt. Jede Check-Definition enthält die zugehörige **ruleId**,

---

<sup>196</sup>Vgl. Tafreshipour et al. 2024, S. 110

**severity**, WCAG-Kriterien und Kategorie. Checks, die erfolgreich bestanden werden, erzeugen kein Finding.

### 7.4 Quellcode-Anreicherung und Anti-Pattern-Erkennung

Das Code-Modul übernimmt zwei Aufgaben: die Anreicherung bestehender Findings mit Quellcode-Kontext (FA-03) und die eigenständige Erkennung von Anti-Patterns im React-Quellcode.

#### 7.4.1 Anreicherung bestehender Findings

Für jedes axe-core- oder Playwright-Finding, das einen CSS-Selektor enthält, aber noch keinen `componentPath` besitzt, wird der Quellcode der React-Anwendung durchsucht. Der Algorithmus extrahiert Suchbegriffe aus dem Selektor – IDs, CSS-Klassen, ARIA-Attribute – und sucht diese in den `.tsx/.jsx/.ts/.js`-Dateien des angegebenen Quellverzeichnis. Bei einem Treffer werden `componentPath`, `codeSnippet` (zehn Zeilen Kontext um die Fundstelle) und `lineRange` im Finding ergänzt.

Diese Anreicherung adressiert die in Abschnitt 2.3.2 beschriebene Diskrepanz zwischen gerendertem DOM und Quellcode. Durchsucht werden ausschließlich Dateien, die durch axe-core- oder Playwright-Findings referenziert werden – nicht die gesamte Codebasis. Dieses selektive Vorgehen reduziert den Token-Verbrauch im späteren Prompt (vgl. Abschnitt 6.2).

#### 7.4.2 Pattern-Findings

Zusätzlich zur Anreicherung erkennt das Modul sechs Anti-Patterns durch reguläre Ausdrücke (vgl. Anhang 7, Tabelle 16): `div-span-onclick`, `img-missing-alt`, `label-missing-htmlfor`, `role-button-non-semantic`, `tabindex-removes-element` und `autofocus-usage`.

Treffer werden nach der Normalisierung dedupliziert und auf maximal acht Treffer pro Pattern begrenzt, um eine Überrepräsentation im Token-Budget zu vermeiden (vgl. Abschnitt 6.2).

### 7.5 LLM-Detektor-Modul

Das LLM-Detektor-Modul ergänzt die regelbasierten Quellen um eine modellbasierte Quellcodeanalyse. Es wird nur ausgeführt, wenn der CLI-Parameter `--llm-detect` gesetzt ist und ein Quellcodepfad via `--src-dir` vorliegt. Ziel ist nicht die Ersetzung bestehender Tools, sondern die Ergänzung um eine zusätzliche Detektionsquelle mit semantischem Fokus.

Die Verarbeitung erfolgt in fünf Schritten:

1. **Dateiselektion:** Das Modul sammelt rekursiv Dateien mit den Endungen `.tsx`, `.ts`, `.jsx`, `.js` und `.css`. Die Anzahl der analysierten Dateien ist über `LLM_DETECT_MAX_FILES` begrenzt (Default: 60; in den Benchmarkläufen auf 25 reduziert).
2. **Chunking:** Die Dateien werden mit Zeilennummern versehen und in Text-Chunks aufgeteilt. Die Chunk-Größe ist über `LLM_DETECT_CHUNK_CHARS` konfigurierbar (Benchmarkläufe: 4 000 Zeichen).
3. **Detektionsprompt:** Für jeden Chunk wird ein eigener Prompt erzeugt, der ausschließlich JSON im fest definierten Schema verlangt.<sup>197</sup>
4. **Parsing und Validierung:** Antworten werden als JSON extrahiert und validiert; ein Fallback überführt Formatabweichungen in das Zielformat.
5. **Normalisierung und Deduplizierung:** Valide Einträge werden als `source="llm"` in das UFS überführt und über den Schlüssel `ruleId|filePath|startLine` dedupliziert.

Dieses Vorgehen reduziert das Risiko von Halluzinationen, weil Findings ohne belastbare Evidenz oder ohne verwertbaren Datei-/Zeilenbezug verworfen werden. Gleichzeitig bleibt die Nachvollziehbarkeit erhalten, da jedes LLM-Finding einem konkreten Quellcodeausschnitt zugeordnet ist.

### 7.5.1 Abgrenzung zu grep und Nutzen der Kombination

Die beiden Detektionsansätze unterscheiden sich grundlegend in ihrer Arbeitsweise:

- **grep** arbeitet regelbasiert und deterministisch. Es erkennt bekannte Muster zuverlässig und reproduzierbar, kann aber nur das finden, was vorher als Regel modelliert wird.
- **LLM-Detektor** arbeitet kontextsensitiv. Er kann auch semantisch ähnliche Problemstellen erkennen, die nicht exakt einem festen Regex-Muster entsprechen, ist jedoch anfälliger für Formatabweichungen und Halluzinationen.

Der PoC kombiniert daher beide Ansätze in komplementärer Weise: grep als stabile Baseline und den LLM-Detektor als zusätzliche Quelle mit potenziellem Recall-Gewinn.

### 7.5.2 Beispielhafter Ablauf eines LLM-Findings

Ein typischer Detektionsfall läuft wie folgt ab: In einer Komponente enthält ein `<div>` einen `onClick`-Handler ohne tastaturäquivalentes Ereignis. Das Modell meldet dazu ein Finding mit Datei- und Zeilenbezug sowie Evidenztext, das normalisiert, dedupliziert und als `source="llm"` in das UFS überführt wird, bevor es in der Priorisierungsphase verarbeitet wird.

---

<sup>197</sup>Der vollständige System- und User-Prompt der Detektor-Phase ist in Anhang 9 dokumentiert.

Listing 7.1: Beispiel eines validierten LLM-Detektor-Findings (vereinfacht)

```
1 {  
2   "title": "Klickbare div-Komponente ohne Tastaturbedienung",  
3   "ruleId": "keyboard-click-only",  
4   "wcagCriteria": ["2.1.1"],  
5   "wcagLevel": "A",  
6   "severity": "serious",  
7   "category": "semantisch",  
8   "filePath": "components/ContactForm.tsx",  
9   "startLine": 45,  
10  "endLine": 49,  
11  "evidence": "<div ... onClick={() => setTopic(t)}>",  
12  "fixSuggestion": "button verwenden oder onKeyDown fuer Enter/Space ergaenzen"  
13 }
```

## 7.6 Prompt-Builder und System-Prompt

Der Prompt-Builder setzt die in Abschnitt 6.2 beschriebene Prompt-Strategie technisch um. Er besteht aus drei Komponenten: dem System-Prompt, der Token-Budget-Steuerung und der Serialisierung der Findings aus vier Quellen (axe-core, Playwright, grep, LLM-Codeanalyse).

### 7.6.1 System-Prompt

Der System-Prompt implementiert die in Kapitel 6 gewählten Prompt-Engineering-Strategien. Das **Role-Play Prompting** erfolgt durch die Anweisung „*Du bist ein erfahrener Barrierefreiheitsexperte für React/TypeScript-Webanwendungen*“, die das Modell in eine domänenspezifische Expertenrolle versetzt (vgl. Abschnitt 2.4.2). Das **Few-Shot Prompting** wird durch zwei konkrete Beispiele realisiert: ein **critical**-Finding (Farbkontrast) mit vollständigem Code-Fix als Must-have-Eintrag und ein **moderate**-Finding (**tabIndex**) als Nice-to-have-Eintrag. Beide Beispiele verdeutlichen dem Modell das erwartete Ausgabeformat einschließlich der WCAG-Angabe, des Dateipfads und eines konkreten Code-Fix-Vorschlags.

Ergänzend enthält der System-Prompt sechs Priorisierungsregeln, mit denen das Must-have/Nice-to-have-Schema umgesetzt wird:

1. Must-have: Severity **critical/serious** und WCAG Level A/AA
2. Nice-to-have: Severity **moderate/minor** oder Level AAA
3. Findings zum selben Element zusammenfassen
4. Codekontext für konkrete React/TypeScript-Fixes nutzen
5. Ausschließlich auf Deutsch antworten
6. Keine Findings erfinden, die nicht in den Daten vorhanden sind

Regel 6 adressiert gezielt das in Abschnitt 2.4 beschriebene Halluzinationsproblem von LLMs. Der vollständige System-Prompt sowie die Few-Shot-Beispiele sind in Anhang 8 dokumentiert.

### 7.6.2 Token-Budget-Steuerung

Wie in Abschnitt 6.2 beschrieben, ist das Kontextfenster lokaler Modelle eine begrenzte Ressource. Der Prompt-Builder reserviert feste Anteile für den System-Prompt und die Modellausgabe; der verbleibende Platz steht für die serialisierten Findings zur Verfügung.<sup>198</sup>

Übersteigt die Gesamtmenge der Findings dieses Budget, werden alle Findings quellenübergreifend nach Schweregrad sortiert; Einträge niedriger Priorität werden bei Bedarf entfernt. Findings mit Severity **critical** und **serious** haben dabei Vorrang. Der User-Prompt enthält einen expliziten Hinweis, wenn Findings aus Budgetgründen weggelassen werden.

### 7.6.3 Serialisierung

Jedes Finding wird in ein kompaktes Textformat serialisiert, das die wesentlichen Informationen auf wenige Zeilen verdichtet. Beschreibungen werden auf 300 Zeichen und Code-Snippets auf 20 Zeilen begrenzt, um den Token-Verbrauch je Finding vorhersagbar zu halten. Das vollständige Serialisierungsformat ist im System-Prompt-Beispiel in Anhang 8 illustriert.

## 7.7 Ollama-Client und Output-Formatter

Der Ollama-Client kapselt den HTTP-Aufruf an die lokale Ollama-Instanz (`localhost:11434`). Die Anfrage nutzt den `/api/generate`-Endpunkt mit `temperature: 0.05` (NFA-04).<sup>199</sup> Die niedrige `temperature`-Einstellung reduziert den Nicht-Determinismus der Ausgaben (vgl. Abschnitt 2.4), ohne ihn vollständig zu eliminieren. Der Client verwendet ein konfigurierbares Timeout (Default: drei Stunden), da die Inferenz auf CPU-basierten Systemen je nach Modellgröße mehrere Minuten in Anspruch nehmen kann. Die Antwort von Ollama enthält neben dem generierten Text auch die tatsächliche Anzahl der Prompt- und Output-Tokens (`prompt_eval_count`, `eval_count`), die für die Evaluation in Kapitel 8 erfasst werden.

Der Output-Formatter erzeugt pro Analysedurchlauf zwei Ausgabedateien: einen Markdown-Report für die menschliche Lesbarkeit sowie einen JSON-Report für die maschinelle Weiterverarbeitung (FA-05). Der Markdown-Report enthält einen Metadaten-Header (URL, Modell, Zeitstempel, Token-Statistiken), die Roh-Ausgabe des Sprachmodells sowie eine Metriken-Tabelle

---

<sup>198</sup>Beim eingesetzten Qwen2.5-Coder beträgt das Kontextfenster 32.768 Tokens. Nach Abzug von System-Prompt und Output-Reserve verbleiben ca. 24.000 Tokens für die Findings. Vgl. Hui et al. 2024 sowie Anhang 10

<sup>199</sup>Der Standardwert `num_predict = 6144` gilt für den operativen Betrieb. In den Benchmarkläufen wurden suiteabhängige Werte eingesetzt: 6144 (test-12), 8192 (test-50) und 12288 (test-100). Vgl. Tabelle 6 und Abschnitt 8.6.2.

mit den Laufzeiten aller Pipeline-Phasen. Der JSON-Report speichert zusätzlich das Parsing-Ergebnis der LLM-Antwort: Der Formatter versucht, die Markdown-Ausgabe in Must-have- und Nice-to-have-Einträge zu zerlegen. Schlägt dieses Parsing fehl, etwa weil das Modell das vorgegebene Format nicht einhält, wird dies im Report dokumentiert (`parsed.success: false`).

## 7.8 Pipeline-Orchestrierung

Die Pipeline-Orchestrierung in `index.ts` verkettet alle Module in der im Anhang dargestellten Reihenfolge (vgl. Anhang 4, Abbildung 6). Jede Phase wird einzeln zeitgemessen, um die in NFA-02 geforderte Laufzeitanalyse zu ermöglichen (für die Laufzeitanalyse siehe Kapitel 8). Die Metriken werden in einem `PipelineMetrics`-Objekt gesammelt, das neben den Phasenzeiten auch Token-Schätzungen, Anreicherungsquoten und Deduplizierungsstatistiken enthält.

Der `--skip-llm`-Modus speichert den fertigen Prompt als Textdatei, ohne Ollama aufzurufen. Dieser Modus wird während der Entwicklung genutzt, um den Prompt unabhängig von der Modellverfügbarkeit zu iterieren und für die Evaluation zu dokumentieren.

## 7.9 Beispielabläufe am Untersuchungsobjekt

Der folgende Ablauf zeigt exemplarisch die test-12-Suite und orientiert sich an den acht Pipeline-Phasen aus Abschnitt 6.1:

**Phase 1 – axe-core** meldet vier Violations, darunter fehlende Alternativtexte und Farbkontrastverstöße.

**Phase 2 – Playwright** Zwei der sieben Interaktionschecks schlagen fehl: `focus-indicator` (Fokusindikator-Verlust bei Tab-Navigation) und `focus-after-dialog` (fehlende Fokusübernahme beim Öffnen eines modalen Dialogs).

**Phase 3 – Code-Anreicherung** Grep lokalisiert die zugehörigen Komponenten im Quellcode und ergänzt die relevanten Code-Ausschnitte – u. a. wird `Modal.tsx` als Ursprungsdatei des `focus-after-dialog`-Befunds identifiziert.

**Phase 4 – Code-Patterns** Grep erkennt sechs Anti-Pattern-Treffer, darunter `<div>`-Elemente mit `onClick`-Handler ohne Tastaturäquivalent.

**Phase 5 – LLM-Codeanalyse** Der LLM-Detektor analysiert die Quellcode-Chunks und ergänzt je nach Modellgröße durchschnittlich 11 bis 23 weitere semantische Findings.

**Phase 6 – Prompt-Builder** Alle Findings werden serialisiert und das Token-Budget angewendet. Bei `qwen3:32b` ist das Budget von 6 144 Tokens ausreichend; bei 7b und 14b ist es gelegentlich knapp.

**Phase 7 – Ollama** Das lokale Modell empfängt den kombinierten Priorisierungsprompt. `qwen3:32b` klassifiziert den `focus-after-dialog`-Befund als Must-have und schlägt einen React-konformen `useEffect`-Hook zur Fokussteuerung vor – mit Verweis auf die betroffene Datei und Zeilennummer.

**Phase 8 – Output** Der Markdown-Report enthält priorisierte Must-have- und Nice-to-have-Empfehlungen mit Datei- und WCAG-Bezug; der JSON-Report speichert zusätzlich Token-Statistiken und Phasenlaufzeiten.

Die vollständige Aufstellung der erkannten Violations findet sich in Anhang 16, Screenshots in Anhang 27, Rohdaten in Anhang 19.

Auf der test-50-Suite (50 Violations) identifiziert axe-core 14 Violations, zwei Playwright-Checks schlagen fehl und grep liefert 21 Anti-Pattern-Treffer. Die größere Komponentenanzahl erhöht die Token-Last, weshalb das Kontextfenster des 7b-Modells gelegentlich durch Truncation begrenzt wird. Auf der test-100-Suite (100 Violations, 11 Komponenten) verstärkt sich dieser Effekt: das 7b-Modell zeigt regelmäßige Truncation, während `qwen3:32b` eine stabile Erkennungsleistung beibehält. Screenshots, Rohdaten und Modellvergleich finden sich in den jeweiligen Anhängen (39, 31, 32 bzw. 55, 43, 44).

Für den BWEC erzeugt die Pipeline zehn axe-core-Violations, zwei Playwright-Checks und acht grep-Treffer. Da die Codebasis weit größer ist, wird sie in Chunks aufgeteilt; bei `maxfiles = 100` (66 Chunks) erzeugt der LLM-Detektor im Mittel 15 bis 32 Findings pro Durchlauf, bei `maxfiles = 500` (330 Chunks) entsprechend mehr. Rohdaten und Modellübersichten beider Konfigurationen befinden sich in Anhang 65, 66 sowie 67, 68. Die vollständige quantitative Auswertung ist in Kapitel 8 dokumentiert.

## 8 Evaluation und Diskussion

Dieses Kapitel evaluiert das ACE-System entlang der in Abschnitt 1.3 formulierten Forschungsfragen. Zunächst werden Versuchsdesign und Metriken beschrieben. Anschließend werden die Ergebnisse zu Detektionsqualität, Priorisierung, Fix-Qualität und Effizienz dargestellt und diskutiert. Abschließend folgen Limitationen, die Beantwortung der Forschungsfragen sowie daraus abgeleitete Einsatzempfehlungen.

### 8.1 Versuchsdesign

Die Evaluation folgt einer mehrstufigen Versuchslogik: Die *test-12-Suite* dient als methodische Kalibrierungsphase – bei vollständig bekannter Ground Truth lässt sich prüfen, ob die Pipeline prinzipiell korrekt funktioniert und alle Verstoßkategorien grundsätzlich erkennt. Die *test-100-Suite* bildet die zentrale Belastungsprüfung: Erst hier gerät das Token-Budget systematisch unter Druck, treten Skalierungseffekte auf und werden Modellunterschiede unter realistischerer Last sichtbar. Die *test-50-Suite* fungiert als Zwischenstufe. Ergänzend wird das reale Untersuchungsobjekt BWEC qualitativ evaluiert; mangels Ground Truth erfolgt dort jedoch keine quantitative Recall-Messung. Die folgenden Unterabschnitte beschreiben die Untersuchungsobjekte und die Versuchslogik im Überblick.

#### 8.1.1 Testobjekte und Ground Truth

Die *test-12-Suite* ist eine eigens entwickelte React-SPA mit zwölf gezielt eingebetteten WCAG-Verstößen (Tabelle 22), die alle drei Kategorien der in Kapitel 2.2.3 eingeführten Taxonomie abdecken: vier syntaktische (V1, V2, V3, V10), drei layout-bezogene (V4, V5, V12) und fünf semantische Verstöße (V6, V7, V8, V9, V11). Da die Ground Truth vollständig bekannt und kontrollierbar ist, eignet sich diese Suite als Kalibrierungsphase: Es lässt sich exakt prüfen, ob alle Detektionsquellen korrekt angebunden sind, die Normalisierung funktioniert und das LLM die Pipeline-Ausgaben grundsätzlich verarbeiten kann. Aufgrund der geringen Komplexität der Suite sind die erzielten Recall-Werte jedoch nicht als repräsentativ für reale Anwendungen zu interpretieren. Die visuelle Gestalt der Testanwendung ist in Abbildung 8 und 9 dokumentiert.

Die *test-50-Suite* (50 Violations) dient als Zwischenstufe zwischen Kalibrierung und Belastungsprüfung. Die *test-100-Suite* (100 Violations, 11 Komponenten, vgl. Anhang 40) bildet die eigentliche Belastungsprüfung: Erst bei 100 Violations gerät das Token-Budget systematisch unter Druck, treten Trunkierungseffekte auf und werden Modellunterschiede unter annähernd realistischer Last sichtbar. Als reales Untersuchungsobjekt dient ergänzend der BWEC der BITBW – eine produktiv betriebene React-SPA mit unbekannter Ground Truth (vgl. Abschnitt 8.7.3).



### 8.1.2 Modelle, Konfiguration und Testläufe

Es werden drei lokal ausgeführte Sprachmodelle verglichen: `qwen2.5-coder:7b`, `qwen2.5-coder:14b`<sup>200</sup> und `qwen3:32b`<sup>201</sup>. Das in Kapitel 5 ebenfalls genannte `deepseek-r1:70b`<sup>202</sup> kann im Rahmen dieser Arbeit nicht evaluiert werden, da das Modell mit 70 Milliarden Parametern die verfügbare Random-Access Memory (RAM)-Kapazität der Testumgebung überschreitet; es bleibt Gegenstand künftiger Evaluation auf leistungsstärkerer Hardware (vgl. Abschnitt 8.7).

Auf jeder der drei synthetischen Suites absolvierte jedes Modell zehn unabhängige Pipeline-Durchläufe, was insgesamt 90 Benchmarkläufe auf synthetischen Testsuiten ergibt. Ergänzend wurden 18 Läufe auf dem realen BWEC durchgeführt (zwei Konfigurationen mit je 9 Testläufen). Die Temperatur wurde auf 0.05 gesetzt, um den Nicht-Determinismus zu minimieren. Der LLM-Detektor operiert mit separaten Parametern: 2048 Tokens für die Code-Analyse, 4000 Zeichen pro Chunk und maximal 25 Dateien pro Durchlauf.

| Modell                         | Typ                       | test-12      | test-50      | test-100     |
|--------------------------------|---------------------------|--------------|--------------|--------------|
| <code>qwen2.5-coder:7b</code>  | Code                      | 10 Testläufe | 10 Testläufe | 10 Testläufe |
| <code>qwen2.5-coder:14b</code> | Code                      | 10 Testläufe | 10 Testläufe | 10 Testläufe |
| <code>qwen3:32b</code>         | Generalist <sup>203</sup> | 10 Testläufe | 10 Testläufe | 10 Testläufe |
| <code>deepseek-r1:70b</code>   | Reasoning <sup>204</sup>  | –            | –            | –            |
| <b>Gesamt (durchgeführt)</b>   |                           | <b>30</b>    | <b>30</b>    | <b>30</b>    |

Tab. 6: Verteilung der Benchmarkläufe auf Modelle und Testsuiten (je 10 Testläufe pro Modell und Suite). `temperature` = 0.05; `num_predict`: test-12 = 6 144; test-50 = 8 192; test-100 = 12 288. `deepseek-r1:70b` konnte aufgrund fehlender RAM-Kapazität sowie prohibitiv hoher CPU- und GPU-Last und resultierender Laufzeit nicht evaluiert werden.

### 8.1.3 Metriken und Messverfahren

Ausgewertet werden vier Metriken:

1. **Recall** (erkannte Violations relativ zur Ground Truth),
2. **Priorisierungsqualität** (Korrektheit der Must-have/Nice-to-have-Klassifikation),
3. **Fix-Qualität** nach der dreistufigen Skala aus Tabelle 18 sowie
4. **Effizienz** (Laufzeit und Konsistenz über mehrere Testläufe).

<sup>200</sup>Vgl. Hui et al. 2024

<sup>201</sup>Vgl. Yang et al. 2025

<sup>202</sup>Vgl. Guo et al. 2025

<sup>204</sup>Vgl. Yang et al. 2025

<sup>204</sup>Vgl. Guo et al. 2025

Eine Violation gilt als erkannt, wenn sie in der Mehrzahl der zehn Testläufe ( $> 5$ ) im finalen LLM-Report erscheint. Diese Schwelle bietet Robustheit gegenüber einzelnen LLM-Ausreißern, ohne bei probabilistischen Modellen zu restriktiv zu sein. Die vollständigen Rohdaten aller Benchmarkläufe finden sich in den Anhangstabellen der jeweiligen Suites.

## 8.2 Ergebnisse: Detektionsqualität (Recall)

Dieser Abschnitt bewertet, welche der 12 Ground-Truth-Violations die Pipeline erkennt – zunächst ohne LLM-Detektor (Baseline), dann mit LLM-Detektor je Modell und abschließend differenziert nach Verstoßkategorie. Die UI-Screenshots der test-12-Suite finden sich in Anhang 8 und 9.

### 8.2.1 Baseline: Tool-Pipeline ohne LLM-Detektor

Ohne LLM-Detektor erkennt die Tool-Pipeline (axe-core + Playwright + grep) in jedem Durchlauf stabil 8 von 12 Violations (Recall: 66,7 %). Nicht erkannt werden V2 (fehlendes `aria-label`), V8 (modaler Fokus-Trap), V11 (DOM-Reihenfolge) und V12 (Mindestgröße) – Fälle, die überwiegend semantische oder kontextabhängige Interpretation erfordern. Ein generischer Fokus-Trap-Test für V8 ließ sich ohne anwendungsspezifische Selektoren nicht robust implementieren (vgl. Abschnitt 9.3).

### 8.2.2 Recall nach LLM-Detektor-Augmentierung

Tabelle 7 zeigt den Recall nach Hinzunahme des LLM-Detektors. Mit `qwen2.5-coder:14b` und `qwen3:32b` werden alle vier zuvor fehlenden Violations konsistent erkannt. `qwen2.5-coder:7b` gewinnt V8 und V12 hinzu, verfehlt jedoch weiterhin V2 und V11; zusätzlich wird V3 im finalen Report nur instabil ausgegeben und unterschreitet dadurch die Konsistenzschwelle.

| Bedingung                        | Erkannte V. | Recall | Neu ggü. Baseline    | Nicht erkannt    |
|----------------------------------|-------------|--------|----------------------|------------------|
| Baseline (Tools only)            | 8 / 12      | 66,7 % | –                    | V2, V8, V11, V12 |
| + <code>qwen2.5-coder:7b</code>  | 9 / 12      | 75,0 % | +V8, +V12; V3*       | V2, V3*, V11     |
| + <code>qwen2.5-coder:14b</code> | 12 / 12     | 100 %  | +V2, +V8, +V11, +V12 | –                |
| + <code>qwen3:32b</code>         | 12 / 12     | 100 %  | +V2, +V8, +V11, +V12 | –                |

Tab. 7: Recall der ACE-Pipeline auf der test-12-Suite (Kalibrierungsphase; 12 kontrollierte Violations mit bekannter Ground Truth). \*V3 wird von `qwen2.5-coder:7b` nur instabil im finalen Report übernommen und verfehlt dadurch die Konsistenzschwelle.

Die detaillierte Aufschlüsselung für alle 12 Violations mit der jeweiligen Erkennungsquelle findet sich in Tabelle 23, die vollständige Recall-Matrix in Tabelle 24.

### 8.2.3 Erkennungsleistung nach Verstoßkategorie

Für TF1 ist nicht nur der Gesamt-Recall relevant, sondern die Frage, welche *Typen* von Violations erkannt werden. Tabelle 8 schlüsselt den Recall nach den drei in Kapitel 2.2.3 eingeführten Kategorien auf.

| Kategorie     | Violations          | Baseline             | + 7b                 | + 14b                  | + 32b                  |
|---------------|---------------------|----------------------|----------------------|------------------------|------------------------|
| Syntaktisch   | V1, V2, V3, V10     | 3 / 4 (75 %)         | 2 / 4 (50 %)         | 4 / 4 (100 %)          | 4 / 4 (100 %)          |
| Layout        | V4, V5, V12         | 2 / 3 (67 %)         | 3 / 3 (100 %)        | 3 / 3 (100 %)          | 3 / 3 (100 %)          |
| Semantisch    | V6, V7, V8, V9, V11 | 3 / 5 (60 %)         | 4 / 5 (80 %)         | 5 / 5 (100 %)          | 5 / 5 (100 %)          |
| <b>Gesamt</b> | <b>12</b>           | <b>8 / 12 (67 %)</b> | <b>9 / 12 (75 %)</b> | <b>12 / 12 (100 %)</b> | <b>12 / 12 (100 %)</b> |

Tab. 8: Erkennungsleistung differenziert nach Verstoßkategorie (test-12-Suite). Werte basieren auf der Mehrzahl der zehn Testläufe je Modell.

Aus dieser Aufschlüsselung ergeben sich drei zentrale Beobachtungen:

1. Die Baseline zeigt die größte Lücke bei semantischen Violations (60 %): Diese Kategorie umfasst konzeptionell die anspruchsvollsten Prüffälle – Zustandsabhängigkeit, fehlende Keyboard-Interaktion und DOM-Konsistenz – wird von regelbasierten Tools am unzuverlässigsten abgedeckt.
2. Der LLM-Detektor trägt seinen größten Recall-Gewinn im semantischen Bereich bei: von 60 % auf 100 % mit 14b und 32b, also eine Steigerung um 40 Prozentpunkte.
3. 7b zeigt, dass eine zusätzliche LLM-Stufe nicht automatisch jede Kategorie stabilisiert: Obwohl V8 und V12 hinzugewonnen werden, wird V3 im finalen Report nur instabil übernommen, sodass der syntaktische Recall vorübergehend auf 50 % sinkt. Erst ab 14b sind alle drei Kategorien vollständig abgedeckt.

### 8.2.4 Precision und F1-Score

Neben dem Recall ist Precision – der Anteil der Report-Items, der tatsächlichen WCAG-Violations entspricht – entscheidend für den praktischen Nutzen: Hohe Precision bedeutet, dass Entwicklerinnen und Entwickler den Findings vertrauen können, ohne jeden Eintrag manuell verifizieren zu müssen. Gemessen wird auf Item-Ebene: Ein Report-Item gilt als True Positive, wenn es mindestens einem der bekannten Ground-Truth-Verstöße zuzuordnen ist; andernfalls als False Positive (Halluzination oder Fehlinterpretation). Die Bewertung erfolgt über alle zehn Testläufe je Modell und Suite.<sup>205</sup>

Die Precision-Werte liegen über alle Modelle und Suites zwischen 96,8 % und 99,1 % und sind damit konsistent hoch – im Einklang mit der Stichproben-Plausibilisierung in Abschnitt 8.6.3,

<sup>205</sup>test-12 wird in der Precision-Analyse nicht gesondert ausgewiesen: Mit nur 12 Ground-Truth-Violations ist die Stichprobe zu klein, um stabile Precision-Schätzungen zu liefern – ein einzelnes FP-Item würde bereits eine Abweichung von über 8 Prozentpunkten erzeugen.

| Suite    | Modell            | Precision (%) | Recall (%) | F1 (%) |
|----------|-------------------|---------------|------------|--------|
| test-50  | qwen3:32b         | 98,2          | 100,0      | 99,1   |
|          | qwen2.5-coder:14b | 98,4          | 96,0       | 97,2   |
|          | qwen2.5-coder:7b  | 97,5          | 72,0       | 82,8   |
| test-100 | qwen3:32b         | 96,8          | 63,0       | 76,3   |
|          | qwen2.5-coder:14b | 98,9          | 53,0       | 69,0   |
|          | qwen2.5-coder:7b  | 99,1          | 40,0       | 57,0   |

Tab. 9: Precision, Recall und F1 auf test-50 und test-100 (Mittelwerte über 10 Testläufe je Modell). Precision gemessen auf Item-Ebene: Anteil der Report-Einträge mit nachweisbarem Bezug zu einer Ground-Truth-Violation.

die auf test-100 nur 1 von 176 geprüften Einträgen als Halluzination einstufte. Der PoC erzeugt damit kaum False-Positive-Einträge, unabhängig von Modellgröße oder Suitekomplexität. Die wesentlichen Unterschiede zwischen den Modellen zeigen sich im Recall und folglich auch im F1-Score: **qwen3:32b** erreicht auf test-50 einen F1 von 99,1 %, während **qwen2.5-coder:7b** auf test-100 mit einem F1 von 57,0 % deutlich zurückfällt. Dieser Unterschied ist ausschließlich durch die Recall-Differenz bedingt, nicht durch mangelnde Genauigkeit.

Ein direkter Benchmark gegen **GenA11y**<sup>206</sup> (Precision 94,5 %, Recall 87,6 %, F1 91,0 %) ist aufgrund abweichender Datensätze, Metriken und Evaluationsumgebungen nur eingeschränkt vergleichbar und daher als orientierend zu verstehen: ACE übertrifft GenA11y bei der Precision, liegt aber bei dem Recall – insbesondere auf test-100 – darunter. Vollständige Auflistungen der Precision je Testlauf und Modell befinden sich in Anhang 36 (test-50) sowie Anhang 49 (test-100).

## 8.3 Ergebnisse: Priorisierungsqualität

Neben dem Recall ist die Korrektheit der Must-have/Nice-to-have-Klassifikation für den praktischen Nutzen des Systems entscheidend: Eine falsch priorisierte Empfehlung kann dazu führen, dass gesetzlich verpflichtende Anforderungen als optional behandelt werden. Dieser Abschnitt vergleicht das Priorisierungsverhalten der drei Modelle.

### 8.3.1 Modellvergleich Must-have und Nice-to-have

Das Prompt-Design schreibt dem Modell vor, Findings nach Must-have und Nice-to-have zu kategorisieren. Da die Priorisierungsphase sämtliche Quellen (axe, Playwright, grep und LLM-Detektor) zusammenführt, ist die Gesamtzahl der Report-Items größer als die Zahl der 12 Ground-Truth-Violations. Tabelle 10 zeigt die mittleren Zählungen über 10 Testläufe.

<sup>206</sup>Vgl. He, Huq, Malek 2025, FSE101:20

Die Spalte *Bewertung* fasst das Verhalten qualitativ zusammen. Zu beachten ist, dass Findings am Listenende – typischerweise Nice-to-have – bei 7b und 14b durch das Output-Token-Limit systematisch häufiger abgeschnitten werden; die Nice-to-have-Werte sind daher als untere Schranke zu interpretieren.

| Modell            | Must-have Ø | Nice-to-have Ø | Gesamt-Items Ø | Bewertung              |
|-------------------|-------------|----------------|----------------|------------------------|
| qwen2.5-coder:7b  | 9,1         | 23,1           | 32,2           | <b>Fehlerhaft</b>      |
| qwen2.5-coder:14b | 27,0        | 8,9            | 35,9           | <b>Undifferenziert</b> |
| qwen3:32b         | 14,6        | 8,5            | 23,1           | <b>Korrekt</b>         |

Tab. 10: Priorisierungsverhalten der drei Modelle (Mittelwerte über 10 Testläufe, test-12-Suite). Nice-to-have-Werte bei 7b und 14b sind durch Token-Limit-Effekte als untere Schranke zu interpretieren.

**qwen2.5-coder:7b** zeigt ein fehlerhaftes Priorisierungsverhalten: Pflichtanforderungen wie Fokussindikator oder Skip-Link werden nicht stabil im Must-have-Bereich gehalten. Für einen BITV-konformen Einsatz ist dieses Modell daher *nicht geeignet*.

**qwen2.5-coder:14b** trennt die beiden Kategorien zwar formal, überbetont aber den Must-have-Bereich deutlich. Das Modell ist damit *undifferenziert*, aber nicht so fehlerhaft wie 7b.

**qwen3:32b** zeigt mit durchschnittlich 14,6 Must-have- und 8,5 Nice-to-have-Einstufungen insgesamt die **plausibelste Trennung** und stellt damit im Kalibrierungsfall das priorisierungsseitig stärkste Modell dar.

## 8.4 Ergebnisse: Fix-Qualität (qualitativ)

Ein hoher Recall allein ist für den Entwicklungsalltag nicht ausreichend: Entscheidend ist, ob die generierten Handlungsempfehlungen konkret und direkt umsetzbar sind. Dieser Abschnitt bewertet die Fix-Qualität anhand der dreistufigen Skala (Stufe 0–2) und illustriert die Unterschiede zwischen den Modellen an konkreten Fallbeispielen.

### 8.4.1 Bewertungsmaßstab

Die Bewertungsskala (Tabelle 18) unterscheidet drei Stufen: Stufe 2 (konkret: Dateiname, Zeilennummer, umsetzbarer Code-Vorschlag), Stufe 1 (teilweise: richtiger Fix-Typ ohne konkreten Kontext) und Stufe 0 (generisch: nur Problembeschreibung). Die vollständige Bewertung aller zwölf Violations findet sich in Tabelle 32. Im Ergebnis erreicht **qwen3:32b** für 11 von 12 Violations Stufe 2; **qwen2.5-coder:14b** erreicht überwiegend Stufe 1; **qwen2.5-coder:7b** schwankt zwischen Stufe 0 und 1.

### 8.4.2 Fallbeispiele nach Modell

**Fallbeispiel 1 – Konkrete Empfehlung (Stufe 2, qwen3:32b).** Für V8 (Modaler Dialog übernimmt Fokus beim Öffnen nicht) generiert `qwen3:32b` eine Empfehlung, die `ContactForm.tsx` namentlich referenziert, einen React-konformen `useEffect`-Hook für `modalOpen` vorschlägt und die Fokusführung inklusive Tab- und Shift+Tab-Logik mit sauberm Event-Listener-Cleanup beschreibt. Die Empfehlung ist damit direkt in den Quellcode übertragbar und erreicht Stufe 2.

**Fallbeispiel 2 – Teilweise Empfehlung (Stufe 1, qwen2.5-coder:14b).** `qwen2.5-coder:14b` empfiehlt für V4 (Kontrastverhältnis) sinngemäß, Hintergrund- oder Textfarbe anzupassen, um den Kontrast zu verbessern, liefert jedoch keinen ausreichend konkreten Bezug zum tatsächlichen Farbpaar oder die betroffene Regel im Stylesheet. Der Fix-Typ stimmt, der konkrete Umsetzungskontext bleibt jedoch zu vage – Stufe 1.

**Fallbeispiel 3 – Fehlklassifikation (Stufe 0, qwen2.5-coder:7b).** `qwen2.5-coder:7b` behandelt den Fokusindikator-Verlust (V5, WCAG 2.4.7 AA) nicht stabil als Pflichtanforderung und formuliert den Fix nur generisch. Damit fehlt sowohl das korrekte Priorisierungssignal als auch die unmittelbare Umsetzbarkeit im Quellcode – Stufe 0.

## 8.5 Ergebnisse: Effizienz und Robustheit

Neben der inhaltlichen Qualität ist für den produktiven Einsatz entscheidend, wie schnell und konsistent die Pipeline arbeitet. Dieser Abschnitt prüft die Konformität mit Anforderung NFA-02 (Laufzeit), analysiert die Varianz der Ergebnisse über mehrere Testläufe und bewertet die Token-Nutzung als Indikator für systematische Antwortabbrüche.

### 8.5.1 Laufzeit und NFA-02-Konformität

Anforderung NFA-02 fordert eine Gesamtlaufzeit von unter zehn Minuten:

- `qwen2.5-coder:7b`: durchschnittlich 231 s; erfüllt Anforderung NFA-02 deutlich; Durchsatz: 0,048 Findings/s
- `qwen2.5-coder:14b`: durchschnittlich 420 s; erfüllt Anforderung NFA-02 deutlich; Durchsatz: 0,054 Findings/s (trotz höherer Laufzeit leicht höher als bei 7b)
- `qwen3:32b`: durchschnittlich 701 s (Ausreißer bis 937 s); überschreitet die Zehn-Minuten-Grenze und ist daher für zeitkritische Entwicklungszyklen nicht als Standardmodell geeignet, stellt jedoch weiterhin das qualitativ stärkste Referenzmodell dar; Durchsatz: 0,028 Findings/s

Die vollständigen Laufzeit- und Effizienztabellen finden sich in Anhang 22.

### 8.5.2 Konsistenz und Parsing-Stabilität

Die Standardabweichung der LLM-Detektor-Findings variiert deutlich zwischen den Modellen. Auf test-12 erreicht **qwen2.5-coder:14b** mit  $\sigma = 0,42$  die höchste Konsistenz; **qwen3:32b** liegt mit  $\sigma = 0,53$  nur geringfügig darüber, während **qwen2.5-coder:7b** mit  $\sigma = 3,28$  eine deutlich höhere Varianz zeigt.

Die festen Detektoren (axe, Playwright, grep) bleiben über alle Benchmarkläufe vollständig deterministisch, sodass die Varianz ausschließlich aus der LLM-Stufe stammt. In allen 30 Testläufen der test-12-Suite wird der LLM-Output erfolgreich geparkt (**parsed.success: true**, 100 %). Das Prompt-Design mit Role-Play- und Few-Shot-Prompting zeigt damit eine hohe Formatstabilität über alle drei Modelle hinweg und unterstützt Anforderung NFA-04.

### 8.5.3 Token-Nutzung

Die Output-Token-Nutzung weist ein deutliches Trunkierungsprofil auf: **qwen2.5-coder:7b** erreicht in 5 von 10 Testläufen das Output-Limit von 6 144 Tokens, **qwen2.5-coder:14b** in 4 von 10 Testläufen; **qwen3:32b** liegt im Mittel bei 3 491 Output-Tokens und wird in lediglich 1 von 10 Testläufen abgeschnitten. Das Token-Budget ist damit für 7b und 14b messbar unter Druck, während 32b noch ausreichend Reserve besitzt.

Tabelle 27 schlüsselt Input- und Output-Tokens je Modell auf. Die größeren Modelle konsumieren tendenziell weniger Output-Tokens bei höherem oder vergleichbarem Recall, was auf eine höhere Fokussierung der Ausgabe hindeutet.

## 8.6 Limitationen und Validität

Die vorliegenden Ergebnisse sind vor dem Hintergrund der methodischen Rahmenbedingungen zu interpretieren. Dieser Abschnitt benennt die wesentlichen Einschränkungen hinsichtlich externer Validität, interner Validität sowie weiterer Einzelaspekte des Versuchsaufbaus.

### 8.6.1 Externe Validität

Die Evaluation stützt sich primär auf drei synthetisch konstruierte Testsuiten (test-12, test-50, test-100). Obwohl alle drei Verstoßkategorien vertreten und die Ground Truths vollständig bekannt sind, lässt sich die Übertragbarkeit auf produktive Anwendungen mit unkontrollierter Ground Truth nicht direkt ableiten. Die ergänzende Evaluation am realen BWEC reduziert diese Lücke, ersetzt jedoch keine formale Ground-Truth-basierte Recall-Messung.

### 8.6.2 Interne Validität und Token-Limit-Effekt

Die Priorisierungszählungen (Must-have/Nice-to-have) sind durch das Token-Limit beeinflusst: Bei 7b endeten 5 von 10 Testläufe auf test-12 am Output-Limit, bei 14b 4 von 10 und bei 32b nur 1 von 10. Auf größeren Suites verstärkt sich dieser Effekt deutlich. Dadurch werden systematische Abschneidungs-Bias begünstigt, insbesondere zulasten später Listenanteile (typischerweise Nice-to-have). Die Recall-Messung bleibt davon weniger stark betroffen, da zentrale Violations tendenziell früher im Output erscheinen.

Zusätzlich birgt die Operationalisierung „Violation erkannt“ ein Konstruktvaliditätsrisiko. Die Erkennung wird über Report-Präsenz (Mehrheit der Testläufe) gemessen, nicht über eine formale semantische Äquivalenzklasse. Paraphrasierte Findings können dadurch konservativ oder liberal zugeordnet werden.

### 8.6.3 Weitere Einschränkungen

**Grep-Limitierungen.** Die regex-basierten grep-Patterns erkennen bekannte Anti-Patterns zuverlässig auf Textebene, sind aber weder erschöpfend noch struktursensitiv. Insbesondere Click-Patterns ohne Tastaturäquivalent können in Einzelfällen legitime Implementierungen zu aggressiv markieren.

**Ursachen der Über-Detektion.** Eine Stichproben-Plausibilisierung an zwei Läufen von `qwen3:32b` auf test-100 zeigt, dass bestätigte Halluzinationen die Ausnahme sind (1 von 176 geprüften Einträgen). Die dominanten Überdetektions-Effekte sind Quell-Duplikate, Mehrfachinstanzen und Grenzfälle der Zuordnung (vgl. Anhang 48). Über-Detektion ist damit überwiegend ein strukturelles und nicht primär ein inhaltliches Qualitätsproblem.

**Hardware-Abhängigkeit.** Alle Laufzeitmessungen wurden auf einem einzelnen CPU-basierten System durchgeführt. Auf GPU-beschleunigter Hardware oder mit weiter optimierten Quantisierungen wären deutlich kürzere Laufzeiten zu erwarten.

## 8.7 Belastungsprüfung: test-50 und test-100

Die in den vorherigen Abschnitten präsentierten Kalibrierungsergebnisse (test-12) zeigen, dass die Pipeline korrekt funktioniert und alle Verstoßkategorien grundsätzlich erkennbar sind. Dieser Abschnitt dokumentiert die eigentliche Belastungsprüfung: die test-50-Suite (50 Violations) als Zwischenstufe sowie die test-100-Suite (100 Violations) als primäres Skalierungsobjekt, an dem Tokenbudget-Effekte, Modellunterschiede und Erkennungsgrenzen unter realistischerer Last sichtbar werden.



### 8.7.1 Evaluation an test-50

Die test-50-Messreihe wurde mit identischer Grundkonfiguration wie test-12 durchgeführt: drei Modelle, je zehn Testläufe, `temperature = 0,05`, CPU-basierte lokale Ollama-Instanz. Das Output-Token-Limit wurde auf `num_predict = 8192` angehoben. Die vollständigen Rohdaten aller 30 Testläufe finden sich in Tabelle 38.

**Token-Budget unter Druck.** Die test-50-Messreihe zeigt als wichtigste Beobachtung: das Token-Budget wird nun systematisch erschöpft. Die mittleren Input-Tokens steigen auf ca. 13 200–14 200. Trotz des angehobenen Output-Limits schöpfen 60–90 % aller Testläufe das Budget vollständig aus: `qwen2.5-coder:7b` in 6 / 10 Testläufen, `qwen2.5-coder:14b` in 7 / 10 Testläufen und `qwen3:32b` in 9 / 10 Testläufen.

**Detektionsleistung und Recall.** Die Baseline-Tools liefern auf test-50 stabil 14 axe-core-, 2 Playwright- und 21 grep-Findings. Der LLM-Detektor erzielt durchschnittlich:

- `qwen2.5-coder:7b`: 46,6 Findings ( $\sigma \approx 3,20$ ); Recall: 36 / 50
- `qwen2.5-coder:14b`: 51,3 Findings ( $\sigma \approx 2,21$ ); Recall: 48 / 50
- `qwen3:32b`: 60,7 Findings ( $\sigma \approx 1,25$ ); Recall: 50 / 50

Ein strukturell bedeutsamer Befund ist in der Recall-Matrix (Tabelle 37) direkt ablesbar: Die Baseline (Tool-only) erzielt 43 / 50 Violations, während `qwen2.5-coder:7b` mit der vollständigen Pipeline lediglich 36 / 50 erreicht. Bei 50 Violations wird die LLM-Zusammenfassungsphase für 7b somit zum Engpass statt zum Mehrwert, da vorhandene Tool-Findings unter Informationsverlust komprimiert werden, anstatt sie zuverlässig zu ergänzen. Erst `qwen2.5-coder:14b` (48 / 50) und `qwen3:32b` (50 / 50) übertreffen das Baseline-Niveau.

**Priorisierungsqualität.** `qwen3:32b` erzielt mit im Mittel 47,6 Must-have die plausibelste Klassifikation relativ zur Ground Truth von 50 Violations. `qwen2.5-coder:14b` zeigt ein bimodales Muster mit einzelnen Testläufen, die fast ausschließlich Must-have ausgeben. `qwen2.5-coder:7b` bleibt instabil. Die vollständigen Priorisierungszählungen finden sich in Tabelle 39 im Anhang.

**Effizienz und NFA-02.** Die Gesamtlaufzeit skaliert auf test-50 substanziell:

- `qwen2.5-coder:7b`: durchschnittlich 413 s; erfüllt Anforderung NFA-02
- `qwen2.5-coder:14b`: durchschnittlich 826 s; überschreitet die Zehn-Minuten-Grenze
- `qwen3:32b`: durchschnittlich 1897 s; überschreitet die Zehn-Minuten-Grenze deutlich und ist damit für zeitkritische Szenarien nicht geeignet.

### 8.7.2 Evaluation an test-100

Die test-100-Suite (100 eingebettete Violations, 11 Komponenten, vgl. Anhang 40) wurde mit allen drei Modellen evaluiert. Pro Modell wurden zehn Testläufe mit `num_predict = 12288` durchgeführt, insgesamt somit 30 Testläufe.

**Token-Budget und Truncation.** Das Output-Limit von 12288 Tokens bewährt sich modellabhängig sehr unterschiedlich. `qwen2.5-coder:7b` schöpft das Budget in 80 % der Testläufe aus (8 / 10). `qwen2.5-coder:14b` erreicht in allen 10 Testläufen das Token-Limit (100 % Truncation) – kein Testlauf liefert einen vollständigen Bericht. `qwen3:32b` verhält sich gegensätzlich: Nur 1 von 10 Testläufen ist trunziert; der mittlere Output liegt bei 7360 Tokens.

**Detektionsleistung und Recall.** Die Baseline-Tools erkennen stabil 34 / 100 Violations. Der LLM-Detektor erzielt durchschnittlich:

- `qwen2.5-coder:7b`: 104,0 Findings ( $\sigma = 5,75$ ); Recall: 40 / 100
- `qwen2.5-coder:14b`: 94,3 Findings ( $\sigma = 3,23$ ); Recall: 53 / 100
- `qwen3:32b`: 99,1 Findings ( $\sigma = 5,63$ ); Recall: 63 / 100

Der deutliche Recall-Zuwachs von `qwen3:32b` gegenüber der Baseline (+29 Violations) spricht auch bei 100 Violations für einen substanziellen Mehrwert der LLM-Erweiterung. Die hohe Truncation-Rate bei 7b und 14b begrenzt deren Erkennungsleistung hingegen systematisch.

Die 37 nicht erkannten Violations bei `qwen3:32b` verteilen sich auf 16 syntaktische, 13 semantische und 8 layout-bezogene Fälle (vgl. Abbildung 14 im Anhang). Strukturell dominieren drei Ursachenklassen: Interaktions- oder Zustandsfälle ohne robuste Playwright-Instrumentierung (z. B. V78), rein manuell prüfbare semantische Fälle (z. B. Status nur durch Farbe) sowie Befunde, die die > 5/10-Konsistenzschwelle verfehlen.

**Einordnung der Pareto-Perspektive.** Für die Ursachenanalyse wird ein Pareto-Diagramm<sup>207</sup> gezielt auf **test-100 mit `qwen3:32b`** angewendet, da dieses Modell den höchsten Recall bei zugleich nur 1 / 10 trunzierten Testläufen erreicht. Die verbleibenden Lücken lassen sich damit weniger auf offensichtliche Modellschwächen als vielmehr auf strukturell schwierige Violations zurückführen.

**Laufzeit und Einsatzkontext.** Die Gesamtlaufzeit steigt auf test-100 deutlich an; alle drei Modelle überschreiten Anforderung NFA-02:

- `qwen2.5-coder:7b`: durchschnittlich 765 s
- `qwen2.5-coder:14b`: durchschnittlich 1 550 s
- `qwen3:32b`: durchschnittlich 2 616 s

---

<sup>207</sup> Ein Pareto-Diagramm kombiniert ein nach Häufigkeit absteigend sortiertes Balkendiagramm mit einer kumulativen Linie und macht so sichtbar, welche Ursachenklassen den größten Anteil am Gesamtproblem ausmachen (Pareto-Prinzip: ca. 80 % der Effekte entstehen durch 20 % der Ursachen).

Dies ist als Erkenntnis über den geeigneten Einsatzkontext zu interpretieren: ACE eignet sich bei komplexen Anwendungen strukturell nicht für per-Commit-CI/CD-Läufe, wohl aber für Release-Gates oder Nightly-Workflows.

**Erkennungsrate, Empfehlungsqualität und CSV-Auszug.** Die vollständige Violation-für-Violation-Auswertung findet sich in den Anhang-Tabellen 47, 48 und 57. In Testlauf 01 erhalten alle 73 erkannten Violations mit `qwen3:32b` die Bewertung Stufe 2. Der konsistente Recall über alle 10 Testläufe beträgt 63 / 100.

**Gesamteinordnung test-100.** Für die test-100-Suite ergibt sich ein klarer Trade-off: `qwen3:32b` liefert den höchsten Recall (63 %) und die stärkste Empfehlungsqualität, ist aber mit deutlichem Laufzeitnachteil verbunden; `qwen2.5-coder:14b` liegt bei der Erkennungsleistung darunter (53 %), bleibt jedoch als pragmatischer Kompromiss aus Qualität und Aufwand relevant.

### 8.7.3 Evaluation am BWEC-Untersuchungsobjekt

Ergänzend wurde das reale Untersuchungsobjekt BWEC der BITBW evaluiert. Da keine bekannte Ground Truth vorliegt, beschränkt sich die Evaluation auf Systemstabilität, Skalierungseffekte und qualitative Plausibilität der generierten Befunde.

**Konfiguration und Tool-Baseline.** Es wurden zwei Konfigurationen mit je 9 Testläufen durchgeführt: *bwec* mit `maxfiles=100` (66 Chunks) und *bwec-500* mit `maxfiles=500` (330 Chunks) als Skalierungsexperiment. Die deterministischen Quellen liefern über alle 18 Testläufe hinweg konstant axe-core 10, Playwright 2 und grep 8 Findings (Summe: 20), was die deterministische Eigenschaft dieser Quellen auch am realen Untersuchungsobjekt bestätigt (vgl. Anhang 64).

**Ergebnisse bei `maxfiles = 100` (66 Chunks).** Mit der für den produktiven Einsatz vorgesehenen Konfiguration verhält sich das System stabil; alle Reports sind parsebar. Der LLM-Detektor liefert:

- `qwen2.5-coder:7b`: durchschnittlich 14,5 Findings, Laufzeit durchschnittlich 328 s; erfüllt Anforderung NFA-02
- `qwen2.5-coder:14b`: durchschnittlich 22,0 Findings, Laufzeit durchschnittlich 824 s; überschreitet Anforderung NFA-02
- `qwen3:32b`: durchschnittlich 32,0 Findings, Laufzeit durchschnittlich 2 128 s; überschreitet Anforderung NFA-02

**Skalierungsexperiment: `maxfiles = 500` (330 Chunks).** Das Experiment adressiert bewusst einen Grenzfall außerhalb des vorgesehenen Einsatzkontexts. Der LLM-Detektor erzeugt deutlich mehr Findings:

- `qwen2.5-coder:7b`: durchschnittlich 257 Findings
- `qwen2.5-coder:14b`: durchschnittlich 271 Findings

- **qwen3:32b**: durchschnittlich 415 Findings

Kein Testlauf von **qwen3:32b** liefert einen parsebaren Report; **qwen2.5-coder:14b** erschöpft in zwei von drei Testläufen das Output-Budget. Dieses Ergebnis ist daher weniger als Systemfehler denn als **Use-Case-Mismatch** zu interpretieren: ACE ist nicht darauf ausgelegt, eine gewachsene Produktivapplikation vollständig nachzuauditieren, sondern den Entwicklungsprozess bei einer begrenzten Anzahl geänderter Komponenten je Iteration zu begleiten.

**Qualitative Plausibilitätsprüfung.** Die im BWEC-Lauf (`maxfiles` = 100) generierten Findings mit **qwen3:32b** referenzieren ausschließlich real im Quellcode vorhandene Dateien und Komponenten. Die benannten Violations entsprechen bekannten React-Accessibility-Anti-Patterns und sind inhaltlich plausibel. Eine formale Expertenvalidierung steht aus; die Dateibezüge und Fix-Vorschläge legen jedoch eine hohe praktische Verwertbarkeit nahe.

## 8.8 Beantwortung der Forschungsfragen

Auf Basis der in den Abschnitten 8.2–8.6 dokumentierten Ergebnisse können die in Abschnitt 1.3 formulierten Forschungsfragen nun beantwortet werden.

### 8.8.1 Übergeordnete Forschungsfrage

Die übergeordnete Forschungsfrage kann positiv beantwortet werden, mit modell- und lastabhängigen Einschränkungen: Das kontextsensitive Assistenzsystem erkennt einen substanziellen Teil relevanter Barrierefreiheitsverstöße automatisiert und erzeugt entwicklernahe Empfehlungen mit konkreten Datei-/Zeilenbezügen. Insbesondere Token-Limits und Laufzeitrestriktionen begrenzen die Ergebnisse jedoch auf größeren Suites.

### 8.8.2 TF1: Erkennungsleistung nach Verstoßtyp

**Ja – mit modellabhängigen Einschränkungen.** Mit **qwen2.5-coder:14b** und **qwen3:32b** erkennt die vollständige Pipeline auf der test-12-Suite alle drei Verstoßkategorien vollständig: syntaktische, layout-bezogene und semantische Violations jeweils zu 100 % (vgl. Tabelle 8). Die größte methodische Herausforderung liegt im semantischen Bereich: Hier ist der Baseline-Recall mit 60 % am niedrigsten, und der LLM-Detektor leistet den größten Einzelbeitrag (+40 Prozentpunkte). Bei **qwen2.5-coder:7b** bestehen hingegen modellspezifische Grenzen.

Über die drei kontrollierten Testsuiten zeigt sich konsistent ein Mehrwert durch die LLM-Erweiterung: auf test-12 steigt der Recall von 66,7 % auf bis zu 100 %, auf test-50 von 43/50 auf 48/50 bzw. 50/50 und auf test-100 von 34/100 auf 53/100 bzw. 63/100. Ein direkter Benchmark gegen Literaturwerte bleibt methodisch eingeschränkt, da Datensätze, Ground-Truth-Konstruktion, Metriken und Laufzeitumgebungen nicht identisch sind.

### 8.8.3 TF2: Mehrwert der Kontextkombination und Ablationsanalyse

**Ja, der Mehrwert ist messbar und zeigt sich sowohl quantitativ als auch qualitativ.** Die Tool-Pipeline (axe + Playwright + grep) erreicht auf test-12 einen Recall von 66,7 % (8/12). Durch den LLM-Detektor steigt der Recall auf bis zu 100 %. Dabei betrifft der Zugewinn genau jene Violations, die durch die regelbasierten Quellen nicht zuverlässig erreichbar sind: V8 (modaler Fokus-Trap), V11 (DOM-/visuelle Reihenfolge) und V12 (Mindestgröße interaktiver Elemente) werden erst durch die LLM-gestützte Analyse konsistent erfasst; V2 (fehlendes `aria-label` auf Icon-Button) ebenfalls ab 14b.

**Ablationsanalyse: Beitrag des LLM-Detektors.** Um den Recall-Beitrag der einzelnen Pipeline-Stufen zu isolieren, werden zwei empirisch gemessene Bedingungen um eine architekturell begründete Bedingung B ergänzt:

| Bed. | Konfiguration                                    | Recall test-12  | Quelle         |
|------|--------------------------------------------------|-----------------|----------------|
| A    | Tool-Baseline (axe + PW + grep, kein LLM)        | 8 / 12 (66,7 %) | gemessen       |
| B    | Stufe-2-Priorisierer ohne LLM-Detektor (Stufe 1) | $\leq 8 / 12$   | architekturell |
| C    | Vollständige Pipeline (Stufe 1 + 2, qwen3:32b)   | 12 / 12 (100 %) | gemessen       |

Tab. 11: Ablationsanalyse auf test-12. Bedingung B ist architekturell begründet: Der Priorisierer (Stufe 2) verarbeitet ausschließlich die ihm übergebenen Findings und kann daher per Konstruktion keine neuen Violations erkennen.

Bedingung B ist konstruktiv ableitbar: Der LLM-Priorisierer in Stufe 2 erhält als Eingabe ausschließlich die von den Tool-Quellen gemeldeten Findings – er kann keine Violations erkennen, die nicht bereits in diesem Input enthalten sind. Die empirischen Daten stützen diese architekturelle Ableitung: In keinem der 30 Testläufe auf test-12 tritt eine Violation erstmals im Stufe-2-Output auf, die nicht bereits durch die Quellen in Stufe 1 gemeldet wurde. Folglich gilt  $\text{Recall}(B) \leq \text{Recall}(A)$ . Der empirisch messbare Recall-Zuwachs von 8/12 auf 12/12 ist damit kausal dem LLM-Detektor (Stufe 1) zuzuschreiben, der den React-Quellcode chunkweise semantisch analysiert und dabei V2, V8, V11 und V12 aufdeckt. Diese Violations entziehen sich der regelbasierten Prüfung, weil sie entweder semantisches Kontextwissen (V2: inhaltlich unzureichendes `aria-label`), Zustandsabhängigkeit (V8: modale Fokusführung) oder Layout-Semantik (V11: DOM-/visuelle Reihenfolgedivergenz) erfordern. Die Aussage bleibt bewusst vorsichtig: Da keine vollständige Ablationsstudie mit isolierten Bedingungen auf allen drei Suites durchgeführt wurde, handelt es sich um eine auf test-12 beschränkte Partialablation.

Zusätzlich verbessert die Kontextkombination die Umsetzbarkeit der Empfehlungen: Tool-Befunde werden mit Quellcodekontext verbunden, wodurch konkrete, entwicklungsnahe Fix-Vorschläge entstehen (Stufe 2 für 11 von 12 Violations mit 32b auf test-12). Gegenüber einer reinen Tool-/DOM-Sicht steigt damit nicht nur die Erkennungsbreite, sondern auch die praktische Anschlussfähigkeit.

## 8.9 Modellwahl und Einsatzempfehlungen

Aus den vorstehenden Ergebnissen zu Recall, Priorisierungsqualität, Fix-Qualität und Laufzeit lassen sich folgende Einsatzempfehlungen ableiten. Eine suiteübergreifende Einordnung findet sich ergänzend in den Anhang-Tabellen 17 und 58.

| Szenario                                       | Empfehlung                                                                                                                  |
|------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------|
| Regulärer Entwicklungszyklus / Compliance-Gate | <b>qwen2.5-coder:14b</b> als Standardmodell für kleine bis mittlere Befundmengen; guter Trade-off aus Qualität und Laufzeit |
| CI/CD-Smoke-Test (nicht compliance-relevant)   | <b>qwen2.5-coder:7b</b> ; schnellstes Feedback, aber nicht für verbindliche Bewertungen geeignet                            |
| Endaudit / Referenzläufe                       | <b>qwen3:32b</b> ; höchste inhaltliche Abdeckung, aber deutlich höhere Laufzeit                                             |

Tab. 12: Modellwahl nach Anwendungsszenario.

**qwen2.5-coder:14b** stellt unter Kalibrierungs- und mittleren Lastbedingungen den besten Trade-off dar. Das Modell erreicht 100 % Recall auf test-12, 96 % auf test-50 und bleibt dort noch in einem vertretbaren Aufwand-Korridor. Auf test-100 wird jedoch deutlich, dass 14b bei großen Befundmengen systematisch an das Output-Limit stößt: 100 % Truncation und 53 % Recall zeigen, dass das Modell für sehr große Reports strukturell überfordert ist.

**qwen3:32b** stellt weiterhin das methodisch stärkste Referenzmodell dar, wenn maximale Stabilität im finalen Bericht und möglichst hohe semantische Abdeckung im Vordergrund stehen. Der Zugewinn gegenüber 14b fällt bei kleinen Suites jedoch geringer aus als der zusätzliche Zeitaufwand. Für regelmäßige Entwicklungszyklen ist 32b daher eher als Referenz- oder Endaudit-Modell zu verstehen.

**qwen2.5-coder:7b** eignet sich vor allem für schnelle Vorprüfungen in CI/CD-nahen Szenarien. Die Laufzeit ist am niedrigsten, zugleich bleibt die Detektionsleistung deutlich hinter 14b und 32b zurück, und die Priorisierung ist für compliance-relevante Einsätze nicht hinreichend verlässlich. Für rechtlich oder fachlich verbindliche Accessibility-Bewertungen sollte 7b daher nicht als Primärmodell eingesetzt werden.

## 9 Fazit

Dieses abschließende Kapitel fasst die Ergebnisse der Arbeit zusammen (Abschnitt 9.1), reflektiert deren Aussagekraft kritisch (Abschnitt 9.2) und skizziert Ansatzpunkte für künftige Weiterentwicklungen (Abschnitt 9.3).

### 9.1 Zusammenfassung der Ergebnisse

#### 9.1.1 Beitrag zur übergeordneten Forschungsfrage

Mit ACE wurde ein DSR-Artefakt entwickelt, das regelbasierte Prüfung, Interaktionsanalyse, Quellcodekontext und LLM-gestützte Auswertung in einer Pipeline zusammenführt. Die Hauptevaluation umfasste 90 Benchmarkläufe (3 Modelle  $\times$  10 Testläufe je Testsuite) über die drei synthetischen Testsuiten test-12, test-50 und test-100. Die Beantwortung beider TFs fällt dabei je nach Evaluationssuite unterschiedlich aus und wird im Folgenden differenziert dargestellt.

Im Rahmen der synthetischen Evaluation kann **TF1** grundsätzlich bestätigt werden. Die kombinierte Pipeline erzielt auf der test-100-Suite mit **qwen3:32b** einen konsistenten Recall von 63 / 100 Violations und liegt damit deutlich über der Tool-only-Baseline von 34 / 100. Die Arbeit zeigt damit keinen vollautomatischen Ersatz manueller Accessibility-Prüfung, sondern vielmehr eine substanzielle Erweiterung bestehender Toolketten.

**TF2** wird auf der Kalibrierungssuite vollständig bestätigt. Auf den Belastungssuiten wird der Effekt jedoch durch Token-Budget-Restriktionen begrenzt, sowohl hinsichtlich der Erkennungsleistung als auch der Empfehlungsqualität. Die Ablationsanalyse in Tabelle 11 zeigt, dass der Recall-Zuwachs von der Tool-Baseline (8 / 12; 66,7%) auf die vollständige Pipeline (12 / 12; 100%) kausal auf den LLM-Detektor (Stufe 1) zurückzuführen ist. Der Priorisierer in Stufe 2 kann konstruktionsbedingt keine Violations erkennen, die nicht bereits in seinem Input enthalten sind, und beeinflusst somit ausschließlich die Priorisierungsqualität, nicht jedoch den Recall. Hinsichtlich der Empfehlungsqualität erreicht **qwen3:32b** auf test-12 für 11 / 12 Violations die Stufe 2. Dies entspricht konkreten, entwicklungsnahen Verbesserungsvorschlägen mit Dateibezug und unmittelbarem Umsetzungsbezug im Code. Diese Aussage ist jedoch bewusst vorsichtig zu interpretieren, da sich die Ablationsanalyse auf test-12 beschränkt. Eine Generalisierung auf größere Suites müsste durch weitere Experimente abgesichert werden. Detaillierte Werte finden sich in den Tabellen 11, 24, 26, 48 und 32.

#### 9.1.2 Erfüllung der funktionalen und nicht-funktionalen Anforderungen

Die fünf funktionalen Anforderungen FA-01 bis FA-05 wurden vollständig umgesetzt. Axe-core übernimmt die regelbasierte Basiserkennung (FA-01), Playwright erfasst zustandsabhängige Bar-

rieren (FA-02), die grep-gestützte Quellcodeanalyse erweitert die Sicht auf statische Muster (FA-03), die zweistufige LLM-Verarbeitung erzeugt priorisierte Handlungsempfehlungen (FA-04) und der strukturierte JSON-Report ermöglicht maschinelle Weiterverarbeitung (FA-05).

NFA-01 (Lokal-First) wird vollständig erfüllt. NFA-02 (Laufzeit) wird nur teilweise erreicht: Auf test-12 erfüllen 7b und 14b die Grenze, 32b nur eingeschränkt; auf test-100 überschreiten alle drei Modelle sie deutlich – ACE eignet sich dort eher für release-nahe oder nächtliche Analysezyklen als für per-Commit-Läufe. NFA-03 (Wartbarkeit) wird durch die modulare Architektur unterstützt. NFA-04 (Reproduzierbarkeit) wird teilweise erreicht: Die Varianz steigt mit der Suite-Größe, ist aber für einen experimentellen PoC ausreichend. Eine tabellarische Gesamtübersicht findet sich in Tabelle 19 im Anhang.

## 9.2 Kritische Reflexion

### 9.2.1 Grenzen der externen Validität

Die belastbarste Evidenz dieser Arbeit stammt aus den drei synthetischen Testsuiten. Synthetisch eingebrachte Violations sind in ihrer Struktur kontrollierter und klarer isolierbar als Barrieren in realen Anwendungssystemen, in denen technische Altlasten, Projektkonventionen und historisch gewachsene UI-Muster zusammenwirken. Der auf test-100 mit **qwen3:32b** erreichte Recall von 63 % ist daher als belastbarer Laborwert innerhalb der gewählten Evaluationslogik zu verstehen, nicht jedoch als direkt übertragbarer Erwartungswert für produktive Systeme.

Die ergänzende Erprobung am BWEC zeigt, dass das System grundsätzlich auf ein reales Untersuchungsobjekt übertragen werden kann und dort plausible, datei- und zeilennahe Befunde erzeugt. Zugleich treten die Skalierungsprobleme der Priorisierungsphase in realen Codebasen deutlicher hervor als in den synthetischen Suiten. Bei **maxfiles** = 500 zeigen sich Truncation, kollabierte Outputs und instabile Priorisierung deutlich. Der BWEC ist daher als Feldtest der praktischen Einsetzbarkeit und Systemgrenzen zu verstehen, nicht als quantitative Recall-Validierung.

### 9.2.2 Methodische Einschränkungen

Die Evaluation unterliegt drei methodischen Einschränkungen:

1. Das verfügbare Token-Budget beeinflusst die Priorisierungsqualität systematisch: Auf test-100 schöpft 14b in allen 10 Testläufen das Output-Limit aus, 7b in 80 % der Testläufe. **qwen3:32b** liefert die methodisch robusteste Basis (nur 1 / 10 trunkierte Testläufe), löst das Skalierungsproblem jedoch nicht vollständig.



2. Die Erkennungsbewertung beruht auf einer Operationalisierung über die Report-Präsenz (Mehrheit der Testläufe), nicht auf einer formalen semantischen Äquivalenzklasse. Semantisch äquivalente, anders formulierte Findings können dadurch zu Unterschätzungen führen. Die Ergebnisse sind deskriptiv belastbar, aber nicht inferenzstatistisch verallgemeinerbar.
3. Eine vollständige Precision-Evaluation über alle Testläufe der großen Suiten wurde nicht durchgeführt. Die ergänzende Stichprobenprüfung für **qwen3:32b** auf test-100 zeigt, dass echte Halluzinationen selten auftreten (1 von 176 geprüften Einträgen), der größere Teil der Überdetektion also auf Quell-Duplikate und Paraphrasen zurückgeht. Für den produktiven Einsatz bleibt dennoch eine nachgelagerte Plausibilisierung erforderlich.

## 9.3 Ausblick

### 9.3.1 Kurz- und mittelfristige Weiterentwicklungen

Kurzfristig bieten sich vier Weiterentwicklungen an:

1. **Manuelle Plausibilisierung des BWEC-Blocks:** Expertenabgleich der Pipeline-Ergebnisse mit einer referenziellen Baseline.
2. **Gezielte Playwright-Interaktionsprüfungen:** Erweiterung der Checks um Dialog-Fokusübernahme und Interaktionsnavigation.
3. **Deduplikations- und Konsolidierungslogik:** Nachgelagerte Zusammenführung überlappender Findings aus den vier Detektionsquellen.
4. **Formalisierung der Stichprobenprüfung:** Integration als fester Workflow-Bestandteil zur systematischen Quantifizierung von Halluzinationsraten und Deduplikationsbedarf.

Mittelfristig stehen Verbesserungen der Skalierbarkeit im Vordergrund: Die Priorisierungsphase könnte hierarchisch umgebaut werden – statt eines einzigen großen Prompts wären mehrstufige Cluster- oder Zusammenfassungsverfahren denkbar, da die BWEC-Messungen den zentralen technischen Engpass in diesem Schritt erkennen lassen. Ergänzend könnte axe-core auf mehreren systematisch durchlaufenen DOM-Zuständen ausgeführt werden, und der strukturierte JSON-Report könnte als Grundlage für nachgelagerte Automatisierung dienen – insbesondere die Übergabe der priorisierten Aufgabenliste an einen nachgelagerten Agenten, der Findings eigenständig in Issue-Tracker überführt, Pull-Request-Beschreibungen generiert oder Korrekturen in einer integrierten Entwicklungsumgebung umsetzt.

### 9.3.2 Langfristige Forschungsperspektiven

Langfristig erscheint insbesondere eine stärkere Spezialisierung des verwendeten Modells vielversprechend. Ein domänenspezifisch feinabgestimmtes Modell auf Accessibility-relevanten React-/TypeScript-Beispielen und typischen BITV-Kontexten könnte systematische Fehlklassifikationen reduzieren und die Priorisierungslogik stabilisieren – eine Verschiebung von der reinen Modellgrößenstrategie hin zu einer wissens- und domänenspezifischen Optimierung.

Realistischer als eine vollständige Analyse großer Codebasen in jeder Pipeline-Ausführung erscheint ein gestuftes Betriebsmodell: leichte Prüfungen auf Komponenten- oder Änderungsbasis während der Entwicklung, tiefere Analysen in qualitätssichernden Release- oder Nightly-Kontexten. In dieser differenzierten Form – als *Continuous-Accessibility-Loop* aus automatischer Erkennung, konsolidierter Priorisierung, unterstützter Behebung und erneuter Prüfung – läge der Beitrag von ACE in der nachhaltigen Reduktion manuellen Prüfaufwands sowie in der frühzeitigen Sichtbarmachung relevanter Barrieren im Entwicklungsprozess.

# Anhang

## Anhangverzeichnis

|           |                                                                                               |     |
|-----------|-----------------------------------------------------------------------------------------------|-----|
| Anhang 1  | Übersicht der Anhangsstruktur . . . . .                                                       | 67  |
| Anhang 2  | Komplexität von Home Pages . . . . .                                                          | 68  |
| Anhang 3  | Erweiterte Konzeptmatrix . . . . .                                                            | 68  |
| Anhang 4  | Schematische Übersicht der ACE-Pipeline . . . . .                                             | 70  |
| Anhang 5  | TypeScript-Interface des Unified Finding Schema . . . . .                                     | 71  |
| Anhang 6  | Projektstruktur des PoC . . . . .                                                             | 72  |
| Anhang 7  | Playwright-Checks und grep-Patterns . . . . .                                                 | 72  |
| Anhang 8  | System-Prompt des ACE-Assistenzsystems . . . . .                                              | 73  |
| Anhang 9  | Prompts der LLM-Detektor-Phase . . . . .                                                      | 75  |
| Anhang 10 | Aufteilung des Token-Budgets . . . . .                                                        | 76  |
| Anhang 11 | Empfehlung nach Anwendungsszenario (konsolidiert) . . . . .                                   | 77  |
| Anhang 12 | Bewertungsskala für die Empfehlungsqualität der LLM-Ausgaben . . . . .                        | 78  |
| Anhang 13 | Erfüllungsgrad der funktionalen und nicht-funktionalen Anforderungen . . . . .                | 79  |
| Anhang 14 | Reproduzierbarkeitsblatt . . . . .                                                            | 81  |
| Anhang 15 | Threats to Validity . . . . .                                                                 | 82  |
| Anhang 16 | Accessibility-Verstöße der Testanwendung und zugehörige Prüfquellen (test-12-Suite) . . . . . | 84  |
| Anhang 17 | Erkennungsrate der Violations im Proof of Concept (test-12-Suite) . . . . .                   | 85  |
| Anhang 18 | Recall-Matrix: Violation × Bedingung (test-12-Suite) . . . . .                                | 86  |
| Anhang 19 | Rohdaten: alle 30 Benchmark-Runs (test-12-Suite) . . . . .                                    | 87  |
| Anhang 20 | Modell-Leistungsvergleich: test-12-Suite Zusammenfassung . . . . .                            | 88  |
| Anhang 21 | Token-Nutzung pro Modell: Input/Output (test-12-Suite) . . . . .                              | 89  |
| Anhang 22 | Laufzeit und Effizienz der Pipeline-Modelle (test-12-Suite) . . . . .                         | 89  |
| Anhang 23 | Über-Detektion relativ zur Ground Truth (test-12-Suite) . . . . .                             | 90  |
| Anhang 24 | Detektor-Konsistenz über alle 30 Runs (test-12-Suite) . . . . .                               | 90  |
| Anhang 25 | Bewertung der Empfehlungsqualität pro Violation (test-12-Suite) . . . . .                     | 91  |
| Anhang 26 | CSV-Auszug: Benchmark-Rohdaten (test-12-Suite) . . . . .                                      | 92  |
| Anhang 27 | Ansichten der Testanwendung (test-12-Suite) . . . . .                                         | 93  |
| Anhang 28 | Accessibility-Verstöße der Testanwendung (test-50-Suite) . . . . .                            | 94  |
| Anhang 29 | Erkennungsrate der Violations im Proof of Concept (test-50-Suite) . . . . .                   | 97  |
| Anhang 30 | Recall-Matrix: Violation × Bedingung (test-50-Suite) . . . . .                                | 100 |
| Anhang 31 | Rohdaten: alle 30 Benchmark-Runs (test-50-Suite) . . . . .                                    | 103 |
| Anhang 32 | Modell-Leistungsvergleich: test-50-Suite Zusammenfassung . . . . .                            | 104 |
| Anhang 33 | Token-Nutzung pro Modell: Input/Output (test-50-Suite) . . . . .                              | 105 |
| Anhang 34 | Effizienzmetriken und Kosten-Nutzen-Verhältnis (test-50-Suite) . . . . .                      | 105 |
| Anhang 35 | Über-Detektion relativ zur Ground Truth (test-50-Suite) . . . . .                             | 106 |

|           |                                                                                                                |     |
|-----------|----------------------------------------------------------------------------------------------------------------|-----|
| Anhang 36 | Precision und F1-Score je Run (test-50-Suite) . . . . .                                                        | 107 |
| Anhang 37 | Detektor-Konsistenz über alle 30 Runs (test-50-Suite) . . . . .                                                | 107 |
| Anhang 38 | Bewertung der Empfehlungsqualität pro Violation (test-50-Suite) . . . . .                                      | 108 |
| Anhang 39 | Ansichten der Testanwendung (test-50-Suite) . . . . .                                                          | 112 |
| Anhang 40 | Accessibility-Verstöße der Testanwendung (test-100-Suite) . . . . .                                            | 114 |
| Anhang 41 | Erkennungsrate der Violations im Proof of Concept (test-100-Suite) . . . . .                                   | 118 |
| Anhang 42 | Recall-Matrix: Violation $\times$ Bedingung (test-100-Suite) . . . . .                                         | 123 |
| Anhang 43 | Rohdaten: alle 30 Benchmark-Runs (test-100-Suite) . . . . .                                                    | 128 |
| Anhang 44 | Modell-Leistungsvergleich: test-100-Suite Zusammenfassung . . . . .                                            | 129 |
| Anhang 45 | Token-Nutzung pro Modell: Input/Output (test-100-Suite) . . . . .                                              | 130 |
| Anhang 46 | Effizienzmetriken (test-100-Suite) . . . . .                                                                   | 130 |
| Anhang 47 | Über-Detektion relativ zur Ground Truth (test-100-Suite) . . . . .                                             | 131 |
| Anhang 48 | Stichproben-Plausibilisierung des finalen Reports ( <b>qwen3:32b</b> , Run 01 &<br>Run 03, test-100) . . . . . | 132 |
| Anhang 49 | Precision und F1-Score je Run (test-100-Suite) . . . . .                                                       | 133 |
| Anhang 50 | Detektor-Konsistenz über alle 30 Runs (test-100-Suite) . . . . .                                               | 134 |
| Anhang 51 | Bewertung der Empfehlungsqualität pro Violation (test-100-Suite) . . . . .                                     | 135 |
| Anhang 52 | Pareto-Diagramm: Nicht erkannte Violations (test-100, <b>qwen3:32b</b> ) . . . . .                             | 142 |
| Anhang 53 | Boxplot der Laufzeiten (test-100, 10 Runs je Modell) . . . . .                                                 | 143 |
| Anhang 54 | Pipeline-Diagramm der Findings-Verarbeitung . . . . .                                                          | 144 |
| Anhang 55 | Ansichten der Testanwendung (test-100-Suite) . . . . .                                                         | 145 |
| Anhang 56 | Vergleich über alle Suites . . . . .                                                                           | 147 |
| Anhang 57 | Recall-Degradation über alle Testsuites . . . . .                                                              | 148 |
| Anhang 58 | Gesamtlaufzeit-Skalierung über alle Testsuites . . . . .                                                       | 149 |
| Anhang 59 | LLM-Konsistenz ( $\sigma$ ) im Suite-Vergleich . . . . .                                                       | 150 |
| Anhang 60 | Recall und Überschuss - nach Suite gruppiert . . . . .                                                         | 151 |
| Anhang 61 | Truncation-Rate im Suite-Vergleich . . . . .                                                                   | 152 |
| Anhang 62 | Heatmap der Recall-Werte . . . . .                                                                             | 153 |
| Anhang 63 | Gestapeltes Balkendiagramm: Must-have vs. Nice-to-have . . . . .                                               | 154 |
| Anhang 64 | Detektionsquellen-Übersicht: BWEC . . . . .                                                                    | 155 |
| Anhang 65 | Rohdaten: BWEC-Messreihe ( <b>maxfiles</b> = 100, 66 Chunks) . . . . .                                         | 156 |
| Anhang 66 | Modell-Leistungsvergleich: BWEC ( <b>maxfiles</b> = 100) . . . . .                                             | 157 |
| Anhang 67 | Rohdaten: BWEC-Messreihe ( <b>maxfiles</b> = 500, 330 Chunks) . . . . .                                        | 158 |
| Anhang 68 | Modell-Leistungsvergleich: BWEC ( <b>maxfiles</b> = 500) . . . . .                                             | 159 |

## Anhang 1: Übersicht der Anhangsstruktur

Tab. 13: Übersicht der Anhangsstruktur mit Trennung zwischen generellen und suite-spezifischen Inhalten.

| Bereich            | Inhalte                                                                                                                                                                                                                                                                                                    |
|--------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Generell           | Komplexität von Home Pages, Konzeptmatrix, Pipeline-Schema, Projektstruktur, Playwright-Checks & grep-Patterns, System-Prompt, LLM-Detektor-Prompts, Token-Budget, konsolidierte Empfehlung, Bewertungsskala, FA/NFA-Erfüllungsgrad, Reproduzierbarkeitsblatt, Console-Output-Auszüge, Threats to Validity |
| Vergleichsgrafiken | Suite-Vergleich (Tabelle), Recall-Degradation, Laufzeit-Skalierung, Konsistenz ( $\sigma$ ), Recall/Überschuss (Suite-Gruppen), Truncation-Rate, Heatmap Recall, Must-/Nice-to-have-Verteilung                                                                                                             |
| test-12-Block      | Violations-Katalog, Erkennungsrate, Recall-Matrix, Rohdaten, Modellvergleich, Token-Nutzung, Laufzeit, Effizienz, Über-Detektion, Konsistenz, Empfehlungsqualität, CSV-Auszug, Ansichten der Testsuite                                                                                                     |
| test-50-Block      | Violations-Katalog, Erkennungsrate, Recall-Matrix, Rohdaten, Modellvergleich, Token-Nutzung, Effizienz, Über-Detektion, Precision/F1 je Run, Konsistenz, Empfehlungsqualität, Ansichten der Testsuite                                                                                                      |
| test-100-Block     | Violations-Katalog, Erkennungsrate, Recall-Matrix, Rohdaten, Modellvergleich, Token-Nutzung, Effizienz, Über-Detektion, Stichproben-Plausibilisierung, Precision/F1 je Run, Konsistenz, Empfehlungsqualität, Pareto-Diagramm, Boxplot Laufzeiten, Pipeline-Diagramm, Ansichten der Testsuite               |
| BWEC-Block         | Detektionsquellen-Übersicht, Rohdaten (maxfiles=100), Modellvergleich (maxfiles=100), Rohdaten (maxfiles=500), Modellvergleich (maxfiles=500)                                                                                                                                                              |

## Anhang 2: Komplexität von Home Pages




Abb. 5: Entwicklung der Komplexität von Home Pages in den letzten sechs Jahren. Die X-Achse zeigt die Jahre, die Y-Achse gibt die Anzahl der Elemente an.<sup>208</sup>

## Anhang 3: Erweiterte Konzeptmatrix

*(Tabelle auf der nächsten Seite.)*

| Studie                                |                     | Konzepte          |                       |                         |                         |                                |                   |                  |                       |                  |                      |                   |              |                   |                            |
|---------------------------------------|---------------------|-------------------|-----------------------|-------------------------|-------------------------|--------------------------------|-------------------|------------------|-----------------------|------------------|----------------------|-------------------|--------------|-------------------|----------------------------|
| Autor(en)<br>& Jahr                   | System              | Ziel              |                       |                         | Datenquellen            |                                |                   | KI- / LLM-Ansatz |                       |                  | Evaluation           |                   |              | Kontext           |                            |
|                                       |                     | WCAG-Konf. prüfen | Barrieren korrigieren | Entwickler unterstützen | Tool-Reports (axe etc.) | Interaktionsdaten (Playwright) | Quellcode-Analyse | LLM-basiert      | Kontextsensitiv / RAG | Lokal ausführbar | Automatisierte Eval. | Qualitative Eval. | Nutzerstudie | Rich-Client / SPA | Rechtl. Rahmen (BFSG etc.) |
| Hoch priorisierte Studien             |                     |                   |                       |                         |                         |                                |                   |                  |                       |                  |                      |                   |              |                   |                            |
| He et al. (2025)                      | GenA11y             | x                 |                       |                         | x                       |                                |                   | x                |                       |                  | x                    |                   |              |                   |                            |
| Fathallah et al. (2025)               | AccessGuru          | x                 | x                     | x                       | x                       | x                              |                   | x                |                       |                  | x                    |                   |              |                   |                            |
| Bassi et al. (2025)                   | LLM Auditing        | x                 | x                     | x                       |                         |                                |                   | x                |                       |                  |                      | x                 |              |                   | x                          |
| Paternò et al. (2025)                 | TeVal               | x                 |                       | x                       | x                       |                                |                   | x                | x                     |                  |                      | x                 |              |                   |                            |
| Tafreshipour et al. (2024)            | Ma11y               | x                 |                       |                         | x                       | x                              |                   |                  |                       |                  | x                    |                   |              |                   |                            |
| Fernández-Navarro & Chicano (2026)    | LLM Remediation     | x                 | x                     | x                       | x                       |                                | x                 | x                |                       |                  | x                    |                   |              | x                 |                            |
| Mittel priorisierte Studien           |                     |                   |                       |                         |                         |                                |                   |                  |                       |                  |                      |                   |              |                   |                            |
| Yu et al. (2025)                      | GenAI Screen Reader | x                 | x                     |                         | x                       |                                | x                 | x                | x                     |                  | x                    | x                 | x            |                   |                            |
| Huang et al. (2024)                   | ACCESS              | x                 | x                     | x                       | x                       | x                              |                   | x                |                       |                  | x                    |                   |              |                   |                            |
| Pool (2023)                           | Testaro             | x                 |                       |                         | x                       | x                              |                   |                  |                       |                  | x                    |                   |              |                   |                            |
| Mowar et al. (2024)                   | Copilot Study       | x                 |                       | x                       |                         |                                |                   | x                |                       |                  |                      |                   | x            |                   |                            |
| Abu Doush & Kassem (2024)             | AI Code Study       | x                 | x                     | x                       |                         |                                |                   | x                |                       |                  | x                    |                   |              |                   |                            |
| Guriță & Vatavu (2025)                | AI UI Study         | x                 |                       |                         |                         |                                |                   | x                |                       |                  | x                    |                   |              |                   |                            |
| Kodithuwakku & Wick. (2025)           | Tool Eval.          | x                 |                       |                         | x                       |                                |                   |                  |                       |                  | x                    |                   |              |                   |                            |
| Manca et al. (2023)                   | Transparency        | x                 |                       | x                       | x                       |                                |                   |                  |                       |                  |                      | x                 | x            |                   |                            |
| Jiang & Nam (2025)                    | Cursor Rules        |                   |                       | x                       |                         |                                | x                 | x                |                       |                  |                      | x                 |              |                   |                            |
| Gubbi Mohanbabu & Pavel (2024)        | Context-Aware Img.  | x                 | x                     |                         |                         |                                |                   | x                | x                     |                  | x                    | x                 | x            |                   |                            |
| Campoverde-Molina & Luján-Mora (2025) | AI A11y SMS         | x                 | x                     | x                       | x                       |                                |                   | x                |                       |                  |                      | x                 |              |                   |                            |
| Leedy et al. (2025)                   | GenAI Builder Eval. | x                 |                       |                         | x                       |                                |                   | x                |                       |                  | x                    | x                 |              |                   |                            |
| Patel & Melcer (2025)                 | AIDA Study          | x                 |                       | x                       |                         |                                |                   | x                |                       |                  |                      | x                 | x            |                   |                            |
| Aljedaani et al. (2024)               | ChatGPT A11y Code   | x                 | x                     | x                       |                         |                                | x                 | x                |                       |                  | x                    |                   |              |                   |                            |
| Niedrig priorisierte Studien          |                     |                   |                       |                         |                         |                                |                   |                  |                       |                  |                      |                   |              |                   |                            |
| Abou-Zahra et al. (2018)              | AI for A11y         | x                 |                       |                         |                         |                                |                   | x                |                       |                  |                      | x                 |              |                   | x                          |
| Delnevo et al. (2024)                 | LLM Interaction     | x                 | x                     |                         |                         |                                |                   | x                |                       |                  |                      | x                 |              | x                 |                            |
| Draffan et al. (2020)                 | Web2Access+AI       | x                 |                       |                         | x                       |                                |                   | x                |                       |                  |                      | x                 |              |                   |                            |
| Eigener Proof of Concept              |                     |                   |                       |                         |                         |                                |                   |                  |                       |                  |                      |                   |              |                   |                            |
| Martínez Campo (2026)                 | ACE (PoC)           | x                 | x                     | x                       | x                       | x                              | x                 | x                | x                     | x                | x                    | x                 | x            | x                 | x                          |

Tab. 14: Konzeptmatrix nach Webster und Watson Webster, Watson 2002: vollständige Übersicht aller analysierten Studien im Vergleich zum eigenen Proof of Concept (PoC). **x** = Konzept vorhanden/adressiert; leer = nicht adressiert. „Barrieren korrigieren“ schließt die Generierung konkreter Code-Fix-Vorschläge ein, nicht notwendigerweise automatisches Patchen.

## Anhang 4: Schematische Übersicht der ACE-Pipeline




Abb. 6: Schematische Übersicht der im PoC implementierten ACE-Pipeline von der Datenerhebung bis zur priorisierten Ausgabe. Die Code-Schiene umfasst regex-basierte Pattern (grep) und die LLM-basierte Codeanalyse. Das verwendete LLM ist in der Pipeline bewusst abstrahiert; die konkrete Modellwahl erfolgt je Einsatzszenario (vgl. Tabelle 17).



## Anhang 5: TypeScript-Interface des Unified Finding Schema

Listing 9.1: TypeScript-Interface des Unified Finding Schema

```
1 export type FindingSource = "axe" | "playwright" | "grep" | "llm";
2 export type Severity = "critical" | "serious" | "moderate" | "minor";
3 export type WcagLevel = "A" | "AA" | "AAA";
4 export type ViolationCategory = "syntaktisch" | "semantisch" | "layout";
5
6 export interface UnifiedFinding {
7   id: string;
8   source: FindingSource;
9   ruleId: string;
10  description: string;
11  severity: Severity;
12  wcagCriteria: string[];
13  wcagLevel: WcagLevel;
14  category: ViolationCategory;
15  selector: string | null;
16  componentPath: string | null;
17  codeSnippet: string | null;
18  lineRange: [number, number] | null;
19 }
```

## Anhang 6: Projektstruktur des PoC

Listing 9.2: Projektstruktur des PoC

```

1 ace/
2   src/
3     index.ts
4     types.ts
5     config.ts
6     prompt.ts
7     ollama.ts
8     output.ts
9   modules/
10    axe.ts
11    playwright.ts
12    code.ts
13    llmDetector.ts
14  results/

```

## Anhang 7: Playwright-Checks und grep-Patterns

| Check-ID               | Prüfgegenstand                                | WCAG       | Kategorie   |
|------------------------|-----------------------------------------------|------------|-------------|
| keyboard-tab-reachable | Interaktive Elemente per Tab erreichbar       | 2.1.1 (A)  | semantisch  |
| keyboard-trap-free     | Kein Keyboard-Trap nach 40 Tab-Presses        | 2.1.2 (A)  | semantisch  |
| focus-visible          | Sichtbarer Fokusindikator vorhanden           | 2.4.7 (AA) | layout      |
| skip-link-present      | Erstes Tab-Ziel ist ein Skip-Link             | 2.4.1 (A)  | semantisch  |
| page-title-present     | Seite hat einen nicht-leeren <title>          | 2.4.2 (A)  | syntaktisch |
| html-lang-present      | <html> hat ein lang-Attribut                  | 3.1.1 (A)  | syntaktisch |
| focus-after-dialog     | Fokus wandert beim Dialogöffnen in den Dialog | 2.4.3 (A)  | semantisch  |

Tab. 15: Implementierte Playwright-Checks mit WCAG-Zuordnung und Kategorie

| Pattern-ID               | Beschreibung                                       | WCAG      | Kategorie   |
|--------------------------|----------------------------------------------------|-----------|-------------|
| div-span-onclick         | onClick auf <div>/<span> ohne Keyboard-Handler     | 2.1.1 (A) | semantisch  |
| img-missing-alt          | <img> ohne alt="..."                               | 1.1.1 (A) | syntaktisch |
| label-missing-htmlfor    | <label> ohne htmlFor                               | 1.3.1 (A) | syntaktisch |
| role-button-non-semantic | role="button" auf Nicht-Button                     | 4.1.2 (A) | semantisch  |
| tabindex-removes-element | tabIndex={-1} entfernt Element aus Tab-Reihenfolge | 2.1.1 (A) | semantisch  |
| autofocus-usage          | autoFocus kann den Fokusfluss stören               | 2.4.3 (A) | semantisch  |

Tab. 16: Implementierte grep-Patterns mit WCAG-Zuordnung

## Anhang 8: System-Prompt des ACE-Assistenzsystems

Der folgende System-Prompt wird dem Sprachmodell bei jedem Pipeline-Durchlauf übergeben. Er implementiert die in Abschnitt 6.2 beschriebenen Prompt-Engineering-Strategien Role-Play Prompting und Few-Shot Prompting (vgl. Abschnitt 7.6).

Listing 9.3: Vollständiger System-Prompt des ACE-Assistenzsystems (aus `src/prompt.ts`)

```

1 Du bist ein erfahrener Barrierefreiheitsexperte für React/TypeScript-Webanwendungen.
2 Deine Aufgabe ist es, Findings aus vier Analysequellen (axe-core, Playwright, grep
3 und LLM-Codeanalyse) zu einer priorisierten, entwicklernahen To-Do-Liste zusammenzufassen
4
5 AUSGABEFORMAT (strikt einhalten):
6
7 ## Must-have
8 *WCAG 2.x Level A und AA, Severity "critical" oder "serious" -- gesetzlich relevant*
9
10 ### [ID] Kurztitel des Problems
11 - **WCAG:** X.X.X (Level X)
12 - **Schweregrad:** critical | serious
13 - **Element/Datei:** CSS-Selektor oder Dateipfad:Zeile
14 - **Problem:** Ein Satz -- was ist konkret falsch?
15 - **Fix:** Konkreter Code-Vorschlag in JSX/TypeScript
16
17 ## Nice-to-have
18 *Severity "moderate" oder "minor", Level AAA -- empfohlen aber nicht gesetzlich verpflichtig*
19
20 ### [ID] Kurztitel des Problems
21 [gleiche Struktur]
22
23 PRIORISIERUNGSREGELN:
24 1. Must-have: Severity "critical" oder "serious" UND WCAG Level A oder AA
25 2. Nice-to-have: Severity "moderate" oder "minor" ODER Level AAA
26 3. Wenn mehrere Findings dasselbe Element betreffen, fasse sie zusammen
27 4. Nutze den Codekontext für konkrete React/TypeScript-Fixes
28 5. Antworte ausschließlich auf Deutsch
29 6. Erfinde keine Findings, die nicht in den Daten vorhanden sind
30
31 BEISPIEL (Few-Shot):
32
33 Eingabe-Finding:
34 [axe-007] CRITICAL | color-contrast | WCAG 1.4.3 (AA)
35 Beschreibung: Element hat unzureichenden Farbkontrast (2.8:1 statt 4.5:1)
36 Element: .sidebar > .nav-link
37 Datei: components/Sidebar.tsx:42-52
38 Code:
39 42: <a className="nav-link" href="/dashboard">
40 43:   Dashboard
41 44: </a>
42
43 Erwartete Ausgabe:
44
45 ## Must-have
46
47 ### [axe-007] Farbkontrast der Sidebar-Navigation unzureichend

```

```
48 - **WCAG:** 1.4.3 (Level AA)
49 - **Schweregrad:** critical
50 - **Element/Datei:** components/Sidebar.tsx:42
51 - **Problem:** Der Link ".nav-link" hat ein Kontrastverhältnis von 2.8:1,
52   gefordert sind mindestens 4.5:1 (WCAG 1.4.3 AA).
53 - **Fix:**
54   ``tsx
55   // Sidebar.tsx -- Farbe des Links anpassen
56   <a className="nav-link" style={{ color: "#1a1a2e" }} href="/dashboard">
57     Dashboard
58   </a>
59   // Alternativ: CSS-Klasse mit ausreichendem Kontrast definieren
60   ``
61
62   ---
63
64   Eingabe-Finding:
65   [grep-002] MODERATE | tabindex-removes-element | WCAG 2.1.1 (A)
66   Beschreibung: tabIndex=-1 entfernt Elemente aus der Tab-Reihenfolge.
67   Datei: components/Modal.tsx:18-28
68   Code:
69   18: <div className="modal-overlay" tabIndex={-1}>
70   19:   <div className="modal-content" role="dialog">
71   20:     <button className="close-btn">Schließen</button>
72
73   Erwartete Ausgabe:
74
75   ## Nice-to-have
76
77   ### [grep-002] tabIndex=-1 auf Modal-Overlay
78 - **WCAG:** 2.1.1 (Level A)
79 - **Schweregrad:** moderate
80 - **Element/Datei:** components/Modal.tsx:18
81 - **Problem:** Das Modal-Overlay hat tabIndex={-1}. Wenn das Overlay selbst
82   fokussierbar sein soll (z.B. für Escape-Handling), ist das korrekt.
83   Andernfalls entfernt es das Element unnötig aus der Tab-Reihenfolge.
84 - **Fix:**
85   ``tsx
86   // Falls Overlay nicht fokussierbar sein muss -- tabIndex entfernen:
87   <div className="modal-overlay">
88     <div className="modal-content" role="dialog" aria-modal="true">
89       <button className="close-btn" autoFocus>Schließen</button>
90   ``
```

## Anhang 9: Prompts der LLM-Detektor-Phase

Die LLM-Detektor-Phase (Stufe 1 der zweistufigen LLM-Strategie, vgl. Abschnitt 7.5) verwendet einen eigenen, vom Priorisierungs-Prompt unabhängigen Prompt-Satz. Er wird für jeden Codechunk separat aufgerufen. In der Implementierung gilt `num_predict=640` als *Default* (vgl. `src/modules/llmDetector.ts`); im Benchmark wird dieser Wert explizit per Umgebungsvariable auf `LLM_DETECT_NUM_PREDICT=2048` gesetzt (vgl. `src/benchmark.ts`), um den Recall in größeren Suites zu stabilisieren.

Damit ergibt sich für Stufe 1 kein globales Einzelbudget, sondern ein **chunkweises Budget**:  $\text{Budget}_{\text{Detektor}} = \text{Anzahl Chunks} \times \text{num\_predict}_{\text{Detektor}}$ . Für die im Benchmark beobachteten mittleren Chunk-Zahlen (test-12:  $\approx 4$ , test-50:  $\approx 8$ , test-100:  $\approx 12$ ) entspricht dies bei `LLM_DETECT_NUM_PREDICT=2048` einem theoretischen Output-Rahmen von ca. 8,192 / 16,384 / 24,576 Tokens in Stufe 1.

### System-Prompt (LLM-Detektor):

Listing 9.4: System-Prompt der LLM-Detektor-Phase (aus `src/modules/llmDetector.ts`)

```

1 Du bist ein präziser Accessibility-Reviewer für React/TypeScript.
2 Analysiere NUR den gegebenen Codechunk.
3
4 Ausgabeformat: Nur JSON (kein Markdown), ein Objekt mit Feld "findings".
5 Schema je Finding:
6 {
7   "title": string,
8   "ruleId": string,
9   "wcagCriteria": string[],
10  "wcagLevel": "A" | "AA" | "AAA",
11  "severity": "critical" | "serious" | "moderate" | "minor",
12  "category": "syntaktisch" | "semantisch" | "layout",
13  "filePath": string,
14  "startLine": number,
15  "endLine": number,
16  "evidence": string,
17  "fixSuggestion": string
18 }
19
20 Regeln:
21 1. Melde nur Findings mit klarer Evidenz im Codechunk.
22 2. Erfinde keine Dateien oder Zeilen.
23 3. Wenn unsicher: nicht melden.
24 4. Maximal 12 Findings pro Chunk.
25 5. Nur JSON ausgeben.
```

**User-Prompt-Template (LLM-Detektor, vereinfacht):**

Listing 9.5: User-Prompt-Template der LLM-Detektor-Phase; `<Chunk-Nr>`, `<Dateiliste>` und `<Code>` werden zur Laufzeit eingesetzt (aus `src/modules/llmDetector.ts`)

```

1 Aufgabe: Finde Barrierefreiheitsprobleme im folgenden Codechunk.
2 Berücksichtige WCAG-relevante Probleme bei Semantik, Keyboard, Fokus,
3 Labels, ARIA und visuellem Kontrast nur wenn im Code direkt ableitbar.
4
5 Chunk: <Chunk-Nr>
6 Dateien im Chunk:
7 - <Datei-1>
8 - <Datei-2>
9 ...
10
11 Code:
12 <Inhalt des Chunks (Quelldateien mit Zeilennummern, max. 4000 Zeichen)>
13
14 Gib nur JSON zurück: {"findings": [...]}

```

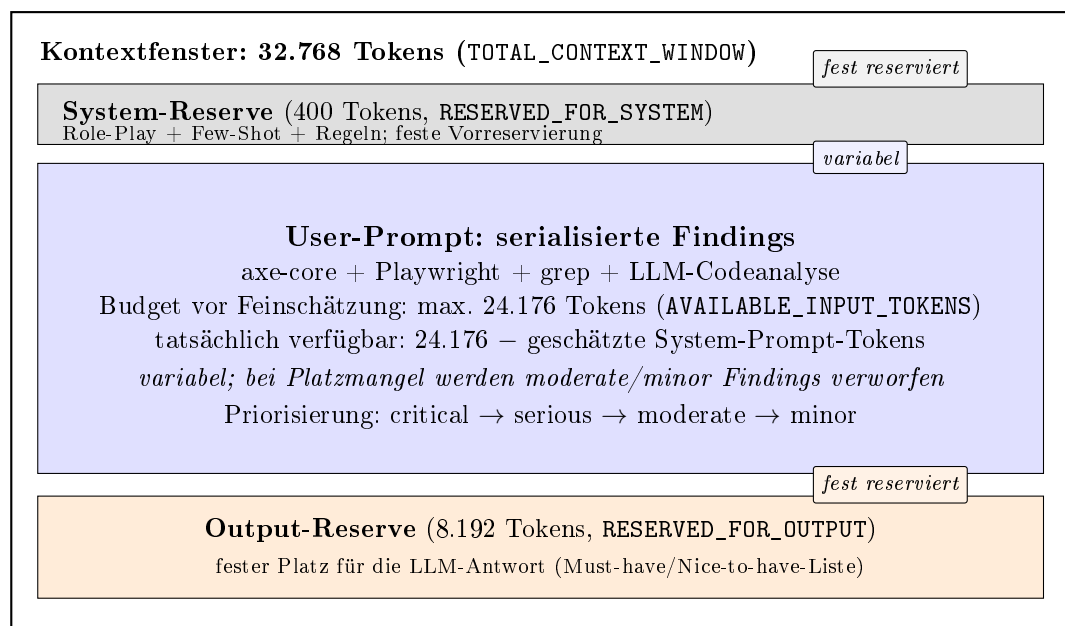
**Anhang 10: Aufteilung des Token-Budgets**

Abb. 7: Aufteilung des Kontextfensters gemäß Implementierung in `src/prompt.ts`: feste Reserven für System (400 Tokens) und Output, variabler Bereich für serialisierte Findings mit Schweregrad-basierter Kürzung bei Budgetüberschreitung. Die Abbildung zeigt ausschließlich Stufe 2 (Priorisierung) mit den Code-Standardkonstanten (`TOTAL_CONTEXT_WINDOW = 32 768`, `RESERVED_FOR_OUTPUT = 8 192`). In den Benchmarks wurde `num_predict` suite-spezifisch überschrieben: 6 144 (test-12), 8 192 (test-50), 12 288 (test-100); für BVEC galt `OLLAMA_NUM_CTX = 65 536` mit `num_predict = 24 576`. Stufe 1 (LLM-Detektor) besitzt ein separates, chunkweises Budget: Default 640, Benchmarks test-12-100: 2 048, BVEC: 4 096 Tokens. Vgl. Abschnitt 6.2.

## Anhang 11: Empfehlung nach Anwendungsszenario (konsolidiert)

**Leseanleitung:** Die nachfolgende Tabelle konsolidiert die Evaluationsergebnisse aus test-12, test-50 und test-100 (Kapitel 8). `qwen2.5-coder:7b` erscheint in der Spalte *Primär* ausschließlich in Szenarien, in denen **kein** BITV-/WCAG-konformes Ergebnis erforderlich ist (CI/CD-Smoke-Test, Prototyp). Für jede rechtlich relevante Barrierefreiheitsprüfung gilt unverändert: `qwen2.5-coder:7b` ist aufgrund der nachgewiesenen inversen bzw. instabilen Priorisierung (vgl. Abschnitt 8.3.1) *nicht geeignet*. Für Enterprise-Kontexte wird ein zweistufiges Betriebsmodell angenommen: schneller, nicht verbindlicher CI-Check und ein verbindlicher Compliance-Gate mit geeignetem Modell. Die Spalte *Eignung BITV-Einsatz* in Tabelle 26, Tabelle 39 und Tabelle 50 ist das übergeordnete Kriterium.

Tab. 17: Konsolidierte Modellwahl in Abhängigkeit vom Einsatzkontext auf Basis von test-12, test-50 und test-100. Primär: bevorzugtes Modell; Sekundär: Alternative. Die Empfehlungen für 7b gelten ausschließlich für nicht-compliance-relevante Szenarien.

| Szenario                                     | Primär | Sekundär | Begründung                                                                                   |
|----------------------------------------------|--------|----------|----------------------------------------------------------------------------------------------|
| CI/CD-Smoke-Test (nicht compliance-relevant) | 7b     | 14b      | Schnellstes Feedback; inverse Priorisierung hier tolerierbar                                 |
| Regulärer Entwicklungszyklus                 | 14b    | 32b      | Bester Kompromiss aus Recall, Priorisierung und Laufzeit                                     |
| BITV-Compliance-Audit                        | 14b    | 32b      | 14b liefert robustes Qualitäts-/Laufzeitprofil über die Suites; 32b als Zweitmeinung         |
| Abnahmeprüfung / Endaudit                    | 32b    | 14b      | Höchste inhaltliche Abdeckung; 14b als zeitlich stabilere Gegenprüfung                       |
| Prototyp / MVP                               | 7b     | –        | Schnelle Iteration; für finale Abnahme durch 14b/32b ersetzen                                |
| Enterprise-Deployment                        | 14b    | 32b      | Produktionstauglich im zweistufigen Betrieb: CI-Schnellcheck + verbindlicher Compliance-Gate |

## Anhang 12: Bewertungsskala für die Empfehlungsqualität der LLM-Ausgaben

Tab. 18: Bewertungsskala für die Empfehlungsqualität der LLM-Ausgaben über alle drei Test-suites (test-12, test-50 und test-100).

| Stufe | Bezeichnung | Kriterium                                                                                                          |
|-------|-------------|--------------------------------------------------------------------------------------------------------------------|
| 2     | Konkret     | Enthält Dateiname, Zeilennummer und einen konkreten Fix-Vorschlag (z. B. <code>aria-label="..."</code> ).          |
| 1     | Teilweise   | Enthält den richtigen Fix-Typ, jedoch ohne konkreten Codekontext (z. B. „Füge ein <code>aria-label</code> hinzu“). |
| 0     | Generisch   | Beschreibt lediglich das Problem, ohne einen umsetzbaren Lösungsvorschlag.                                         |



## **Anhang 13: Erfüllungsgrad der funktionalen und nicht-funktionalen Anforderungen**

*(Tabelle auf der nächsten Seite.)*

Tab. 19: Dargestellt ist der Erfüllungsgrad der funktionalen (FA) und nicht-funktionalen (NFA) Anforderungen im realisierten PoC. Die Bewertung basiert auf der konsolidierten Evaluation über test-12, test-50 und test-100. ✓ = vollständig erfüllt; (∼) = bedingt erfüllt; × = nicht erfüllt.

| Anf.   | Beschreibung                                       | Status | Bemerkung                                                                                                                                                                                                             |
|--------|----------------------------------------------------|--------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| FA-01  | Regelbasierte Accessibility-Erkennung via axe-core | ✓      | axe-core ist vollständig integriert und liefert auf allen Suites stabile, deterministische Baseline-Findings; die Abdeckung bleibt jedoch auf automatisierbare Regelverstöße begrenzt.                                |
| FA-02  | Dynamische Zustandserfassung via Playwright        | ✓      | Generische Interaktionschecks (z. B. Skip-Link, Fokusindikator) sind umgesetzt und liefern stabile Findings; modalspezifische Fokusübernahme wird jedoch nicht in allen Suites zuverlässig erfasst.                   |
| FA-03  | Statische Quellcodeanalyse via grep                | ✓      | Pattern-Matching und Kontextanreicherung liefern datei- und zeilenspezifischen Kontext für grep-basierte bzw. angereicherte Befunde; eine vollständige Quellcodeabdeckung aller Violations ist damit nicht verbunden. |
| FA-04  | LLM-gestützte Analyse und Handlungsempfehlung      | ✓      | Zweistufige Strategie (Detektor + Priorisierung) umgesetzt; Fix-Qualität mit qwen3:32b auf test-12 überwiegend Stufe 2.                                                                                               |
| FA-05  | Strukturierter JSON-Report                         | ✓      | Maschinenlesbarer JSON-Output und separate Report-Artefakte sind implementiert; Parsing-Erfolg in den Benchmarkläufen 100 %.                                                                                          |
| NFA-01 | Lokal-First / Datenschutz (kein Cloud-Transfer)    | ✓      | Ollama-Infrastruktur; kein Quellcode verlässt das lokale System.                                                                                                                                                      |
| NFA-02 | Laufzeit < 10 Min.                                 | (∼)    | In test-12 erfüllen 7b und 14b die Anforderung, in test-50 nur 7b; in test-100 überschreiten alle drei Modelle die Zehn-Minuten-Grenze.                                                                               |
| NFA-03 | Wartbarkeit (modulare Architektur)                 | ✓      | Trennung in Detection, Context-Building und Synthesis; unabhängig erweiterbar.                                                                                                                                        |
| NFA-04 | Reproduzierbarkeit (stabile Ausgaben)              | (∼)    | Temperature 0,05 und JSON-Schema-Prompting sichern Grundstabilität; auf test-12 zeigt 14b mit $\sigma = 0,42$ die höchste Konsistenz, auf größeren Suites steigt die Varianz jedoch an.                               |

## Anhang 14: Reproduzierbarkeitsblatt

Tab. 20: Umgebungs- und Konfigurationsparameter zur Reproduktion der Benchmark-Runs über alle drei Testsuites.

| Parameter                        | Wert                                                   |
|----------------------------------|--------------------------------------------------------|
| <b>Hardware</b>                  |                                                        |
| CPU                              | Apple M4 Max                                           |
| RAM                              | 128 GB                                                 |
| GPU                              | integrierte GPU nicht genutzt; CPU-basierte Ausführung |
| Speicher                         | 4TB                                                    |
| <b>Betriebssystem</b>            |                                                        |
| OS                               | macOS 26.4 (25E246)                                    |
| <b>Modelle und Infrastruktur</b> |                                                        |
| Ollama-Version                   | 0.19.0                                                 |
| Modellinstanz 7b                 | qwen2.5-coder:7b, Quantisierung                        |
| Modellinstanz 14b                | qwen2.5-coder:14b, Quantisierung                       |
| Modellinstanz 32b                | qwen3:32b, Quantisierung                               |
| <b>zentrale Parameter</b>        |                                                        |
| temperature                      | 0,05 für alle Runs                                     |
| num_predict (test-12)            | 6 144 Tokens                                           |
| num_predict (test-50)            | 8 192 Tokens                                           |
| num_predict (test-100)           | 12 288 Tokens                                          |
| Chunk-Größe (Codeanalyse)        | 4000 Zeichen max.                                      |
| Max. Dateien (Codeanalyse)       | 25                                                     |
| Runs pro Modell                  | 10 Runs je Testsuite                                   |
| <b>Toolchain</b>                 |                                                        |
| Node.js-Version                  | 24.12.0                                                |
| TypeScript-Version               | 5.7.3                                                  |
| axe-core-Version                 | 4.10.3                                                 |
| Playwright-Version               | 1.50.1                                                 |

## Anhang 15: Threats to Validity

Tab. 21: Systematische Analyse der internen, externen und Konstruktvalidität des PoC.

| Validitätsebene                                      | Threat                                                                                                                                                                 | Mitigationsmaßnahmen / Aussagekraft                                                                                                                                                           |
|------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Interne Validität: Korrektheit der Ergebnisse</b> |                                                                                                                                                                        |                                                                                                                                                                                               |
| Modell-abhängigkeit                                  | Die drei Modellgrößen liefern teils deutlich unterschiedliche Ergebnisse; auf test-100 reicht der Recall von 40–63 %                                                   | Der Mehrmodellvergleich wird offengelegt. Für produktive Einsätze sind größere Modelle besser geeignet als 7b.                                                                                |
| Prompt-Abhängigkeit                                  | System-Prompt und Few-Shot-Beispiele wurden fest vorgegeben; alternative Prompt-Varianten wurden nicht untersucht                                                      | Der Prompt wird als fester Bestandteil des PoC behandelt. Eine Sensitivitätsanalyse war out of Scope der Arbeit.                                                                              |
| Konfigurationsparameter                              | Einstellungen wie Temperatur (0,05), num_predict und Chunk-Größe ( 4000 Zeichen) beeinflussen das Antwortverhalten der Modelle                                         | Alle Parameter sind dokumentiert und reproduzierbar. Eine nachträgliche Optimierung zugunsten einzelner Ergebnisse fand nicht statt.                                                          |
| Ground-Truth-Genauigkeit                             | Die 100 Violations wurden manuell in die Testanwendung eingebracht und nicht durch externe Accessibility-Audits validiert                                              | Innerhalb der Testumgebung ist die Ground Truth konsistent. Die externe Absicherung bleibt jedoch begrenzt.                                                                                   |
| <b>Externe Validität: Generalisierbarkeit</b>        |                                                                                                                                                                        |                                                                                                                                                                                               |
| Testanwendungs-Spezifik                              | Die Hauptevaluation basiert auf drei synthetischen React-Testsuites mit bekannter Ground Truth; der reale BWEC wurde ergänzend ohne Ground Truth qualitativ betrachtet | Die Ergebnisse sind primär auf vergleichbare React-/SPA-Umgebungen übertragbar. Eine breitere Generalisierung erfordert zusätzliche Ground-Truth-basierte Tests an realen Anwendungssystemen. |
| WCAG-Coverage                                        | Abgedeckt werden zentrale WCAG-Kriterien aus den Bereichen 1.x bis 4.1.x, jedoch kein vollständiger Kriterienkatalog                                                   | Für eine an WCAG AA orientierte Bewertung ist die Abdeckung ausreichend. Aussagen zu AAA bleiben nur eingeschränkt möglich.                                                                   |
| <i>Fortsetzung auf der nächsten Seite</i>            |                                                                                                                                                                        |                                                                                                                                                                                               |

Tab. 21: Threats to Validity (Fortsetzung)

| Validitätsebene                                          | Threat                                                                                                                                                                                                                        | Mitigationsmaßnahmen / Aussagekraft                                                                                                                                                                                                                     |
|----------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Modell-verfügbarkeit                                     | Evaluiert wurden ausschließlich lokal ausgeführte Modelle ( <code>qwen2.5-coder</code> , <code>qwen3</code> )                                                                                                                 | Der Fokus liegt bewusst auf einem datenschutzfreundlichen Local-First-Ansatz. Die Ergebnisse lassen sich daher nicht unmittelbar auf Cloud-Modelle übertragen.                                                                                          |
| Skalierbarkeit                                           | Ground-Truth-basiert wurden die Testsuites <code>test-50</code> und <code>test-100</code> untersucht; ergänzend wurde mit <code>BWEC-500</code> auch eine große reale Codebasis qualitativ erprobt, jedoch ohne Recall-Metrik | Das Verfahren ist durch Chunking grundsätzlich skalierbar. Praktische Grenzen bei Laufzeit, Kontextfenster und Priorisierungsstabilität wurden im <code>BWEC-500</code> -Experiment sichtbar und sollten in künftigen Studien weiter untersucht werden. |
| <b>Konstruktvalidität: Repräsentation der Konstrukte</b> |                                                                                                                                                                                                                               |                                                                                                                                                                                                                                                         |
| Recall vs. Precision                                     | Der Schwerpunkt der Evaluation liegt auf dem Recall; Precision wurde für <code>test-50</code> und <code>test-100</code> per Run berechnet, jedoch ohne vollständige manuelle Plausibilisierung aller Einträge                 | Per-Run-Precision-Werte für alle drei Modelle finden sich in Anhang 36 ( <code>test-50</code> ) und Anhang 49 ( <code>test-100</code> ). Für <code>qwen3:32b</code> auf <code>test-100</code> wurde ergänzend eine Stichprobenprüfung durchgeführt.     |
| Metrik-Einschränkungen                                   | Das gesetzte Zeitlimit von 10 Minuten wird in <code>test-100</code> nicht eingehalten                                                                                                                                         | Die Bewertung erfolgt deshalb sowohl aus strenger als auch aus pragmatischer Perspektive. Ein Einsatz ist eher im Release-Kontext denkbar als in einer kurzen CI/CD-Pipeline.                                                                           |
| Priorisierungsqualität                                   | Die Fix-Konkretheit wurde über eine Skala von 0 bis 2 bewertet; eine automatisierte Validierung erfolgte nicht                                                                                                                | Es wurden einzelne Checks durchgeführt. Ob sich diese Einschätzung auf alle Runs übertragen lässt, bleibt offen. <sup>209</sup>                                                                                                                         |

<sup>209</sup>Vgl. Anhang 25, Anhang 38 und Anhang 51.

## Anhang 16: Accessibility-Verstöße der Testanwendung und zugehörige Prüfquellen (test-12-Suite)

Tab. 22: Alle 12 eingebetteten Accessibility-Verstöße mit Kategorie, erwarteter Erkennungsquelle und zugehörigem WCAG-Kriterium.

| #  | Violation                                              | Kategorie   | Erwartete Quelle                  | WCAG  |
|----|--------------------------------------------------------|-------------|-----------------------------------|-------|
| 1  | <img> ohne alt="..."                                   | syntaktisch | axe-core                          | 1.1.1 |
| 2  | <button> ohne sichtbaren Text und ohne aria-label      | syntaktisch | axe-core                          | 4.1.2 |
| 3  | Formularfeld ohne <label>                              | syntaktisch | axe-core                          | 1.3.1 |
| 4  | Kontrastverhältnis < 4.5 : 1 (Text auf Hintergrund)    | layout      | axe-core                          | 1.4.3 |
| 5  | Fokus-Outline via CSS entfernt (outline: none)         | layout      | axe-core + Playwright             | 2.4.7 |
| 6  | onClick-Handler ohne onKeyDown-Pendant                 | semantisch  | grep + LLM-Codeanalyse            | 2.1.1 |
| 7  | role="button" auf <div> ohne tabIndex                  | semantisch  | axe-core + grep + LLM-Codeanalyse | 4.1.2 |
| 8  | Modaler Dialog übernimmt Fokus beim Öffnen nicht       | semantisch  | Playwright                        | 2.4.3 |
| 9  | Skip-Link fehlt                                        | semantisch  | Playwright                        | 2.4.1 |
| 10 | aria-hidden="true" auf fokussierbarem Element          | syntaktisch | axe-core                          | 4.1.2 |
| 11 | Reihenfolge im DOM weicht von visueller Reihenfolge ab | semantisch  | axe-core                          | 1.3.2 |
| 12 | Interaktives Element zu klein (< 24 × 24px)            | layout      | LLM-Codeanalyse                   | 2.5.8 |

## Anhang 17: Erkennungsrate der Violations im Proof of Concept (test-12-Suite)

*Erwartete Quelle* = vor der Evaluation theoretisch zugeordnete Primärquelle (vgl. Tabelle 22);  
*Tatsächliche Quelle* = empirisch beobachtete Detektionsquelle.

Tab. 23: Erkennungsrate aller 12 Violations über alle Modelle (Konsistenzschwelle: > 5/10 Runs). *Erkannt* = konsistent über alle Modelle hinweg; modellabhängige Abweichungen sind in *Anmerkung* dokumentiert.<sup>210</sup>

| #  | Violation                                     | Erkannt (✓/×) | Tatsächliche Quelle   | Anmerkung                                  |
|----|-----------------------------------------------|---------------|-----------------------|--------------------------------------------|
| 1  | <img> ohne alt="..."                          | ✓             | axe-core              | Alle Modelle                               |
| 2  | <button> ohne aria-label                      | ✓             | LLM-Detektor          | Nur 14b/32b; 7b miss                       |
| 3  | Formularfeld ohne <label>                     | ✓             | axe-core + grep       | 7b instabil; 14b/32b konsistent            |
| 4  | Kontrastverhältnis < 4.5 : 1                  | ✓             | axe-core              | 2 axe-Findings (nav + submit)              |
| 5  | Fokus-Outline entfernt (outline: none)        | ✓             | axe-core + Playwright | Alle Modelle                               |
| 6  | onClick ohne onKeyDown                        | ✓             | grep                  | Alle Modelle                               |
| 7  | role="button" auf <div> ohne tabIndex         | ✓             | axe-core + grep       | Alle Modelle                               |
| 8  | Modal: Fokusübernahme beim Öffnen fehlt       | ✓             | LLM-Detektor          | Playwright-Check greift nicht; nur mit LLM |
| 9  | Skip-Link fehlt                               | ✓             | Playwright            | Alle Modelle                               |
| 10 | aria-hidden="true" auf fokussierbarem Element | ✓             | axe-core              | Alle Modelle                               |
| 11 | DOM-Reihenfolge vs. visuelle Reihenfolge      | ✓             | LLM-Detektor          | 14b/32b konsistent; 7b miss                |
| 12 | Interaktives Element zu klein (< 24 × 24 px)  | ✓             | LLM-Detektor          | Alle Modelle                               |

## Anhang 18: Recall-Matrix: Violation × Bedingung (test-12-Suite)

Tab. 24: Erkennungsstatus je Violation. ✓ = konsistent erkannt (> 5/10 Runs); ~ = instabil (3–5/10 Runs); × = nicht erkannt (0–2/10 Runs).

| #             | Violation                                           | Baseline      | + 7b          | + 14b          | + 32b          | LLM-exklusiv |
|---------------|-----------------------------------------------------|---------------|---------------|----------------|----------------|--------------|
| 1             | <img> ohne alt="..."                                | ✓             | ✓             | ✓              | ✓              |              |
| 2             | <button> ohne aria-label (Icon-Button)              | ×             | ×             | ✓              | ✓              | ✓            |
| 3             | Formularfeld ohne <label>                           | ✓             | ~             | ✓              | ✓              |              |
| 4             | Kontrastverhältnis < 4.5 : 1                        | ✓             | ✓             | ✓              | ✓              |              |
| 5             | Fokus-Outline entfernt (outline: none)              | ✓             | ✓             | ✓              | ✓              |              |
| 6             | onClick ohne onKeyDown                              | ✓             | ✓             | ✓              | ✓              |              |
| 7             | role="button" auf <div> ohne tabIndex               | ✓             | ✓             | ✓              | ✓              |              |
| 8             | Modaler Dialog übernimmt Fokus beim Öffnen nicht    | ×             | ✓             | ✓              | ✓              | ✓            |
| 9             | Skip-Link fehlt                                     | ✓             | ✓             | ✓              | ✓              |              |
| 10            | aria-hidden="true" auf fokussierbarem Element       | ✓             | ✓             | ✓              | ✓              |              |
| 11            | DOM-Reihenfolge weicht von visueller Reihenfolge ab | ×             | ×             | ✓              | ✓              | ✓            |
| 12            | Interaktives Element zu klein (< 24 × 24 px)        | ×             | ✓             | ✓              | ✓              | ✓            |
| <b>Recall</b> |                                                     | <b>8 / 12</b> | <b>9 / 12</b> | <b>12 / 12</b> | <b>12 / 12</b> | 4 Violations |



## Anhang 19: Rohdaten: alle 30 Benchmark-Runs (test-12-Suite)

Tab. 25: Vollständige Messdaten der 30 Pipeline-Durchläufe. LLM-Det. = Findings des LLM-Detektors; Axe/PW/Grep = Tool-Findings (konstant); Tokens = Output-Tokens; Dauer = Priorisierungslaufzeit in Sekunden.

| Run | Modell            | LLM-Det. | Axe | PW | Grep | Gesamt | Tokens | Dauer (s) |
|-----|-------------------|----------|-----|----|------|--------|--------|-----------|
| 01  | qwen2.5-coder:7b  | 11       | 4   | 2  | 6    | 23     | 6144   | 112       |
| 02  | qwen2.5-coder:7b  | 11       | 4   | 2  | 6    | 23     | 6144   | 134       |
| 03  | qwen2.5-coder:7b  | 11       | 4   | 2  | 6    | 23     | 6144   | 139       |
| 04  | qwen2.5-coder:7b  | 4        | 4   | 2  | 6    | 16     | 2448   | 53        |
| 05  | qwen2.5-coder:7b  | 10       | 4   | 2  | 6    | 22     | 6144   | 133       |
| 06  | qwen2.5-coder:7b  | 16       | 4   | 2  | 6    | 28     | 3132   | 76        |
| 07  | qwen2.5-coder:7b  | 14       | 4   | 2  | 6    | 26     | 2744   | 65        |
| 08  | qwen2.5-coder:7b  | 9        | 4   | 2  | 6    | 21     | 6144   | 137       |
| 09  | qwen2.5-coder:7b  | 14       | 4   | 2  | 6    | 26     | 3108   | 71        |
| 10  | qwen2.5-coder:7b  | 11       | 4   | 2  | 6    | 23     | 2179   | 51        |
| 11  | qwen2.5-coder:14b | 23       | 4   | 2  | 6    | 35     | 3090   | 149       |
| 12  | qwen2.5-coder:14b | 23       | 4   | 2  | 6    | 35     | 6144   | 285       |
| 13  | qwen2.5-coder:14b | 23       | 4   | 2  | 6    | 35     | 5395   | 258       |
| 14  | qwen2.5-coder:14b | 23       | 4   | 2  | 6    | 35     | 6142   | 291       |
| 15  | qwen2.5-coder:14b | 23       | 4   | 2  | 6    | 35     | 5254   | 253       |
| 16  | qwen2.5-coder:14b | 22       | 4   | 2  | 6    | 34     | 6144   | 290       |
| 17  | qwen2.5-coder:14b | 23       | 4   | 2  | 6    | 35     | 5403   | 241       |
| 18  | qwen2.5-coder:14b | 23       | 4   | 2  | 6    | 35     | 2679   | 127       |
| 19  | qwen2.5-coder:14b | 22       | 4   | 2  | 6    | 34     | 6144   | 266       |
| 20  | qwen2.5-coder:14b | 23       | 4   | 2  | 6    | 35     | 6144   | 267       |
| 21  | qwen3:32b         | 19       | 4   | 2  | 6    | 31     | 2846   | 290       |
| 22  | qwen3:32b         | 20       | 4   | 2  | 6    | 32     | 3153   | 324       |
| 23  | qwen3:32b         | 19       | 4   | 2  | 6    | 31     | 4233   | 440       |
| 24  | qwen3:32b         | 19       | 4   | 2  | 6    | 31     | 2794   | 300       |
| 25  | qwen3:32b         | 20       | 4   | 2  | 6    | 32     | 2908   | 312       |
| 26  | qwen3:32b         | 19       | 4   | 2  | 6    | 31     | 2649   | 301       |
| 27  | qwen3:32b         | 20       | 4   | 2  | 6    | 32     | 2963   | 311       |
| 28  | qwen3:32b         | 20       | 4   | 2  | 6    | 32     | 4033   | 398       |
| 29  | qwen3:32b         | 20       | 4   | 2  | 6    | 32     | 3191   | 321       |
| 30  | qwen3:32b         | 19       | 4   | 2  | 6    | 31     | 6144   | 609       |

## Anhang 20: Modell-Leistungsvergleich: test-12-Suite

### Zusammenfassung

Tab. 26: Zusammenfassung der Leistungsmetriken für die drei evaluierten Modelle (je  $n = 10$  Runs, `num_predict = 6144`).  $\sigma$  = Stichproben-Standardabweichung. Der Recall basiert auf Konsistenzschwelle  $> 5/10$  Runs je Modell.

| Metrik                                         | qwen2.5-coder:7b | qwen2.5-coder:14b | qwen3:32b       |
|------------------------------------------------|------------------|-------------------|-----------------|
| Recall (konsistent)                            | 9 / 12 (75 %)    | 12 / 12 (100 %)   | 12 / 12 (100 %) |
| LLM-Detektor-Findings ( $\bar{O} \pm \sigma$ ) | 11,1 $\pm$ 3,28  | 22,8 $\pm$ 0,42   | 19,5 $\pm$ 0,53 |
| LLM-Detektor-Findings (Min–Max)                | 4–16             | 22–23             | 19–20           |
| Konsistenz $\sigma$                            | 3,28             | 0,42              | 0,53            |
| Priorisierungsqualität                         | Fehlerhaft       | Undifferenziert   | Korrekt         |
| Output-Tokens ( $\bar{O}$ )                    | 4,433            | 5,254             | 3,491           |
| Output-Limit ausgeschöpft                      | 5 / 10 (50 %)    | 4 / 10 (40 %)     | 1 / 10 (10 %)   |
| Parsing-Erfolg                                 | 100 %            | 100 %             | 100 %           |
| NFA-02-Konformität                             | Erfüllt          | Erfüllt           | Bedingt         |
| Eignung BITV-Einsatz                           | Nicht geeignet   | Empfohlen         | Eingeschränkt   |
| <i>Suite-spezifische Zusatzmetriken</i>        |                  |                   |                 |
| Fix-Qualität (Stufe)                           | 0–1              | 0–2               | 1–2             |
| Tool-Findings (axe/PW/grep)                    | 4 / 2 / 6        | 4 / 2 / 6         | 4 / 2 / 6       |
| Must-have im Bericht ( $\bar{O}$ )             | 9,1              | 27,0              | 14,6            |
| Nice-to-have ( $\bar{O}$ ) Bericht             | 23,1             | 8,9               | 8,5             |
| Gesamt-Report-Items ( $\bar{O}$ )              | 32,2             | 35,9              | 23,1            |
| LLM-Detektor-Laufzeit ( $\bar{O}$ )            | 139 s            | 231 s             | 374 s           |
| Priorisierungslaufzeit ( $\bar{O}$ )           | 92 s             | 189 s             | 327 s           |
| Priorisierungslaufzeit (Min–Max)               | 51–139 s         | 127–291 s         | 290–609 s       |
| Gesamtlaufzeit ( $\bar{O}$ )                   | 231 s            | 420 s             | 701 s           |
| Gesamtlaufzeit (Min–Max)                       | 191–284 s        | 300–480 s         | 617–937 s       |

## Anhang 21: Token-Nutzung pro Modell: Input/Output (test-12-Suite)

Tab. 27: Durchschnittliche Token-Nutzung je Run und Modell auf Basis der test-12-Suite (`num_predict` = 6 144). Input-Tokens umfassen System-Prompt, serialisierte Findings und Konfigurationsparameter. 5 / 10 Runs (7b) und 4 / 10 Runs (14b) erreichten das Output-Limit; 32b-Runs blieben mit Ø 3 491 deutlich darunter.

| Modell                                                                              | Input-Tokens (Ø) | Output-Tokens (Ø) | Truncation       |
|-------------------------------------------------------------------------------------|------------------|-------------------|------------------|
| qwen2.5-coder:7b                                                                    | 4 451            | 4 433             | 5/10 Runs (50 %) |
| qwen2.5-coder:14b                                                                   | 5 547            | 5 254             | 4/10 Runs (40 %) |
| qwen3:32b                                                                           | 5 214            | 3 491             | 1/10 Runs (10 %) |
| <i>Gesamt (30 Runs): Input <math>\approx</math> 152 100 / Output 131 784 Tokens</i> |                  |                   |                  |

## Anhang 22: Laufzeit und Effizienz der Pipeline-Modelle (test-12-Suite)

| Modell            | LLM-Detektor Ø | LLM-Priorisierung Ø | Gesamt Ø | Min   | Max   |
|-------------------|----------------|---------------------|----------|-------|-------|
| qwen2.5-coder:7b  | 139 s          | 92 s                | 231 s    | 191 s | 284 s |
| qwen2.5-coder:14b | 231 s          | 189 s               | 420 s    | 300 s | 480 s |
| qwen3:32b         | 374 s          | 327 s               | 701 s    | 617 s | 937 s |

Tab. 28: Mittlere Laufzeiten je Pipeline-Phase ( $n = 10$  je Modell, test-12-Suite).

Tab. 29: Effizienzvergleich auf Basis der 30 Benchmark-Runs der test-12-Suite. *LLM-Findings/s* bezieht sich auf LLM-Detektor-Findings pro Sekunde Gesamtlaufzeit.

| Modell            | LLM-Findings Ø | Gesamtlaufzeit Ø (s) | LLM-Findings/s | Zusatznutzen ggü. 7b         |
|-------------------|----------------|----------------------|----------------|------------------------------|
| qwen2.5-coder:7b  | 11,1           | 231                  | 0,048          | Referenz                     |
| qwen2.5-coder:14b | 22,8           | 420                  | 0,054          | +105 % bei +82 % Zeitaufwand |
| qwen3:32b         | 19,5           | 701                  | 0,028          | +76 % bei +203 % Zeitaufwand |

## Anhang 23: Über-Detektion relativ zur Ground Truth (test-12-Suite)

Tab. 30: Vergleich der durchschnittlichen LLM-Detektor-Findings pro Run mit der Ground Truth (12 Violations). Die LLM-only-Betrachtung vermeidet Doppelzählungen zwischen überlappenden Detektoren.

| Modell            | LLM-Findings $\emptyset$ | Ground Truth | Quote   | Interpretation                                                                       |
|-------------------|--------------------------|--------------|---------|--------------------------------------------------------------------------------------|
| qwen2.5-coder:7b  | 11,1                     | 12           | 92,5 %  | nahe an der Ground Truth; niedrigste LLM-Überdetektion, aber instabile Priorisierung |
| qwen2.5-coder:14b | 22,8                     | 12           | 190 %   | deutlicher Überschuss; hoher Recall bei erhöhter Redundanz                           |
| qwen3:32b         | 19,5                     | 12           | 162,5 % | moderater Überschuss; konsistenter als 7b und mit besserer Priorisierung             |

## Anhang 24: Detektor-Konsistenz über alle 30 Runs (test-12-Suite)

Tab. 31: Konsistenzanalyse der Detektoren über alle 30 Benchmark-Runs. Da axe-core, Playwright und grep vollständig deterministisch bleiben, wird die relevante Varianz auf Modellebene innerhalb des LLM-Detektors ausgewiesen.

| Detektor / Modell   | Runs | Gesamt-Findings | $\emptyset$ pro Run | Min-Max | $\sigma^2 / \sigma$ | Interpretation                           |
|---------------------|------|-----------------|---------------------|---------|---------------------|------------------------------------------|
| axe-core            | 30   | 120             | 4,0                 | 4–4     | 0,00 / 0,00         | vollständig deterministisch              |
| Playwright          | 30   | 60              | 2,0                 | 2–2     | 0,00 / 0,00         | vollständig deterministisch              |
| grep                | 30   | 180             | 6,0                 | 6–6     | 0,00 / 0,00         | vollständig deterministisch              |
| qwen2.5-coder:7b    | 10   | 111             | 11,1                | 4–16    | 10,76 / 3,28        | höchste Streuung                         |
| qwen2.5-coder:14b   | 10   | 228             | 22,8                | 22–23   | 0,18 / 0,42         | hohe Konsistenz bei höchster Trefferzahl |
| qwen3:32b           | 10   | 195             | 19,5                | 19–20   | 0,28 / 0,53         | stabil, aber mit höherer Laufzeit        |
| LLM-Detektor gesamt | 30   | 534             | 17,8                | 4–23    | modell-abhängig     | –                                        |

Die Tabelle zeigt, dass die Unterschiede zwischen den Detektoren selbst methodisch kaum relevant sind: axe-core, Playwright und grep liefern über alle 30 Runs exakt konstante Ergebnisse. Die tatsächlich relevante Varianz entsteht ausschließlich innerhalb des LLM-Detektors und dort vor allem durch die Modellwahl. **qwen2.5-coder:14b** weist mit  $\sigma = 0,42$  die höchste Konsistenz bei zugleich höchster durchschnittlicher Fundzahl auf, während **qwen2.5-coder:7b** mit  $\sigma = 3,28$  deutlich volatiler reagiert. **qwen3:32b** ist ebenfalls sehr stabil ( $\sigma = 0,53$ ), erkaufte diese Stabilität jedoch mit einer wesentlich höheren Laufzeit. Für die Interpretation der Gesamtpipeline ist daher nicht die Frage entscheidend, welcher Detektor variiert, sondern welches Modell im LLM-Detektor eingesetzt wird.

## Anhang 25: Bewertung der Empfehlungsqualität pro Violation (test-12-Suite)

*Kürzel:* DT = DataTable, SR = SearchResults, FU = FileUpload, N.= Notifications, Cal.= Calendar, Dash.= Dashboard, User = UserProfile.

Die Bewertung basiert auf Run 01 von **qwen3:32b** (Tabelle 25) und verwendet dieselbe dreistufige Skala wie Tabelle 18. Stufe 2 liegt vor, wenn Dateiname, Zeilennummer und ein konkreter Code-Vorschlag vorhanden sind; Stufe 1, wenn der richtige Fix-Typ erkannt, aber kein konkreter Codekontext geliefert wird.

Tab. 32: Bewertung der Fix-Qualität für alle 12 Violations (**qwen3:32b**, Run 01).

| #  | Violation                                                                          | Stufe (0–2) | Anmerkung (qwen3:32b)                                                                      |
|----|------------------------------------------------------------------------------------|-------------|--------------------------------------------------------------------------------------------|
| 1  | <code>&lt;img&gt;</code> ohne <code>alt="..."</code>                               | 2           | Datei App.tsx:37, konkreter <code>alt</code> -Text angegeben                               |
| 2  | <code>&lt;button&gt;</code> ohne <code>aria-label</code>                           | 2           | <code>aria-label</code> -Wert mit entsprechendem Text vorgeschlagen                        |
| 3  | Formularfeld ohne <code>&lt;label&gt;</code>                                       | 2           | <code>label</code> + <code>htmlFor</code> + <code>id</code> vollständig ausgearbeitet      |
| 4  | Kontrastverhältnis $< 4.5 : 1$                                                     | 2           | CSS-Regel mit konkreten Hex-Farben je betroffener Klasse                                   |
| 5  | Fokus-Outline entfernt ( <code>outline: none</code> )                              | 2           | CSS-Klasse mit <code>outline: 2px solid</code> als Ersatz                                  |
| 6  | <code>onClick</code> ohne <code>onKeyDown</code>                                   | 1           | <code>onKeyDown</code> -Muster korrekt, aber generisch; kein Dateikontext                  |
| 7  | <code>role="button"</code> auf <code>&lt;div&gt;</code> ohne <code>tabIndex</code> | 2           | <code>tabIndex={0}</code> + <code>onKeyDown</code> JSX-Snippet mit Kontext                 |
| 8  | Modal: Fokusübernahme beim Öffnen fehlt                                            | 2           | Vollständiger <code>useEffect</code> -Fokus-Trap mit <code>Shift+Tab</code> -Logik         |
| 9  | Skip-Link fehlt                                                                    | 2           | <code>&lt;a href="#main-content&gt;</code> -Snippet mit CSS-Klasse                         |
| 10 | <code>aria-hidden="true"</code> auf fokussierbarem Element                         | 2           | Korrektur ( <code>aria-hidden</code> entfernen oder <code>tabIndex=-1</code> ) mit Kontext |
| 11 | DOM-Reihenfolge vs. visuelle Reihenfolge                                           | 2           | CSS <code>order</code> -Property als Lösung; DOM-Reihenfolge erhalten                      |
| 12 | Interaktives Element zu klein ( $< 24 \times 24$ px)                               | 2           | CSS <code>width/height</code> auf 24px mit Klasse <code>.btn-tiny</code>                   |

## Anhang 26: CSV-Auszug: Benchmark-Rohdaten (test-12-Suite)

Die Benchmark-Rohdaten wurden zusätzlich als CSV-Datei exportiert (**results/benchmark/summary.csv**). Tabelle 33 dokumentiert das reale Spaltenschema, Tabelle 34 zeigt exemplarische Zeilen (je ein Run pro Modell).

Tab. 33: Spaltenschema des CSV-Exports **results/benchmark/summary.csv**.

| Spalte                          | Bedeutung                                                      |
|---------------------------------|----------------------------------------------------------------|
| model                           | Verwendetes Modell (z. B. <b>qwen2.5-coder:14b</b> )           |
| suite                           | Testsuite (hier: test-12)                                      |
| run                             | Laufnummer innerhalb einer Modellserie                         |
| success / parseSuccess          | Pipeline-Erfolg und Parsing-Erfolg der Ausgabe                 |
| mustHaveCount / niceToHaveCount | Anzahl Must-have- bzw. Nice-to-have-Findings im finalen Report |
| durationMs                      | Gesamtlaufzeit der Pipeline in Millisekunden                   |
| promptTokens / outputTokens     | Tatsächlich verwendete Prompt- und Output-Tokens               |
| numPredict                      | Verwendetes Output-Token-Limit der Priorisierungsphase         |
| Axe / Playwright / Grep / LLM   | Anzahl erkannter Findings je Detektor                          |
| error                           | Fehlermeldung (leer bei erfolgreichem Run)                     |

Tab. 34: Repräsentative Beispielzeilen aus **results/benchmark/summary.csv** (test-12-Suite; jeweils Run 01 pro Modell).

| model             | run | must | nice | LLM | Axe | PW | Grep | durationMs | prompt | output | parse |
|-------------------|-----|------|------|-----|-----|----|------|------------|--------|--------|-------|
| qwen2.5-coder:7b  | 1   | 14   | 33   | 11  | 4   | 2  | 6    | 111817     | 4405   | 6144   | true  |
| qwen2.5-coder:14b | 1   | 6    | 16   | 23  | 4   | 2  | 6    | 148920     | 5635   | 3090   | true  |
| qwen3:32b         | 1   | 12   | 8    | 19  | 4   | 2  | 6    | 289630     | 5200   | 2846   | true  |

## Anhang 27: Ansichten der Testanwendung (test-12-Suite)

The screenshot shows a login window titled "Anmelden" with a blue header bar containing "120 x 40" and "Kontakt Login". The form includes fields for "E-Mail-Adresse" (containing "name@beispiel.de") and "Passwort eingeben". Below these is a "Anmelden" button with a "7" icon and a "Passwort vergessen?" link. The footer text reads "ALZ Synthetische Testkomponente – Nur für Evaluationszwecke".

Abb. 8: Anmeldefenster der test-12-Suite

The screenshot shows a contact form titled "Kontaktformular". It features a "Name" field with the placeholder "Ihr Name". Below this is a "Betreff auswählen" section with three buttons: "Allgemein", "Technisch", and "Sonstiges". The "Technisch" button is selected. A "Nachricht" field with the placeholder "Ihre Nachricht..." is also present. A "Zurücksetzen" button is located at the bottom right. The form is set against a light blue background.

Abb. 9: Kontaktformular der test-12-Suite

## Anhang 28: Accessibility-Verstöße der Testanwendung (test-50-Suite)

Tab. 35: Alle 50 eingebetteten Accessibility-Verstöße mit Kategorie, erwarteter Erkennungsquelle und zugehörigem WCAG-Kriterium. *LLM* = ausschließlich LLM-Codeanalyse; *manuell* = keine automatische Erkennungsquelle erwartet.

| #                                  | Violation                                           | Kat. | Erwartete Quelle | WCAG  |
|------------------------------------|-----------------------------------------------------|------|------------------|-------|
| V1                                 | Skip-Link fehlt                                     | sem. | Playwright       | 2.4.1 |
| V2                                 | <html> ohne lang-Attribut                           | syn. | axe-core         | 3.1.1 |
| V3                                 | Logo <img> ohne alt="..."                           | syn. | axe-core + grep  | 1.1.1 |
| V4                                 | Deko-Bild ohne alt= / role="presentation"           | syn. | axe-core + grep  | 1.1.1 |
| V5                                 | Hamburger-Button ohne zugänglichen Namen            | syn. | axe-core         | 4.1.2 |
| V6                                 | <a> ohne href – nicht fokussierbar                  | sem. | axe-core         | 2.1.1 |
| V7                                 | Badge-Kontrast zu niedrig (#aac auf #0057b8)        | lay. | axe-core         | 1.4.3 |
| V8                                 | CSS order weicht von DOM-Reihenfolge ab             | sem. | LLM-Codeanalyse  | 1.3.2 |
| V9                                 | <nav> ohne aria-label                               | syn. | axe-core         | 1.3.1 |
| V10                                | onClick auf <li> ohne onKeyDown (1)                 | sem. | grep             | 2.1.1 |
| V11                                | onClick auf <li> ohne onKeyDown (2)                 | sem. | grep             | 2.1.1 |
| V12                                | role="button" ohne tabIndex (Sidebar)               | sem. | axe-core + grep  | 4.1.2 |
| V13                                | onClick auf <li> ohne onKeyDown (3)                 | sem. | grep             | 2.1.1 |
| V14                                | Button 16×16 px < 24×24 px (Sidebar)                | lay. | grep (CSS)       | 2.5.8 |
| V15                                | aria-hidden="true" auf fokussierbarem Element       | syn. | axe-core         | 4.1.2 |
| V16                                | Überschriften-Hierarchie übersprungen (h3 statt h1) | sem. | axe-core         | 1.3.1 |
| V17                                | KPI-Icon <img> ohne alt="..." (1)                   | syn. | axe-core + grep  | 1.1.1 |
| V18                                | KPI-Wert Kontrast zu niedrig (#bbb auf #fff)        | lay. | axe-core         | 1.4.3 |
| V19                                | KPI-Icon <img> ohne alt="..." (2)                   | syn. | axe-core + grep  | 1.1.1 |
| V20                                | onClick auf <div> ohne onKeyDown                    | sem. | grep             | 2.1.1 |
| Fortsetzung auf der nächsten Seite |                                                     |      |                  |       |



Tab. 35: Accessibility-Verstöße der test-50-Suite (Fortsetzung)

| #                                  | Violation                                                                          | Kat. | Erwartete Quelle          | WCAG  |
|------------------------------------|------------------------------------------------------------------------------------|------|---------------------------|-------|
| V21                                | <code>role="button"</code> auf <code>&lt;div&gt;</code> ohne <code>tabIndex</code> | sem. | axe-core + grep           | 4.1.2 |
| V22                                | Chart-Bild ohne <code>alt="..."</code>                                             | syn. | axe-core + grep           | 1.1.1 |
| V23                                | Tabelle ohne <code>&lt;caption&gt;</code> oder <code>aria-label</code>             | sem. | axe-core                  | 1.3.1 |
| V24                                | <code>&lt;th&gt;</code> ohne <code>scope</code> -Attribut                          | syn. | axe-core                  | 1.3.1 |
| V25                                | Status nur durch Farbe kodiert (Dashboard)                                         | sem. | LLM-Codeanalyse (manuell) | 1.4.1 |
| V26                                | Avatar <code>&lt;img&gt;</code> ohne <code>alt="..."</code>                        | syn. | axe-core + grep           | 1.1.1 |
| V27                                | Input ohne <code>&lt;label&gt;</code> (Anzeigename)                                | syn. | axe-core                  | 1.3.1 |
| V28                                | Input ohne <code>&lt;label&gt;</code> (E-Mail)                                     | syn. | axe-core                  | 1.3.1 |
| V29                                | Textarea ohne <code>&lt;label&gt;</code> (Bio)                                     | syn. | axe-core                  | 1.3.1 |
| V30                                | Pflichtfeld ohne <code>required/aria-required</code>                               | syn. | LLM-Codeanalyse (manuell) | 3.3.2 |
| V31                                | Fehlermeldung nicht programmatisch verknüpft                                       | sem. | LLM-Codeanalyse (manuell) | 3.3.1 |
| V32                                | Button-Kontrast zu niedrig (#999 auf #fff)                                         | lay. | axe-core                  | 1.4.3 |
| V33                                | <code>outline: none</code> auf Button (Fokus entfernt)                             | lay. | Playwright                | 2.4.7 |
| V34                                | Statusmeldung ohne <code>aria-live</code>                                          | sem. | LLM-Codeanalyse (manuell) | 4.1.3 |
| V35                                | Duplikat-ID <code>help-text</code>                                                 | syn. | axe-core                  | 4.1.1 |
| V36                                | <code>onClick</code> auf <code>&lt;span&gt;</code> ohne <code>onKeyDown</code>     | sem. | grep                      | 2.1.1 |
| V37                                | Suchfeld ohne sichtbares Label                                                     | syn. | axe-core                  | 1.3.1 |
| V38                                | Tabelle ohne <code>&lt;caption&gt;</code> (DataTable)                              | sem. | axe-core                  | 1.3.1 |
| V39                                | Checkbox ohne Label (Header)                                                       | syn. | axe-core                  | 1.3.1 |
| V40                                | Checkbox ohne Label (Zeilen)                                                       | syn. | axe-core                  | 1.3.1 |
| V41                                | Status nur durch Farbe kodiert (DataTable)                                         | sem. | LLM-Codeanalyse (manuell) | 1.4.1 |
| V42                                | Icon-Button ohne zugänglichen Namen                                                | syn. | axe-core                  | 4.1.2 |
| V43                                | Paginierung: <code>onClick</code> auf <code>&lt;div&gt;</code> ohne Keyboard       | sem. | grep                      | 2.1.1 |
| V44                                | <code>&lt;li&gt;</code> mit <code>onClick</code> ohne <code>onKeyDown</code>       | sem. | grep                      | 2.1.1 |
| Fortsetzung auf der nächsten Seite |                                                                                    |      |                           |       |

Tab. 35: Accessibility-Verstöße der test-50-Suite (Fortsetzung)

| #   | Violation                                                           | Kat. | Erwartete Quelle          | WCAG  |
|-----|---------------------------------------------------------------------|------|---------------------------|-------|
| V45 | Ungelesen nur durch Farbe kodiert                                   | sem. | LLM-Codeanalyse (manuell) | 1.4.1 |
| V46 | Zeitangabe Kontrast zu niedrig ( <b>#bbb</b> auf <b>#fff</b> )      | lay. | axe-core                  | 1.4.3 |
| V47 | Button $16 \times 16 \text{ px} < 24 \times 24 \text{ px}$ (Notif.) | lay. | grep (CSS)                | 2.5.8 |
| V48 | Modaler Dialog übernimmt Fokus beim Öffnen nicht                    | sem. | Playwright                | 2.4.3 |
| V49 | Dialog ohne <code>aria-labelledby</code>                            | syn. | axe-core                  | 4.1.2 |
| V50 | <code>outline: none</code> im Modal-Button (Fokus entfernt)         | lay. | Playwright                | 2.4.7 |

Kat.: syn. = syntaktisch, sem. = semantisch, lay. = layout.

## Anhang 29: Erkennungsrate der Violations im Proof of Concept (test-50-Suite)

Tab. 36: Erkennungsrate aller 50 Violations (Konsistenzschwelle: > 5/10 Runs je Modell). *Erkannt* = konsistent über alle Modelle hinweg; modellabhängige Abweichungen sind in *Anmerkung* dokumentiert.<sup>211</sup>

| #                                  | Violation                              | Erkannt | Tatsächl. Quelle | Anmerkung                                       |
|------------------------------------|----------------------------------------|---------|------------------|-------------------------------------------------|
| V1                                 | Skip-Link fehlt                        | ✓       | Playwright       | 14b/32b kons.; 7b inst. (4/10)                  |
| V2                                 | <html> ohne lang                       | ✓       | axe-core         | 14b/32b kons.; 7b selten (1/10)                 |
| V3                                 | Logo <img> ohne alt="..."              | ✓       | axe-core + grep  | Alle Modelle                                    |
| V4                                 | Deko-Bild ohne alt=                    | ✓       | axe-core + grep  | Alle Modelle                                    |
| V5                                 | Hamburger-Button ohne Namen            | ✓       | axe-core         | Alle Modelle                                    |
| V6                                 | <a> ohne href                          | ✓       | axe-core         | 14b/32b kons.; 7b selten (1/10)                 |
| V7                                 | Badge-Kontrast zu niedrig              | ✓       | axe-core         | Alle Modelle                                    |
| V8                                 | CSS order ≠ DOM-Reihenfolge            | ✓       | LLM-Detektor     | nur 32b kons.; 14b nie erkannt; 7b inst. (3/10) |
| V9                                 | <nav> ohne aria-label                  | ✓       | axe-core         | Alle Modelle                                    |
| V10                                | onClick auf <li> o. onKeyDown (1)      | ✓       | grep             | Alle Modelle                                    |
| V11                                | onClick auf <li> o. onKeyDown (2)      | ✓       | grep             | Alle Modelle                                    |
| V12                                | role="button" o. tabIndex (Sidebar)    | ✓       | axe-core + grep  | Alle Modelle                                    |
| V13                                | onClick auf <li> o. onKeyDown (3)      | ✓       | grep             | Alle Modelle                                    |
| V14                                | Button < 24 px (Sidebar)               | ✓       | grep (CSS)       | Alle Modelle                                    |
| V15                                | aria-hidden auf fokussierbarem Element | ✓       | axe-core         | Alle Modelle                                    |
| V16                                | Überschriften-Hierarchie übersprungen  | ✓       | axe-core         | 14b/32b kons.; 7b selten (1/10)                 |
| V17                                | KPI-Icon <img> ohne alt="..." (1)      | ✓       | axe-core + grep  | 14b/32b kons.; 7b inst. (5/10)                  |
| V18                                | KPI-Wert Kontrast zu niedrig           | ✓       | axe-core         | Alle Modelle                                    |
| V19                                | KPI-Icon <img> ohne alt="..." (2)      | ✓       | axe-core + grep  | 14b/32b kons.; 7b inst. (5/10)                  |
| V20                                | onClick auf <div> o. onKeyDown         | ✓       | grep             | 7b/14b kons.; 32b inst. (5/10)                  |
| Fortsetzung auf der nächsten Seite |                                        |         |                  |                                                 |

Tab. 36: Erkennungsrate der Violations (test-50-Suite, Fortsetzung)

| #                                  | Violation                            | Erkannt | Tatsächl. Quelle | Anmerkung                              |
|------------------------------------|--------------------------------------|---------|------------------|----------------------------------------|
| V21                                | role="button" auf <div> o. tabIndex  | ✓       | axe-core + grep  | 7b/14b kons.; 32b inst. (5/10)         |
| V22                                | Chart-Bild ohne alt="..."            | ✓       | axe-core + grep  | Alle Modelle                           |
| V23                                | Tabelle o. <caption> (Dashboard)     | ✓       | axe-core         | 14b/32b kons.; 7b selten (1/10)        |
| V24                                | <th> ohne scope                      | ✓       | axe-core         | 14b/32b kons.; 7b inst. (3/10)         |
| V25                                | Status nur durch Farbe (Dashboard)   | ✓       | LLM-Detektor     | 14b/32b kons.; 7b inst. (4/10)         |
| V26                                | Avatar <img> ohne alt="..."          | ✓       | axe-core + grep  | Alle Modelle                           |
| V27                                | Input ohne <label> (Anzeigename)     | ✓       | axe-core         | Alle Modelle                           |
| V28                                | Input ohne <label> (E-Mail)          | ✓       | axe-core         | Alle Modelle                           |
| V29                                | Textarea ohne <label> (Bio)          | ✓       | axe-core         | Alle Modelle                           |
| V30                                | Pflichtfeld ohne required/aria-req.  | ✓       | LLM-Detektor     | Alle Modelle (LLM-Detektor)            |
| V31                                | Fehlermeldung nicht progr. verknüpft | ✓       | LLM-Detektor     | Alle Modelle (LLM-Detektor)            |
| V32                                | Button-Kontrast zu niedrig           | ✓       | axe-core         | Alle Modelle                           |
| V33                                | outline: none auf Button             | ✓       | Playwright       | Alle Modelle                           |
| V34                                | Statusmeldung ohne aria-live         | ✓       | LLM-Detektor     | Alle Modelle (LLM-Detektor)            |
| V35                                | Duplikat-ID help-text                | ✓       | axe-core         | 7b/14b kons.; 32b inst. (5/10)         |
| V36                                | onClick auf <span> o. onKeyDown      | ✓       | grep             | 32b kons.; 7b/14b inst. (4-5/10)       |
| V37                                | Suchfeld ohne sichtbares Label       | ✓       | axe-core         | 32b kons.; 14b inst.; 7b selten (2/10) |
| V38                                | Tabelle o. <caption> (DataTable)     | ✓       | axe-core         | 14b/32b kons.; 7b selten (1/10)        |
| V39                                | Checkbox ohne Label (Header)         | ✓       | axe-core         | 14b/32b kons.; 7b inst. (3/10)         |
| V40                                | Checkbox ohne Label (Zeilen)         | ✓       | axe-core         | 14b/32b kons.; 7b inst. (3/10)         |
| V41                                | Status nur durch Farbe (DataTable)   | ✓       | LLM-Detektor     | 14b/32b kons.; 7b inst. (3/10)         |
| V42                                | Icon-Button ohne zugängl. Namen      | ✓       | axe-core         | 14b kons.; 7b/32b inst. (3/10)         |
| Fortsetzung auf der nächsten Seite |                                      |         |                  |                                        |

Tab. 36: Erkennungsrate der Violations (test-50-Suite, Fortsetzung)

| #   | Violation                                                                    | Erkannt | Tatsächl. Quelle | Anmerkung                              |
|-----|------------------------------------------------------------------------------|---------|------------------|----------------------------------------|
| V43 | Paginierung <code>&lt;div&gt;</code> ohne Keyboard                           | ✓       | grep             | Alle Modelle                           |
| V44 | <code>&lt;li&gt;</code> mit <code>onClick</code> ohne <code>onKeyDown</code> | ✓       | grep             | Alle Modelle                           |
| V45 | Ungelesen nur durch Farbe                                                    | ✓       | LLM-Detektor     | Alle Modelle (LLM-Detektor)            |
| V46 | Zeitangabe Kontrast zu niedrig                                               | ✓       | axe-core         | 32b kons.; 14b inst.; 7b selten (1/10) |
| V47 | Button <code>&lt; 24 px</code> (Notif.)                                      | ✓       | grep (CSS)       | 7b/32b kons.; 14b inst. (5/10)         |
| V48 | Modaler Dialog übernimmt Fokus beim Öffnen nicht                             | ✓       | Playwright       | 14b kons.; 32b inst. (5/10); 7b selten |
| V49 | Dialog ohne <code>aria-labelledby</code>                                     | ✓       | axe-core         | 7b kons. (8/10); 14b/32b inst. (5/10)  |
| V50 | <code>outline: none</code> im Modal-Button                                   | ✓       | Playwright       | 32b kons.; 14b inst. (4/10); 7b selten |

## Anhang 30: Recall-Matrix: Violation × Bedingung (test-50-Suite)

Tab. 37: Erkennungsstatus je Violation. ✓ = konsistent erkannt (> 5/10 Runs); ~ = instabil (3–5/10 Runs); × = nicht erkannt (0–2/10 Runs).

| #                                  | Violation                              | Baseline | + 7b | + 14b | + 32b | LLM-exkl. |
|------------------------------------|----------------------------------------|----------|------|-------|-------|-----------|
| V1                                 | Skip-Link fehlt                        | ✓        | ~    | ✓     | ✓     |           |
| V2                                 | <html> ohne lang                       | ✓        | ~    | ✓     | ✓     |           |
| V3                                 | Logo <img> ohne alt="..."              | ✓        | ✓    | ✓     | ✓     |           |
| V4                                 | Deko-Bild ohne alt=                    | ✓        | ✓    | ✓     | ✓     |           |
| V5                                 | Hamburger-Button ohne Namen            | ✓        | ✓    | ✓     | ✓     |           |
| V6                                 | <a> ohne href                          | ✓        | ~    | ×     | ✓     |           |
| V7                                 | Badge-Kontrast zu niedrig              | ✓        | ✓    | ✓     | ✓     |           |
| V8                                 | CSS order ≠ DOM-Reihenfolge            | ×        | ~    | ×     | ✓     | ✓         |
| V9                                 | <nav> ohne aria-label                  | ✓        | ✓    | ✓     | ✓     |           |
| V10                                | onClick auf <li> o. onKeyDown (1)      | ✓        | ✓    | ✓     | ✓     |           |
| V11                                | onClick auf <li> o. onKeyDown (2)      | ✓        | ✓    | ✓     | ✓     |           |
| V12                                | role="button" o. tabIndex (Sb.)        | ✓        | ✓    | ✓     | ✓     |           |
| V13                                | onClick auf <li> o. onKeyDown (3)      | ✓        | ✓    | ✓     | ✓     |           |
| V14                                | Button <24px (Sidebar)                 | ✓        | ✓    | ✓     | ✓     |           |
| V15                                | aria-hidden auf fokussierbarem Element | ✓        | ✓    | ✓     | ✓     |           |
| V16                                | Überschriften-Hierarchie übersprungen  | ✓        | ~    | ✓     | ✓     |           |
| V17                                | KPI-Icon <img> ohne alt="..." (1)      | ✓        | ✓    | ✓     | ✓     |           |
| V18                                | KPI-Wert Kontrast zu niedrig           | ✓        | ✓    | ✓     | ✓     |           |
| V19                                | KPI-Icon <img> ohne alt="..." (2)      | ✓        | ✓    | ✓     | ✓     |           |
| V20                                | onClick auf <div> o. onKeyDown         | ✓        | ✓    | ✓     | ✓     |           |
| Fortsetzung auf der nächsten Seite |                                        |          |      |       |       |           |

Tab. 37: Recall-Matrix test-50-Suite (Fortsetzung)

| #                                  | Violation                                 | Baseline | + 7b | + 14b | + 32b | LLM-exkl. |
|------------------------------------|-------------------------------------------|----------|------|-------|-------|-----------|
| V21                                | role="button" auf <div><br>o. tabIndex    | ✓        | ✓    | ✓     | ✓     |           |
| V22                                | Chart-Bild ohne alt="..."                 | ✓        | ✓    | ✓     | ✓     |           |
| V23                                | Tabelle o. <caption> (Dash-<br>board)     | ✓        | ~    | ✓     | ✓     |           |
| V24                                | <th> ohne scope                           | ✓        | ~    | ✓     | ✓     |           |
| V25                                | Status nur durch Farbe (Das-<br>hboard)   | ×        | ✓    | ✓     | ✓     | ✓         |
| V26                                | Avatar <img> ohne alt="..."               | ✓        | ✓    | ✓     | ✓     |           |
| V27                                | Input ohne <label> (Anzei-<br>gename)     | ✓        | ✓    | ✓     | ✓     |           |
| V28                                | Input ohne <label> (E-Mail)               | ✓        | ✓    | ✓     | ✓     |           |
| V29                                | Textarea ohne <label> (Bio)               | ✓        | ✓    | ✓     | ✓     |           |
| V30                                | Pflichtfeld ohne<br>required/aria-req.    | ×        | ✓    | ✓     | ✓     | ✓         |
| V31                                | Fehlermeldung nicht pro-<br>gr. verknüpft | ×        | ✓    | ✓     | ✓     | ✓         |
| V32                                | Button-Kontrast zu niedrig                | ✓        | ✓    | ✓     | ✓     |           |
| V33                                | outline: none auf Button                  | ✓        | ✓    | ✓     | ✓     |           |
| V34                                | Statusmeldung ohne<br>aria-live           | ×        | ✓    | ✓     | ✓     | ✓         |
| V35                                | Duplikat-ID help-text                     | ✓        | ✓    | ✓     | ✓     |           |
| V36                                | onClick auf <span><br>o. onKeyDown        | ✓        | ~    | ✓     | ✓     |           |
| V37                                | Suchfeld ohne sichtbares La-<br>bel       | ✓        | ~    | ✓     | ✓     |           |
| V38                                | Tabelle o. <caption> (Data-<br>Table)     | ✓        | ~    | ✓     | ✓     |           |
| V39                                | Checkbox ohne Label (Hea-<br>der)         | ✓        | ~    | ✓     | ✓     |           |
| V40                                | Checkbox ohne Label (Zeilen)              | ✓        | ~    | ✓     | ✓     |           |
| V41                                | Status nur durch Farbe (Data-<br>Table)   | ×        | ~    | ✓     | ✓     | ✓         |
| Fortsetzung auf der nächsten Seite |                                           |          |      |       |       |           |

Tab. 37: Recall-Matrix test-50-Suite (Fortsetzung)

| #             | Violation                                        | Baseline       | + 7b           | + 14b          | + 32b          | LLM-exkl.    |
|---------------|--------------------------------------------------|----------------|----------------|----------------|----------------|--------------|
| V42           | Icon-Button ohne zugängl. Namen                  | ✓              | ~              | ✓              | ✓              |              |
| V43           | Paginierung <div> ohne Keyboard                  | ✓              | ✓              | ✓              | ✓              |              |
| V44           | <li> mit onClick o. onKeyDown                    | ✓              | ✓              | ✓              | ✓              |              |
| V45           | Ungelesen nur durch Farbe                        | ×              | ✓              | ✓              | ✓              | ✓            |
| V46           | Zeitangabe Kontrast zu niedrig                   | ✓              | ~              | ✓              | ✓              |              |
| V47           | Button < 24 px (Notif.)                          | ✓              | ✓              | ✓              | ✓              |              |
| V48           | Modaler Dialog übernimmt Fokus beim Öffnen nicht | ✓              | ✓              | ✓              | ✓              |              |
| V49           | Dialog ohne aria-labelledby                      | ✓              | ✓              | ✓              | ✓              |              |
| V50           | outline: none im Modal-Button                    | ✓              | ✓              | ✓              | ✓              |              |
| <b>Recall</b> |                                                  | <b>43 / 50</b> | <b>36 / 50</b> | <b>48 / 50</b> | <b>50 / 50</b> | 7 Violations |

**Hinweis:** Die Werte 14/2/21 sind Detektor-*Finding*-Counts (axe/Playwright/grep), während 43/50 die Abdeckung der 50 definierten Ground-Truth-*Violations* angibt; beide Kennzahlen sind daher nicht direkt gegeneinander austauschbar.



## Anhang 31: Rohdaten: alle 30 Benchmark-Runs (test-50-Suite)

Tab. 38: Vollständige Messdaten der 30 Pipeline-Durchläufe (`num_predict = 8192`). LLM-Det. = Findings des LLM-Detektors; Axe/PW/Grep = Tool-Findings (konstant); Tokens = Output-Tokens; Dauer = Priorisierungslaufzeit in Sekunden.

| Run | Modell            | LLM-Det. | Axe | PW | Grep | Must | Nice | Tokens | Dauer (s) |
|-----|-------------------|----------|-----|----|------|------|------|--------|-----------|
| 01  | qwen2.5-coder:7b  | 47       | 14  | 2  | 21   | 10   | 17   | 3409   | 123       |
| 02  | qwen2.5-coder:7b  | 47       | 14  | 2  | 21   | 14   | 51   | 8192   | 228       |
| 03  | qwen2.5-coder:7b  | 47       | 14  | 2  | 21   | 27   | 41   | 8192   | 232       |
| 04  | qwen2.5-coder:7b  | 47       | 14  | 2  | 21   | 26   | 34   | 8192   | 234       |
| 05  | qwen2.5-coder:7b  | 40       | 14  | 2  | 21   | 10   | 4    | 1996   | 75        |
| 06  | qwen2.5-coder:7b  | 44       | 14  | 2  | 21   | 13   | 59   | 8192   | 236       |
| 07  | qwen2.5-coder:7b  | 47       | 14  | 2  | 21   | 24   | 49   | 8192   | 241       |
| 08  | qwen2.5-coder:7b  | 47       | 14  | 2  | 21   | 24   | 23   | 5683   | 180       |
| 09  | qwen2.5-coder:7b  | 53       | 14  | 2  | 21   | 54   | 10   | 7291   | 205       |
| 10  | qwen2.5-coder:7b  | 47       | 14  | 2  | 21   | 13   | 68   | 8192   | 224       |
| 11  | qwen2.5-coder:14b | 45       | 14  | 2  | 21   | 50   | 8    | 8192   | 457       |
| 12  | qwen2.5-coder:14b | 52       | 14  | 2  | 21   | 14   | 48   | 8192   | 462       |
| 13  | qwen2.5-coder:14b | 52       | 14  | 2  | 21   | 14   | 45   | 8192   | 458       |
| 14  | qwen2.5-coder:14b | 52       | 14  | 2  | 21   | 14   | 48   | 8192   | 480       |
| 15  | qwen2.5-coder:14b | 52       | 14  | 2  | 21   | 14   | 45   | 8192   | 473       |
| 16  | qwen2.5-coder:14b | 52       | 14  | 2  | 21   | 59   | 0    | 8192   | 465       |
| 17  | qwen2.5-coder:14b | 52       | 14  | 2  | 21   | 14   | 33   | 6014   | 352       |
| 18  | qwen2.5-coder:14b | 52       | 14  | 2  | 21   | 14   | 34   | 6239   | 361       |
| 19  | qwen2.5-coder:14b | 52       | 14  | 2  | 21   | 14   | 47   | 8192   | 459       |
| 20  | qwen2.5-coder:14b | 52       | 14  | 2  | 21   | 14   | 49   | 8046   | 470       |
| 21  | qwen3:32b         | 60       | 14  | 2  | 21   | 36   | 38   | 8192   | 1084      |
| 22  | qwen3:32b         | 60       | 14  | 2  | 21   | 37   | 46   | 8192   | 1030      |
| 23  | qwen3:32b         | 62       | 14  | 2  | 21   | 66   | 0    | 8192   | 1014      |
| 24  | qwen3:32b         | 60       | 14  | 2  | 21   | 66   | 12   | 8192   | 1004      |
| 25  | qwen3:32b         | 63       | 14  | 2  | 21   | 73   | 7    | 8192   | 1008      |
| 26  | qwen3:32b         | 60       | 14  | 2  | 21   | 49   | 22   | 8192   | 996       |
| 27  | qwen3:32b         | 61       | 14  | 2  | 21   | 32   | 46   | 8192   | 998       |
| 28  | qwen3:32b         | 60       | 14  | 2  | 21   | 30   | 36   | 7179   | 885       |
| 29  | qwen3:32b         | 62       | 14  | 2  | 21   | 49   | 30   | 8192   | 995       |
| 30  | qwen3:32b         | 59       | 14  | 2  | 21   | 38   | 36   | 8192   | 987       |

## Anhang 32: Modell-Leistungsvergleich: test-50-Suite

### Zusammenfassung

Tab. 39: Zusammenfassung der Leistungsmetriken für die drei evaluierten Modelle (je  $n = 10$  Runs, `num_predict` = 8 192).  $\sigma$  = Stichproben-Standardabweichung. Der Recall basiert auf Konsistenzschwelle  $> 5/10$  Runs je Modell.

| Metrik                                         | qwen2.5-coder:7b | qwen2.5-coder:14b | qwen3:32b       |
|------------------------------------------------|------------------|-------------------|-----------------|
| Recall (konsistent)                            | 36 / 50 (72 %)   | 48 / 50 (96 %)    | 50 / 50 (100 %) |
| LLM-Detektor-Findings ( $\bar{O} \pm \sigma$ ) | 46,6 $\pm$ 3,20  | 51,3 $\pm$ 2,21   | 60,7 $\pm$ 1,25 |
| LLM-Detektor-Findings (Min–Max)                | 40–53            | 45–52             | 59–63           |
| Konsistenz $\sigma$                            | 3,20             | 2,21              | 1,25            |
| Priorisierungsqualität                         | Instabil         | Bimodal           | Plausibel       |
| Output-Tokens ( $\bar{O}$ )                    | 6 753            | 7 764             | 8 091           |
| Output-Limit ausgeschöpft                      | 6 / 10 (60 %)    | 7 / 10 (70 %)     | 9 / 10 (90 %)   |
| Parsing-Erfolg                                 | 100 %            | 100 %             | 100 %           |
| NFA-02-Konformität                             | Erfüllt          | Erfüllt           | Nicht erfüllt   |
| Eignung BITV-Einsatz                           | Nicht geeignet   | Empfohlen         | Eingeschränkt   |
| <i>Suite-spezifische Zusatzmetriken</i>        |                  |                   |                 |
| Fix-Qualität (Stufe)                           | 0–1              | 0–2               | 1–2             |
| Tool-Findings (axe/PW/grep)                    | 14 / 2 / 21      | 14 / 2 / 21       | 14 / 2 / 21     |
| Must-have im Bericht ( $\bar{O}$ )             | 21,5             | 22,1              | 47,6            |
| Nice-to-have ( $\bar{O}$ ) Bericht             | 35,6             | 35,7              | 27,3            |
| Gesamt-Report-Items ( $\bar{O}$ )              | 57,1             | 57,8              | 74,9            |
| LLM-Detektor-Laufzeit ( $\bar{O}$ )            | 215 s            | 382 s             | 897 s           |
| Priorisierungslaufzeit ( $\bar{O}$ )           | 198 s            | 444 s             | 1 000 s         |
| Priorisierungslaufzeit (Min–Max)               | 75–241 s         | 352–480 s         | 885–1 084 s     |
| Gesamtlaufzeit ( $\bar{O}$ )                   | 413 s            | 826 s             | 1 897 s         |
| Gesamtlaufzeit (Min–Max)                       | 291–465 s        | 733–871 s         | 1 752–2 011 s   |

## Anhang 33: Token-Nutzung pro Modell: Input/Output (test-50-Suite)

Tab. 40: Durchschnittliche Token-Nutzung je Run und Modell auf Basis der test-50-Suite (`num_predict` = 8 192). Input-Tokens umfassen System-Prompt, serialisierte Findings und Konfigurationsparameter. Der höhere Input gegenüber test-12 reflektiert die größere Anzahl serialisierter Violations.

| Modell                                                                              | Input-Tokens (Ø) | Output-Tokens (Ø) | Truncation         |
|-------------------------------------------------------------------------------------|------------------|-------------------|--------------------|
| qwen2.5-coder:7b                                                                    | 13 196           | 6 753             | 6 / 10 Runs (60 %) |
| qwen2.5-coder:14b                                                                   | 13 556           | 7 764             | 7 / 10 Runs (70 %) |
| qwen3:32b                                                                           | 14 231           | 8 091             | 9 / 10 Runs (90 %) |
| <i>Gesamt (30 Runs): Input <math>\approx</math> 409 500 / Output 226 740 Tokens</i> |                  |                   |                    |

## Anhang 34: Effizienzmetriken und Kosten-Nutzen-Verhältnis (test-50-Suite)

Tab. 41: Effizienzvergleich auf Basis der 30 Benchmark-Runs der test-50-Suite. *LLM-Findings/s* bezieht sich auf LLM-Detektor-Findings pro Sekunde Gesamtlaufzeit.

| Modell            | LLM-Findings Ø | Gesamtlaufzeit Ø (s) | LLM-Findings/s | Zusatznutzen ggü. 7b           |
|-------------------|----------------|----------------------|----------------|--------------------------------|
| qwen2.5-coder:7b  | 46,6           | 413                  | 0,113          | Referenz                       |
| qwen2.5-coder:14b | 51,3           | 826                  | 0,062          | +10,1 % bei +99 % Zeitaufwand  |
| qwen3:32b         | 60,7           | 1897                 | 0,032          | +30,3 % bei +359 % Zeitaufwand |

## Anhang 35: Über-Detektion relativ zur Ground Truth (test-50-Suite)

Tab. 42: Vergleich der durchschnittlichen LLM-Detektor-Findings pro Run mit der Ground Truth (50 Violations). Die LLM-only-Betrachtung vermeidet Doppelzählungen zwischen überlappenden Detektoren.

| Modell            | LLM-Findings $\bar{O}$ | Ground Truth | Quote   | Interpretation                                                                       |
|-------------------|------------------------|--------------|---------|--------------------------------------------------------------------------------------|
| qwen2.5-coder:7b  | 46,6                   | 50           | 93,2 %  | nahe an der Ground Truth; LLM liefert teils Underdetektion bei einzelnen Runs        |
| qwen2.5-coder:14b | 51,3                   | 50           | 102,6 % | sehr nahe an der Ground Truth; geringste Abweichung im Mittel                        |
| qwen3:32b         | 60,7                   | 50           | 121,4 % | erhöhter Überschuss; zugleich konsistenteste LLM-Detektion ( $\sigma \approx 1,25$ ) |

## Anhang 36: Precision und F1-Score je Run (test-50-Suite)

Per-Run-Auflistung der Precision für alle 30 Benchmark-Runs auf der test-50-Suite. Precision gemessen auf Item-Ebene: Ein Report-Item gilt als True Positive (TP), wenn es per Modell-ID-Präfix einem Tool-Fund (axe, Playwright, grep) zugeordnet werden kann oder per Inhalt auf ein WCAG-Kriterium der Ground Truth verweist; andernfalls als False Positive (FP). Konsistenz-Recall und F1 beziehen sich auf die modellübergreifenden Werte aus Tabelle 9.

Tab. 43: Precision je Run auf test-50 für alle drei evaluierten Modelle ( $n = 10$  Runs je Modell). TP = True-Positive-Items, FP = False-Positive-Items (keine nachweisbare Entsprechung in der Ground Truth). Modell-Gesamtwerte in der letzten Zeile.

| Run                                                                                                       | qwen2.5-coder:7b |          |             | qwen2.5-coder:14b |           |             | qwen3:32b  |          |             |
|-----------------------------------------------------------------------------------------------------------|------------------|----------|-------------|-------------------|-----------|-------------|------------|----------|-------------|
|                                                                                                           | Items            | FP       | Prec. %     | Items             | FP        | Prec. %     | Items      | FP       | Prec. %     |
| 01                                                                                                        | 27               | 0        | 100,0       | 58                | 0         | 100,0       | 74         | 0        | 100,0       |
| 02                                                                                                        | 65               | 3        | 95,4        | 62                | 0         | 100,0       | 83         | 0        | 100,0       |
| 03                                                                                                        | 68               | 0        | 100,0       | 59                | 2         | 96,6        | 66         | 0        | 100,0       |
| 04                                                                                                        | 60               | 1        | 98,3        | 62                | 0         | 100,0       | 78         | 0        | 100,0       |
| 05                                                                                                        | 14               | 0        | 100,0       | 59                | 0         | 100,0       | 80         | 0        | 100,0       |
| 06                                                                                                        | 72               | 0        | 100,0       | 59                | 0         | 100,0       | 71         | 0        | 100,0       |
| 07                                                                                                        | 73               | 0        | 100,0       | 47                | 3         | 93,6        | 78         | 1        | 98,7        |
| 08                                                                                                        | 47               | 0        | 100,0       | 48                | 3         | 93,8        | 66         | 0        | 100,0       |
| 09                                                                                                        | 64               | 0        | 100,0       | 61                | 0         | 100,0       | 79         | 1        | 98,7        |
| 10                                                                                                        | 81               | 3        | 96,3        | 63                | 2         | 96,8        | 74         | 1        | 98,6        |
| <b>Ø</b>                                                                                                  | <b>571</b>       | <b>7</b> | <b>99,0</b> | <b>578</b>        | <b>10</b> | <b>98,1</b> | <b>749</b> | <b>3</b> | <b>99,6</b> |
| Kons.-Recall: 72 %    F1: 83,4 %    Kons.-Recall: 96 %    F1: 97,0 %    Kons.-Recall: 100 %    F1: 99,8 % |                  |          |             |                   |           |             |            |          |             |

## Anhang 37: Detektor-Konsistenz über alle 30 Runs (test-50-Suite)

Tab. 44: Konsistenzanalyse der Detektoren über alle 30 Benchmark-Runs. Die festen Detektoren bleiben vollständig deterministisch; die LLM-Varianz ist modellabhängig.

| Detektor / Modell   | Runs | Gesamt-Findings | Ø pro Run | Min-Max | $\sigma^2 / \sigma$ | Interpretation                   |
|---------------------|------|-----------------|-----------|---------|---------------------|----------------------------------|
| axe-core            | 30   | 420             | 14,0      | 14–14   | 0,00 / 0,00         | vollständig deterministisch      |
| Playwright          | 30   | 60              | 2,0       | 2–2     | 0,00 / 0,00         | vollständig deterministisch      |
| grep                | 30   | 630             | 21,0      | 21–21   | 0,00 / 0,00         | vollständig deterministisch      |
| qwen2.5-coder:7b    | 10   | 466             | 46,6      | 40–53   | 10,27 / 3,20        | höchste Streuung                 |
| qwen2.5-coder:14b   | 10   | 513             | 51,3      | 45–52   | 4,90 / 2,21         | gute Konsistenz (1 Ausreißer)    |
| qwen3:32b           | 10   | 607             | 60,7      | 59–63   | 1,57 / 1,25         | höchste Konsistenz aller Modelle |
| LLM-Detektor gesamt | 30   | 1586            | 52,9      | 40–63   | modellabhängig      | –                                |

## Anhang 38: Bewertung der Empfehlungsqualität pro Violation (test-50-Suite)

*Kürzel:* DT = DataTable, SR = SearchResults, FU = FileUpload, N.= Notifications, Cal.= Calendar, Dash.= Dashboard, User = UserProfile.

Die Bewertung basiert auf Run 01 von **qwen3:32b** (Tabelle 38) und verwendet dieselbe dreistufige Skala wie Tabelle 18. Stufe 2 liegt vor, wenn Dateiname, Zeilennummer und ein konkreter Code-Vorschlag vorhanden sind; Stufe 1, wenn der richtige Fix-Typ erkannt, aber kein konkreter Codekontext geliefert wird.

Tab. 45: Bewertung der Fix-Qualität für alle 50 Violations (**qwen3:32b**, Run 01).

| #                                  | Violation                                                 | Stufe (0–2) | Anmerkung (qwen3:32b)                                                           |
|------------------------------------|-----------------------------------------------------------|-------------|---------------------------------------------------------------------------------|
| V1                                 | Skip-Link fehlt                                           | 2           | App.tsx, <code>&lt;a href="#main-content&gt;</code> -Snippet mit CSS-Klasse     |
| V2                                 | <code>&lt;html&gt;</code> ohne <code>lang</code>          | 2           | index.html, <code>&lt;html lang="de"&gt;</code> direkt angegeben                |
| V3                                 | Logo <code>&lt;img&gt;</code> ohne <code>alt="..."</code> | 2           | App.tsx:29, beschreibender <code>alt</code> -Text vorgeschlagen                 |
| V4                                 | Deko-Bild ohne <code>alt=/role</code>                     | 2           | App.tsx:32, <code>alt=role="presentation"</code> korrekt                        |
| V5                                 | Hamburger-Button ohne Namen                               | 2           | App.tsx:36, <code>aria-label="Menü öffnen"</code> mit vollst. JSX               |
| V6                                 | <code>&lt;a&gt;</code> ohne <code>href</code>             | 2           | App.tsx:41, <code>href="/help"</code> mit konkretem Pfad                        |
| V7                                 | Badge-Kontrast                                            | 2           | App.tsx:44, CSS <code>.header-badge</code> mit Hex-Farben                       |
| V8                                 | CSS <code>order</code> vs. DOM-Reihenfolge                | 1           | App.tsx:48; nur allgemeiner Hinweis („Vermeide CSS order“), kein konkreter Code |
| V9                                 | <code>&lt;nav&gt;</code> ohne <code>aria-label</code>     | 2           | Sidebar.tsx:11, <code>aria-label="Hauptnavigation"</code>                       |
| V10                                | <code>onClick</code> li ohne <code>onKeyDown</code> (1)   | 2           | Sidebar.tsx:14, vollst. <code>onKeyDown</code> -Handler mit Enter-Logik         |
| V11                                | <code>onClick</code> li ohne <code>onKeyDown</code> (2)   | 2           | Sidebar.tsx:21, Querverweis auf V10-Fix                                         |
| Fortsetzung auf der nächsten Seite |                                                           |             |                                                                                 |

Tab. 45: Bewertung der Empfehlungsqualität pro Violation (test-50) (Fortsetzung)

| #                                  | Violation                                                 | Stufe (0–2) | Anmerkung (qwen3:32b)                                                    |
|------------------------------------|-----------------------------------------------------------|-------------|--------------------------------------------------------------------------|
| V12                                | <code>role="button"</code> ohne <code>tabIndex</code>     | 2           | Sidebar.tsx:30, <code>tabIndex={0}</code> + vollst. JSX-Snippet          |
| V13                                | <code>onClick</code> li ohne <code>onKeyDown</code> (3)   | 2           | Sidebar.tsx:38, Querverweis auf V10-Fix                                  |
| V14                                | Button 16×16 px Sidebar                                   | 2           | styles.css, <code>.btn-tiny-sidebar</code> auf 32×32 px mit CSS          |
| V15                                | <code>aria-hidden</code> auf fokus. Element               | 2           | Sidebar.tsx:55, <code>aria-hidden</code> entfernt; vollst. JSX           |
| V16                                | Überschriften-Hierarchie                                  | 2           | Dashboard.tsx:7, <code>&lt;h1&gt;</code> -Ersatz mit Dateikontext        |
| V17                                | KPI-Icon ohne <code>alt="..."</code> (1)                  | 2           | Dashboard.tsx:12, beschreibender <code>alt</code> -Text                  |
| V18                                | KPI-Wert Kontrast                                         | 2           | Dashboard.tsx:16, CSS-Fix mit Hex-Farben                                 |
| V19                                | KPI-Icon ohne <code>alt="..."</code> (2)                  | 2           | Dashboard.tsx:22, Querverweis auf V17-Fix                                |
| V20                                | <code>onClick</code> div ohne <code>onKeyDown</code>      | 2           | Dashboard.tsx:30, <code>onKeyDown</code> + <code>tabIndex</code> vollst. |
| V21                                | <code>role="button"</code> div ohne <code>tabIndex</code> | 2           | Dashboard.tsx:38, <code>tabIndex={0}</code> mit JSX-Snippet              |
| V22                                | Chart-Bild ohne <code>alt="..."</code>                    | 2           | Dashboard.tsx:49, inhaltsbeschreibender <code>alt</code> -Text           |
| V23                                | Tabelle ohne <code>caption/aria-label</code>              | 2           | Dashboard.tsx:53, <code>aria-label="Dashboard-Daten"</code>              |
| V24                                | <code>&lt;th&gt;</code> ohne <code>scope</code>           | 2           | Dashboard.tsx:57, <code>scope="col"</code> ergänzt                       |
| V25                                | Status nur Farbe (Dashboard) ( <i>manuell</i> )           | 2           | styles.css:247, CSS <code>::after</code> mit Textalternative             |
| V26                                | Avatar ohne <code>alt="..."</code>                        | 2           | UserProfile.tsx:17, <code>alt="Profilbild des Nutzers"</code>            |
| V27                                | Input ohne <code>&lt;label&gt;</code> (Name)              | 2           | UserProfile.tsx:20, <code>htmlFor="name"</code> + id vollst.             |
| V28                                | Input ohne <code>&lt;label&gt;</code> (E-Mail)            | 2           | UserProfile.tsx:32, Querverweis auf V27-Fix                              |
| Fortsetzung auf der nächsten Seite |                                                           |             |                                                                          |

Tab. 45: Bewertung der Empfehlungsqualität pro Violation (test-50) (Fortsetzung)

| #                                  | Violation                                                                | Stufe (0–2) | Anmerkung (qwen3:32b)                                                |
|------------------------------------|--------------------------------------------------------------------------|-------------|----------------------------------------------------------------------|
| V29                                | Textarea ohne <code>&lt;label&gt;</code>                                 | 2           | UserProfile.tsx:44, Querverweis auf V27-Fix                          |
| V30                                | Pflichtfeld ohne <code>required</code> ( <i>manuell</i> )                | 2           | UserProfile.tsx:56, <code>required aria-required="true"</code>       |
| V31                                | Fehlermeldung nicht verknüpft ( <i>manuell</i> )                         | 2           | UserProfile.tsx:64, <code>aria-describedby-Snippet</code>            |
| V32                                | Button-Kontrast                                                          | 2           | UserProfile.tsx:73, CSS-Fix mit Hex-Farben                           |
| V33                                | <code>outline: none</code> Button                                        | 2           | UserProfile.tsx:78, <code>outline: "2px solid #000"</code>           |
| V34                                | Statusmeldung ohne <code>aria-live</code> ( <i>manuell</i> )             | 2           | UserProfile.tsx:83, <code>aria-live="polite"</code>                  |
| V35                                | Duplikat-ID <code>help-text</code>                                       | 2           | UserProfile.tsx:86, <code>id="help-text-1"/-2</code>                 |
| V36                                | <code>onClick</code> span ohne <code>onKeyDown</code>                    | 2           | DataTable.tsx:24, Umwandlung in <code>&lt;button&gt;</code> -Element |
| V37                                | Suchfeld ohne Label                                                      | 2           | DataTable.tsx:29, <code>&lt;label htmlFor&gt; + id</code>            |
| V38                                | Tabelle ohne <code>&lt;caption&gt;</code>                                | 2           | DataTable.tsx:33, <code>&lt;caption&gt;</code> -Element              |
| V39                                | Checkbox ohne Label (Header)                                             | 2           | DataTable.tsx:37, <code>htmlFor + id</code> vollst.                  |
| V40                                | Checkbox ohne Label (Zeilen)                                             | 2           | DataTable.tsx:50, Querverweis auf V39-Fix                            |
| V41                                | Status nur Farbe (DataTable) ( <i>manuell</i> )                          | 2           | DataTable.tsx:63 + styles.css:405, CSS <code>::after</code>          |
| V42                                | Icon-Button ohne Namen                                                   | 2           | DataTable.tsx:71, <code>aria-label="Bearbeiten"</code>               |
| V43                                | Paginierung <code>&lt;div&gt;</code> ohne Keyboard                       | 2           | DataTable.tsx:80, Umwandlung in <code>&lt;button&gt;</code>          |
| V44                                | <code>&lt;li&gt;</code> <code>onClick</code> ohne <code>onKeyDown</code> | 2           | Notifications.tsx:21, <code>onKeyDown-Enter-Snippet</code>           |
| V45                                | Ungelesen nur Farbe ( <i>manuell</i> )                                   | 2           | styles.css:485, CSS <code>::after</code> mit Textalternative         |
| Fortsetzung auf der nächsten Seite |                                                                          |             |                                                                      |



Tab. 45: Bewertung der Empfehlungsqualität pro Violation (test-50) (Fortsetzung)

| #              | Violation                                        | Stufe (0–2) | Anmerkung (qwen3:32b)                                            |
|----------------|--------------------------------------------------|-------------|------------------------------------------------------------------|
| V46            | Zeitangabe Kontrast                              | 2           | Notifications.tsx:34, CSS-Fix mit Dateikontext                   |
| V47            | Button 16×16 px Notifications                    | 2           | styles.css + Notifications.tsx:41, CSS 32×32 px                  |
| V48            | Modaler Dialog übernimmt Fokus beim Öffnen nicht | 2           | Notifications.tsx:46, <code>useEffect-</code> Fokus-Snippet      |
| V49            | Dialog ohne <code>aria-labelledby</code>         | 2           | Notifications.tsx:49, <code>aria-labelledby="modal-title"</code> |
| V50            | <code>outline: none</code> Modal-Button          | 2           | Notifications.tsx:54, <code>autoFocus</code> + korrekter Button  |
| Gesamt Stufe 2 |                                                  | 49 / 50     | 98 % konkrete Fixes mit Dateikontext                             |

## Anhang 39: Ansichten der Testanwendung (test-50-Suite)




Abb. 10: Dashboard-Übersicht der test-50-Suite




Abb. 11: Profil-Tab (Profil bearbeiten) der test-50-Suite

140 x 40

Serverstatus

Sortierung: A-Z Suchen...

| <input type="checkbox"/> | Name         | Status | Last (%) | Aktionen |
|--------------------------|--------------|--------|----------|----------|
| <input type="checkbox"/> | Server Alpha | ●      | 42       |          |
| <input type="checkbox"/> | Server Beta  | ●      | 0        |          |
| <input type="checkbox"/> | Server Delta | ●      | 15       |          |
| <input type="checkbox"/> | Server Gamma | ●      | 87       |          |

◀ Zurück 1 2 Weiter ▶

ACE Test-50 Synthetische Testkomponente

Dashboard  
Profil  
Datentabelle  
Benachrichtigungen  
Einstellungen

Abb. 12: Serverstatus der test-50-Suite

140 x 40

Benachrichtigungen

- Deployment abgeschlossen vor 3 Std.
- Neuer Kommentar vor 1 Std.
- Sicherheitswarnung vor 3 Std.

Benachrichtigungen

Abb. 13: Benachrichtigungen der test-50-Suite

## Anhang 40: Accessibility-Verstöße der Testanwendung (test-100-Suite)

Tab. 46: Alle 100 eingebetteten Accessibility-Verstöße mit Kategorie, erwarteter Erkennungsquelle und zugehörigem WCAG-Kriterium. *LLM* = ausschließlich LLM-Codeanalyse; *manuell* = keine automatische Erkennungsquelle erwartet.

| #                                  | Violation                      | Kat. | Erwartete Quelle | WCAG  |
|------------------------------------|--------------------------------|------|------------------|-------|
| V1                                 | Skip-Link fehlt                | sem. | Playwright       | 2.4.1 |
| V2                                 | <html> ohne lang               | syn. | axe-core         | 3.1.1 |
| V3                                 | Logo ohne alt="..."            | syn. | axe-core + grep  | 1.1.1 |
| V4                                 | Deko-Bild ohne alt=            | syn. | axe-core + grep  | 1.1.1 |
| V5                                 | Button ohne zugänglichen Namen | syn. | axe-core         | 4.1.2 |
| V6                                 | Badge Kontrast zu niedrig      | lay. | axe-core         | 1.4.3 |
| V7                                 | <a> ohne href                  | sem. | axe-core         | 2.1.1 |
| V8                                 | CSS order weicht von DOM ab    | sem. | axe-core         | 1.3.2 |
| V9                                 | <nav> ohne aria-label          | syn. | axe-core         | 1.3.1 |
| V10                                | onClick auf <li> o. onKeyDown  | sem. | grep             | 2.1.1 |
| V11                                | Headings übersprungen (h3)     | sem. | axe-core         | 1.3.1 |
| V12                                | KPI-Icon ohne alt="..."        | syn. | axe-core + grep  | 1.1.1 |
| V13                                | KPI-Wert Kontrast niedrig      | lay. | axe-core         | 1.4.3 |
| V14                                | KPI-Icon ohne alt="..."        | syn. | axe-core + grep  | 1.1.1 |
| V15                                | onClick auf <div> o. onKeyDown | sem. | grep             | 2.1.1 |
| V16                                | role="button" ohne tabIndex    | sem. | axe-core + grep  | 4.1.2 |
| V17                                | Chart ohne alt="..."           | syn. | axe-core + grep  | 1.1.1 |
| V18                                | Tabelle ohne <caption>         | sem. | axe-core         | 1.3.1 |
| V19                                | <th> ohne scope                | syn. | axe-core         | 1.3.1 |
| V20                                | Status nur durch Farbe         | sem. | manuell          | 1.4.1 |
| V21                                | Avatar ohne alt="..."          | syn. | axe-core + grep  | 1.1.1 |
| V22                                | Input ohne <label>             | syn. | axe-core         | 1.3.1 |
| V23                                | Input ohne <label>             | syn. | axe-core         | 1.3.1 |
| V24                                | Textarea ohne <label>          | syn. | axe-core         | 1.3.1 |
| V25                                | Pflichtfeld ohne required      | syn. | manuell          | 3.3.2 |
| V26                                | Fehlermeldung nicht verknüpft  | sem. | manuell          | 3.3.1 |
| V27                                | Button Kontrast niedrig        | lay. | axe-core         | 1.4.3 |
| V28                                | outline: none auf Button       | lay. | Playwright       | 2.4.7 |
| Fortsetzung auf der nächsten Seite |                                |      |                  |       |

Tab. 46: Accessibility-Verstöße der test-100-Suite (Fortsetzung)

| #                                  | Violation                                                  | Kat. | Erwartete Quelle | WCAG  |
|------------------------------------|------------------------------------------------------------|------|------------------|-------|
| V29                                | Statusmeldung ohne <b>aria-live</b>                        | sem. | manuell          | 4.1.3 |
| V30                                | Duplikat-ID                                                | syn. | axe-core         | 4.1.1 |
| V31                                | <b>onClick</b> auf <b>&lt;span&gt;</b> o. <b>onKeyDown</b> | sem. | grep             | 2.1.1 |
| V32                                | Suchfeld ohne Label                                        | syn. | axe-core         | 1.3.1 |
| V33                                | Tabelle ohne <b>&lt;caption&gt;</b>                        | sem. | axe-core         | 1.3.1 |
| V34                                | Checkbox ohne Label                                        | syn. | axe-core         | 1.3.1 |
| V35                                | Checkbox ohne Label (Zeilen)                               | syn. | axe-core         | 1.3.1 |
| V36                                | Status nur durch Farbe                                     | sem. | manuell          | 1.4.1 |
| V37                                | Icon-Button ohne Namen                                     | syn. | axe-core         | 4.1.2 |
| V38                                | Paginierung <b>onClick</b> o. Keyboard                     | sem. | grep             | 2.1.1 |
| V39                                | Paginierung <b>onClick</b> o. Keyboard                     | sem. | grep             | 2.1.1 |
| V40                                | Paginierung <b>onClick</b> o. Keyboard                     | sem. | grep             | 2.1.1 |
| V41                                | <b>&lt;li&gt;</b> <b>onClick</b> o. <b>onKeyDown</b>       | sem. | grep             | 2.1.1 |
| V42                                | Ungelesen nur durch Farbe                                  | sem. | manuell          | 1.4.1 |
| V43                                | Kontrast Zeitangabe niedrig                                | lay. | axe-core         | 1.4.3 |
| V44                                | <b>&lt;li&gt;</b> <b>onClick</b> o. <b>onKeyDown</b>       | sem. | grep             | 2.1.1 |
| V45                                | <b>&lt;li&gt;</b> <b>onClick</b> o. <b>onKeyDown</b>       | sem. | grep             | 2.1.1 |
| V46                                | Button 16×16 px < 24×24 px                                 | lay. | grep (CSS)       | 2.5.8 |
| V47                                | Modal: Fokusübernahme beim Öffnen fehlt                    | sem. | Playwright       | 2.4.3 |
| V48                                | Dialog ohne <b>aria-labelledby</b>                         | syn. | axe-core         | 4.1.2 |
| V49                                | <b>outline: none</b> auf Button                            | lay. | Playwright       | 2.4.7 |
| V50                                | <b>aria-hidden</b> auf fokussierbarem                      | syn. | axe-core         | 4.1.2 |
| V51                                | Tab <b>onClick</b> o. <b>onKeyDown</b>                     | sem. | grep             | 2.1.1 |
| V52                                | Tab <b>onClick</b> o. <b>onKeyDown</b>                     | sem. | grep             | 2.1.1 |
| V53                                | Tab <b>onClick</b> o. <b>onKeyDown</b>                     | sem. | grep             | 2.1.1 |
| V54                                | Toggle ohne zugänglichen Namen                             | syn. | axe-core         | 4.1.2 |
| V55                                | Select ohne Label                                          | syn. | axe-core         | 1.3.1 |
| V56                                | Input ohne Label                                           | syn. | axe-core         | 1.3.1 |
| V57                                | Passwortfeld ohne Label                                    | syn. | axe-core         | 1.3.1 |
| V58                                | Passwortfeld ohne Label                                    | syn. | axe-core         | 1.3.1 |
| V59                                | Button Kontrast niedrig                                    | lay. | axe-core         | 1.4.3 |
| V60                                | Checkbox ohne Label                                        | syn. | axe-core         | 1.3.1 |
| Fortsetzung auf der nächsten Seite |                                                            |      |                  |       |

Tab. 46: Accessibility-Verstöße der test-100-Suite (Fortsetzung)

| #                                  | Violation                                                          | Kat. | Erwartete Quelle | WCAG  |
|------------------------------------|--------------------------------------------------------------------|------|------------------|-------|
| V61                                | Suchfeld ohne Label                                                | syn. | axe-core         | 1.3.1 |
| V62                                | Button ohne Namen                                                  | syn. | axe-core         | 4.1.2 |
| V63                                | Filter-Chips onClick o. Keyboard                                   | sem. | grep             | 2.1.1 |
| V64                                | <li> onClick o. onKeyDown                                          | sem. | grep             | 2.1.1 |
| V65                                | <li> onClick o. onKeyDown                                          | sem. | grep             | 2.1.1 |
| V66                                | <li> onClick o. onKeyDown                                          | sem. | grep             | 2.1.1 |
| V67                                | <li> onClick o. onKeyDown                                          | sem. | grep             | 2.1.1 |
| V68                                | Typ-Badge nur durch Farbe                                          | sem. | manuell          | 1.4.1 |
| V69                                | Kontrast Datum niedrig                                             | lay. | axe-core         | 1.4.3 |
| V70                                | Paginierung <code>role="button"</code><br>o. <code>tabIndex</code> | sem. | axe-core + grep  | 4.1.2 |
| V71                                | Dropzone onClick o. onKeyDown                                      | sem. | grep             | 2.1.1 |
| V72                                | Upload-Icon ohne <code>alt="..."</code>                            | syn. | axe-core + grep  | 1.1.1 |
| V73                                | File-Input ohne Label                                              | syn. | axe-core         | 1.3.1 |
| V74                                | Löschen-Button ohne Namen                                          | syn. | axe-core         | 4.1.2 |
| V75                                | Progressbar ohne <code>aria-valuenow</code>                        | syn. | axe-core         | 4.1.2 |
| V76                                | Kontrast Hilfetext niedrig                                         | lay. | axe-core         | 1.4.3 |
| V77                                | Button $16 \times 16 \text{ px} < 24 \times 24 \text{ px}$         | lay. | grep (CSS)       | 2.5.8 |
| V78                                | Modal: Fokusübernahme beim Öffnen fehlt                            | sem. | Playwright       | 2.4.3 |
| V79                                | Dialog ohne <code>aria-labelledby</code>                           | syn. | axe-core         | 4.1.2 |
| V80                                | <code>outline: none</code> auf Button                              | lay. | Playwright       | 2.4.7 |
| V81                                | Tabelle ohne <caption>                                             | sem. | axe-core         | 1.3.1 |
| V82                                | <th> ohne scope                                                    | syn. | axe-core         | 1.3.1 |
| V83                                | <td> onClick o. onKeyDown                                          | sem. | grep             | 2.1.1 |
| V84                                | Event nur durch Farbe                                              | sem. | manuell          | 1.4.1 |
| V85                                | <code>role="button"</code> ohne <code>tabIndex</code>              | sem. | axe-core + grep  | 4.1.2 |
| V86                                | Detail ohne <code>aria-live</code>                                 | sem. | manuell          | 4.1.3 |
| V87                                | Banner-Bild ohne <code>alt="..."</code>                            | syn. | axe-core + grep  | 1.1.1 |
| V88                                | Chat ohne <code>aria-live</code>                                   | sem. | manuell          | 4.1.3 |
| V89                                | Kontrast Zeitstempel niedrig                                       | lay. | axe-core         | 1.4.3 |
| V90                                | Chat-Input ohne Label                                              | syn. | axe-core         | 1.3.1 |
| V91                                | Senden-Button ohne Namen                                           | syn. | axe-core         | 4.1.2 |
| Fortsetzung auf der nächsten Seite |                                                                    |      |                  |       |

Tab. 46: Accessibility-Verstöße der test-100-Suite (Fortsetzung)

| #    | Violation                                                | Kat. | Erwartete Quelle | WCAG  |
|------|----------------------------------------------------------|------|------------------|-------|
| V92  | Emoji <code>onClick</code> o. <code>onKeyDown</code>     | sem. | grep             | 2.1.1 |
| V93  | Online-Status nur durch Farbe                            | sem. | manuell          | 1.4.1 |
| V94  | Kontrast Hilfetext niedrig                               | lay. | axe-core         | 1.4.3 |
| V95  | Suchfeld ohne Label                                      | syn. | axe-core         | 1.3.1 |
| V96  | Accordion <code>onClick</code> o. <code>onKeyDown</code> | sem. | grep             | 2.1.1 |
| V97  | Accordion ohne <code>aria-expanded</code>                | sem. | manuell          | 4.1.2 |
| V98  | Kontaktbild ohne <code>alt="..."</code>                  | syn. | axe-core + grep  | 1.1.1 |
| V99  | Kontrast Kontaktinfo niedrig                             | lay. | axe-core         | 1.4.3 |
| V100 | <code>aria-hidden</code> auf fokussierbarem              | syn. | axe-core         | 4.1.2 |

Kat.: syn. = syntaktisch, sem. = semantisch, lay. = layout.

## Anhang 41: Erkennungsrate der Violations im Proof of Concept (test-100-Suite)

Tab. 47: Erkennungsrate aller 100 Violations (Gesamterkennungsquote durch Vollpipeline). *Erkannt* = konsistent über alle Modelle hinweg; modellabhängige Abweichungen sind in *Anmerkung* dokumentiert.<sup>212</sup>

| #                                  | Violation                      | Erkannt | Tatsächl. Quelle | Anmerkung                   |
|------------------------------------|--------------------------------|---------|------------------|-----------------------------|
| V1                                 | Skip-Link fehlt                | ✓       | Playwright       | Alle Modelle                |
| V2                                 | <html> ohne lang               | ✓       | axe-core         | Alle Modelle                |
| V3                                 | Logo ohne alt="..."            | ✓       | axe-core         | Alle Modelle                |
| V4                                 | Deko-Bild ohne alt=            | ✓       | axe-core         | Alle Modelle                |
| V5                                 | Button ohne zugängl. Namen     | ✓       | axe-core         | Alle Modelle                |
| V6                                 | Badge Kontrast zu niedrig      | ✓       | axe-core         | Alle Modelle                |
| V7                                 | <a> ohne href                  | ✓       | LLM-Detektor     | nur 32b kons.; 7b/14b inst. |
| V8                                 | CSS order weicht von DOM ab    | ×       | –                | nicht erkannt               |
| V9                                 | <nav> ohne aria-label          | ✓       | LLM-Detektor     | 14b/32b kons.; 7b inst.     |
| V10                                | onClick <li> o. onKeyDown      | ✓       | grep             | Alle Modelle                |
| V11                                | Headings übersprungen (h3)     | ×       | –                | nicht erkannt               |
| V12                                | KPI-Icon ohne alt="..." (1)    | ✓       | axe-core         | Alle Modelle                |
| V13                                | KPI-Wert Kontrast niedrig      | ✓       | axe-core         | Alle Modelle                |
| V14                                | KPI-Icon ohne alt="..." (2)    | ✓       | axe-core         | Alle Modelle                |
| V15                                | onClick <div> o. onKeyDown     | ✓       | grep             | Alle Modelle                |
| V16                                | role="button" o. tabIndex (D.) | ✓       | grep             | Alle Modelle                |
| V17                                | Chart ohne alt="..."           | ✓       | axe-core         | Alle Modelle                |
| V18                                | Tabelle ohne <caption> (Dash.) | ✓       | LLM-Detektor     | 14b/32b kons.; 7b inst.     |
| V19                                | <th> ohne scope (Dash.)        | ✓       | LLM-Detektor     | 14b/32b kons.; 7b inst.     |
| V20                                | Status nur durch Farbe (Dash.) | ✓       | LLM-Detektor     | nur 32b kons.; manuell      |
| V21                                | Avatar ohne alt="..."          | ✓       | LLM-Detektor     | 14b/32b kons.; 7b inst.     |
| V22                                | Input ohne <label> (Anzeige)   | ×       | –                | nicht erkannt               |
| Fortsetzung auf der nächsten Seite |                                |         |                  |                             |



Tab. 47: Erkennungsrate der Violations (test-100-Suite, Fortsetzung)

| #                                  | Violation                           | Erkannt | Tatsächl. Quelle | Anmerkung               |
|------------------------------------|-------------------------------------|---------|------------------|-------------------------|
| V23                                | Input ohne <label> (E-Mail)         | ×       | –                | nicht erkannt           |
| V24                                | Textarea ohne <label>               | ×       | –                | nicht erkannt           |
| V25                                | Pflichtfeld ohne required           | ×       | –                | nicht erkannt (manuell) |
| V26                                | Fehlermeldung nicht verknüpft       | ×       | –                | nicht erkannt (manuell) |
| V27                                | Button Kontrast niedrig (User)      | ×       | –                | nicht erkannt           |
| V28                                | outline: none auf Button (User)     | ×       | –                | nicht erkannt           |
| V29                                | Statusmeldung ohne aria-live        | ✓       | LLM-Detektor     | nur 32b kons.; manuell  |
| V30                                | Duplikat-ID                         | ✓       | LLM-Detektor     | Alle Modelle (LLM)      |
| V31                                | onClick <span> o. onKeyDown         | ✓       | grep             | Alle Modelle            |
| V32                                | Suchfeld ohne Label (DT)            | ×       | –                | nicht erkannt           |
| V33                                | Tabelle ohne <caption> (DT)         | ✓       | LLM-Detektor     | 14b/32b kons.; 7b inst. |
| V34                                | Checkbox ohne Label (Header)        | ×       | –                | nicht erkannt           |
| V35                                | Checkbox ohne Label (Zeilen)        | ×       | –                | nicht erkannt           |
| V36                                | Status nur durch Farbe (DT)         | ✓       | LLM-Detektor     | nur 32b kons.; manuell  |
| V37                                | Icon-Button ohne Namen (DT)         | ✓       | LLM-Detektor     | Alle Modelle (LLM)      |
| V38                                | Paginierung onClick o. Keyboard (1) | ✓       | grep             | Alle Modelle            |
| V39                                | Paginierung onClick o. Keyboard (2) | ✓       | grep             | Alle Modelle            |
| V40                                | Paginierung onClick o. Keyboard (3) | ✓       | grep             | Alle Modelle            |
| V41                                | <li> onClick o. onKeyDown (N.)      | ✓       | grep             | Alle Modelle            |
| V42                                | Ungelesen nur durch Farbe           | ×       | –                | nicht erkannt (manuell) |
| V43                                | Kontrast Zeitangabe niedrig         | ✓       | LLM-Detektor     | nur 32b kons.           |
| Fortsetzung auf der nächsten Seite |                                     |         |                  |                         |

Tab. 47: Erkennungsrate der Violations (test-100-Suite, Fortsetzung)

| #                                  | Violation                                        | Erkannt | Tatsächl. Quelle | Anmerkung               |
|------------------------------------|--------------------------------------------------|---------|------------------|-------------------------|
| V44                                | <li> onClick o. onKeyDown (2)                    | ✓       | grep             | Alle Modelle            |
| V45                                | <li> onClick o. onKeyDown (3)                    | ✓       | grep             | Alle Modelle            |
| V46                                | Button 16×16 px (Notif.)                         | ✓       | grep             | Alle Modelle            |
| V47                                | Modal: Fokusübernahme beim Öffnen fehlt (Notif.) | ✓       | LLM-Detektor     | 14b/32b kons.; 7b inst. |
| V48                                | Dialog ohne aria-labelledby (N.)                 | ✓       | LLM-Detektor     | Alle Modelle (LLM)      |
| V49                                | outline: none (Notif.)                           | ×       | –                | nicht erkannt           |
| V50                                | aria-hidden auf fokuss. El. (N.)                 | ✓       | LLM-Detektor     | 14b/32b kons.; 7b inst. |
| V51                                | Tab onClick o. onKeyDown (1)                     | ✓       | grep             | Alle Modelle            |
| V52                                | Tab onClick o. onKeyDown (2)                     | ✓       | grep             | Alle Modelle            |
| V53                                | Tab onClick o. onKeyDown (3)                     | ✓       | grep             | Alle Modelle            |
| V54                                | Toggle ohne zugängl. Namen                       | ✓       | LLM-Detektor     | Alle Modelle (LLM)      |
| V55                                | Select ohne Label                                | ✓       | LLM-Detektor     | Alle Modelle (LLM)      |
| V56                                | Input ohne Label (Settings)                      | ✓       | LLM-Detektor     | Alle Modelle (LLM)      |
| V57                                | Passwortfeld ohne Label (1)                      | ✓       | LLM-Detektor     | 14b/32b kons.; 7b inst. |
| V58                                | Passwortfeld ohne Label (2)                      | ✓       | LLM-Detektor     | 14b/32b kons.; 7b inst. |
| V59                                | Button Kontrast niedrig (Settings)               | ×       | –                | nicht erkannt           |
| V60                                | Checkbox ohne Label (Settings)                   | ✓       | LLM-Detektor     | 14b/32b kons.; 7b inst. |
| V61                                | Suchfeld ohne Label (Search)                     | ✓       | LLM-Detektor     | Alle Modelle (LLM)      |
| V62                                | Button ohne Namen (Search)                       | ✓       | LLM-Detektor     | Alle Modelle (LLM)      |
| V63                                | Filter-Chips onClick o. Keyboard                 | ✓       | grep             | Alle Modelle            |
| Fortsetzung auf der nächsten Seite |                                                  |         |                  |                         |

Tab. 47: Erkennungsrate der Violations (test-100-Suite, Fortsetzung)

| #   | Violation                                       | Erkannt | Tatsächl. Quelle | Anmerkung                   |
|-----|-------------------------------------------------|---------|------------------|-----------------------------|
| V64 | <li> onClick o. onKeyDown<br>(4)                | ✓       | grep             | Alle Modelle                |
| V65 | <li> onClick o. onKeyDown<br>(5)                | ✓       | grep             | Alle Modelle                |
| V66 | <li> onClick o. onKeyDown<br>(6)                | ✓       | grep             | Alle Modelle                |
| V67 | <li> onClick o. onKeyDown<br>(7)                | ✓       | grep             | Alle Modelle                |
| V68 | Typ-Badge nur durch Farbe                       | ×       | –                | nicht erkannt (manuell)     |
| V69 | Kontrast Datum niedrig                          | ✓       | LLM-Detektor     | nur 32b kons.               |
| V70 | Paginierung ohne tabIndex<br>(SR)               | ✓       | LLM-Detektor     | nur 32b kons.               |
| V71 | Dropzone onClick o.<br>onKeyDown                | ✓       | grep             | Alle Modelle                |
| V72 | Upload-Icon ohne<br>alt="..."                   | ✓       | LLM-Detektor     | nur 32b kons.               |
| V73 | File-Input ohne Label                           | ×       | –                | nicht erkannt               |
| V74 | Löschen-Button ohne Namen                       | ✓       | LLM-Detektor     | nur 32b kons.               |
| V75 | Progressbar ohne<br>aria-valuenow               | ✓       | LLM-Detektor     | 32b inst.; 7b/14b<br>selten |
| V76 | Kontrast Hilfetext niedrig<br>(FU)              | ✓       | LLM-Detektor     | nur 32b kons.               |
| V77 | Button 16×16 px (FileU-<br>pload)               | ✓       | grep             | Alle Modelle                |
| V78 | Modal: Fokusübernahme<br>beim Öffnen fehlt (FU) | ×       | –                | nicht erkannt               |
| V79 | Dialog ohne<br>aria-labelledby (FU)             | ✓       | LLM-Detektor     | 14b/32b kons.; 7b<br>inst.  |
| V80 | outline: none (FU)                              | ✓       | LLM-Detektor     | 32b inst.; 7b/14b<br>selten |
| V81 | Tabelle ohne <caption><br>(Cal.)                | ×       | –                | nicht erkannt               |
| V82 | <th> ohne scope (Cal.)                          | ✓       | LLM-Detektor     | 32b inst.; 7b/14b<br>selten |
| V83 | <td> onClick o. onKeyDown                       | ✓       | grep             | Alle Modelle                |
| V84 | Event nur durch Farbe (Cal.)                    | ×       | –                | nicht erkannt (manuell)     |

Fortsetzung auf der nächsten Seite

Tab. 47: Erkennungsrate der Violations (test-100-Suite, Fortsetzung)

| #                     | Violation                         | Erkannt | Tatsächl. Quelle                                      | Anmerkung                |
|-----------------------|-----------------------------------|---------|-------------------------------------------------------|--------------------------|
| V85                   | role="button" o. tabIndex (Cal.)  | ×       | –                                                     | nicht erkannt            |
| V86                   | Detail ohne aria-live (Cal.)      | ✓       | LLM-Detektor                                          | 32b inst.; manuell       |
| V87                   | Banner-Bild ohne alt="..." (Cal.) | ✓       | LLM-Detektor                                          | 32b inst.; 7b/14b selten |
| V88                   | Chat ohne aria-live               | ×       | –                                                     | nicht erkannt (manuell)  |
| V89                   | Kontrast Zeitstempel niedrig      | ×       | –                                                     | nicht erkannt            |
| V90                   | Chat-Input ohne Label             | ✓       | LLM-Detektor                                          | 32b inst.; 7b/14b selten |
| V91                   | Senden-Button ohne Namen          | ✓       | LLM-Detektor                                          | 32b inst.; 7b/14b selten |
| V92                   | Emoji onClick o. onKeyDown        | ✓       | grep                                                  | Alle Modelle             |
| V93                   | Online-Status nur durch Farbe     | ×       | –                                                     | nicht erkannt (manuell)  |
| V94                   | Kontrast Hilfetext niedrig (HC)   | ×       | –                                                     | nicht erkannt            |
| V95                   | Suchfeld ohne Label (HC)          | ×       | –                                                     | nicht erkannt            |
| V96                   | Accordion onClick o. onKeyDown    | ✓       | grep                                                  | Alle Modelle             |
| V97                   | Accordion ohne aria-expanded      | ×       | –                                                     | nicht erkannt (manuell)  |
| V98                   | Kontaktbild ohne alt="..."        | ✓       | LLM-Detektor                                          | 32b inst.; 7b/14b selten |
| V99                   | Kontrast Kontaktinfo niedrig      | ✓       | LLM-Detektor                                          | 32b inst.; 7b/14b selten |
| V100                  | aria-hidden auf fokuss. El. (HC)  | ✓       | LLM-Detektor                                          | 32b inst.; 7b/14b selten |
| <b>Erkannt gesamt</b> |                                   |         | 73 / 100 (Baseline: 34 / 100; LLM-exklusiv: 39 / 100) |                          |

## Anhang 42: Recall-Matrix: Violation × Bedingung (test-100-Suite)

*Hinweis:* 63 / 100 bezeichnet den **konsistenten** Recall über 10 Runs (Schwelle > 5/10), 99,1 den mittleren **Roh-Finding-Output pro Run**, und 73 / 100 einen **Einzelrun** (Run 01).

Tab. 48: Erkennungsstatus je Violation. ✓ = konsistent erkannt (> 5/10 Runs); ~ = instabil (3–5/10 Runs); × = nicht erkannt (0–2/10 Runs).

| #   | Violation                      | Baseline | + 7b | + 14b | + 32b | LLM-exkl. |
|-----|--------------------------------|----------|------|-------|-------|-----------|
| V1  | Skip-Link fehlt                | ✓        | ✓    | ✓     | ✓     |           |
| V2  | <html> ohne lang               | ✓        | ✓    | ✓     | ✓     |           |
| V3  | Logo ohne alt="..."            | ✓        | ✓    | ✓     | ✓     |           |
| V4  | Deko-Bild ohne alt=            | ✓        | ✓    | ✓     | ✓     |           |
| V5  | Button ohne zugängl. Namen     | ✓        | ✓    | ✓     | ✓     |           |
| V6  | Badge Kontrast zu niedrig      | ✓        | ✓    | ✓     | ✓     |           |
| V7  | <a> ohne href                  | ×        | ×    | ×     | ✓     | ✓         |
| V8  | CSS order weicht von DOM ab    | ×        | ×    | ×     | ×     |           |
| V9  | <nav> ohne aria-label          | ×        | ×    | ✓     | ✓     | ✓         |
| V10 | onClick <li> o. onKeyDown      | ✓        | ✓    | ✓     | ✓     |           |
| V11 | Headings übersprungen (h3)     | ×        | ×    | ×     | ×     |           |
| V12 | KPI-Icon ohne alt="..." (1)    | ✓        | ✓    | ✓     | ✓     |           |
| V13 | KPI-Wert Kontrast niedrig      | ✓        | ✓    | ✓     | ✓     |           |
| V14 | KPI-Icon ohne alt="..." (2)    | ✓        | ✓    | ✓     | ✓     |           |
| V15 | onClick <div> o. onKeyDown     | ✓        | ✓    | ✓     | ✓     |           |
| V16 | role="button" o. tabIndex (D.) | ✓        | ✓    | ✓     | ✓     |           |
| V17 | Chart ohne alt="..."           | ✓        | ✓    | ✓     | ✓     |           |
| V18 | Tabelle ohne <caption> (Dash.) | ×        | ×    | ✓     | ✓     | ✓         |
| V19 | <th> ohne scope (Dash.)        | ×        | ×    | ✓     | ✓     | ✓         |
| V20 | Status nur durch Farbe (Dash.) | ×        | ×    | ×     | ✓     | ✓         |
| V21 | Avatar ohne alt="..."          | ×        | ×    | ✓     | ✓     | ✓         |
| V22 | Input ohne <label> (Anzeige)   | ×        | ×    | ×     | ×     |           |
| V23 | Input ohne <label> (E-Mail)    | ×        | ×    | ×     | ×     |           |

Fortsetzung auf der nächsten Seite

Tab. 48: Recall-Matrix test-100-Suite (Fortsetzung)

| #                                  | Violation                           | Baseline | + 7b | + 14b | + 32b | LLM-exkl. |
|------------------------------------|-------------------------------------|----------|------|-------|-------|-----------|
| V24                                | Textarea ohne <label>               | ×        | ×    | ×     | ×     |           |
| V25                                | Pflichtfeld ohne required           | ×        | ×    | ×     | ×     |           |
| V26                                | Fehlermeldung nicht verknüpft       | ×        | ×    | ×     | ×     |           |
| V27                                | Button Kontrast niedrig (User)      | ×        | ×    | ×     | ×     |           |
| V28                                | outline: none auf Button (User)     | ×        | ×    | ×     | ×     |           |
| V29                                | Statusmeldung ohne aria-live        | ×        | ×    | ×     | ✓     | ✓         |
| V30                                | Duplikat-ID                         | ×        | ✓    | ✓     | ✓     | ✓         |
| V31                                | onClick <span> o. onKeyDown         | ✓        | ✓    | ✓     | ✓     |           |
| V32                                | Suchfeld ohne Label (DT)            | ×        | ×    | ×     | ×     |           |
| V33                                | Tabelle ohne <caption> (DT)         | ×        | ×    | ✓     | ✓     | ✓         |
| V34                                | Checkbox ohne Label (Header)        | ×        | ×    | ×     | ×     |           |
| V35                                | Checkbox ohne Label (Zeilen)        | ×        | ×    | ×     | ×     |           |
| V36                                | Status nur durch Farbe (DT)         | ×        | ×    | ×     | ✓     | ✓         |
| V37                                | Icon-Button ohne Namen (DT)         | ×        | ✓    | ✓     | ✓     | ✓         |
| V38                                | Paginierung onClick o. Keyboard (1) | ✓        | ✓    | ✓     | ✓     |           |
| V39                                | Paginierung onClick o. Keyboard (2) | ✓        | ✓    | ✓     | ✓     |           |
| V40                                | Paginierung onClick o. Keyboard (3) | ✓        | ✓    | ✓     | ✓     |           |
| V41                                | <li> onClick o. onKeyDown (N.)      | ✓        | ✓    | ✓     | ✓     |           |
| V42                                | Ungelesen nur durch Farbe           | ×        | ×    | ×     | ×     |           |
| V43                                | Kontrast Zeitangabe niedrig         | ×        | ×    | ×     | ✓     | ✓         |
| V44                                | <li> onClick o. onKeyDown (2)       | ✓        | ✓    | ✓     | ✓     |           |
| V45                                | <li> onClick o. onKeyDown (3)       | ✓        | ✓    | ✓     | ✓     |           |
| V46                                | Button 16×16 px (Notif.)            | ✓        | ✓    | ✓     | ✓     |           |
| Fortsetzung auf der nächsten Seite |                                     |          |      |       |       |           |

Tab. 48: Recall-Matrix test-100-Suite (Fortsetzung)

| #                                  | Violation                                        | Baseline | + 7b | + 14b | + 32b | LLM-exkl. |
|------------------------------------|--------------------------------------------------|----------|------|-------|-------|-----------|
| V47                                | Modal: Fokusübernahme beim Öffnen fehlt (Notif.) | ×        | ×    | ✓     | ✓     | ✓         |
| V48                                | Dialog ohne aria-labelledby (N.)                 | ×        | ✓    | ✓     | ✓     | ✓         |
| V49                                | outline: none (Notif.)                           | ×        | ×    | ×     | ×     |           |
| V50                                | aria-hidden auf fokuss. El. (N.)                 | ×        | ×    | ✓     | ✓     | ✓         |
| V51                                | Tab onClick o. onKeyDown (1)                     | ✓        | ✓    | ✓     | ✓     |           |
| V52                                | Tab onClick o. onKeyDown (2)                     | ✓        | ✓    | ✓     | ✓     |           |
| V53                                | Tab onClick o. onKeyDown (3)                     | ✓        | ✓    | ✓     | ✓     |           |
| V54                                | Toggle ohne zugängl. Namen                       | ×        | ✓    | ✓     | ✓     | ✓         |
| V55                                | Select ohne Label                                | ×        | ✓    | ✓     | ✓     | ✓         |
| V56                                | Input ohne Label (Settings)                      | ×        | ✓    | ✓     | ✓     | ✓         |
| V57                                | Passwortfeld ohne Label (1)                      | ×        | ×    | ✓     | ✓     | ✓         |
| V58                                | Passwortfeld ohne Label (2)                      | ×        | ×    | ✓     | ✓     | ✓         |
| V59                                | Button Kontrast niedrig (Settings)               | ×        | ×    | ×     | ×     |           |
| V60                                | Checkbox ohne Label (Settings)                   | ×        | ×    | ✓     | ✓     | ✓         |
| V61                                | Suchfeld ohne Label (Search)                     | ×        | ✓    | ✓     | ✓     | ✓         |
| V62                                | Button ohne Namen (Search)                       | ×        | ✓    | ✓     | ✓     | ✓         |
| V63                                | Filter-Chips onClick o. Keyboard                 | ✓        | ✓    | ✓     | ✓     |           |
| V64                                | <li> onClick o. onKeyDown (4)                    | ✓        | ✓    | ✓     | ✓     |           |
| V65                                | <li> onClick o. onKeyDown (5)                    | ✓        | ✓    | ✓     | ✓     |           |
| V66                                | <li> onClick o. onKeyDown (6)                    | ✓        | ✓    | ✓     | ✓     |           |
| V67                                | <li> onClick o. onKeyDown (7)                    | ✓        | ✓    | ✓     | ✓     |           |
| V68                                | Typ-Badge nur durch Farbe                        | ×        | ×    | ×     | ×     |           |
| V69                                | Kontrast Datum niedrig                           | ×        | ×    | ×     | ✓     | ✓         |
| Fortsetzung auf der nächsten Seite |                                                  |          |      |       |       |           |

Tab. 48: Recall-Matrix test-100-Suite (Fortsetzung)

| #                                  | Violation                                                              | Baseline | + 7b | + 14b | + 32b | LLM-exkl. |
|------------------------------------|------------------------------------------------------------------------|----------|------|-------|-------|-----------|
| V70                                | Paginierung ohne <code>tabIndex</code> (SR)                            | ×        | ×    | ×     | ✓     | ✓         |
| V71                                | Dropzone <code>onClick</code> o. <code>onKeyDown</code>                | ✓        | ✓    | ✓     | ✓     |           |
| V72                                | Upload-Icon ohne <code>alt="..."</code>                                | ×        | ×    | ×     | ✓     | ✓         |
| V73                                | File-Input ohne Label                                                  | ×        | ×    | ×     | ×     |           |
| V74                                | Löschen-Button ohne Namen                                              | ×        | ×    | ×     | ✓     | ✓         |
| V75                                | Progressbar ohne <code>aria-valuenow</code>                            | ×        | ×    | ×     | ~     | ✓         |
| V76                                | Kontrast Hilfetext niedrig (FU)                                        | ×        | ×    | ×     | ✓     | ✓         |
| V77                                | Button 16×16 px (FileUpload)                                           | ✓        | ✓    | ✓     | ✓     |           |
| V78                                | Modal: Fokusübernahme beim Öffnen fehlt (FU)                           | ×        | ×    | ×     | ×     |           |
| V79                                | Dialog ohne <code>aria-labelledby</code> (FU)                          | ×        | ×    | ✓     | ✓     | ✓         |
| V80                                | <code>outline: none</code> (FU)                                        | ×        | ×    | ×     | ~     | ✓         |
| V81                                | Tabelle ohne <code>&lt;caption&gt;</code> (Cal.)                       | ×        | ×    | ×     | ×     |           |
| V82                                | <code>&lt;th&gt;</code> ohne <code>scope</code> (Cal.)                 | ×        | ×    | ×     | ~     | ✓         |
| V83                                | <code>&lt;td&gt;</code> <code>onClick</code> o. <code>onKeyDown</code> | ✓        | ✓    | ✓     | ✓     |           |
| V84                                | Event nur durch Farbe (Cal.)                                           | ×        | ×    | ×     | ×     |           |
| V85                                | <code>role="button"</code> o. <code>tabIndex</code> (Cal.)             | ×        | ×    | ×     | ×     |           |
| V86                                | Detail ohne <code>aria-live</code> (Cal.)                              | ×        | ×    | ×     | ~     | ✓         |
| V87                                | Banner-Bild ohne <code>alt="..."</code> (Cal.)                         | ×        | ×    | ×     | ~     | ✓         |
| V88                                | Chat ohne <code>aria-live</code>                                       | ×        | ×    | ×     | ×     |           |
| V89                                | Kontrast Zeitstempel niedrig                                           | ×        | ×    | ×     | ×     |           |
| V90                                | Chat-Input ohne Label                                                  | ×        | ×    | ×     | ~     | ✓         |
| V91                                | Senden-Button ohne Namen                                               | ×        | ×    | ×     | ~     | ✓         |
| V92                                | Emoji <code>onClick</code> o. <code>onKeyDown</code>                   | ✓        | ✓    | ✓     | ✓     |           |
| V93                                | Online-Status nur durch Farbe                                          | ×        | ×    | ×     | ×     |           |
| Fortsetzung auf der nächsten Seite |                                                                        |          |      |       |       |           |



Tab. 48: Recall-Matrix test-100-Suite (Fortsetzung)

| #                   | Violation                        | Baseline | + 7b     | + 14b    | + 32b    | LLM-exkl.    |
|---------------------|----------------------------------|----------|----------|----------|----------|--------------|
| V94                 | Kontrast Hilfetext niedrig (HC)  | ×        | ×        | ×        | ×        |              |
| V95                 | Suchfeld ohne Label (HC)         | ×        | ×        | ×        | ×        |              |
| V96                 | Accordion onClick o. onKeyDown   | ✓        | ✓        | ✓        | ✓        |              |
| V97                 | Accordion ohne aria-expanded     | ×        | ×        | ×        | ×        |              |
| V98                 | Kontaktbild ohne alt="..."       | ×        | ×        | ×        | ~        | ✓            |
| V99                 | Kontrast Kontaktinfo niedrig     | ×        | ×        | ×        | ~        | ✓            |
| V100                | aria-hidden auf fokuss. El. (HC) | ×        | ×        | ×        | ~        | ✓            |
| Recall (konsistent) |                                  | 34 / 100 | 40 / 100 | 53 / 100 | 63 / 100 | 39 LLM-exkl. |

## Anhang 43: Rohdaten: alle 30 Benchmark-Runs (test-100-Suite)

Tab. 49: Vollständige Messdaten der 30 Pipeline-Durchläufe (`num_predict` = 12288). LLM-Det. = Findings des LLM-Detektors; Axe/PW/Grep = Tool-Findings (konstant je Run); Tokens = Output-Tokens; Dauer = Priorisierungslaufzeit in Sekunden.

| Run | Modell            | LLM-Det. | Axe | PW | Grep | Gesamt-Det. | Tokens | Dauer (s) |
|-----|-------------------|----------|-----|----|------|-------------|--------|-----------|
| 01  | qwen2.5-coder:7b  | 107      | 11  | 2  | 24   | 144         | 12288  | 424       |
| 02  | qwen2.5-coder:7b  | 99       | 11  | 2  | 24   | 136         | 12288  | 395       |
| 03  | qwen2.5-coder:7b  | 98       | 11  | 2  | 24   | 135         | 12288  | 401       |
| 04  | qwen2.5-coder:7b  | 97       | 11  | 2  | 24   | 134         | 7902   | 261       |
| 05  | qwen2.5-coder:7b  | 110      | 11  | 2  | 24   | 147         | 12288  | 408       |
| 06  | qwen2.5-coder:7b  | 109      | 11  | 2  | 24   | 146         | 12288  | 388       |
| 07  | qwen2.5-coder:7b  | 109      | 11  | 2  | 24   | 146         | 12288  | 372       |
| 08  | qwen2.5-coder:7b  | 96       | 11  | 2  | 24   | 133         | 8007   | 258       |
| 09  | qwen2.5-coder:7b  | 106      | 11  | 2  | 24   | 143         | 12288  | 371       |
| 10  | qwen2.5-coder:7b  | 109      | 11  | 2  | 24   | 146         | 12288  | 369       |
| 11  | qwen2.5-coder:14b | 93       | 11  | 2  | 24   | 130         | 12288  | 759       |
| 12  | qwen2.5-coder:14b | 91       | 11  | 2  | 24   | 128         | 12288  | 790       |
| 13  | qwen2.5-coder:14b | 93       | 11  | 2  | 24   | 130         | 12288  | 865       |
| 14  | qwen2.5-coder:14b | 91       | 11  | 2  | 24   | 128         | 12288  | 867       |
| 15  | qwen2.5-coder:14b | 100      | 11  | 2  | 24   | 137         | 12288  | 864       |
| 16  | qwen2.5-coder:14b | 93       | 11  | 2  | 24   | 130         | 12288  | 818       |
| 17  | qwen2.5-coder:14b | 94       | 11  | 2  | 24   | 131         | 12288  | 821       |
| 18  | qwen2.5-coder:14b | 95       | 11  | 2  | 24   | 132         | 12288  | 822       |
| 19  | qwen2.5-coder:14b | 100      | 11  | 2  | 24   | 137         | 12288  | 844       |
| 20  | qwen2.5-coder:14b | 93       | 11  | 2  | 24   | 130         | 12288  | 759       |
| 21  | qwen3:32b         | 94       | 11  | 2  | 24   | 131         | 8936   | 1220      |
| 22  | qwen3:32b         | 104      | 11  | 2  | 24   | 141         | 6698   | 960       |
| 23  | qwen3:32b         | 104      | 11  | 2  | 24   | 141         | 12288  | 1708      |
| 24  | qwen3:32b         | 106      | 11  | 2  | 24   | 143         | 6367   | 971       |
| 25  | qwen3:32b         | 94       | 11  | 2  | 24   | 131         | 7355   | 1000      |
| 26  | qwen3:32b         | 104      | 11  | 2  | 24   | 141         | 6890   | 976       |
| 27  | qwen3:32b         | 94       | 11  | 2  | 24   | 131         | 5476   | 781       |
| 28  | qwen3:32b         | 93       | 11  | 2  | 24   | 130         | 4206   | 634       |
| 29  | qwen3:32b         | 94       | 11  | 2  | 24   | 131         | 8571   | 1126      |
| 30  | qwen3:32b         | 104      | 11  | 2  | 24   | 141         | 6816   | 954       |

## Anhang 44: Modell-Leistungsvergleich: test-100-Suite

### Zusammenfassung

Tab. 50: Zusammenfassung der Leistungsmetriken für die drei evaluierten Modelle (je  $n = 10$  Runs, `num_predict = 12 288`).  $\sigma$  = Stichproben-Standardabweichung. Der Recall basiert auf Konsistenzschwelle  $> 5/10$  Runs je Modell.

| Metrik                                         | qwen2.5-coder:7b | qwen2.5-coder:14b  | qwen3:32b          |
|------------------------------------------------|------------------|--------------------|--------------------|
| Recall (konsistent)                            | 40 / 100 (40 %)  | 53 / 100 (53 %)    | 63 / 100 (63 %)    |
| LLM-Detektor-Findings ( $\bar{O} \pm \sigma$ ) | 104,0 $\pm$ 5,75 | 94,3 $\pm$ 3,23    | 99,1 $\pm$ 5,63    |
| LLM-Detektor-Findings (Min–Max)                | 96–110           | 91–100             | 93–106             |
| Konsistenz $\sigma$                            | 5,75             | 3,23               | 5,63               |
| Priorisierungsqualität                         | Fehlerhaft       | Bimodal / instabil | Bimodal / instabil |
| Output-Tokens ( $\bar{O}$ )                    | 11 421           | 12 288             | 7 360              |
| Output-Limit ausgeschöpft                      | 8 / 10 (80 %)    | 10 / 10 (100 %)    | 1 / 10 (10 %)      |
| Parsing-Erfolg                                 | 100 %            | 100 %              | 100 %              |
| NFA-02-Konformität                             | Nicht erfüllt    | Nicht erfüllt      | Nicht erfüllt      |
| Eignung BITV-Einsatz                           | Nicht geeignet   | Empfohlen          | Eingeschränkt      |
| <i>Suite-spezifische Zusatzmetriken</i>        |                  |                    |                    |
| Fix-Qualität (Stufe)                           | 0–1              | 0–2                | 0–2 (73 % Stufe 2) |
| Tool-Findings (axe/PW/grep)                    | 11 / 2 / 24      | 11 / 2 / 24        | 11 / 2 / 24        |
| Must-have im Bericht ( $\bar{O}$ )             | 46,1             | 58,9               | 39,2               |
| Nice-to-have ( $\bar{O}$ ) Bericht             | 45,4             | 27,9               | 18,9               |
| Gesamt-Report-Items ( $\bar{O}$ )              | 91,5             | 86,8               | 58,1               |
| LLM-Detektor-Laufzeit ( $\bar{O}$ )            | 394 s            | 723 s              | 1 576 s            |
| Priorisierungslaufzeit ( $\bar{O}$ )           | 365 s            | 821 s              | 1 033 s            |
| Priorisierungslaufzeit (Min–Max)               | 258–424 s        | 759–867 s          | 634–1 708 s        |
| Gesamtlaufzeit ( $\bar{O}$ )                   | 765 s            | 1 550 s            | 2 616 s            |
| Gesamtlaufzeit (Min–Max)                       | 648–839 s        | 1 418–1 688 s      | 2 172–3 314 s      |

*Hinweis:* Die Bewertung in der Spalte *Eignung BITV-Einsatz* priorisiert die Balance zwischen Erkennungsqualität und Zeitaufwand und kann daher auch bei Verletzung von NFA-02 positiv ausfallen. Bei strikter Auslegung von NFA-02 (Laufzeit  $< 10$  Min.) wäre auf test-100 hingegen kein Modell uneingeschränkt geeignet.

## Anhang 45: Token-Nutzung pro Modell: Input/Output (test-100-Suite)

Tab. 51: Durchschnittliche Token-Nutzung je Run und Modell auf Basis der test-100-Suite (`num_predict` = 12 288). Input-Tokens umfassen System-Prompt, serialisierte Findings und Konfigurationsparameter. 14b schöpfte in allen 10 Runs das Output-Limit aus; 32b blieb mit Ø 7 360 deutlich darunter.

| Modell                                                                              | Input-Tokens (Ø) | Output-Tokens (Ø) | Truncation           |
|-------------------------------------------------------------------------------------|------------------|-------------------|----------------------|
| qwen2.5-coder:7b                                                                    | 17 503           | 11 421            | 8 / 10 Runs (80 %)   |
| qwen2.5-coder:14b                                                                   | 17 043           | 12 288            | 10 / 10 Runs (100 %) |
| qwen3:32b                                                                           | 17 197           | 7 360             | 1 / 10 Runs (10 %)   |
| <i>Gesamt (30 Runs): Input <math>\approx</math> 517 400 / Output 310 700 Tokens</i> |                  |                   |                      |

## Anhang 46: Effizienzmetriken (test-100-Suite)

Tab. 52: Effizienzvergleich auf Basis der 30 Benchmark-Runs der test-100-Suite. *LLM-Findings/s* bezieht sich auf LLM-Detektor-Findings pro Sekunde Gesamtlaufzeit.

| Modell            | LLM-Findings Ø | Gesamtlaufzeit Ø (s) | LLM-Findings/s | Zusatznutzen ggü. 7b          |
|-------------------|----------------|----------------------|----------------|-------------------------------|
| qwen2.5-coder:7b  | 104,0          | 765                  | 0,136          | Referenz                      |
| qwen2.5-coder:14b | 94,3           | 1 550                | 0,061          | −9,3 % bei +103 % Zeitaufwand |
| qwen3:32b         | 99,1           | 2 616                | 0,038          | −4,7 % bei +242 % Zeitaufwand |

## Anhang 47: Über-Detektion relativ zur Ground Truth (test-100-Suite)

Tab. 53: Vergleich der durchschnittlichen LLM-Detektor-Findings pro Run mit der Ground Truth (100 Violations). Die LLM-only-Betrachtung vermeidet Doppelzählungen mit Tool-Detektoren.

| Modell            | LLM-Findings Ø | Ground Truth | Quote  | Interpretation                                                                                           |
|-------------------|----------------|--------------|--------|----------------------------------------------------------------------------------------------------------|
| qwen2.5-coder:7b  | 104,0          | 100          | 104 %  | Leichte Überdetektion; hohe LLM-Finding-Zahl trotz inverser Priorisierung und 80 % Truncation            |
| qwen2.5-coder:14b | 94,3           | 100          | 94,3 % | Leichte Unterdetektion; alle 10 Runs bei 12 288 Output-Tokens; Vollständigkeit durch Truncation begrenzt |
| qwen3:32b         | 99,1           | 100          | 99,1 % | Nahe an Ground Truth; 1 / 10 Runs trunziert; höchste absolute Nähe zur Ziellanzahl                       |

## Anhang 48: Stichproben-Plausibilisierung des finalen Reports (qwen3:32b, Run 01 & Run 03, test-100)

Da die Überdetektions-Quote ausschließlich eine Mengenrelation zwischen LLM-Detektor-Rohoutput und Ground Truth misst, wurde eine manuelle Stichprobenprüfung an zwei Runs durchgeführt, um die inhaltliche Qualität des finalen Reports einzuschätzen. Grundlage ist `qwen3:32b` auf `test-100`: Run 01 ist vollständig (keine Truncation, 72 Report-Einträge), Run 03 ist trunkiert (12 288 Output-Tokens ausgeschöpft, 104 Einträge). Jeder Eintrag wurde dem Quellcode unter `test/test-100/src/` sowie dem Ground-Truth-Katalog (Tabelle 46) zugeordnet.

Tab. 54: Kategorisierung aller Report-Einträge aus Run 01 (vollständig) und Run 03 (trunkiert) von `qwen3:32b` auf `test-100`. *Quell-Duplikat* = axe-core und LLM-Detektor finden dieselbe Violation unabhängig voneinander; *Instanz-Mehrfach* = zweite DOM-Instanz einer Violation, die im Ground Truth als ein Eintrag zählt; *Gebündelt* = ein Finding umfasst mehrere GT-Violations.

| Kategorie        | Beschreibung                                                                  | Run-01    | Run-03     |
|------------------|-------------------------------------------------------------------------------|-----------|------------|
| True Positive    | Unique Finding, eindeutig einer GT-Violation zugeordnet                       | 51        | 82         |
| Quell-Duplikat   | Dieselbe Violation durch axe-core <i>und</i> LLM-Detektor unabhängig gemeldet | 10        | 2          |
| Instanz-Mehrfach | Zweite DOM-Instanz; GT zählt Violationsklasse einmalig                        | 2         | –          |
| Gebündelt        | Ein Finding deckt mehrere GT-Violations ab (z.B. 11m-076: V51+V52+V53)        | 1         | 2          |
| Halluzination    | Kein GT-Match, kein Basis im Quellcode                                        | 0         | 1          |
| Nicht eindeutig  | Mögliche Paraphrase oder Violation außerhalb der 100 GT-Einträge              | 8         | 17         |
| <b>Gesamt</b>    |                                                                               | <b>72</b> | <b>104</b> |

**Fazit:** Von 176 untersuchten Einträgen ( $72 + 104$ ) ist 1 als Halluzination bestätigt ([11m-061] in Run 03 meldet eine Tabelle ohne `caption` in `Notifications.tsx`, obwohl dort keine Tabelle existiert). Die Halluzinationsrate liegt damit unter 1 %. Die dominanten “Über-Detektion”-Effekte sind Quell-Duplikate und nicht eindeutig zugeordnete Findings – keine inhaltlichen Fehler, sondern strukturelle Artefakte der zweistufigen Pipeline.

## Anhang 49: Precision und F1-Score je Run (test-100-Suite)

Per-Run-Auflistung der Precision für alle 30 Benchmark-Runs auf der test-100-Suite. Methodik identisch zu Anhang 36: TP = Item referenziert ein in der Ground Truth vorhandenes WCAG-Kriterium oder stammt von einem Tool-Detektor (axe/Playwright/grep); FP = kein nachweisbarer Ground-Truth-Bezug. Die Stichproben-Plausibilisierung (Tabelle 54) bestätigt eine Halluzinationsrate von  $< 1\%$  für **qwen3:32b**. Konsistenz-Recall und F1 gemäß Tabelle 9.

Tab. 55: Precision je Run auf test-100 für alle drei evaluierten Modelle ( $n = 10$  Runs je Modell). TP = True-Positive-Items, FP = False-Positive-Items. Modell-Gesamtwerte in der letzten Zeile.

| Run                                                                                                      | qwen2.5-coder:7b |           |             | qwen2.5-coder:14b |          |             | qwen3:32b  |          |             |
|----------------------------------------------------------------------------------------------------------|------------------|-----------|-------------|-------------------|----------|-------------|------------|----------|-------------|
|                                                                                                          | Items            | FP        | Prec. %     | Items             | FP       | Prec. %     | Items      | FP       | Prec. %     |
| 01                                                                                                       | 94               | 4         | 95,7        | 86                | 0        | 100,0       | 72         | 0        | 100,0       |
| 02                                                                                                       | 110              | 9         | 91,8        | 69                | 1        | 98,6        | 49         | 0        | 100,0       |
| 03                                                                                                       | 94               | 4         | 95,7        | 91                | 0        | 100,0       | 98         | 0        | 100,0       |
| 04                                                                                                       | 62               | 1         | 98,4        | 84                | 0        | 100,0       | 52         | 0        | 100,0       |
| 05                                                                                                       | 109              | 7         | 93,6        | 90                | 0        | 100,0       | 68         | 0        | 100,0       |
| 06                                                                                                       | 93               | 2         | 97,8        | 89                | 0        | 100,0       | 52         | 0        | 100,0       |
| 07                                                                                                       | 104              | 0         | 100,0       | 91                | 0        | 100,0       | 41         | 0        | 100,0       |
| 08                                                                                                       | 64               | 2         | 96,9        | 87                | 0        | 100,0       | 29         | 0        | 100,0       |
| 09                                                                                                       | 93               | 2         | 97,8        | 89                | 0        | 100,0       | 68         | 0        | 100,0       |
| 10                                                                                                       | 92               | 1         | 98,9        | 91                | 0        | 100,0       | 52         | 1        | 98,1        |
| <b>Ø</b>                                                                                                 | <b>915</b>       | <b>32</b> | <b>96,7</b> | <b>867</b>        | <b>1</b> | <b>99,9</b> | <b>581</b> | <b>1</b> | <b>99,8</b> |
| Kons.-Recall: 40 %    F1: 57,4 %    Kons.-Recall: 53 %    F1: 69,2 %    Kons.-Recall: 63 %    F1: 76,9 % |                  |           |             |                   |          |             |            |          |             |

## Anhang 50: Detektor-Konsistenz über alle 30 Runs (test-100-Suite)

Tab. 56: Konsistenzanalyse der Detektoren über alle 30 Benchmark-Runs. Axe-core, Playwright und grep bleiben vollständig deterministisch; die Varianz entsteht ausschließlich im LLM-Detektor.

| Detektor / Modell   | Runs | Gesamt-Findings | Ø/Run | Min–Max | $\sigma^2$ / $\sigma$ | Interpretation                              |
|---------------------|------|-----------------|-------|---------|-----------------------|---------------------------------------------|
| axe-core            | 30   | 330             | 11,0  | 11–11   | 0,00 / 0,00           | vollständig deterministisch                 |
| Playwright          | 30   | 60              | 2,0   | 2–2     | 0,00 / 0,00           | vollständig deterministisch                 |
| grep                | 30   | 720             | 24,0  | 24–24   | 0,00 / 0,00           | vollständig deterministisch                 |
| qwen2.5-coder:7b    | 10   | 1 040           | 104,0 | 96–110  | 33,11 / 5,75          | höchste Streuung; 80 % Truncation           |
| qwen2.5-coder:14b   | 10   | 943             | 94,3  | 91–100  | 10,46 / 3,23          | moderate Konsistenz; 100 % Truncation       |
| qwen3:32b           | 10   | 991             | 99,1  | 93–106  | 31,66 / 5,63          | moderate Streuung; deutlich höhere Laufzeit |
| LLM-Detektor gesamt | 30   | 2 974           | 99,1  | 91–110  | modell-abhängig       | –                                           |



## Anhang 51: Bewertung der Empfehlungsqualität pro Violation (test-100-Suite)

*Kürzel:* DT = DataTable, SR = SearchResults, FU = FileUpload, N.= Notifications, Cal.= Calendar, Dash.= Dashboard, User = UserProfile.

Die Bewertung basiert auf Run 01 von **qwen3:32b** und verwendet dieselbe dreistufige Skala wie Tabelle 18. Stufe 2 liegt vor, wenn Dateiname, Zeilennummer und ein konkreter Code-Vorschlag vorhanden sind. Violations, die in Run 01 nicht erkannt wurden (27 von 100), werden mit Stufe 0 ausgewiesen. Violations mit (*manuell*) waren als rein manuelle Prüffälle klassifiziert – die LLM-Erkennung stellt einen Mehrwert über die Erwartung hinaus dar.

Tab. 57: Bewertung der Fix-Qualität für alle 100 Violations (**qwen3:32b**, Run 01). Stufe 0 = nicht erkannt; Stufe 2 = konkreter Dateiname, Zeile und Code-Snippet.

| #                                  | Violation                                                 | Stufe (0–2) | Anmerkung (qwen3:32b)                                                               |
|------------------------------------|-----------------------------------------------------------|-------------|-------------------------------------------------------------------------------------|
| V1                                 | Skip-Link fehlt                                           | 2           | App.tsx, <code>&lt;a href="#main-content&gt;</code> -Snippet mit CSS-Positionierung |
| V2                                 | <code>&lt;html&gt;</code> ohne <code>lang</code>          | 2           | index.html, <code>&lt;html lang="de"&gt;</code> direkt angegeben                    |
| V3                                 | Logo ohne <code>alt="..."</code>                          | 2           | App.tsx, beschreibender <code>alt="Company Logo"</code> vorge-schlagen              |
| V4                                 | Deko-Bild ohne <code>alt=</code>                          | 2           | App.tsx, <code>alt=</code> <code>role="presentation"</code> kor-<br>rekt ergänzt    |
| V5                                 | Button ohne zugängl. Namen                                | 2           | App.tsx, <code>aria-label="Menü öffnen"</code> mit JSX-Snippet                      |
| V6                                 | Badge Kontrast zu niedrig                                 | 2           | App.tsx, CSS <code>.badge</code> mit kor-<br>rektem Hex-Farbpaar                    |
| V7                                 | <code>&lt;a&gt;</code> ohne <code>href</code>             | 2           | App.tsx, <code>href="/help"</code> mit <code>role="link"</code> ergänzt             |
| V8                                 | CSS <code>order</code> weicht von DOM ab                  | 0           | nicht erkannt                                                                       |
| V9                                 | <code>&lt;nav&gt;</code> ohne <code>aria-label</code>     | 2           | App.tsx, <code>aria-label="Hauptnavigation"</code>                                  |
| V10                                | <code>onClick &lt;li&gt;</code> o. <code>onKeyDown</code> | 2           | App.tsx, vollst. <code>onKeyDown</code> -<br>Handler mit Enter-Logik                |
| V11                                | Headings übersprungen ( <code>h3</code> )                 | 0           | nicht erkannt                                                                       |
| Fortsetzung auf der nächsten Seite |                                                           |             |                                                                                     |

Tab. 57: Empfehlungsqualität (test-100) (Fortsetzung)

| #                                  | Violation                                               | Stufe (0–2) | Anmerkung (qwen3:32b)                                                            |
|------------------------------------|---------------------------------------------------------|-------------|----------------------------------------------------------------------------------|
| V12                                | KPI-Icon ohne <code>alt="..."</code> (1)                | 2           | Dashboard.tsx, beschreibender <code>alt</code> -Text je KPI-Typ                  |
| V13                                | KPI-Wert Kontrast niedrig                               | 2           | Dashboard.tsx, CSS-Fix mit WCAG-konformem Hex-Farbpaar                           |
| V14                                | KPI-Icon ohne <code>alt="..."</code> (2)                | 2           | Dashboard.tsx, Querverweis auf V12-Fix                                           |
| V15                                | <code>onClick &lt;div&gt; o. onKeyDown</code>           | 2           | Dashboard.tsx, <code>onKeyDown + tabIndex={0}</code> vollst.                     |
| V16                                | <code>role="button" o. tabIndex</code> (D.)             | 2           | Dashboard.tsx, <code>tabIndex={0}</code> + JSX-Snippet                           |
| V17                                | Chart ohne <code>alt="..."</code>                       | 2           | Dashboard.tsx, inhaltsbeschreibender <code>alt</code> -Text                      |
| V18                                | Tabelle ohne <code>&lt;caption&gt;</code> (Dash.)       | 2           | Dashboard.tsx, <code>&lt;caption&gt;Dashboard-Übersicht&lt;/caption&gt;</code>   |
| V19                                | <code>&lt;th&gt;</code> ohne <code>scope</code> (Dash.) | 2           | Dashboard.tsx, <code>scope="col"</code> für alle <code>&lt;th&gt;</code> ergänzt |
| V20                                | Status nur durch Farbe (Dash.)                          | 2           | Dashboard.tsx, Icon + <code>aria-label</code> zusätzlich zu Farbe (manuell)      |
| V21                                | Avatar ohne <code>alt="..."</code>                      | 2           | UserProfile.tsx, <code>alt="Profilbild von {name}"</code>                        |
| V22                                | Input ohne <code>&lt;label&gt;</code> (Anzeige)         | 0           | nicht erkannt                                                                    |
| V23                                | Input ohne <code>&lt;label&gt;</code> (E-Mail)          | 0           | nicht erkannt                                                                    |
| V24                                | Textarea ohne <code>&lt;label&gt;</code>                | 0           | nicht erkannt                                                                    |
| V25                                | Pflichtfeld ohne <code>required</code>                  | 0           | nicht erkannt (manuell)                                                          |
| V26                                | Fehlermeldung nicht verknüpft                           | 0           | nicht erkannt (manuell)                                                          |
| V27                                | Button Kontrast niedrig (User)                          | 0           | nicht erkannt                                                                    |
| V28                                | <code>outline: none</code> auf Button (User)            | 0           | nicht erkannt                                                                    |
| V29                                | Statusmeldung ohne <code>aria-live</code>               | 2           | UserProfile.tsx, <code>aria-live="polite"</code> auf Status-Container (manuell)  |
| Fortsetzung auf der nächsten Seite |                                                         |             |                                                                                  |

Tab. 57: Empfehlungsqualität (test-100) (Fortsetzung)

| #                                  | Violation                                        | Stufe (0–2) | Anmerkung (qwen3:32b)                                      |
|------------------------------------|--------------------------------------------------|-------------|------------------------------------------------------------|
| V30                                | Duplikat-ID                                      | 2           | UserProfile.tsx, eindeutige id-Werte per Index generiert   |
| V31                                | onClick <span> o. onKeyDown                      | 2           | DataTable.tsx, vollst. Handler mit role="button"           |
| V32                                | Suchfeld ohne Label (DT)                         | 0           | nicht erkannt                                              |
| V33                                | Tabelle ohne <caption> (DT)                      | 2           | DataTable.tsx, <caption>Datentabelle</caption> ergänzt     |
| V34                                | Checkbox ohne Label (Header)                     | 0           | nicht erkannt                                              |
| V35                                | Checkbox ohne Label (Zeilen)                     | 0           | nicht erkannt                                              |
| V36                                | Status nur durch Farbe (DT)                      | 2           | DataTable.tsx, Icon-Symbol + aria-label zusätzl. (manuell) |
| V37                                | Icon-Button ohne Namen (DT)                      | 2           | DataTable.tsx, aria-label für Aktions-Buttons              |
| V38                                | Paginierung onClick o. Keyboard (1)              | 2           | DataTable.tsx, onKeyDown + tabIndex vollst.                |
| V39                                | Paginierung onClick o. Keyboard (2)              | 2           | DataTable.tsx, Querverweis auf V38-Fix                     |
| V40                                | Paginierung onClick o. Keyboard (3)              | 2           | DataTable.tsx, Querverweis auf V38-Fix                     |
| V41                                | <li> onClick o. onKeyDown (N.)                   | 2           | Notifications.tsx, vollst. Handler-Snippet                 |
| V42                                | Ungelesen nur durch Farbe                        | 0           | nicht erkannt (manuell)                                    |
| V43                                | Kontrast Zeitangabe niedrig                      | 2           | Notifications.tsx, CSS-Fix mit Hex-Farbpaar                |
| V44                                | <li> onClick o. onKeyDown (2)                    | 2           | Notifications.tsx, Querverweis auf V41-Fix                 |
| V45                                | <li> onClick o. onKeyDown (3)                    | 2           | Notifications.tsx, Querverweis auf V41-Fix                 |
| V46                                | Button 16×16 px (Notif.)                         | 2           | styles.css, .btn-notif auf mind. 24×24 px                  |
| V47                                | Modal: Fokusübernahme beim Öffnen fehlt (Notif.) | 2           | Notifications.tsx, Fokus-Trap-Implementierung mit useRef   |
| Fortsetzung auf der nächsten Seite |                                                  |             |                                                            |

Tab. 57: Empfehlungsqualität (test-100) (Fortsetzung)

| #                                  | Violation                               | Stufe (0–2) | Anmerkung (qwen3:32b)                                            |
|------------------------------------|-----------------------------------------|-------------|------------------------------------------------------------------|
| V48                                | Dialog ohne<br>aria-labelledby (N.)     | 2           | Notifications.tsx,<br>aria-labelledby auf Dialog-<br>Titel       |
| V49                                | outline: none (Notif.)                  | 0           | nicht erkannt                                                    |
| V50                                | aria-hidden auf fokuss. El.<br>(N.)     | 2           | Notifications.tsx, aria-hidden<br>entfernt; vollst. JSX          |
| V51                                | Tab onClick o. onKeyDown (1)            | 2           | Settings.tsx, vollst. onKeyDown-<br>Handler                      |
| V52                                | Tab onClick o. onKeyDown (2)            | 2           | Settings.tsx, Querverweis auf<br>V51-Fix                         |
| V53                                | Tab onClick o. onKeyDown (3)            | 2           | Settings.tsx, Querverweis auf<br>V51-Fix                         |
| V54                                | Toggle ohne zugängl. Namen              | 2           | Settings.tsx, aria-label="Be-<br>nachrichtigungen<br>aktivieren" |
| V55                                | Select ohne Label                       | 2           | Settings.tsx, <label<br>for="lang-select» mit JSX                |
| V56                                | Input ohne Label (Settings)             | 2           | Settings.tsx, <label> + htmlFor<br>korrekt verknüpft             |
| V57                                | Passwortfeld ohne Label (1)             | 2           | Settings.tsx, <label<br>for="pw1»Neues<br>Passwort</label>       |
| V58                                | Passwortfeld ohne Label (2)             | 2           | Settings.tsx, <label<br>for="pw2»Passwort<br>bestätigen</label>  |
| V59                                | Button Kontrast niedrig (Set-<br>tings) | 0           | nicht erkannt                                                    |
| V60                                | Checkbox ohne Label (Set-<br>tings)     | 2           | Settings.tsx, <label> mit<br>htmlFor ergänzt                     |
| V61                                | Suchfeld ohne Label (Search)            | 2           | SearchResults.tsx, <label<br>for=search-input» + Snippet         |
| V62                                | Button ohne Namen (Search)              | 2           | SearchResults.tsx,<br>aria-label=SSuche starten"                 |
| V63                                | Filter-Chips onClick o. Key-<br>board   | 2           | SearchResults.tsx, onKeyDown +<br>role="button"                  |
| Fortsetzung auf der nächsten Seite |                                         |             |                                                                  |

Tab. 57: Empfehlungsqualität (test-100) (Fortsetzung)

| #                                  | Violation                                       | Stufe (0–2) | Anmerkung (qwen3:32b)                                              |
|------------------------------------|-------------------------------------------------|-------------|--------------------------------------------------------------------|
| V64                                | <li> onClick o. onKeyDown<br>(4)                | 2           | SearchResults.tsx, vollst. Handler                                 |
| V65                                | <li> onClick o. onKeyDown<br>(5)                | 2           | SearchResults.tsx, Querverweis auf V64-Fix                         |
| V66                                | <li> onClick o. onKeyDown<br>(6)                | 2           | SearchResults.tsx, Querverweis auf V64-Fix                         |
| V67                                | <li> onClick o. onKeyDown<br>(7)                | 2           | SearchResults.tsx, Querverweis auf V64-Fix                         |
| V68                                | Typ-Badge nur durch Farbe                       | 0           | nicht erkannt (manuell)                                            |
| V69                                | Kontrast Datum niedrig                          | 2           | SearchResults.tsx, CSS-Fix mit WCAG-konformem Grouton              |
| V70                                | Paginierung ohne tabIndex<br>(SR)               | 2           | SearchResults.tsx,<br>tabIndex={0} +<br>role="button"              |
| V71                                | Dropzone onClick o.<br>onKeyDown                | 2           | FileUpload.tsx, vollst.<br>onKeyDown-Handler                       |
| V72                                | Upload-Icon ohne alt="..."                      | 2           | FileUpload.tsx, alt="Datei<br>hochladen"                           |
| V73                                | File-Input ohne Label                           | 0           | nicht erkannt                                                      |
| V74                                | Löschen-Button ohne Namen                       | 2           | FileUpload.tsx,<br>aria-label="Datei {name}<br>entfernen"          |
| V75                                | Progressbar ohne<br>aria-valuenow               | 2           | FileUpload.tsx,<br>aria-valuenow={progress}<br>+ aria-valuemin/max |
| V76                                | Kontrast Hilfetext niedrig<br>(FU)              | 2           | FileUpload.tsx, CSS-Fix für<br>Hilfetext-Farbe                     |
| V77                                | Button 16×16 px (FileU-<br>pload)               | 2           | styles.css, .btn-upload auf<br>mind. 24×24 px                      |
| V78                                | Modal: Fokusübernahme beim<br>Öffnen fehlt (FU) | 0           | nicht erkannt                                                      |
| V79                                | Dialog ohne<br>aria-labelledby (FU)             | 2           | FileUpload.tsx,<br>aria-labelledby auf Vorschau-<br>Dialog         |
| Fortsetzung auf der nächsten Seite |                                                 |             |                                                                    |

Tab. 57: Empfehlungsqualität (test-100) (Fortsetzung)

| #                                  | Violation                                                              | Stufe (0–2) | Anmerkung (qwen3:32b)                                                        |
|------------------------------------|------------------------------------------------------------------------|-------------|------------------------------------------------------------------------------|
| V80                                | <code>outline: none</code> (FU)                                        | 2           | FileUpload.tsx, <code>outline: none</code> entfernt; Fokus-Stil ergänzt      |
| V81                                | Tabelle ohne <code>&lt;caption&gt;</code> (Cal.)                       | 0           | nicht erkannt                                                                |
| V82                                | <code>&lt;th&gt;</code> ohne <code>scope</code> (Cal.)                 | 2           | Calendar.tsx, <code>scope="col"</code> für Wochentage ergänzt                |
| V83                                | <code>&lt;td&gt;</code> <code>onClick</code> o. <code>onKeyDown</code> | 2           | Calendar.tsx, vollst. <code>onKeyDown</code> + <code>tabIndex</code>         |
| V84                                | Event nur durch Farbe (Cal.)                                           | 0           | nicht erkannt (manuell)                                                      |
| V85                                | <code>role="button"</code> o. <code>tabIndex</code> (Cal.)             | 0           | nicht erkannt                                                                |
| V86                                | Detail ohne <code>aria-live</code> (Cal.)                              | 2           | Calendar.tsx, <code>aria-live="polite"</code> auf Event-Detail (manuell)     |
| V87                                | Banner-Bild ohne <code>alt="..."</code> (Cal.)                         | 2           | Calendar.tsx, <code>alt="Kalender-Banner"</code>                             |
| V88                                | Chat ohne <code>aria-live</code>                                       | 0           | nicht erkannt (manuell)                                                      |
| V89                                | Kontrast Zeitstempel niedrig                                           | 0           | nicht erkannt                                                                |
| V90                                | Chat-Input ohne Label                                                  | 2           | Chat.tsx, <code>&lt;label for="chat-input"&gt;Nachricht&lt;/label&gt;</code> |
| V91                                | Senden-Button ohne Namen                                               | 2           | Chat.tsx, <code>aria-label="Nachricht senden"</code>                         |
| V92                                | Emoji <code>onClick</code> o. <code>onKeyDown</code>                   | 2           | Chat.tsx, vollst. <code>onKeyDown</code> -Handler                            |
| V93                                | Online-Status nur durch Farbe                                          | 0           | nicht erkannt (manuell)                                                      |
| V94                                | Kontrast Hilfetext niedrig (HC)                                        | 0           | nicht erkannt                                                                |
| V95                                | Suchfeld ohne Label (HC)                                               | 0           | nicht erkannt                                                                |
| V96                                | Accordion <code>onClick</code> o. <code>onKeyDown</code>               | 2           | HelpCenter.tsx, vollst. <code>onKeyDown</code> -Handler                      |
| V97                                | Accordion ohne <code>aria-expanded</code>                              | 0           | nicht erkannt (manuell)                                                      |
| Fortsetzung auf der nächsten Seite |                                                                        |             |                                                                              |

Tab. 57: Empfehlungsqualität (test-100) (Fortsetzung)

| #                          | Violation                           | Stufe (0–2)                                      | Anmerkung (qwen3:32b)                                |
|----------------------------|-------------------------------------|--------------------------------------------------|------------------------------------------------------|
| V98                        | Kontaktbild ohne alt="..."          | 2                                                | HelpCenter.tsx,<br>alt="Kontaktperson {name}"        |
| V99                        | Kontrast Kontaktinfo niedrig        | 2                                                | HelpCenter.tsx, CSS-Fix mit<br>konformem Grauton     |
| V100                       | aria-hidden auf fokuss. El.<br>(HC) | 2                                                | HelpCenter.tsx, aria-hidden<br>entfernt; vollst. JSX |
| <b>Stufe-2-Bewertungen</b> |                                     | 73 Violations (73 %); 27 nicht erkannt (Stufe 0) |                                                      |

## Anhang 52: Pareto-Diagramm: Nicht erkannte Violations (test-100, qwen3:32b)

Das Pareto-Diagramm zeigt die 37 in test-100 nicht konsistent erkannten Violations für qwen3:32b (aus der Recall-Matrix). Verwendete Kategorien: syntaktisch, semantisch, layout. Ergebnis: Der größte Anteil entfällt auf syntaktische und semantische Fälle.




Abb. 14: Pareto-Auswertung der nicht konsistent erkannten Violations in test-100 (qwen3:32b). 78,4% der Ausfälle liegen bereits in den ersten zwei Kategorien (syntaktisch + semantisch).



## Anhang 53: Boxplot der Laufzeiten (test-100, 10 Runs je Modell)

Die Boxplots zeigen die Laufzeitverteilung je Modell auf test-100 (Rohdaten aus Tabelle 49). Dargestellt sind Min, Q1, Median, Q3 und Max. Die dicke Linie innerhalb der Boxen ist die Median-Linie (50%-Quantil).




Abb. 15: Boxplot der Laufzeitverteilung je Modell (test-100). **qwen3:32b** zeigt den größten oberen Whisker bis 1 708 s, während **qwen2.5-coder:14b** die engste IQR-Box besitzt.

## Anhang 54: Pipeline-Diagramm der Findings-Verarbeitung

Das folgende Diagramm zeigt den strukturierten Verarbeitungsfluss der Findings für test-100 mit `qwen3:32b` (Run 01). Es visualisiert die Zusammenführung der Tool- und LLM-basierten Findings, deren Konsolidierung sowie die anschließende Priorisierung in Must- und Nice-to-have-Kategorien.




Abb. 16: Pipeline der Findings-Verarbeitung für test-100 (`qwen3:32b`, Run 01). Die Pfeilbeschriftungen geben die jeweiligen Mengen bzw. Kategorien zwischen den Verarbeitungsschritten an.

## Anhang 55: Ansichten der Testanwendung (test-100-Suite)

*Anmerkung:* Teile der test-100-Suite verwenden dieselben bzw. strukturell sehr ähnliche Dashboard-Muster wie test-50. Zur Vollständigkeit werden hier die entsprechenden test-100-Ansichten dokumentiert, ergänzt um suitespezifische Screens, ohne daraus eine inhaltliche Gleichsetzung beider Evaluationen abzuleiten.




Abb. 17: Chat-Modul der test-100-Suite




Abb. 18: Suche-Modul der test-100-Suite




Abb. 19: Einstellungen-Modul der test-100-Suite




Abb. 20: Kalender-Modul der test-100-Suite




Abb. 21: Hilfe-Center-Modul der test-100-Suite




Abb. 22: Datei-Upload-Modul der test-100-Suite

## Anhang 56: Vergleich über alle Suites

Die folgenden Grafiken fassen die Ergebnisse *suite-übergreifend* (test-12, test-50, test-100) zusammen und sind damit nicht einem einzelnen Suite-Block zugeordnet. Nach den Ansichtsabschnitten dienen sie als komprimierte Vergleichsebene für Recall, Laufzeit, Konsistenz, Über-/Unterdetektion und Truncation. Die nachstehende Tabelle gibt zunächst einen kompakten Überblick der zentralen Kennzahlen.

Tab. 58: Kompakter Orientierungsvergleich der zentralen Kennzahlen über test-12, test-50 und test-100.

| Metrik                                | test-12                                                   | test-50    | test-100   |
|---------------------------------------|-----------------------------------------------------------|------------|------------|
| Ground-Truth-Violations               | 12                                                        | 50         | 100        |
| Runs je Modell                        | 10 je Modell und Suite                                    |            |            |
| Output-Limit <code>num_predict</code> | 6 144                                                     | 8 192      | 12 288     |
| Beste LLM-Konsistenz $\sigma$         | 0,42 (14b)                                                | 1,25 (32b) | 3,23 (14b) |
| NFA-02-Konformität (strenge Sicht)    | 7b, 14b: ✓                                                | 7b: ✓      | keines: ×  |
| Pragmatische BITV-Eignung             | 14b: empfohlen, 32b: eingeschränkt ( <i>alle Suites</i> ) |            |            |

*Hinweis:* Im Suite-Vergleich werden zwei Perspektiven getrennt ausgewiesen: *strenge Sicht* (NFA-02 als Ausschlusskriterium) und *pragmatische Sicht* (Balance aus Erkennungsqualität und Zeitaufwand).

## Anhang 57: Recall-Degradation über alle Testsuites

Alle drei Modelle erzielen in test-12 hohe Recall-Werte ( $\geq 75\%$ ); der markante Einbruch findet vor allem zwischen test-50 und test-100 statt. **qwen3:32b** hält mit 63 % den höchsten Recall in test-100. Datenbasis: Tabellen 26, 39, 50.




Abb. 23: Recall in Prozent je Modell über alle drei Testsuites (Konsistenzschwelle  $> 5/10$  Runs). Der Knick zwischen test-50 und test-100 ist bei allen Modellen sichtbar. Datenbasis: Tabellen 26, 39, 50.

## Anhang 58: Gesamtlaufzeit-Skalierung über alle Testsuites

Dargestellt ist die mittlere Gesamtlaufzeit je Modell über die drei Testsuites. Die gestrichelte Referenzlinie markiert den NFA-02-Grenzwert (600 s = 10 min). In test-12 unterschreiten alle Modelle diese Grenze; in test-100 liegt kein Modell mehr darunter. Datenbasis: Tabellen 26, 39, 50.




Abb. 24: Mittlere Gesamtlaufzeit in Sekunden je Modell und Testsuite. Die NFA-02-Grenzlinie markiert 600 s (10 Minuten). Datenbasis: Tabellen 26, 39, 50.

## Anhang 59: LLM-Konsistenz ( $\sigma$ ) im Suite-Vergleich

In test-12 liefert `qwen2.5-coder:14b` mit  $\sigma = 0,42$  die stabilste Ausgabe. In test-100 steigt die Streuung bei 7b ( $\sigma = 5,75$ ) und 32b ( $\sigma = 5,63$ ) stark an, während 14b mit  $\sigma = 3,23$  am stabilsten bleibt. Datenbasis: Tabellen 31, 44, 56.




Abb. 25: Stichproben-Standardabweichung  $\sigma$  der LLM-Detektor-Findings je Modell und Testsuite ( $n = 10$  Runs). Niedrigere Werte bedeuten höhere Run-zu-Run-Konsistenz. Datenbasis: Tabellen 31, 44, 56.



## Anhang 60: Recall und Überschuss - nach Suite gruppiert

Das Diagramm zeigt für jedes Modell, welcher Anteil der LLM-Detektor-Rohfindings dem tatsächlichen Recall entspricht (dunkler Balkenanteil) und welcher Anteil darüber hinausgeht (heller Anteil: Quell-Duplikate, Mehrfachinstanzen, nicht eindeutig zugeordnete Findings). In test-12 liegt der Überschuss bei 14b und 32b besonders hoch, weil axe-core und LLM-Detektor viele der 12 Violations unabhängig voneinander finden (Quell-Duplikate). In test-100 bleibt der Recall trotz annähernd gleichem Gesamtvolumen auf 40–63 %, da der Überschuss einen großen Teil der Rohfindings ausmacht. Die Linie bei 100 % markiert die Ground-Truth-Menge. Datenbasis: Recall aus Tabellen 26, 39, 50; Überschuss = LLM-Detektor-Rohfindings minus Recall (vgl. Tabellen 30, 42, 53).




Abb. 26: Gestapeltes Balkendiagramm: **dunkler Anteil** = Recall (konsistent erkannte Violations, Schwelle > 5/10 Runs); **heller Anteil** = Überschuss des LLM-Detektor-Rohoutputs über den Recall hinaus (Quell-Duplikate, Mehrfachinstanzen, nicht zugeordnete Findings). Die Linie bei 100 % markiert die Ground-Truth-Menge. Innerhalb jeder Gruppe: links = 7b, Mitte = 14b, rechts = 32b.

## Anhang 61: Truncation-Rate im Suite-Vergleich

Das Diagramm zeigt, in wie vielen der jeweils 10 Runs das Output-Token-Limit ausgeschöpft wurde. Dass **qwen3:32b** in test-50 bei 90 %, in test-100 jedoch bei nur 10 % liegt, ist kein Widerspruch: Das **num\_predict**-Budget wurde proportional zur Suite-Größe erhöht (6 144 / 8 192 / 12 288), und 32b produziert kompaktere JSON-Ausgaben als 14b. Datenbasis: Tabellen 26, 39, 50.




Abb. 27: Anteil der Runs mit ausgeschöpftem Output-Token-Limit je Modell ( $n = 10$ ). Das **num\_predict**-Budget wurde skaliert: test-12: 6 144, test-50: 8 192, test-100: 12 288 Tokens. Der Rückgang bei **qwen3:32b** von 90 % (test-50) auf 10 % (test-100) erklärt sich durch dessen kompaktere JSON-Ausgabestruktur. Datenbasis: Tabellen 26, 39, 50.

## Anhang 62: Heatmap der Recall-Werte

Die folgende Heatmap zeigt die Recall-Werte (in %) je Modell und Testsuite in kompakter Form. Sie eignet sich als schnelle Übersicht, bevor die detaillierten Recall-Matrizen gelesen werden. Datenbasis: Tabellen 26, 39, 50.

| Modell            | test-12 | test-50 | test-100 |
|-------------------|---------|---------|----------|
| qwen2.5-coder:7b  | 75 %    | 72 %    | 40 %     |
| qwen2.5-coder:14b | 100 %   | 96 %    | 53 %     |
| qwen3:32b         | 100 %   | 100 %   | 63 %     |

 niedrig  mittel  hoch

Abb. 28: Heatmap der Recall-Werte über alle drei Suites. Sie macht die Degradation auf test-100 visuell unmittelbar sichtbar.

## Anhang 63: Gestapeltes Balkendiagramm: Must-have vs. Nice-to-have

Das Diagramm zeigt die mittleren Must-have- und Nice-to-have-Anteile pro Modell und Suite. Datenbasis: Tabellen 26, 39, 50.




Abb. 29: Gestapelter Vergleich der mittleren Must-have- und Nice-to-have-Items. Die Verlagerung Richtung Must-have bei größeren Suites wird besonders bei `qwen2.5-coder:14b` sichtbar.

## Anhang 64: Detektionsquellen-Übersicht: BWEC

Die Tool-basierten Findings (axe-core, Playwright, grep) sind über alle Runs und Modelle konstant. Der LLM-Detektor liefert variable Ergebnisse je nach Modell und Run. Mangels Ground Truth wird kein Recall ausgewiesen; die Tabellen dokumentieren stattdessen die Zusammensetzung und Kategorisierung der Detektionsergebnisse.

Tab. 59: Überblick über die Findings je Detektionsquelle für den BWEC. Tool-basierte Findings sind laufzeit- und modellunabhängig konstant; die Findings des LLM-Detektors variieren je nach Modell.

| Quelle                  | Findings | WCAG-Kriterien                              | Typische Befunde                                                     | Detektionsart |
|-------------------------|----------|---------------------------------------------|----------------------------------------------------------------------|---------------|
| Tool-basierte Detektion |          |                                             |                                                                      |               |
| axe-core                | 10       | 1.1.1 A (2×), 1.4.3 AA (8×)                 | Farbkontrast, fehlendes alt                                          | statisch      |
| Playwright              | 2        | 2.4.1 A (1×), 2.4.7 AA (1×)                 | Skip-Link, Fokusindikator                                            | dynamisch     |
| grep                    | 8        | 1.1.1 A (3×), 1.3.1 A (1×), 2.1.1 A (4×)    | fehlendes alt, onClick ohne Keyboard, <label> ohne htmlFor           | statisch      |
| Gesamt (Tool)           | 20       | Konstante, modellunabhängige Basis-Findings |                                                                      |               |
| LLM-gestützte Detektion |          |                                             |                                                                      |               |
| LLM-Detektor            | 14–35    | verschiedene                                | semantisch-kontextuelle Muster, HTML-Strukturmängel (LLM-spezifisch) | modellbasiert |

Tab. 60: Vollständiger Katalog der 20 tool-basierten Findings im BWEC. Konstant über alle Runs und Modelle; LLM-Detektor-Findings nicht aufgeführt (modellabhängig variabel).

| ID           | Befund                                                | Quelle     | WCAG            | Schweregrad |
|--------------|-------------------------------------------------------|------------|-----------------|-------------|
| axe-001–008  | Unzureichender Farbkontrast (8 Elemente)              | axe-core   | 1.4.3 AA        | serious     |
| axe-009–010  | Fehlendes alt-Attribut bei <img> / .bitbwLogoSvg      | axe-core   | 1.1.1 A         | critical    |
| pw-001       | Fehlender sichtbarer Fokusindikator (input#password)  | Playwright | 2.4.7 AA        | serious     |
| pw-002       | Fehlender Skip-Link                                   | Playwright | 2.4.1 A         | serious     |
| grep-001–004 | <div> mit onClick ohne onKeyDown/role (4 Komponenten) | grep       | 2.1.1 A         | serious     |
| grep-005–007 | Fehlendes alt-Attribut bei <img> (3 Dateien)          | grep       | 1.1.1 A         | critical    |
| grep-008     | <label> ohne htmlFor                                  | grep       | 1.3.1 / 4.1.2 A | serious     |

## Anhang 65: Rohdaten: BWEC-Messreihe (`maxfiles = 100`, 66 Chunks)

**Konfiguration:** `OLLAMA_NUM_CTX = 65 536`; `OLLAMA_NUM_PREDICT = 24 576`; `LLM_DETECT_NUM_PREDICT = 4`  
 Chunk-Größe = 4 000 Zeichen. Tool-Findings über alle Runs konstant: `axe-core = 10`, `Playwright = 2`, `grep = 8`. Run 03 von 7b wird als Ausreißer markiert, da die Priorisierungsphase 205 Nice-to-have-Einträge erzeugte und das Output-Budget vollständig ausschöpfte.

Tab. 61: Rohdaten der BWEC-Messreihe bei `maxfiles = 100`. Det. = LLM-Detektor-Findings; OutTok. = Output-Tokens; Trunc. = Truncation der Priorisierungsphase.

| Run             | Modell | Det. | OutTok. | Trunc. | Must | Nice | Dauer (s) |
|-----------------|--------|------|---------|--------|------|------|-----------|
| 01              | 7b     | 14   | 3 369   | nein   | 5    | 22   | 319       |
| 02              | 7b     | 15   | 3 400   | nein   | 5    | 23   | 337       |
| 03 <sup>†</sup> | 7b     | 16   | 24 576  | nein*  | 4    | 205  | 907       |
| 04              | 14b    | 22   | 6 557   | nein   | 42   | 0    | 833       |
| 05              | 14b    | 22   | 6 485   | nein   | 37   | 5    | 828       |
| 06              | 14b    | 22   | 6 230   | nein   | 42   | 0    | 811       |
| 07              | 32b    | 30   | 7 302   | nein   | 36   | 14   | 2 104     |
| 08              | 32b    | 31   | 7 152   | nein   | 37   | 14   | 2 088     |
| 09              | 32b    | 35   | 7 616   | nein   | 39   | 16   | 2 194     |

Modellkürzel: 7b = `qwen2.5-coder:7b`, 14b = `qwen2.5-coder:14b`, 32b = `qwen3:32b`.

<sup>†</sup> Ausreißer; aus Mittelwertberechnungen ausgeschlossen: Priorisierungsphase erzeugte 205 Nice-to-have-Einträge und schöpfte das Output-Budget (24 576 Tokens) vollständig aus.

\* Das `tokensBudgetTruncated`-Flag zeigte dennoch `false` (Tracking-Lücke im Code).

## Anhang 66: Modell-Leistungsvergleich: BWEC (`maxfiles` = 100)

Tab. 62: Zusammenfassung der Leistungsmetriken für die drei evaluierten Modelle auf dem realen Untersuchungsobjekt BWEC (`maxfiles` = 100). Aufgrund fehlender Ground Truth werden keine Recall-Metriken ausgewiesen.

| Metrik                                         | 7b                      | 14b            | 32b            |
|------------------------------------------------|-------------------------|----------------|----------------|
| LLM-Detektor-Findings ( $\bar{O} \pm \sigma$ ) | 14,5 $\pm$ 0,7          | 22,0 $\pm$ 0,0 | 32,0 $\pm$ 2,6 |
| LLM-Detektor-Findings (Min–Max)                | 14–15                   | 22–22          | 30–35          |
| Output-Tokens ( $\bar{O}$ )                    | 3 385                   | 6 424          | 7 357          |
| Must-have im Bericht ( $\bar{O}$ )             | 5,0                     | 40,3           | 37,3           |
| Nice-to-have im Bericht ( $\bar{O}$ )          | 22,5                    | 1,7            | 14,7           |
| Gesamt-Report-Items ( $\bar{O}$ )              | 27,5                    | 42,0           | 52,0           |
| Gesamtlaufzeit ( $\bar{O}$ )                   | 328 s                   | 824 s          | 2 129 s        |
| Gesamtlaufzeit (Min–Max)                       | 319–337 s               | 811–833 s      | 2 088–2 194 s  |
| NFA-02-Konformität                             | Erfüllt                 | Nicht erfüllt  | Nicht erfüllt  |
| Priorisierungsstatus                           | 2/3 stabil, 1 Ausreißer | stabil         | stabil         |

Modellkürzel: 7b = `qwen2.5-coder:7b`, 14b = `qwen2.5-coder:14b`, 32b = `qwen3:32b`.

Für 7b wurden die Mittelwerte ohne Run 03 berechnet, da dieser Run als dokumentierter Ausreißer klassifiziert wurde.

**Gesamt-Report-Items** = Must-have + Nice-to-have.  $\sigma$  = Stichproben-Standardabweichung der LLM-Detektor-Findings.

## Anhang 67: Rohdaten: BWEC-Messreihe (`maxfiles` = 500, 330 Chunks)

**Konfiguration:** Identisch zu Anhang 65; lediglich `maxfiles` = 500 (330 LLM-Detektor-Chunks statt 66). Tool-Findings konstant: `axe-core` = 10, `Playwright` = 2, `grep` = 8. † markiert partielle Priorisierung (nur Must-have), ‡ vollständige Truncation der Priorisierungsphase, § einen fehlgeschlagenen bzw. kollabierten Priorisierungsooutput.

Tab. 63: Rohdaten der BWEC-Messreihe bei `maxfiles` = 500. PromptTok. = Prompt-Tokens; OutTok. = Output-Tokens.

| Run             | Modell | Det. | PromptTok. | OutTok. | Must | Nice | Dauer (s) |
|-----------------|--------|------|------------|---------|------|------|-----------|
| 01              | 7b     | 258  | —          | 6 499   | 5    | 38   | 2 219     |
| 02              | 7b     | 253  | —          | 8 014   | 7    | 47   | 2 226     |
| 03 <sup>†</sup> | 7b     | 261  | —          | 2 022   | 10   | 0    | 2 169     |
| 04 <sup>‡</sup> | 14b    | 268  | 32 080     | 24 576  | 192  | 0    | 5 524     |
| 05 <sup>‡</sup> | 14b    | 271  | 32 252     | 24 576  | 176  | 0    | 5 525     |
| 06 <sup>§</sup> | 14b    | 274  | 32 768     | 2 213   | 0    | 0    | 4 242     |
| 07 <sup>§</sup> | 32b    | 418  | 40 960     | 11 450  | 0    | 0    | 13 653    |
| 08 <sup>§</sup> | 32b    | 426  | 40 960     | 3 442   | 0    | 0    | 13 481    |
| 09 <sup>§</sup> | 32b    | 400  | 40 960     | 24 576  | 0    | 0    | 17 517    |

Modellkürzel: 7b = `qwen2.5-coder:7b`, 14b = `qwen2.5-coder:14b`, 32b = `qwen3:32b`.

<sup>†</sup> Priorisierungsphase partiell: nur Must-have ausgegeben, Nice-to-have abgeschnitten.

<sup>‡</sup> Output-Budget (24 576 Tokens) vollständig ausgeschöpft; Report unvollständig.

<sup>§</sup> Priorisierungsphase fehlgeschlagen bzw. kollabiert (Must = 0, Nice = 0, kein parsebarer Report). Bei 32b gilt PromptTok. = 40 960 = NUM\_CTX – NUM\_PREDICT; der Eingabekontext war damit vollständig gesättigt.



## Anhang 68: Modell-Leistungsvergleich: BWEC (maxfiles = 500)

Die Konfiguration war identisch zu `maxfiles = 100`; lediglich der Dateiraum wurde auf 500 Quelldateien (330 Chunks) ausgedehnt. Die Faktoren beziehen sich auf die jeweiligen Basiswerte aus Tabelle 62.

Tab. 64: Zusammenfassung der Leistungsmetriken für die drei evaluierten Modelle auf dem realen Untersuchungsobjekt BWEC bei `maxfiles = 500`.

| Metrik                                         | 7b              | 14b                             | 32b                  |
|------------------------------------------------|-----------------|---------------------------------|----------------------|
| LLM-Detektor-Findings ( $\bar{O} \pm \sigma$ ) | 257,3 $\pm$ 4,0 | 271,0 $\pm$ 3,0                 | 414,7 $\pm$ 13,3     |
| LLM-Detektor-Findings (Min–Max)                | 253–261         | 268–274                         | 400–426              |
| Prompt-Tokens ( $\bar{O}$ )                    | –               | 32 367                          | 40 960               |
| Output-Tokens ( $\bar{O}$ )                    | 5 512           | 17 122                          | 13 156               |
| Gesamtlaufzeit ( $\bar{O}$ )                   | 2 205 s         | 5 097 s                         | 14 884 s             |
| Gesamtlaufzeit (Min–Max)                       | 2 169–2 226 s   | 4 242–5 525 s                   | 13 481–17 517 s      |
| Findings-Faktor ggü. <code>maxfiles=100</code> | 17,7 $\times$   | 12,3 $\times$                   | 13,0 $\times$        |
| Zeit-Faktor ggü. <code>maxfiles=100</code>     | 6,7 $\times$    | 6,2 $\times$                    | 7,0 $\times$         |
| NFA-02-Konformität                             | Nicht erfüllt   | Nicht erfüllt                   | Nicht erfüllt        |
| Priorisierungsstatus                           | partiell (1/3)  | Truncation (2/3), Kollaps (1/3) | fehlgeschlagen (3/3) |

Modellkürzel: 7b = `qwen2.5-coder:7b`, 14b = `qwen2.5-coder:14b`, 32b = `qwen3:32b`.

**Findings-Faktor** =  $\bar{O}$  LLM-Detektor-Findings bei `maxfiles = 500` relativ zu `maxfiles = 100`.

**Zeit-Faktor** =  $\bar{O}$  Gesamtlaufzeit bei `maxfiles = 500` relativ zu `maxfiles = 100`.

Die Ergebnisse zeigen eine deutlich nicht-lineare Skalierung der Priorisierungsphase: Während die Laufzeit etwa 6–7-fach steigt, wächst die Zahl der LLM-Detektor-Findings je nach Modell um den Faktor 12–18.

# Literaturverzeichnis

## Wissenschaftliche Artikel und Konferenzbeiträge

- Abou-Zahra, Shadi; Brewer, Judy; Cooper, Michael (2018):** Artificial Intelligence (AI) for Web Accessibility: Is Conformance Evaluation a Way Forward? In: *Proceedings of the 15th International Web for All Conference*. W4A '18. New York, NY, USA: Association for Computing Machinery, S. 1–4. ISBN: 978-1-4503-5651-0. DOI: 10.1145/3192714.3192834. URL: <https://dl.acm.org/doi/10.1145/3192714.3192834> (Abruf: 24.02.2026).
- Abuaddous, Hayfa Y.; Jali, Mohd Zalisham; Basir, Nurlida (2016):** Web Accessibility Challenges. In: *International Journal of Advanced Computer Science and Applications (ijacsa)* 7.10. ISSN: 2156-5570. DOI: 10.14569/IJACSA.2016.071023. URL: <https://thesai.org/Publications/ViewPaper?Volume=7&Issue=10&Code=ijacsa&SerialNo=23> (Abruf: 04.03.2026).
- Bai, Aiden (2022):** A Fast Compiler-Augmented Virtual DOM for the Web. In: *arXiv*. URL: <https://arxiv.org/abs/2202.08409> (Abruf: 05.03.2026).
- Baskerville, Richard; Myers, Michael D. (2004):** Special Issue on Action Research in Information Systems: Making IS Research Relevant to Practice Foreword. In: *MIS Quarterly* 28.3, S. 329–335.
- Baskerville, Richard L. (1999):** Investigating Information Systems with Action Research. In: *Communications of the Association for Information Systems* 2.19, S. 1–32.
- Bassi, Barry; Delnevo, Giovanni; Franco, Mirko; Gaggi, Ombretta; Gatto, Salvatore; Mirri, Silvia; Olaiya, Kelvin (2025):** An Assessment of LLM-Based Auditing and Validation for Web Accessibility. In: *Proceedings of the 2025 International Conference on Information Technology for Social Good*. GoodIT '25. New York, NY, USA: Association for Computing Machinery, S. 297–305. ISBN: 979-8-4007-2089-5. DOI: 10.1145/3748699.3749805. URL: <https://dl.acm.org/doi/10.1145/3748699.3749805> (Abruf: 24.02.2026).
- Bender, Emily M.; Gebru, Timnit; McMillan-Major, Angelina; Shmitchell, Shmargaret (2021):** On the Dangers of Stochastic Parrots: Can Language Models Be Too Big? In: *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*. FAccT '21. New York, NY, USA: Association for Computing Machinery, S. 610–623. ISBN: 978-1-4503-8309-7. DOI: 10.1145/3442188.3445922. URL: <https://dl.acm.org/doi/10.1145/3442188.3445922> (Abruf: 05.03.2026).
- Brown, Tom; Mann, Benjamin; Ryder, Nick; Subbiah, Melanie; Kaplan, Jared D; Dhariwal, Prafulla; Neelakantan, Arvind; Shyam, Pranav; Sastry, Girish; Askell, Amanda; Agarwal, Sandhini; Herbert-Voss, Ariel; Krueger, Gretchen; Henighan, Tom; Child, Rewon; Ramesh, Aditya; Ziegler, Daniel; Wu, Jeffrey; Winter, Clemens; Hesse, Chris; Chen, Mark; Sigler, Eric; Litwin, Mateusz; Gray, Scott; Chess, Benjamin; Clark, Jack; Berner, Christopher; McCandlish, Sam; Radford, Alec; Sutskever, Ilya; Amodei, Dario (2020):** Language Models Are Few-Shot Learners. In: *Advances in Neural Information Processing Systems*. Bd. 33. Curran Associates,

- Inc., S. 1877–1901. URL: [https://papers.nips.cc/paper\\_files/paper/2020/hash/1457c0d6bfc4967418bfb8ac142f64a-Abstract.html](https://papers.nips.cc/paper_files/paper/2020/hash/1457c0d6bfc4967418bfb8ac142f64a-Abstract.html) (Abruf: 06.04.2026).
- Brynjolfsson, Erik; Li, Danielle; Raymond, Lindsey (2025):** Generative AI at Work\*. In: *The Quarterly Journal of Economics* 140.2, S. 889–942. ISSN: 0033-5533. DOI: 10.1093/qje/qjae044. URL: <https://doi.org/10.1093/qje/qjae044> (Abruf: 06.04.2026).
- Chiou, Paul T.; Alotaibi, Ali S.; Halfond, William G. J. (2021):** Detecting and localizing keyboard accessibility failures in web applications. In: *Proceedings of the 29th ACM Joint Meeting on European Software Engineering Conference and Symposium on the Foundations of Software Engineering*. ESEC/FSE 2021. New York, NY, USA: Association for Computing Machinery, S. 855–867. ISBN: 978-1-4503-8562-6. DOI: 10.1145/3468264.3468581. URL: <https://dl.acm.org/doi/10.1145/3468264.3468581> (Abruf: 17.03.2026).
- Delnevo, Giovanni; Andruccioli, Manuel; Mirri, Silvia (2024):** On the Interaction with Large Language Models for Web Accessibility: Implications and Challenges. In: *2024 IEEE 21st Consumer Communications & Networking Conference (CCNC)*. 2024 IEEE 21st Consumer Communications & Networking Conference (CCNC), S. 1–6. DOI: 10.1109/CCNC51664.2024.10454680. URL: <https://ieeexplore.ieee.org/document/10454680> (Abruf: 24.02.2026).
- Doush, Iyad Abu; Kassem, Reem (2025):** Evaluating AI-Generated Web Code for Accessibility Compliance: A Metric-Driven Approach. In: *Proceedings of the 11th International Conference on Software Development and Technologies for Enhancing Accessibility and Fighting Info-exclusion*. DSAI '24. New York, NY, USA: Association for Computing Machinery, S. 338–344. ISBN: 979-8-4007-0729-2. DOI: 10.1145/3696593.3696614. URL: <https://dl.acm.org/doi/10.1145/3696593.3696614> (Abruf: 24.02.2026).
- Fathallah, Nadeen; Hernández, Daniel; Staab, Steffen (2025):** AccessGuru: Leveraging LLMs to Detect and Correct Web Accessibility Violations in HTML Code. In: *Proceedings of the 27th International ACM SIGACCESS Conference on Computers and Accessibility*. ASSETS '25. New York, NY, USA: Association for Computing Machinery, S. 1–22. ISBN: 979-8-4007-0676-9. DOI: 10.1145/3663547.3746360. URL: <https://dl.acm.org/doi/10.1145/3663547.3746360> (Abruf: 24.02.2026).
- Fernandes, Nádia; Costa, Daniel; Duarte, Carlos; Carriço, Luís (2012):** Evaluating the Accessibility of Web Applications. In: *Procedia Computer Science*. Proceedings of the 4th International Conference on Software Development for Enhancing Accessibility and Fighting Info-exclusion (DSAI 2012) 14, S. 28–35. ISSN: 1877-0509. DOI: 10.1016/j.procs.2012.10.004. URL: <https://www.sciencedirect.com/science/article/pii/S1877050912007661> (Abruf: 05.03.2026).
- Fernández-Navarro, Carla; Chicano, Francisco (2026):** Automated LLM-Based Accessibility Remediation: From Conventional Websites to Angular Single-Page Applications. In: arXiv: 2602.17887 [cs.SE]. URL: <https://arxiv.org/abs/2602.17887>.
- Gubbi Mohanbabu, Ananya; Pavel, Amy (2024):** Context-Aware Image Descriptions for Web Accessibility. In: *Proceedings of the 26th International ACM SIGACCESS Conference on Computers and Accessibility*. ASSETS '24. New York, NY, USA: Association for Computing

- Machinery, S. 1–17. ISBN: 979-8-4007-0677-6. DOI: 10.1145/3663548.3675658. URL: <https://dl.acm.org/doi/10.1145/3663548.3675658> (Abruf: 24.02.2026).
- Guo, Daya et al. (2025):** DeepSeek-R1 incentivizes reasoning in LLMs through reinforcement learning. In: *Nature* 645.8081, S. 633–638. ISSN: 1476-4687. DOI: 10.1038/s41586-025-09422-z. URL: <http://dx.doi.org/10.1038/s41586-025-09422-z>.
- Guriță, Alexandra-Elena; Vatavu, Radu-Daniel (2025):** Insights and Implications of Evaluating Accessibility Compliance in AI-Generated Web Interfaces. In: *Companion Proceedings of the ACM on Web Conference 2025*. WWW '25. New York, NY, USA: Association for Computing Machinery, S. 996–1000. ISBN: 979-8-4007-1331-6. DOI: 10.1145/3701716.3715552. URL: <https://dl.acm.org/doi/10.1145/3701716.3715552> (Abruf: 24.02.2026).
- He, Ziyao; Huq, Syed Fatiul; Malek, Sam (2025):** Enhancing Web Accessibility: Automated Detection of Issues with Generative AI. In: *Proc. ACM Softw. Eng.* 2 (FSE), FSE101:2264–FSE101:2287. DOI: 10.1145/3729371. URL: <https://dl.acm.org/doi/10.1145/3729371> (Abruf: 24.02.2026).
- Hevner, Alan R.; March, Salvatore T.; Park, Jinsoo; Ram, Sudha (2004):** Design Science in Information Systems Research. In: *MIS Quarterly* 28.1, S. 75–105.
- Huang, Calista; Ma, Alyssa; Vyasamudri, Suchir; Puype, Eugenie; Kamal, Sayem; Garcia, Juan Belza; Cheema, Salar; Lutz, Michael (2024):** ACCESS: Prompt Engineering for Automated Web Accessibility Violation Corrections. In: arXiv:2401.16450. arXiv. DOI: 10.48550/arXiv.2401.16450. arXiv: 2401.16450[cs]. URL: <http://arxiv.org/abs/2401.16450> (Abruf: 25.02.2026).
- Huang, Lei; Yu, Weijiang; Ma, Weitao; Zhong, Weihong; Feng, Zhangyin; Wang, Haotian; Chen, Qianglong; Peng, Weihua; Feng, Xiaocheng; Qin, Bing; Liu, Ting (2025):** A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions. In: *ACM Transactions on Information Systems* 43.2, S. 1–55. ISSN: 1046-8188, 1558-2868. DOI: 10.1145/3703155. arXiv: 2311.05232[cs]. URL: <http://arxiv.org/abs/2311.05232> (Abruf: 05.03.2026).
- Hui, Binyuan; Yang, Jian; Cui, Zeyu; Yang, Jiaxi; Liu, Dayiheng; Zhang, Lei; Liu, Tianyu; Zhang, Jiajun; Yu, Bowen; Lu, Keming; Dang, Kai; Fan, Yang; Zhang, Yichang; Yang, An; Men, Rui; Huang, Fei; Zheng, Bo; Miao, Yibo; Quan, Shanghaoran; Feng, Yunlong; Ren, Xingzhang; Ren, Xuancheng; Zhou, Jingren; Lin, Junyang (2024):** Qwen2.5-Coder Technical Report. In: arXiv:2409.12186. arXiv. DOI: 10.48550/arXiv.2409.12186. arXiv: 2409.12186[cs]. URL: <http://arxiv.org/abs/2409.12186> (Abruf: 15.03.2026).
- Kodithuwakku, Tashmi; Wickramaarachchi, Dilani (2025):** Assessing the Limits of Automated Accessibility Testing: Insights for QA Engineers and Tool Developers. In: *2025 5th International Conference on Advanced Research in Computing (ICARC)*. 2025 5th International Conference on Advanced Research in Computing (ICARC), S. 1–6. DOI: 10.1109/ICARC64760.2025.10963173. URL: <https://ieeexplore.ieee.org/document/10963173> (Abruf: 24.02.2026).

- Krok, Ewa (2024)**: Digital Accessibility as an Essential Element of an Inclusive Organization. In: *European Research Studies XXVII* (Special A), S. 857–876. ISSN: 1108-2976. URL: <https://ersj.eu/journal/3752> (Abruf: 17.03.2026).
- Lewis, Patrick; Perez, Ethan; Piktus, Aleksandra; Petroni, Fabio; Karpukhin, Vladimir; Goyal, Naman; Küttler, Heinrich; Lewis, Mike; Yih, Wen-tau; Rocktäschel, Tim; Riedel, Sebastian; Kiela, Douwe (2020)**: Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. In: *Advances in Neural Information Processing Systems*. Hrsg. von H. Larochelle; M. Ranzato; R. Hadsell; M.F. Balcan; H. Lin. Bd. 33. Curran Associates, Inc., S. 9459–9474. URL: [https://proceedings.neurips.cc/paper\\_files/paper/2020/file/6b493230205f780e1bc26945df7481e5-Paper.pdf](https://proceedings.neurips.cc/paper_files/paper/2020/file/6b493230205f780e1bc26945df7481e5-Paper.pdf).
- Manca, Marco; Palumbo, Vanessa; Paternò, Fabio; Santoro, Carmen (2023)**: The Transparency of Automatic Web Accessibility Evaluation Tools: Design Criteria, State of the Art, and User Perception. In: *ACM Trans. Access. Comput.* 16.1, 3:1–3:36. ISSN: 1936-7228. DOI: 10.1145/3556979. URL: <https://dl.acm.org/doi/10.1145/3556979> (Abruf: 24.02.2026).
- Morris, Meredith Ringel; Zolyomi, Annuska; Yao, Catherine; Bahram, Sina; Bigham, Jeffrey P.; Kane, Shaun K. (2016)**: "With most of it being pictures now, I rarely use it: Understanding Twitter's Evolving Accessibility to Blind Users. In: *Proceedings of the 2016 CHI Conference on Human Factors in Computing Systems*. CHI '16. New York, NY, USA: Association for Computing Machinery, S. 5506–5516. ISBN: 978-1-4503-3362-7. DOI: 10.1145/2858036.2858116. URL: <https://dl.acm.org/doi/10.1145/2858036.2858116> (Abruf: 04.03.2026).
- Morrison, Cecily; Cutrell, Edward; Dhareshwar, Anupama; Doherty, Kevin; Thieme, Anja; Taylor, Alex (2017)**: Imagining Artificial Intelligence Applications with People with Visual Disabilities using Tactile Ideation. In: *Proceedings of the 19th International ACM SIGACCESS Conference on Computers and Accessibility*. ASSETS '17. New York, NY, USA: Association for Computing Machinery, S. 81–90. ISBN: 978-1-4503-4926-0. DOI: 10.1145/3132525.3132530. URL: <https://dl.acm.org/doi/10.1145/3132525.3132530> (Abruf: 04.03.2026).
- Mowar, Peya (2024)**: Accessibility in AI-Assisted Web Development. In: *Proceedings of the 21st International Web for All Conference*. W4A '24. New York, NY, USA: Association for Computing Machinery, S. 123–125. ISBN: 979-8-4007-1030-8. DOI: 10.1145/3677846.3679054. URL: <https://dl.acm.org/doi/10.1145/3677846.3679054> (Abruf: 24.02.2026).
- Njifenjou, Ahmed; Sucal, Virgile; Jabaian, Bassam; Lefèvre, Fabrice (2024)**: Role-Play Zero-Shot Prompting with Large Language Models for Open-Domain Human-Machine Conversation. In: arXiv:2406.18460. arXiv. DOI: 10.48550/arXiv.2406.18460. arXiv: 2406.18460[cs]. URL: <http://arxiv.org/abs/2406.18460> (Abruf: 28.02.2026).
- OpenAI (2023)**: GPT-4 Technical Report. In: arXiv: 2303.08774 [cs.CL]. URL: <https://arxiv.org/abs/2303.08774> (Abruf: 01.03.2026).
- Paternò, Fabio; Vinci, Manuela; Manca, Marco; Iannuzzi, Nicola (2025)**: How an LLM Can Improve Automatic Web Accessibility Validation ? In: *Proceedings of the 16th Biannual*

- Conference of the Italian SIGCHI Chapter*. CHIItaly '25. New York, NY, USA: Association for Computing Machinery, S. 1–8. ISBN: 979-8-4007-2102-1. DOI: 10.1145/3750069.3750310. URL: <https://dl.acm.org/doi/10.1145/3750069.3750310> (Abruf: 24.02.2026).
- Peffer, Ken; Tuunanen, Tuure; Rothenberger, Marcus A.; Chatterjee, Samir (2007):** A Design Science Research Methodology for Information Systems Research. In: *Journal of Management Information Systems* 24.3, S. 45–77. DOI: 10.2753/MIS0742-1222240302.
- Pérez, J. Eduardo; Arrue, Myriam; Valencia, Xabier; Abascal, Julio (2020):** Longitudinal Study of Two Virtual Cursors for People With Motor Impairments: A Performance and Satisfaction Analysis on Web Navigation. In: *IEEE Access*. DOI: 10.1109/ACCESS.2020.3001766.
- Pool, Jonathan Robert (2023):** Testaro: Efficient Ensemble Testing for Web Accessibility. In: *Proceedings of the 25th International ACM SIGACCESS Conference on Computers and Accessibility*. ASSETS '23. New York, NY, USA: Association for Computing Machinery, S. 1–4. ISBN: 979-8-4007-0220-4. DOI: 10.1145/3597638.3614505. URL: <https://dl.acm.org/doi/10.1145/3597638.3614505> (Abruf: 24.02.2026).
- Purwandari, Nuraini; Dewi, Ratna Kusuma; Rinaldo; Sucipto, Purwo Agus (2025):** Policy in Practice: A Systematic Review of WCAG 2.2 and ADA 2024 Effects on Web and Mobile Accessibility. In: *Digitus*. DOI: 10.61978/digitus.v3i2.957. URL: [https://www.researchgate.net/publication/396366120\\_Policy\\_in\\_Practice\\_A\\_Systematic\\_Review\\_of\\_WCAG\\_22\\_and\\_ADA\\_2024\\_Effects\\_on\\_Web\\_and\\_Mobile\\_Accessibility](https://www.researchgate.net/publication/396366120_Policy_in_Practice_A_Systematic_Review_of_WCAG_22_and_ADA_2024_Effects_on_Web_and_Mobile_Accessibility) (Abruf: 04.03.2026).
- Schulhoff, Sander; Ilie, Michael; Balepur, Nishant; Kahadze, Konstantine; Liu, Amanda; Si, Chenglei; Li, Yinheng; Gupta, Aayush; Han, HyoJung; Schulhoff, Sevien; Dulepet, Pranav Sandeep; Vidyadhara, Saurav; Ki, Dayeon; Agrawal, Sweta; Pham, Chau; Kroiz, Gerson; Li, Feileen; Tao, Hudson; Srivastava, Ashay; Da Costa, Hevander; Gupta, Saloni; Rogers, Megan L.; Goncarenco, Inna; Sarli, Giuseppe; Galynker, Igor; Peskoff, Denis; Carpuat, Marine; White, Jules; Anadkat, Shyamal; Hoyle, Alexander; Resnik, Philip (2024):** The Prompt Report: A Systematic Survey of Prompting Techniques. In: arXiv: 2406.06608 [cs.CL]. URL: <https://arxiv.org/abs/2406.06608> (Abruf: 09.03.2026).
- Silvestre, Pedro F.; Pietzuch, Peter (2025):** Systems Opportunities for LLM Fine-Tuning using Reinforcement Learning. In: *Proceedings of the 5th Workshop on Machine Learning and Systems*. EuroMLSys '25. New York, NY, USA: Association for Computing Machinery, S. 90–99. ISBN: 979-8-4007-1538-9. DOI: 10.1145/3721146.3721944. URL: <https://dl.acm.org/doi/10.1145/3721146.3721944> (Abruf: 09.03.2026).
- Souza, Aline; de Souza Filho, José Cezar; Bezerra, Carla; Alves, Victor Anthony; Lima, Lara; Marques, Anna Beatriz; Teixeira Monteiro, Ingrid (2024):** Accessibility Evaluation of Web Systems for People with Visual Impairments: Findings from a Literature Survey. In: *Proceedings of the XXIII Brazilian Symposium on Human Factors in Computing Systems*. IHC '24. New York, NY, USA: Association for Computing Machinery, S. 1–13. ISBN: 979-8-4007-1224-1. DOI: 10.1145/3702038.3702090. URL: <https://dl.acm.org/doi/10.1145/3702038.3702090> (Abruf: 04.03.2026).

- Tafreshipour, Mahan; Deshpande, Anmol; Mehralian, Forough; Ahmed, Iftekhhar; Malek, Sam (2024):** Mally: A Mutation Framework for Web Accessibility Testing. In: *Proceedings of the 33rd ACM SIGSOFT International Symposium on Software Testing and Analysis*. ISSTA 2024. New York, NY, USA: Association for Computing Machinery, S. 100–111. ISBN: 979-8-4007-0612-7. DOI: 10.1145/3650212.3652113. URL: <https://dl.acm.org/doi/10.1145/3650212.3652113> (Abruf: 24.02.2026).
- Touvron, Hugo; Martin, Louis; Stone, Kevin; Albert, Peter; Almahairi, Amjad; Babaei, Yasmine; Bashlykov, Nikolay; Batra, Soumya; Bhargava, Prajjwal; Bhosale, Shruti; Bikel, Dan; Blecher, Lukas; Ferrer, Cristian Canton; Chen, Moya; Cucurull, Guillem; Esiobu, David; Fernandes, Jude; Fu, Jeremy; Fu, Wenying; Fuller, Brian; Gao, Cynthia; Goswami, Vedanuj; Goyal, Naman; Hartshorn, Anthony; Hosseini, Saghar; Hou, Rui; Inan, Hakan; Kardas, Marcin; Kerkez, Viktor; Khabsa, Madian; Kloumann, Isabel; Korenev, Artem; Koura, Punit Singh; Lachaux, Marie-Anne; Lavril, Thibaut; Lee, Jenya; Liskovich, Diana; Lu, Yinghai; Mao, Yuning; Martinet, Xavier; Mihaylov, Todor; Mishra, Pushkar; Molybog, Igor; Nie, Yixin; Poulton, Andrew; Reizenstein, Jeremy; Rungta, Rashi; Saladi, Kalyan; Schelten, Alan; Silva, Ruan; Smith, Eric Michael; Subramanian, Ranjan; Tan, Xiaoqing Ellen; Tang, Binh; Taylor, Ross; Williams, Adina; Kuan, Jian Xiang; Xu, Puxin; Yan, Zheng; Zarov, Iliyan; Zhang, Yuchen; Fan, Angela; Kambadur, Melanie; Narang, Sharan; Rodriguez, Aurelien; Stojnic, Robert; Edunov, Sergey; Scialom, Thomas (2023):** Llama 2: Open Foundation and Fine-Tuned Chat Models. In: arXiv: 2307.09288 [cs.CL]. URL: <https://arxiv.org/abs/2307.09288> (Abruf: 01.03.2026).
- Vaswani, Ashish; Shazeer, Noam; Parmar, Niki; Uszkoreit, Jakob; Jones, Llion; Gomez, Aidan N.; Kaiser, Lukasz; Polosukhin, Illia (2023):** Attention Is All You Need. In: arXiv: 1706.03762 [cs.CL]. URL: <https://arxiv.org/abs/1706.03762>.
- Wang, Yuqing; Zhao, Yun (2024):** Metacognitive Prompting Improves Understanding in Large Language Models. In: arXiv:2308.05342. arXiv. DOI: 10.48550/arXiv.2308.05342. arXiv: 2308.05342[cs]. URL: <http://arxiv.org/abs/2308.05342> (Abruf: 09.03.2026).
- Webster, Jane; Watson, Richard T. (2002):** Analyzing the Past to Prepare for the Future: Writing a Literature Review. In: *MIS Quarterly* 26.2, S. 2–6.
- Wei, Jason; Tay, Yi; Bommasani, Rishi; Raffel, Colin; Zoph, Barret; Borgeaud, Sebastian; Yogatama, Dani; Bosma, Maarten; Zhou, Denny; Metzler, Donald; Chi, Ed H.; Hashimoto, Tatsunori; Vinyals, Oriol; Liang, Percy; Dean, Jeffrey; Fedus, William (2022):** Emergent Abilities of Large Language Models. In: *Transactions on Machine Learning Research*, S. 1–35. URL: <https://arxiv.org/abs/2206.07682> (Abruf: 28.02.2026).
- Wei, Jason; Wang, Xuezhi; Schuurmans, Dale; Bosma, Maarten; Ichter, Brian; Xia, Fei; Chi, Ed; Le, Quoc V; Zhou, Denny (2022):** Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. In: *Advances in Neural Information Processing Systems*. Hrsg. von S. Koyejo; S. Mohamed; A. Agarwal; D. Belgrave; K. Cho; A. Oh. Bd. 35. Curran Associates, Inc., S. 24824–24837. URL: [https://proceedings.neurips.cc/paper\\_files/paper/2022/file/9d5609613524ecf4f15af0f7b31abca4-Paper-Conference.pdf](https://proceedings.neurips.cc/paper_files/paper/2022/file/9d5609613524ecf4f15af0f7b31abca4-Paper-Conference.pdf).

- Yang, An; Li, Anfeng; Yang, Baosong; Zhang, Beichen; Hui, Binyuan; Zheng, Bo; Yu, Bowen; Gao, Chang; Huang, Chengen; Lv, Chenxu; Zheng, Chujie; Liu, Dayiheng; Zhou, Fan; Huang, Fei; Hu, Feng; Ge, Hao; Wei, Haoran; Lin, Huan; Tang, Jialong; Yang, Jian; Tu, Jianhong; Zhang, Jianwei; Yang, Jianxin; Yang, Jiayi; Zhou, Jing; Zhou, Jingren; Lin, Junyang; Dang, Kai; Bao, Keqin; Yang, Kexin; Yu, Le; Deng, Lianghao; Li, Mei; Xue, Mingfeng; Li, Mingze; Zhang, Pei; Wang, Peng; Zhu, Qin; Men, Rui; Gao, Ruize; Liu, Shixuan; Luo, Shuang; Li, Tianhao; Tang, Tianyi; Yin, Wenbiao; Ren, Xingzhang; Wang, Xinyu; Zhang, Xinyu; Ren, Xuancheng; Fan, Yang; Su, Yang; Zhang, Yichang; Zhang, Yinger; Wan, Yu; Liu, Yuqiong; Wang, Zekun; Cui, Zeyu; Zhang, Zhenru; Zhou, Zhipeng; Qiu, Zihan (2025):** Qwen3 Technical Report. In: arXiv: 2505.09388 [cs.CL]. URL: <https://arxiv.org/abs/2505.09388>.
- Yao, Shunyu; Zhao, Jeffrey; Yu, Dian; Du, Nan; Shafran, Izhak; Narasimhan, Karthik R.; Cao, Yuan (2022):** ReAct: Synergizing Reasoning and Acting in Language Models. In: The Eleventh International Conference on Learning Representations. URL: [https://openreview.net/forum?id=WE\\_vluYUL-X](https://openreview.net/forum?id=WE_vluYUL-X) (Abruf: 06.04.2026).

## Bücher und Sammelwerke

- Flanagan, David (2020):** JavaScript: The Definitive Guide. 7. Aufl. Sebastopol, CA: O'Reilly Media. ISBN: 978-1491952023.
- Heinemann, Daniela (2024):** „Barrierefreiheit“. In: *Digitalisierte Verwaltung - Vernetztes E-Government*. Hrsg. von Margrit Seckelmann. Berlin: Erich Schmidt Verlag GmbH & Co. KG, S. 469–488. ISBN: 978-3-503-23763-0. DOI: 10.37307/b.978-3-503-23763-0.15. URL: <https://doi.org/10.37307/b.978-3-503-23763-0.15> (Abruf: 24.02.2026).
- Hevner, Alan; Chatterjee, Samir (2010):** Design Research in Information Systems: Theory and Practice. Bd. 22. Integrated Series in Information Systems. New York, NY: Springer. DOI: 10.1007/978-1-4419-5653-8.
- Jurafsky, Daniel; Martin, James H. (2026):** Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models. 3rd. Online manuscript released January 6, 2026. URL: <https://web.stanford.edu/~jurafsky/slp3/> (Abruf: 12.04.2026).
- Kerkmann, Friederike; Lewandowski, Dirk (2015):** Barrierefreie Informationssysteme: Zugänglichkeit für Menschen mit Behinderung in Theorie und Praxis. Walter de Gruyter GmbH & Co KG. 292 S. ISBN: 978-3-11-033729-7.
- Kouroupetroglou, Georgios (2013):** Assistive Technologies and Computer Access for Motor Disabilities. IGI Global Scientific Publishing. ISBN: 978-1-4666-4438-0.
- Lazar, Jonathan; Feng, Jinjuan Heidi; Hochheiser, Harry (2017):** Research Methods in Human-Computer Interaction. Elsevier. ISBN: 978-0-12-805390-4.
- Russell, Stuart; Norvig, Peter (2021):** Artificial Intelligence: A Modern Approach. Hoboken: Pearson. 1136 S. ISBN: 978-0-13-461099-3.



- Sommerville, Ian (2016):** Software Engineering. 10. Aufl. Pearson. ISBN: 978-0133943030.
- Yin, Robert K. (2018):** Case Study Research and Applications: Design and Methods. Los Angeles London New Delhi Singapore Washington DC Melbourne: SAGE Publications, Inc. 352 S. ISBN: 978-1-5063-3616-9.

## Internetquellen und Medien

- BITBW (2021):** 6 Jahre BITBW. URL: <https://bitbw.de/neuigkeiten/artikel/6-jahre-bitbw-1> (Abruf: 28.02.2026).
- Land Baden-Württemberg (2025):** Neuer BW-Empfangsclient treibt Digitalisierung der Verwaltung voran. URL: <https://www.baden-wuerttemberg.de/de/service/presse/pressemitteilung/pid/neuer-bw-empfangsclient-treibt-digitalisierung-der-verwaltung-voran-1> (Abruf: 24.02.2026).
- Stack Overflow (2025):** Survey index. URL: <https://survey.stackoverflow.co/2025/> (Abruf: 05.03.2026).
- WebAIM (2019):** The WebAIM Million - 2019 report on the accessibility of the top 1,000,000 home pages. URL: <https://webaim.org/projects/million/2019> (Abruf: 24.02.2026).
- WebAIM (2025):** The WebAIM Million - 2025 report on the accessibility of the top 1,000,000 home pages. URL: <https://webaim.org/projects/million/> (Abruf: 24.02.2026).
- WebAIM (2026b):** WebAIM: Keyboard Accessibility. URL: <https://webaim.org/techniques/keyboard/> (Abruf: 04.03.2026).
- World Health Organization (2026):** Disability. URL: [https://www.who.int/health-topics/disability#tab=tab\\_1](https://www.who.int/health-topics/disability#tab=tab_1) (Abruf: 28.02.2026).
- World Wide Web Consortium (W3C) (2026a):** Evaluation Tool List. URL: <https://www.w3.org/WAI/test-evaluate/tools/list/> (Abruf: 28.02.2026).
- World Wide Web Consortium (W3C) (2026b):** Web Accessibility Initiative. URL: <https://www.w3.org/WAI/> (Abruf: 28.02.2026).

## Technische Dokumentation und Software

- Anthropic (2026a):** *Claude Model Overview*. URL: <https://www.anthropic.com/claude> (Abruf: 01.03.2026).
- Anthropic (2026b):** *System Card: Claude Sonnet 4.6*. URL: <https://www-cdn.anthropic.com/78073f739564e986ff3e28522761a7a0b4484f84.pdf> (Abruf: 02.03.2026).
- Deque Systems (2026):** *axe-core: Accessibility engine for automated Web UI testing*. Version 4.10.3. URL: <https://github.com/dequelabs/axe-core> (Abruf: 24.02.2026).
- Google (2025):** *Lighthouse: Automated auditing, performance, and accessibility tool for web pages*. URL: <https://developer.chrome.com/docs/lighthouse/overview> (Abruf: 28.02.2026).
- JavaScript With Syntax For Types. (2026).** URL: <https://www.typescriptlang.org/> (Abruf: 14.03.2026).

- Meta Open Source (2026a):** *React Documentation: Render and Commit*. URL: <https://react.dev/learn/render-and-commit> (Abruf: 05.03.2026).
- Meta Open Source (2026b):** *React: A JavaScript library for building user interfaces*. URL: <https://react.dev/> (Abruf: 05.03.2026).
- Microsoft (2026):** *Playwright: Fast and reliable end-to-end testing for modern web apps*. URL: <https://playwright.dev/docs/intro> (Abruf: 24.02.2026).
- Ollama (2026):** *Ollama Documentation: Quickstart Guide*. URL: <https://docs.ollama.com/quickstart> (Abruf: 04.03.2026).
- OpenAI (2026):** *Create completion*. URL: <https://developers.openai.com/api/reference/resources/completions/methods/create/> (Abruf: 01.03.2026).
- Robie, Jonathan (2026):** *What is the Document Object Model?* URL: <https://www.w3.org/TR/WD-DOM/introduction.html> (Abruf: 04.03.2026).
- WebAIM (2026a):** *Wave Web Accessibility Evaluation Tools*. URL: <https://wave.webaim.org/> (Abruf: 28.02.2026).

## Rechtliche Grundlagen und Standards

- Bundesministerium für Digitales und Staatsmodernisierung (2025):** *Barrierefreie Informationstechnik-Verordnung (BITV 2.0)*. URL: <https://www.barrierefreiheit-dienstekonsolidierung.bund.de/Webs/PB/DE/gesetze-und-richtlinien/bitv2-0/bitv2-0-node.html> (Abruf: 24.02.2026).
- Deutscher Bundestag (2026):** *BFSG (Barrierefreiheitsstärkungsgesetz)*. URL: <https://bfsg-gesetz.de/> (Abruf: 24.02.2026).
- Europäisches Parlament und Rat der Europäischen Union (2016):** *Verordnung (EU) 2016/679 des Europäischen Parlaments und des Rates vom 27. April 2016 zum Schutz natürlicher Personen bei der Verarbeitung personenbezogener Daten, zum freien Datenverkehr und zur Aufhebung der Richtlinie 95/46/EG (Datenschutz-Grundverordnung)*. URL: <https://eur-lex.europa.eu/eli/reg/2016/679/oj> (Abruf: 10.03.2026).
- European Commission (2026):** *European accessibility act (EAA)*. URL: [https://commission.europa.eu/strategy-and-policy/policies/justice-and-fundamental-rights/disability/european-accessibility-act-eaa\\_en](https://commission.europa.eu/strategy-and-policy/policies/justice-and-fundamental-rights/disability/european-accessibility-act-eaa_en) (Abruf: 24.02.2026).
- Landesrecht BW (2015):** *Gesetz zur Errichtung der Landesoberbehörde BITBW*. URL: <https://www.landesrecht-bw.de/bsbw/document/jlr-ITErGBWV3P2> (Abruf: 28.02.2026).
- United Nations (2006):** *Convention on the Rights of Persons with Disabilities*. URL: <https://www.ohchr.org/en/instruments-mechanisms/instruments/convention-rights-persons-disabilities> (Abruf: 28.02.2026).
- World Wide Web Consortium (W3C) (2018):** *Web Content Accessibility Guidelines (WCAG) 2.1*. URL: <https://www.w3.org/TR/WCAG21/> (Abruf: 24.02.2026).
- World Wide Web Consortium (W3C) (2023):** *Web Content Accessibility Guidelines (WCAG) 2.2*. URL: <https://www.w3.org/TR/WCAG22/> (Abruf: 24.02.2026).

# Erklärung zur Verwendung generativer KI-Systeme

Bei der Erstellung der eingereichten Arbeit habe ich auf künstlicher Intelligenz (KI) basierte Systeme benutzt:

☒ ja

☐ nein<sup>213</sup>

Falls ja: Die nachfolgend aufgeführten auf künstlicher Intelligenz (KI) basierten Systeme habe ich bei der Erstellung der eingereichten Arbeit benutzt:

1. Claude (Anthropic)
2. ChatGPT (OpenAI)
3. Microsoft Copilot

Ich erkläre, dass ich

- mich aktiv über die Leistungsfähigkeit und Beschränkungen der oben genannten KI-Systeme informiert habe,<sup>214</sup>
- die aus den oben angegebenen KI-Systemen direkt oder sinngemäß übernommenen Passagen gekennzeichnet habe,
- überprüft habe, dass die mithilfe der oben genannten KI-Systeme generierten und von mir übernommenen Inhalte faktisch richtig sind,
- mir bewusst bin, dass ich als Autorin bzw. Autor dieser Arbeit die Verantwortung für die in ihr gemachten Angaben und Aussagen trage.

---

<sup>213</sup>Die Erklärung ist in jedem Fall zu unterzeichnen, auch wenn Sie keine KI-Systeme genutzt haben und Ihr Kreuz bei „nein“ gesetzt haben.

<sup>214</sup>U.a. gilt es hierbei zu beachten, dass an KI weitergegebene Inhalte ggf. als Trainingsdaten genutzt und wiederverwendet werden. Dies ist insb. für betriebliche Aspekte als kritisch einzustufen.

Die oben genannten KI-Systeme habe ich wie im Folgenden dargestellt eingesetzt:

| Arbeitsschritt                         | KI-System(e)               | Verwendungsweise                                                                                                                                                                      |
|----------------------------------------|----------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Ideenfindung und Strukturierung        | Claude (Anthropic)         | Unterstützung bei der Strukturierung der Arbeit, Formulierung von Forschungsfragen sowie Gliederung einzelner Kapitel. Inhalte wurden kritisch geprüft und eigenständig überarbeitet. |
| Sprachliche Überarbeitung und Glättung | ChatGPT (OpenAI)           | Unterstützung bei der sprachlichen Verbesserung einzelner Textpassagen (Grammatik, Stil). Inhaltliche Aussagen wurden nicht automatisiert übernommen.                                 |
| Code-Unterstützung                     | GitHub Copilot (Microsoft) | Unterstützung bei der Erklärung und Optimierung von Codefragmenten im Rahmen der Implementierung. Der finale Code wurde eigenständig entwickelt und validiert.                        |

(Ort, Datum)

(Unterschrift)

# Erklärung

Ich versichere hiermit, dass ich die vorliegende Arbeit mit dem Thema: *Kontextsensitive, lokale KI-Assistenz zur automatisierten Barrierefreiheitsanalyse von Rich-Client-Webanwendungen mittels Tool-Reports, Playwright-Interaktionen und Codeanalyse* selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Ich versichere zudem, dass die eingereichte elektronische Fassung mit der gedruckten Fassung übereinstimmt.

(Ort, Datum)

(Unterschrift)